

第 1 章 序論

漫画は，平面をコマへと分割し，その上に物語を描く表現形式である．各コマは時間および空間の連続性を離散化した単位として出来事の順序や場面転換を担い，その配置は，キャラクターやセリフ配置とともに，視線誘導，強調，テンポといった物語に基づく演出上の意思決定を反映する．このような漫画の構成上の配置は，一般にネームと呼ばれる下書きにおいて定められ，作品の核となる重要な役割をもつ [fukaya`mangalayout]．しかし，要素の配置問題を数理的に扱うレイアウト生成の研究において，漫画のネームのように物語の文脈に深く紐づく生成物を対象にした研究はこれまで十分に取り組まれてこなかった．

従来，レイアウト生成モデルの開発に取り組む研究は，与えられた要素群を平面上に配置し，可読性・視認性・審美性などの要件を満たす構成を，自動的に設計する試みとして発展してきた．Web UI やポスター，文書レイアウト等の機能的媒体を対象として，要素の種類やサイズ，要素間関係といった条件に基づく生成や部分的な欠損要素の補完，既存配置の精緻化など，多様な問題設定が提案されてきた [tanaka`scipostlayout`2024, seol`posterllama`2024, guo`vinci`2021, kikuchi`modeling`2021, deka`rico`2017, zhong`publaynet`2019]．しかし，漫画のレイアウト設計は，物語上の展開や演出意図と不可分に決定されるという点で，機能的媒体の配置問題とは前提が異なる．制作工程で用いられるネームは外部に公開されにくい内部資料であり，物語を条件にして漫画のレイアウトおよびそれを内包するネームの自動生成に取り組むには，漫画画像に紐づく物語文および演出情報の不足という観点で，入出力の双方に，学習および評価に耐える規模の体系的に整備されたデータが不足していた．

ここで本研究では，この「ネーム」を，作品の下書き画像そのものではなく，その本質をもとに「要素の幾何学的な配置」と，カメラワークやキャラクターの表情といった「演出情報」が統合された，物語から作品へ至るための「構造化された中間表現」として定義する．このようにしてネームを捉えると，ネームデータの構築には，漫画画像から物語の文脈や演出上の意味を高次に読み取る能力が不可欠となる．

一方、連続する画像から物語を抽出する研究領域として、ビジュアルストーリーテリングが存在する。これまで、この分野では、単一画像のキャプション生成を組み合わせる試みや単純な連続的状况を記述する試みが取り組まれてきた [huang-etal-2016-visual, nahian'hierarchical'2019]。しかし、近年は大規模視覚言語モデル (Large Vision-Language Model; LVLM) の登場により、本領域における技術的水準が飛躍的な進化を遂げている。最新のモデルは、単一画像の要素認識に留まらず、複数の画像にまたがる文脈の統合や、物語構造に関わる高次な意味内容までも言語化し得る推論能力を示し始めている [yang'storyllava'2025]。

そこで本研究では、LVLM の高度な画像認識能力を応用し、漫画画像に紐づく脚本データ・演出データの構築を行った。具体的には、Manga109Dataset [matsui2017sketch] に含まれる全 19,555 ページの漫画画像から脚本情報を抽出した Manga109ScriptDataset の構築と、これを技術の進展に伴い、物語文を刷新し演出情報まで加え構造化した Manga109NameDataset の構築である。Manga109ScriptDataset には人手による評価も与え、その信頼性を担保した。

両データセットの構築にあたり中心となった技術は Visual Prompting [shredritski'what'2023] である。Visual Prompting は画像に特定のマーキングなどの処理を加え、LVLM の性能向上を図る手法である。本研究においては、これを漫画の読解性能を高める技術として応用した。特に Manga109NameDataset の構築にあたっては、Manga109Dataset 内に含まれる全 103,850 コマ、全 127,887 セリフに対し、LVLM 単体性能による認識や自動推定がまだ困難であり、かつ、物語構造の決定に不可欠な「読み順」を、人手によるアノテーションにより付与し、このアノテーションデータを視覚的な手がかりとする独自の Visual Prompting 手法を開発した。これにより LVLM の物語抽出精度および演出情報の記述能力を高め、漫画画像に紐づく物語・脚本情報と各コマにおけるキャラクターのポーズや表情、カメラワークといった詳細な演出情報の抽出を可能にした。

本研究では、以上のように獲得したデータセットを構造的に整備したうえで、脚本を入力側に、演出情報を出力側にして、脚本を入力とした漫画ネーム生成モデルの学習基盤を構築した。本研究で開発したモデルは、大規模言語モデル (Large Language Model; LLM) をベースモデルとした追加学習 (ファインチューニング) モデルであり、脚本を入力にネームを生成する。提案モデルを既存のレイアウト生成モデル [inoue'layoutdm'2023, jiang'layoutformer'2023, lin'layoutprompter'2023] と比較した結果、複数の評価指標 [inoue'layoutdm'2023, otani'ltsim'2024] で既存モデルの精度を上回り、構築した脚本データおよびネームデータの有効性を確認した。さらに、複数の入

出力の生成設定を比較検討することで、物語構造・演出情報を含むネームデータの効果的な活用手法を、脚本に基づく漫画ネーム生成モデルのベースラインとして整備した。一方で、生成された演出情報を客観的に評価する手法については、その評価設計の難しさが課題として明らかとなった。本論文では、Manga109ScriptDataset の構築とこれを活用した実験内容を第一部に、Manga109NameDataset の構築とこれを活用した実験内容を第二部に扱う。本研究における取り組みをの概略を図 1.1 に示す。




図 1.1: 本研究における取り組みの概略図. Manga109Dataset から大規模視覚言語モデル (LVLM) を用いて脚本情報および演出情報を抽出し、ネームデータセットとして構築した。そのデータセットを用いて脚本から漫画のネームを生成する漫画ネーム生成モデルを構築した (漫画: 『犯罪交渉人 峰岸英太郎』 © 記伊 孝/講談社)。

現在、生成 AI は創作領域に新たな可能性を開きつつある一方、倫理的課題を抱え、社会的受容には依然として隔たりがある。とりわけ、既存作品の安易な模倣に基づく粗悪な派生物を拡散する危険性を持ち、これは日本が培ってきた創作資産の価値と流通を毀損する恐れがある。生成 AI 技術の進展に少なからず寄与してきた日本のコンテンツ産業を守り持続的な発展を維持するためにも、その価値が適切に還元され得る AI 活用の枠組みを整備する必要がある。画像や映像といった最終成果物を直接生成す

るのではなく，制作工程の核であり，演出上の意思決定が集約されるネームを支援対象とする本研究における取り組みは，作者の創造性を尊重しつつ，社会的受容と実制作における効率性向上の両立に資することを目的とする．

本研究の貢献は以下の 5 点にまとめられる

1. 全 19,555 ページの漫画画像に紐づいた脚本データセット Manga109ScriptDataset の構築
2. Manga109ScriptDataset への評価アノテーションの付与
3. Manga109Dataset に含まれる全 103,850 コマ・全 127,887 セリフに対する，人手による読み順アノテーションデータの整備
4. 独自の Visual Prompting 手法を用いた LVLMM の活用による物語情報および演出情報を含む全 9,827 の見開き漫画画像分の漫画ネームデータセット Manga109NameDataset の構築
5. Manga109ScriptDataset および Manga109NameDataset を活用した，漫画ネーム生成モデルの構築および既存のレイアウト生成手法との比較実験を経た漫画ネーム生成モデルのベースラインの整備