

第 1 章 Manga109ScriptDataset

本章では，本研究の第一段階において構築した，漫画画像に紐づく脚本データセット Manga109ScriptDataset について，その構築手法や統計量，評価アノテーション手法の詳細を述べる．

序論で定義したとおり，本研究では漫画の「ネーム」を，幾何学的な「要素配置 (Layout)」と「演出情報 (Directions)」を統合した，物語と作品とを接続する中間表現として位置づける．このネームを物語に基づいて生成する取り組みに先立ち，第一段階では，物語としての「脚本」と「要素配置」との対応関係の学習に焦点を当て，Manga109ScriptDataset を構築した．

構築においては，漫画画像を，OpenAI API を介して GPT-4o に入力し，描画内容を脚本として記述させる手法を基本方針とした．本章では，この生成プロセスにおいて，モデルが複雑な文脈を正確に理解するために導入した画像加工やチャットフローの活用といった具体的な技術詳細について記述する．

本章の構成は以下の通りである．まず ?? 節では，本データセットの基本設計である脚本形式の定義について述べる．続く 1.2 節では，正確な脚本生成を可能にするため LVLM のキャラクター認識精度の向上を図り実装した Visual Prompting について述べる．1.3 節では，画像間にまたがる連続的な文脈理解の精度を高めるため設計した，LVLM とのチャットフローについて示す．1.4 節では，構築したデータセットの統計量を示し，最後に 1.5 節では，人手によるアノテーションに基づく脚本の品質評価手法と，その結果について論じる．

1.1 脚本形式の定義

本研究において採用した物語文の形式は，日本の映像制作現場において標準的に用いられる脚本形式に準拠する．脚本は，テキストから視覚的イメージを具体化することを主目的として設計された記述様式であり，その「視覚化のための物語文」というフォーマットは，ネーム生成というタスクにおいて親和性が高い．本研究では，将来

的な制作支援応用を見据え、プロの作家や編集者が違和感なく扱える実用性を考慮し、日本国内で標準的な形式をそのまま採用した。その形式は、以下の 3 つの主要な構成要素から成る。

1. 柱: 物語の場面・場所を示す情報。行頭に記号「○」を付記し、その後に「場所」や「時間帯」を記述する（例：○ 公園・昼）。
2. ト書き: キャラクターの動作、表情、視線、および周囲の環境音や状況説明を記述する文章。視認性を高めるため、全角 3 文字分の字下げを行って記述する。これは、コマ割りや構図、カメラワークを示唆する重要な情報源となる。
3. セリフ: キャラクターの発話内容。「話者名『セリフ内容』」の形式で記述する。

本データセットの構築においては、プロンプトに形式に関する詳細な説明を加えるとともに、Few-shot Learning の形で数例提示することで、モデルからの出力を脚本形式に制御した。実際にプロンプトに含めた Few-shot の例を図 1.1 に示す。

○ 藤田の部屋の中

部屋の中にいる藤田歩は、部屋の窓から見える若葉の美しさに気づく。
そして、感激しながら独り言を言う。

藤田歩「いつのまにか時はもう 5 月」
藤田歩「若葉が最高に美しい季節」

彼女は両手を胸元でギュッと握りしめ、瞳に輝きを宿しながら感激を示す。

藤田歩「こういう季節ってまるで感激しちゃうね!!」
藤田歩「かんげき!!」

部屋の隅には新しく購入したひとり用炊飯器が置かれている。
それを見つめて、嬉しそうに話し始める。

藤田歩「つ…ついに買ったのね!!ピカピカのひとり用炊飯器を!!」

図 1.1: 脚本生成プロンプトにおける Few-shot の例

1.2 Visual Prompting

本節では、LVLM の画像認識能力を補助し、正確な脚本生成を実現するために導入した Visual Prompting について述べる。

Manga109ScriptDataset の構築において、最も重要な要件の一つは、生成される

脚本内で動作主や話者を正確に特定することである。しかし、第 2 章で述べた通り、漫画画像は白黒の線画表現であり、しばしばキャラクターが著しくデフォルメされるといった独自のドメイン特性を持つため、GPT-4o などの最新 LVLM であっても、そのまま適用するだけでは正確な認識、特にキャラクターの識別は十分になされない [**<empty citation>**]. そこで本研究では、登場人物を取り違え、物語の整合性を著しく損なうハルシネーションを抑制するための手段として、画像内に視覚的な手がかりを直接埋め込む Visual Prompting を採用した。キャラクターの顔を色のついた円で囲い、視覚的な識別補助を与える手法である。

Manga109Dataset には、キャラクターの顔領域を示す Bounding Box が付与されており、各領域は作品内で一意のキャラクター ID と紐付いている。本研究ではこの情報を利用し、以下の手順で画像に加工を施した。まず、作品内に登場するキャラクター ID ごとに、HSV 色空間上で等間隔となるよう識別性の高い色を動的に割り当てる。次に、各顔領域に対して、割り当てた色で顔を囲う円を描画した。円の色とキャラクター名を紐づける情報をプロンプト内で提示することで、キャラクターの識別を促した。図 1.2 に加工後の画像を示す。



図 1.2: Visual Prompting の例

このアプローチは、Shtedritski ら [shtedritski'what'2023] の手法を漫画ドメイン向けに適応させたものである。この処理により、LVLM はデフォルメされた顔の識

別といった高難度なタスクを色の識別という単純な視覚タスクへ置き換えることが可能となる。結果として、複雑な線画や類似したキャラクターが混在するシーンにおいても、モデルは視覚的アンカーを手がかりとして強固にキャラクターの識別能力を向上させた。

1.3 画像間文脈理解のためのチャットフロー

本節では、ページ間の文脈を考慮し、物語の一貫性を担保するために設計したチャットフローについて述べる。

1.3.1 整序したセリフの入力

前節で述べた Visual Prompting に加え、モデルがキャラクターの同一性とともに物語の文脈を正しく理解するためには、正確なテキスト情報とその読み順が不可欠である。そこで本研究では、以下の 2 つの外部情報を利用し、漫画画像内の一連のセリフを整序した形でプロンプト内に提示した。

1. セリフテキストと話者名: 各フキダシ内のテキスト内容およびその話者名については、それらが対応付けられた既存のアノテーションデータセット Manga109Dialog [li'manga109dialog'2024] を利用した。
2. セリフの順序: コマやフキダシの読み順決定には, Sachdeva ら [sachdeva'manga'2024] による Magi アルゴリズムを採用した。

ここで Magi [sachdeva'manga'2024] を採用した理由は, LVLM 単体での空間的な順序推定能力の限界にある。我々の予備実験において, GPT-4o に画像のみを与えて読み順を推定させたところ, サンプルングした 109 ページ中, 正解したのはわずか 26 ページに留まった。対照的に, ルールベースの手法である Magi を用いた場合, 96 ページにおいて正確な順序が得られた。この結果は, 脚本生成の前段階として, アルゴリズムによる明示的な順序決定が不可欠であることを示している。

1.3.2 文脈理解のための 3 段階のインタラクション

複数ページにわたる連続した物語を矛盾なく記述するため, 本研究では GPT-4o に対して単純な 1 往復の指示を与えるのではなく, 各ページ i の生成において以下の 3 つのコンポーネント (α, β, γ) から成る構造化されたインタラクションプロセスを構築した。上述の内容にある事前整備した情報は, このプロセスにおいて適切な組み合

わせのもと利用した。

- $\alpha(i)$: 一連のセリフを用いた大域的文脈の理解

脚本生成の対象となるページ i が含まれるエピソード全体の一連のセリフをモデルに入力するインタラクション。モデルからの応答を「完了」の肯定的応答としてシミュレートすることで、チャット内における文脈理解状態を確立させた。

- $\beta(i)$: ページ i の脚本生成

脚本を生成させるインタラクション。入力として、「Visual Prompting を施したページ i の画像」、「ページ i の一連のセリフ」、および「直前のステップ $\gamma(i-1)$ で生成された物語の要約」を与える。過去の要約を与えることにより、前ページまでの展開を踏まえた一貫性のある物語の生成を促進する。

- $\gamma(i)$: 文脈情報の要約と更新

次ページ $i+1$ の生成に備え、ここまでの物語の展開を要約させるインタラクション。生成された脚本と対話履歴に基づき、物語の現状を要約として出力させ、これを次のステップ $\beta(i+1)$ の入力として利用する。

上記3つのインタラクションを組み合わせ、各ページ i の脚本生成を以下のシーケンスにより実行した。ここで、矢印は同一チャットセッション内での対話の遷移を示している。

- 先頭ページ ($i = 1$) の場合

過去の文脈が存在しないため、以下の順序で実行する。

$$\alpha(1) \rightarrow \beta(1)$$

- 第 2 ページ以降 ($i \geq 2$) の場合

直前のページの生成結果を履歴として保持しつつ、以下の順序で実行する。

$$\alpha(i) \rightarrow \beta(i-1) \rightarrow \beta(i)$$

このように、脚本生成 $\beta(i \geq 2)$ においては常に一つ前のやり取りを履歴に残し、物語の一貫性を保持する工夫とした。また、次ページへの文脈受け渡し用として要約を生成する際は、以下のシーケンスへと拡張した。

- 先頭ページ ($i = 1$) の場合

$$\alpha(1) \rightarrow \beta(1) \rightarrow \gamma(1)$$

- 第 2 ページ以降 ($i \geq 2$) の場合

$$\alpha(i) \rightarrow \beta(i-1) \rightarrow \beta(i) \rightarrow \gamma(i)$$

各作品に対し、この一連のインタラクションを最終ページまで反復的に適用することで、Manga109ScriptDataset の全データを構築した。入力とした漫画画像と生成された脚本データの一例を図 1.3 に示す。




図 1.3: 入力に利用した漫画画像 (左:『犯罪交渉人峯岸英太郎』より。© /講談社) と生成された脚本データ (右) の例。

1.4 データセットの統計量

上述した方法により、本研究では、109 作品・計 19,555 ページに対し、約 2 万 7 千件の柱、約 14 万件のト書き、および約 13 万件のセリフを含む脚本データを構築した。その詳細な統計量を表 1.1 に示す。

1.5 品質評価

本研究では、構築された脚本データの品質を検証するため、人手による評価アノテーションを実施した。

1.5.1 評価手法と指標

一般的な画像キャプションの生成タスクとは異なり、本研究で生成する脚本には正解データが存在しない。また、脚本として漫画画像の物語を抽出することは、単純な画像の言語化ではなく、前後の文脈的な整合性やより複雑な状況の記述が求められる

表 1.1: Manga109ScriptDataset の統計量.

要素	総数	平均 (/頁)
レイアウト要素		
総ページ数	19,555	—
コマ数	103,850	5.31
キャラクターの描画数	157,865	8.70
ページごとのキャラクターの種類数	60,812	3.11
フキダシ数	146,549	7.49
話者種類数	55,778	2.85
脚本要素		
柱	26,931	1.38
ト書き	138,890	7.04
セリフ	134,901	7.10
総文字数	6,703,063	342.78

ため, BLEU [[empty citation](#)] や CIDEr [[empty citation](#)] といった既存の自動評価指標の適用は困難である. そこで本研究では, 各要素ごとに評価単位を定義し, 人手による正誤判定に基づいて算出される 5 つの指標を用い, 脚本データの品質を定量的に評価した.

1. 柱の再現率: 対象ページの漫画画像に含まれる場所・シーンの数を分母とし, それらが生成された脚本内で「柱」として正しく言及されている数を分子として算出する再現率. 各ページごとに算出した値を全ページで平均した
2. 柱の適合率: 生成された脚本内の各「柱」を評価単位とし, その記述が対象ページの漫画画像に実際に描かれている場所・シーンに対応しているかを人手で正誤判定した. 正と判定された柱の割合を柱の適合率とし, その平均値を用いた.
3. ト書きの適合率: 各ト書きを評価単位とし, 対象ページに対応するト書きと, ランダムに抽出した他ページのト書きを混在させた候補集合を提示し, 評価者が正しく対象ページのト書きを識別できたかを判定した. ト書きごとの正答率を算出し, その平均値をト書きの適合率とした.
4. 文脈外ト書きの検出精度: 他ページから混入させた無関係なト書きを評価単位とし, それらを対象ページのものではないと正しく棄却できた割合を算出した.
5. セリフの再現率: 対象ページの漫画画像内に存在するフキダシ中のセリフ数を分母とし, それらが生成された脚本内に漏れなく転記されている数を分子とし

て算出する再現率.

1.5.2 実験設定と結果

評価データとして, Manga109ScriptDataset に含むの各作品から物語の連続性を確保する目的で, 連続した 10 ページをランダムに抽出し, 合計 1,000 ページを評価対象とした. この 1,000 ページを 500 ページごとの 2 セットに分割し, 計 6 名の評価者が 2 グループに別れ評価を行った (各ページにつき 3 名が重複して評価を実施). 評価者はアノテーション企業に所属する専門のアノテーターであり, 事前に脚本形式および評価指標の説明を受けた上で評価を行った.

評価の結果, 各指標の平均スコアは以下の通りとなった.

表 1.2: 人手による品質評価の結果

評価指標	
柱の再現率	0.793
柱の適合率	0.838
ト書きの適合率	0.664
文脈外ト書きの検出精度	0.910
セリフの再現率	0.988

柱の再現率および適合率がいずれも 0.8 前後の値を示したことは, 複数のコマを含む漫画ページ全体から, 場面としての場所や時間帯, あるいは場面転換といった大域的な文脈情報が一定程度一貫して抽出されていることを示唆している. 漫画画像から場面の場所を認識する関連研究として, Ikuta ら [ikuta`mangaub`2024] による MangaUB では, 単一のコマ画像を入力に屋内・屋外を判別するタスクが設定されている. このタスクにおいては, LVLM が高い性能を示すことが報告されている. 本研究で扱う柱の抽出は, このような場面認識と関心を共有しつつも, 単一コマではなく複数のコマを含むページ全体を対象とし, さらにその結果を脚本として言語化する点で, 前提とする情報の粒度や統合の条件が異なる. そのような設定の違いを踏まえた上で, 柱に関する指標が一定の値を示したことは, ページ全体を対象とした場面理解が大きく破綻することなく行われていることを示す結果といえる.

一方で, ト書きはキャラクターの動作や視線, 周囲の状況といったより細粒度な情報を記述する要素であり, ページ内外の文脈理解や状況把握をより強く要求するため, 柱と比較して評価値が低くなる傾向が見られた. この点は, 複数コマにまた

がる理解や状況把握が単純な認識タスクに比べて困難であることを指摘した既存研究 [ikuta·mangaub·2024] とも整合的である。それにもかかわらず，ト書きの適合率が一定水準を維持していることは，脚本としての状況理解が致命的に破綻することなく行われていることを示唆している。

これらの結果は，Visual Prompting によるキャラクター識別の補助や，セリフ情報を明示的に整序して与えるチャットフロー，ならびにページ間文脈を保持するインタラクション設計といった，本研究で導入した複数の工夫が，脚本生成時の文脈理解を安定化させた可能性を示すものと考えられる。一方で，特にト書きに関しては，より高精度な状況理解を実現する余地が依然として残されており，今後の課題である。

本節の評価結果から，本研究で構築した脚本データは，後続のモデル学習に用いる基礎データとして，実用上十分な整合性と妥当性を有していると判断し，本データセットを用いて，脚本に基づくレイアウト生成モデルの学習および検証を行った。