

修士論文

2025 年度

漫画ネームの
構造化データセットの構築と
脚本からの自動生成

渡邊 謙吾
(学籍番号：82420611)

指導教員 教授 栗原 聡

2026 年 3 月

慶應義塾大学大学院理工学研究科
開放環境科学専攻

論文要旨

現在、AI は創作領域に新たな可能性を開きつつある一方、倫理的課題を抱え、社会的受容には依然として隔たりがある。とりわけ、既存作品の安易な模倣に基づく粗悪な派生物を拡散する危険性を持ち、これは日本が培ってきた創作資産の価値と流通を毀損する恐れがある。日本のコンテンツ産業を守り持続的な発展を維持するためにも、その価値が適切に還元され得る AI 活用の枠組みを整備する必要がある。そこで本研究では、最終成果物そのものではなく、制作工程で用いられるレイアウトのような中間的生成物に着目し、創作を支援する AI 活用の可能性を検討する。とりわけ漫画制作には、コマ割りやセリフ配置などの演出上の意思決定を担う内部資料として、ネームが存在する。漫画は平面をコマへと分割し、その上に物語を描く表現形式である。コマやキャラクター、セリフの配置は演出上の意思決定を反映し、一般にネームと呼ばれる下書きにおいて定められ、作品の核となる役割を担う。一方、要素の配置を扱うレイアウト生成の研究は主に機能的媒体を対象として発展してきたため、ネームのように物語文脈と不可分に決まる配置を対象とした研究は十分ではない。ネームは内部資料として公開されにくく、学習・評価に耐える規模で脚本情報や演出情報が整備されたデータも不足していた。そこで本研究では、ネームを下書き画像そのものではなく、要素の幾何学的配置と演出情報が統合された、物語から作品へ至るための構造的中間表現として定義し、この定義に基づき、大規模視覚言語モデルを用いて、Manga109Dataset に含まれる 19,555 ページの漫画画像から脚本情報および演出情報を抽出した Manga109ScriptDataset と Manga109NameDataset を整備した。この過程では、漫画の読解の要となる読み順を明示するため、103,850 のコマおよび 144,875 のセリフに人手で順序を付与し、これを視覚的手がかりとしたビジュアルプロンプティング手法により情報抽出精度を高めた。さらに、これらのデータセットを用いて、脚本を入力としネームを生成する漫画ネーム生成モデルを構築した。提案モデルは既存のレイアウト生成手法との比較により、複数の評価指標で性能の向上を示した。その一方で、演出情報の定量的な評価指標の不足が課題となった。以上により、本研究は、創作分野における社会に受容され得る AI 活用のあり方を模索する目的で、漫画制作の中核であるネームを対象とした大規模データの整備と、脚本に基づくネーム生成の学習基盤を提示する。

Thesis Abstract

Manga Name Generation from Scripts

AI creates new possibilities for art, but ethical issues remain. Low-quality copies made by AI can hurt the value of Japan’s creative assets. To support the industry, we explore AI that helps with the process rather than just making final outputs. We focus on the ”name” (storyboard), a key document in manga that decides panel layouts and dialogue placement. Manga tells a story by splitting a page into panels. This layout reflects the author’s intent. However, previous layout generation research focused on simple media and ignored layouts tied to stories. Also, because manga names are private, there is not enough data for machine learning. In this study, we define a manga name as a structured representation combining layout and direction. We extracted data from 19,555 pages using Large Vision-Language Models to create the *Manga109ScriptDataset* and *Manga109NameDataset*. To ensure accuracy, we manually annotated the reading order of 103,850 panels and 144,875 dialogue balloons. We used this order as a visual cue in a visual prompting method to improve data extraction. Using these datasets, we built a model that generates manga names directly from scripts. Our model performs better than existing methods on several metrics, though quantitatively evaluating ”directing” quality remains a challenge. Overall, this work provides large-scale resources and a foundation for manga storyboard generation. Through these contributions, we aim to explore a form of AI utilization that is socially accepted by supporting the creative process rather than automating the final outcome.

目次

第 1 章	序論	9
第 2 章	関連研究	12
2.1	レイアウト生成	12
2.1.1	ルールベースおよび最適化に基づくレイアウト生成	12
2.1.2	深層生成モデルによるレイアウト生成	13
2.1.3	LLM を用いたレイアウト生成	21
2.1.4	制約付き・条件付きレイアウト生成の整理	23
2.1.5	本研究の位置づけ	25
2.2	ビジュアルストーリーテリング	26
2.2.1	画像キャプション生成	26
2.2.2	画像系列からの物語生成	27
2.2.3	LVLMM への発展	27
2.2.4	Visual Prompting	29
2.3	漫画を対象とした研究	32
2.3.1	漫画理解を支えるデータセット	32
2.3.2	漫画読解の多段構造と評価ベンチマーク	33
第 3 章	Manga109ScriptDataset	36
3.1	脚本形式の定義	36
3.2	Visual Prompting	37
3.3	画像間文脈理解のためのチャットフロー	38
3.3.1	整序したセリフの入力	39
3.3.2	文脈理解のための 3 段階のインタラクション	39
3.4	データセットの統計量	40
3.5	品質評価	41

3.5.1	評価死票	42
3.5.2	評価の実施設定と結果	42
第 4 章	脚本に基づく漫画のレイアウト生成	44
4.1	漫画のレイアウト生成における問題設定	44
4.2	脚本に基づく漫画のレイアウト生成手法	45
4.3	漫画のレイアウト生成における実験設定	47
4.3.1	データセット分割	47
4.3.2	比較手法	47
4.3.3	制約条件	48
4.3.4	評価指標	48
4.3.5	レイアウト生成の学習および実装詳細	50
4.4	漫画のレイアウト生成における結果と考察	51
4.4.1	Gen-T 条件下でのレイアウト生成結果と考察	51
4.4.2	Gen-TS 条件下での結果と考察:	54
4.4.3	考察のまとめと手法の課題	55
第 5 章	Manga109NameDataset	57
5.1	Manga109NameDataset の概要	58
5.2	データセット構築手法	59
5.2.1	読み順アノテーションの付与	60
5.2.2	ID 情報を付記する独自 Visual Prompting	62
5.2.3	超解像度処理による認識性能の向上	64
5.2.4	文脈理解を促進する画像・セリフの入力	67
5.3	Manga109NameDataset の統計的特性	67
5.3.1	データセット全体の規模	68
5.3.2	Spread ノードに付与された物語情報の統計	68
5.3.3	Panel ノードに付与された構成要素と演出属性の統計	69
5.3.4	Character ノードの統計的特性	71
5.3.5	Character Instance ノードの統計的特性	72
5.3.6	Speech ノードの統計的特性	73
5.3.7	キャラクター間相互作用を表す Action Edge の統計	76
5.4	構造化データの可視化例	77

第 6 章	脚本に基づく漫画のネーム生成	82
6.1	漫画のネーム生成における問題設定	82
6.1.1	ネーム表現の定義	83
6.1.2	ネーム生成タスクの定式化	84
6.2	脚本に基づく漫画のネーム生成手法	84
6.3	漫画のネーム生成における実験設定	85
6.3.1	データセットと入力・出力の整理	86
6.3.2	データセット分割	88
6.3.3	比較手法	88
6.3.4	ネーム生成における学習設定および実装詳細	88
6.3.5	評価方法	89
6.4	漫画のネーム生成における結果と考察	90
6.4.1	ネーム生成におけるレイアウト生成性能の定量的評価	90
6.4.2	GNN を用いた演出情報生成の間接的評価	92
6.4.3	ネーム生成における生成されたレイアウトの可視化と考察	93
6.4.4	ネーム生成において推定された演出情報の可視化と考察	95
第 7 章	結論	98
	謝辞	99
	参考文献	110
	研究業績一覧	111
付録 A	学習および実装の詳細	113
A.1	Script2Layout の LoRA ファインチューニングの学習設定およびハイパーパラメータ	113
A.2	Script2Name の LoRA ファインチューニングの学習設定およびハイパーパラメータ	113
A.3	GNN によるレイアウト推定モデルの詳細	114

図目次

1.1	本研究における取り組みの概略図. Manga109Dataset から大規模視覚言語モデル (LVLM) を用いて脚本情報および演出情報を抽出し, ネームデータセットとして構築した. そのデータセットを用いて脚本から漫画のネームを生成する漫画ネーム生成モデルを構築した (漫画: 『犯罪交渉人 峰岸英太郎』©記伊 孝/講談社).	11
2.1	Manga109Dataset [11] に含まれる漫画画像の例 (『ARMS』© 加藤 雅基/東京三世社)	33
3.1	脚本生成プロンプトにおける Few-shot の例	37
3.2	Visual Prompting の例 (漫画: 『犯罪交渉人 峰岸英太郎』©記伊 孝/講談社).	38
3.3	入力に利用した漫画画像 (左: 『犯罪交渉人 峰岸英太郎』©記伊 孝/講談社) と生成された脚本データ (右) の例.	41
4.1	Script2Layout による脚本条件付きレイアウト生成の概略図. 上段は, 本研究で提案する手法であり, 自然言語として記述された脚本を直接入力として扱いつつ, キャラクター, セリフ, およびコマに対応する要素を抽出し, Fine-tuned LLM によりページ全体のレイアウトを生成する. 下段は, 既存のレイアウト生成手法の例であり, 要素数やカテゴリといった構造化情報を入力としてレイアウトを生成する点で異なる.	46
4.2	Gen-T 条件下におけるレイアウト生成の可視化結果. 各行に対して, 左から順に正解レイアウト, 既存手法の生成例, Script2Layout の生成例, が並び, Script2Layout では上段に Script 条件なし, 下段に Script 条件ありの結果を示す. (漫画: 上段『ヒーリング・プラネット』©桜野 みねね/エニックス, 下段『ドールガン』©出口 竜正/秋田書店)	53
5.1	Manga109NameDataset における 1 サンプル分のデータ構造の概略	58
5.2	読み順アノテーションツールの操作画面 (漫画: 『ARMS』©加藤 雅基/東京三世社)	61

5.3	コマの読み順が一致しなかった見開き画像の例. 本来は 4, 5 と読み進めるべきコマの順序が, 自動推定では逆転してしまった (漫画:『空っぽハイスクール』© 高口 里純/角川書店).	62
5.4	セリフの読み順が一致しなかった見開き画像の例. 本来は 6 番のコマに帰属するセリフは, 5 番のコマに帰属する 2 つのセリフの間で読まれるべきであるが, 自動推定では 5 番のコマの 2 つのセリフよりも後に推定されてしまった (漫画:『ヒーリング・プラネット』© 桜野 みねね/ エニックス).	63
5.5	ID を付記した Visual Prompting の例 (漫画:『愛さずにはいられない』© よし まさこ/集英社).	63
5.6	ID ラベルによりキャラクターの識別等状況が正確に構造化された例. 画像内の ID タグである ci (Character Instance) はキャラクターを, s (Speech) はセリフを一意に識別しており, これらが右側の構造化データとして正しく対応付けられている (漫画:『愛さずにはいられない』© よし まさこ/集英社).	65
5.7	超解像度処理による ID ラベルの視認性が向上した例. 左が最小フォントサイズを 12pt に設定した画像, 中央が画像比率にあわせ最小フォントサイズを設定した画像, 右が超解像度処理を施し 12pt のフォントサイズを設定した画像である. 左は画像全体にオクルージョンが生じ, 中央はラベル自体が付記できていないが, 右は適度なサイズで ID ラベルを描画できている (漫画:『うるとら★イレブン』© やぶの てんや, 渡辺 達也/集英社).	66
5.8	ID ラベルの最小フォントサイズの縮小に伴う遮蔽率の変化と超解像度処理に伴う遮蔽率の比較. Normal の最小フォントサイズは 12pt で設定され, Small は 9pt, Extra Small は 6pt に設定された. SuperRes(Half) は 2 倍の超解像度処理画像, SuperRes(Full) は 4 倍の超解像度処理画像を表す.	66
5.9	文脈付与入力により, 見開き単体では理解が困難な場面で, 過去の状況を正しく盛り込み正確な理解で summary が生成された例 (漫画:『愛さずにはいられない』© よし まさこ/集英社).	68
5.10	本節で例示する Manga109NameDataset の入力見開き画像 (漫画:『あっけら貫刃帖』© 小林 ゆき/集英社).	78
5.11	構築された階層構造の例. Inst は CharacterInstance ノードを表す.	78
5.12	Spread ノードの例.	78
5.13	Panel ノードの例.	79
5.14	Speech ノードにの例.	79

5.15	キャラクターインスタンス間の相互作用 (Action Edge) の例. C_inst は Character Instance ノードを表す.	79
5.16	同一ページ内の Panel 間の参照関係の例. Pnl は Panel ノードを表す.	80
5.17	CharacterInstance と CharacterNode 間の参照関係の例. C_inst は Character Instance ノードを表し, Globalchar は Character ノードを表す.	80
5.18	Speech と Character Instance および Character を結ぶ参照関係の例. C_inst は CharacterInstance ノードを表し, Sp は Speech ノードを, Globalchar は Character ノードを表す.	81
6.1	脚本に基づく漫画ネーム生成タスクの概略図	83
6.2	ネーム生成におけるレイアウト生成結果の定性的比較. 左の列から順に, 正解となる漫画画像, 既存手法の生成結果, Script2Layout の生成結果, Script → (Direction + Layout) の生成結果, (Script + Direction) → Layout の生成結果, Script2Direction2Layout の生成結果. を示し, それぞれの列で各行は, モデルの違いに対応している. Scr は Script を, Dir は Direction を, Lyt は Layout を表す (漫画: 上段『うるとら☆イレブン』© やぶの てんや, 渡辺 達也/集英社, 下段『永遠のウィズ』© みやうち 沙矢/講談社).	94
6.3	脚本に基づくネーム生成において推定されたコマに対する演出情報の可視化の例. 上段左が対象となったコマ画像, 上段中央が, 対象のコマを含んだ見開きに対する入力に用いられた脚本情報 (Input Script), 上段右 Ground Truth(GT) となる演出情報 (Direction), 下段が, Script を入力に推定された Direction を示す. Input Script を示すパネルには, 見開き全体の要約文 (Sum) と脚本 (Scr), 注意書き (Note) が途中まで示され, Direction を示すパネルには, そのパネルにおける要約文 (Sum) および, 役割 (ROLES), 形状 (SHAPE), カメラ距離 (DIST), カメラ角度 (ANG) がカテゴリ情報として示されている (漫画: 『太陽にスマッシュ!』©あゆみ ゆい/講談社).	95
6.4	脚本に基づくネーム生成において推定された action edge の可視化の例. 上段左側が対象となった見開き, 上段中央が, 対象の見開きに対する入力に用いられた脚本情報 (Input Script), 上段右 Ground Truth(GT) となる Action Edge, 下段が, Script を入力に推定された Action Edge を示す. Input Script を示すパネルには, 見開き全体の要約文 (Sum) と脚本 (Scr), 注意書き (Note) が途中まで示され, Action Edge 内に示された C_inst は Character Instance ノードを表す (漫画: 『太陽にスマッシュ!』©あゆみ ゆい/講談社).	96

表目次

3.1	Manga109ScriptDataset の統計量.	41
3.2	人手による品質評価の結果	43
4.1	Gen-T 条件下におけるレイアウト生成の定量評価の結果.	52
4.2	Gen-TS 条件下におけるレイアウト生成の定量評価結果.	55
5.1	Manga109NameDataset に含まれる各ノード種別の総数と 1 Spread あたりの平均数, なお Character ノードについても Spread ごとに集計した数を示す.	68
5.2	Spread ノードに付与された summary の文字数の統計.	69
5.3	Panel ノードに付与された summary の文字数統計.	69
5.4	役割属性の分布	70
5.5	コマ形状の分布	70
5.6	カメラ距離の分布	70
5.7	カメラアングルの分布	70
5.8	Character ノードに付与された profile の文字数統計.	71
5.9	Character role の分布	72
5.10	Character importance の分布	72
5.11	Character Instance ノードに付与された自由記述属性の文字数統計	73
5.12	姿勢属性の分布	74
5.13	行動属性の分布	74
5.14	感情属性の分布	75
5.15	face_body 属性の分布	75
5.16	Speech ノードに付与された発話テキストの文字数統計	75
5.17	Speech ノードにおける発話種別属性の分布	76
5.18	Action Edge に付与された相互作用記述の文字数統計	77
6.1	Manga109NameDataset における Script/Direction/Layout 構成の整理	86

6.2	脚本に基づくネーム生成の比較設定. GNN は Graphical Neural Network を表す. . .	87
6.3	脚本に基づくネーム生成におけるレイアウト生成の定量評価結果.	91
6.4	GNN によるレイアウト生成性能を指標とした, 演出情報 (Direction) 生成品質の間 接的評価結果. 正解 (GT) Direction を用いた 理想的設定 と, 各 LLM により生成さ れた Direction を用いた場合を比較する.	93
A.1	Script2Layout の LoRA ファインチューニングに用いた学習ハイパーパラメータ . .	113
A.2	Script2Name の LoRA ファインチューニング設定 (再現用ハイパーパラメータ) . .	114
A.3	Script2Direction2Layout における GNN (HeteroConv) モデル構成 (実装に基づく)	115
A.4	GNN (Script2Direction2Layout) 学習設定 (実装の既定値)	115

第 1 章 序論

漫画は、平面をコマへと分割し、その上に物語を描く表現形式である。各コマは時間および空間の連続性を離散化した単位として出来事の順序や場面転換を担い、その配置は、キャラクターやセリフ配置とともに、視線誘導、強調、テンポといった物語に基づく演出上の意思決定を反映する。このような漫画の構成上の配置は、一般にネームと呼ばれる下書きにおいて定められ、作品の核となる重要な役割をもつ [1]。しかし、要素の配置問題を数理的に扱うレイアウト生成の研究において、漫画のネームのように物語の文脈に深く紐づく生成物を対象にした研究はこれまで十分に組み込まれてこなかった。

従来、レイアウト生成モデルの開発に取り組む研究は、与えられた要素群を平面上に配置し、可読性・視認性・審美性などの要件を満たす構成を、自動的に設計する試みとして発展してきた。Web UI やポスター、文書レイアウト等の機能的媒体を対象として、要素の種類やサイズ、要素間関係といった条件に基づく生成や部分的な欠損要素の補完、既存配置の精緻化など、多様な問題設定が提案されてきた [2, 3, 4, 5, 6, 7]。しかし、漫画のレイアウト設計は、物語上の展開や演出意図と不可分に決定されるという点で、機能的媒体の配置問題とは前提が異なる。制作工程で用いられるネームは外部に公開されにくい内部資料であり、物語を条件にして漫画のレイアウトおよびそれを内包するネームの自動生成に取り組むには、漫画画像に紐づく物語文および演出情報の不足という観点で、入出力の双方に、学習および評価に耐える規模の体系的に整備されたデータが不足していた。

ここで本研究では、この「ネーム」を、作品の下書き画像そのものではなく、その本質をもとに「要素の幾何学的な配置」と、カメラワークやキャラクターの表情といった「演出情報」が統合された、物語から作品へ至るための「構造化された中間表現」として定義する。このようにしてネームを捉えると、ネームデータの構築には、漫画画像から物語の文脈や演出上の意味を高次に読み取る能力が不可欠となる。

一方、連続する画像から物語を抽出する研究領域として、ビジュアルストーリーテリングが存在する。これまで、この分野では、単一画像のキャプション生成を組み合わせる試みや単純な連続的状況を記述する試みが組み込まれてきた [8, 9]。しかし、近年は大規模視覚言語モデル (Large Vision-Language Model; LVM) の登場により、本領域における技術的水準が飛躍的な進化を遂げている。最新のモデルは、単一画像の要素認識に留まらず、複数の画像にまたがる文脈の統合や、物語構造に関わる高次元意味内容までも言語化し得る推論能力を示し始めている [10]。

そこで本研究では、LVLMM の高度な画像認識能力を応用し、漫画画像に紐づく脚本データ・演出データの構築を行った。具体的には、Manga109Dataset [11] に含まれる全 19,555 ページの漫画画像から脚本情報を抽出した Manga109ScriptDataset の構築と、これを技術の進展に伴い、物語文を刷新し演出情報まで加え構造化した Manga109NameDataset の構築である。Manga109ScriptDataset には人手による評価も与え、その信頼性を担保した。

両データセットの構築にあたり中心となった技術は Visual Prompting [12] である。Visual Prompting は画像に特定のマーキングなどの処理を加え、LVLMM の性能向上を図る手法である。本研究においては、これを漫画の読解性能を高める技術として応用した。特に Manga109NameDataset の構築にあたっては、Manga109Dataset 内に含まれる全 103,850 のコマ、全 144,875 のセリフに対し、LVLMM 単体性能による認識や自動推定がまだ困難であり、かつ、物語構造の決定に不可欠な「読み順」を、人手によるアノテーションにより付与し、このアノテーションデータを視覚的な手がかりとする独自の Visual Prompting 手法を開発した。これにより LVLMM の物語抽出精度および演出情報の記述能力を高め、漫画画像に紐づく物語・脚本情報と各コマにおけるキャラクターのポーズや表情、カメラワークといった詳細な演出情報の抽出を可能にした。

本研究では、以上のように獲得したデータセットを構造的に整備したうえで、脚本を入力側に、演出情報を出力側にして、脚本を入力とした漫画ネーム生成モデルの学習基盤を構築した。本研究で開発したモデルは、大規模言語モデル (Large Language Model; LLM) をベースモデルとした追加学習（ファインチューニング）モデルであり、脚本を入力にネームを生成する。提案モデルを既存のレイアウト生成モデル [13, 14, 15] と比較した結果、複数の評価指標 [13, 16] で既存モデルの精度を上回り、構築した脚本データおよびネームデータの有効性を確認した。さらに、複数の入出力の生成設定を比較検討することで、物語構造・演出情報を含むネームデータの効果的な活用手法を、脚本に基づく漫画ネーム生成モデルのベースラインとして整備した。一方で、生成された演出情報を客観的に評価する手法については、その評価設計の難しさが課題として明らかとなった。本論文では、Manga109ScriptDataset の構築とこれを活用した実験内容を第一部に、Manga109NameDataset の構築とこれを活用した実験内容を第二部に扱う。本研究における取り組みをの概略を図 1.1 に示す。

現在、生成 AI は創作領域に新たな可能性を開きつつある一方、倫理的課題を抱え、社会的受容には依然として隔たりがある。とりわけ、既存作品の安易な模倣に基づく粗悪な派生物を拡散する危険性を持ち、これは日本が培ってきた創作資産の価値と流通を毀損する恐れがある。生成 AI 技術の進展に少なからず寄与してきた日本のコンテンツ産業を守り持続的な発展を維持するためにも、その価値が適切に還元され得る AI 活用の枠組みを整備する必要がある。画像や映像といった最終成果物を直接生成するのではなく、制作工程の核であり、演出上の意思決定が集約されるネームを支援対象とする本研究における取り組みは、作者の創造性を尊重しつつ、社会的受容と実制作における効率性向上の両立に資することを目的とする。




図 1.1: 本研究における取り組みの概略図. Manga109Dataset から大規模視覚言語モデル (LVLM) を用いて脚本情報および演出情報を抽出し、ネームデータセットとして構築した. そのデータセットを用いて脚本から漫画のネームを生成する漫画ネーム生成モデルを構築した (漫画: 『犯罪交渉人 峰岸英太郎』 © 記伊 孝/講談社).

本研究の貢献は以下の 5 点にまとめられる

1. 全 19,555 ページの漫画画像に紐づいた脚本データセット Manga109ScriptDataset の構築
2. Manga109ScriptDataset への評価アノテーションの付与
3. Manga109Dataset に含まれる全 103,850 のコマ・全 144,875 のセリフに対する、人手による読み順アノテーションデータの整備
4. 独自の Visual Prompting 手法を用いた LVLM の活用による物語情報および演出情報を含む全 9,827 の見開き漫画画像分の漫画ネームデータセット Manga109NameDataset の構築
5. Manga109ScriptDataset および Manga109NameDataset を活用した、漫画ネーム生成モデルの構築および既存のレイアウト生成手法との比較実験を経た漫画ネーム生成モデルのベースラインの整備

第2章 関連研究

本研究は、(1) 視覚要素の配置を扱うレイアウト生成の研究、(2) 画像から物語的文脈を抽出・生成するビジュアルストーリーテリングの研究、(3) 漫画を対象とした研究、という3つの研究領域に関連し、本章ではこれらについて整理する。

まず、2.1節でレイアウト生成研究の流れを概観し、要素配置問題としての定式化から、深層生成モデル、LLMを用いた近年の発展までを整理する。次に、2.2節で画像列から物語を生成するビジュアルストーリーテリング研究について、従来手法からLVLMおよびVisual Promptingに至る技術的進展を述べる。最後に、2.3節で漫画を対象とした画像理解・物語理解研究を取り上げ、特にManga109Datasetを中心としたデータセット整備と、漫画特有の課題について整理する。

これらの関連研究を踏まえ、脚本に基づいて漫画のネームを生成するという本研究の位置づけと、既存研究に対する新規性を明確にする。

2.1 レイアウト生成

レイアウトの自動生成技術は、数理的な最適化に基づく古典的手法から、近年の深層学習を用いたデータ駆動型的手法へと大きく発展してきた。本節では、この技術的変遷を、体系的に記述するとともに、レイアウト生成タスクがどのような媒体を対象としてきたかを整理する。

2.1.1 ルールベースおよび最適化に基づくレイアウト生成

レイアウト生成の初期研究においては、視覚要素の配置を人間のデザイン知識に基づくルールや制約として明示的に定義し、それらを満たす配置を探索するアプローチが主流であった[17, 18, 19]。

このアプローチでは、レイアウト生成を「制約充足問題」あるいは「最適化問題」として定式化する。具体的には、要素の整列や間隔、余白の確保、サイズ比率の一貫性といったデザイン原則を数理的な制約条件として表現する。典型的には、各要素の位置 (x_i, y_i) や大きさ (w_i, h_i) を決定変数とし、可読性や審美性を反映した目的関数（エネルギー関数） E を定義して、その最大化（あるいはコストの最小化）を行うことでレイアウトを決定する[20]。

例えば、要素間の重なりを避ける制約、グリッドへの整列を促すペナルティ項、視線誘導を考慮した

配置順序の制約などが導入され [21, 19], これらを満たす最適解としてレイアウトが求められる。この枠組みは、専門家の知識を数式として表現する必要があったものの、レイアウト生成を明確な「要素配置問題」として定義した点で重要な基盤を与えた。

しかし、これらの手法は、設計者があらかじめ想定した制約や評価指標に強く依存するという本質的な課題を抱えていた。デザイン原則の重み付けは経験的に決定されることが多く、新たな媒体や異なる表現様式に適用する際にはルールの再設計が不可欠となる。また、複雑な制約を同時に満たす大域的最適解を探索することは計算量的に困難であり、生成される表現の多様性や柔軟性にも限界があった [22]。

こうした「人手による特徴設計」の限界から、データセットからレイアウトの分布や配置パターンを直接学習する手法への関心が高まり、次節で述べる深層生成モデルへと研究の主軸が移行していった。

2.1.2 深層生成モデルによるレイアウト生成

深層生成モデルは、データ分布を明示的あるいは暗黙的に近似することで、新たなサンプルを生成する枠組みである。レイアウト生成においては、視覚要素の配置全体を一つの確率分布として捉え、その分布から妥当な配置をサンプリングするという観点が重要となる。

GAN・VAE に基づく手法

ここでは、まず Generative Adversarial Network (GAN) [23] および Variational AutoEncoder (VAE) [24] の基本的定式化を整理した上で、それらをレイアウト生成に適用した代表的手法である LayoutGAN [25] および LayoutVAE [26] について詳述する。

GAN GAN は、Generator G と Discriminator D の二者による敵対的学習を通じて、データ分布 $p_{\text{data}}(x)$ を暗黙的に近似する生成モデルである。Generator は潜在変数 $z \sim p(z)$ からデータ空間への写像 $G(z)$ を学習し、Discriminator は入力サンプルが実データか生成データかを識別する。学習は以下のミニマックス問題として定式化される：

$$\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D(G(z)))]. \quad (2.1)$$

GAN は高品質なサンプル生成が可能である一方、生成対象の構造を明示的に制御することが難しく、レイアウトのように「複数要素の相対関係」が重要なタスクでは、そのまま適用することは困難であった。

LayoutGAN LayoutGAN [25] は、GAN をレイアウト生成に適用するため、レイアウトを複数要素の集合として定式化した。各レイアウトは、

$$\mathcal{L} = \{(b_i, c_i)\}_{i=1}^N \quad (2.2)$$

として表され, $b_i = (x_i, y_i, w_i, h_i)$ は要素 i の位置およびサイズ, c_i はカテゴリラベルである.

Generator G は, 潜在変数 z を入力として, N 個の要素特徴 $\{f_i\}_{i=1}^N$ を生成し, それぞれから (b_i, c_i) を出力する. しかし, 単純に独立生成すると要素間の整列や重なりといった構造的関係を捉えられない. そこで LayoutGAN は, 要素間の相互作用を考慮するために *relation module* を導入している.

この module では, 要素 i と j の関係を相対位置などの関係特徴 r_{ij} として表し, 注意機構に類似した計算により要素特徴を更新する:

$$\tilde{f}_i = \sum_{j=1}^N \alpha_{ij} f_j, \quad (2.3)$$

$$\alpha_{ij} = \frac{\exp(\phi(f_i, f_j, r_{ij}))}{\sum_{k=1}^N \exp(\phi(f_i, f_k, r_{ik}))}, \quad (2.4)$$

ここで $\phi(\cdot)$ は学習可能な関数である. この設計により, LayoutGAN は要素集合全体を一つの構造として扱い, 整合性のあるレイアウト生成を可能にしている.

Variational Autoencoder (VAE) VAE は, 確率的潜在変数モデルに基づき, データ x を潜在変数 z を介して生成する枠組みである. Encoder $q_\phi(z | x)$ と Decoder $p_\theta(x | z)$ を用い, 対数尤度 $\log p_\theta(x)$ の下界である変分下限を最大化する:

$$\log p_\theta(x) \geq \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)] - \text{KL}(q_\phi(z | x) \| p(z)). \quad (2.5)$$

VAE は, 潜在空間の連続性と生成の安定性に優れる一方, 生成結果が平均化されやすいという特徴を持つ.

LayoutVAE LayoutVAE [26] は, VAE をレイアウト生成に適用し, 要素数が可変なレイアウトを確率的に生成可能とした. レイアウト $\mathcal{L}$ を,

$$\mathcal{L} = \{(e_i, b_i, c_i)\}_{i=1}^N \quad (2.6)$$

として表し, $e_i \in \{0, 1\}$ は要素 i の存在を表す確率変数である. Decoder は以下のように分解される:

$$p_\theta(\mathcal{L} | z) = \prod_{i=1}^N p(e_i | z) p(b_i | z, e_i) p(c_i | z, e_i). \quad (2.7)$$

この定式化により, LayoutVAE はレイアウト構造そのものの不確実性を潜在変数として扱うことが可能となった. また, 複数の妥当なレイアウトを確率的に生成できる点が特徴である.

Transformer に基づくレイアウト生成

GAN や VAE に基づく手法では、レイアウト全体を一括して生成することにより、要素間の幾何学的関係を暗黙的に学習するアプローチが取られてきた。一方で、要素数が可変であること、要素間に明示的な制約（関係・サイズ・配置条件など）が存在すること、また部分的な入力からの生成（補完・洗練）といった多様な条件付き生成を単一の枠組みで扱うことは困難であった。

この課題に対し、近年ではレイアウトを「要素列」として扱い、自己注意機構により要素間関係を明示的にモデル化する Transformer [27] ベースの手法が提案されている。代表的な手法として、LayoutTransformer [28], BLT [29], LayoutFormer [30], およびその拡張である LayoutFormer++ [14] が挙げられる。

Transformer の基本構造と系列モデリング Transformer は、自己注意機構 (Self-Attention) により入力系列全体を同時に参照することで、長距離依存関係を効率的に捉えることができるモデルである。レイアウト生成においては、各要素を系列中のトークンとして扱うことで、要素間の複雑な相互作用を自然にモデル化できる点が重要である。

入力系列を $X = (x_1, x_2, \dots, x_T)$ とし、各トークン x_t を d 次元のベクトル表現 $h_t \in \mathbb{R}^d$ に埋め込む。これらをまとめた行列を $H \in \mathbb{R}^{T \times d}$ とする。自己注意機構では、 H から線形変換によりクエリ Q , キー K , バリュース V を構成する：

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V, \quad (2.8)$$

ここで、 $W_Q, W_K, W_V \in \mathbb{R}^{d \times d_k}$ は学習可能な重み行列である。

注意重みは、スケールド内積に基づき次式で計算される：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V. \quad (2.9)$$

この操作により、各要素は他のすべての要素を参照し、文脈（レイアウト全体の構造）を考慮した表現へと更新される。

さらに、複数の注意ヘッドを並列に用いる Multi-Head Attention (MHA) により、異なる部分空間における要素間関係を同時に学習する：

$$\text{head}_i = \text{Attention}(HW_Q^{(i)}, HW_K^{(i)}, HW_V^{(i)}), \quad (2.10)$$

$$\text{MHA}(H) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W_O. \quad (2.11)$$

続いて、各位置ごとに Position-wise Feed-Forward Network (FFN) が適用される：

$$\text{FFN}(h) = \sigma(hW_1 + b_1)W_2 + b_2, \quad (2.12)$$

ここで $\sigma(\cdot)$ は ReLU や GELU などの活性化関数である。これらの層が積層されることで、モデルはレイアウト要素間の高次元依存関係を獲得する。

レイアウトの系列化表現 上述の Transformer アーキテクチャをレイアウト生成に適用するためには、2 次元的なレイアウト情報を 1 次元のトークン列に変換する必要がある。Transformer 系手法では、一般にレイアウトを N 個の要素から構成される系列として表現する。

各要素 i は要素種別 c_i と、位置および大きさを表す属性 (x_i, y_i, w_i, h_i) により定義される。これらの連続値は事前に量子化され、各属性が離散トークンとして扱われる。このとき、レイアウト L は次のような系列となる：

$$L = \langle \text{SOS} \rangle c_1, x_1, y_1, w_1, h_1, \dots, c_N, x_N, y_N, w_N, h_N \langle \text{EOS} \rangle. \quad (2.13)$$

Transformer デコーダは、この系列を自己回帰的に生成し、時刻 t におけるトークン L_t の生成確率を

$$P(L_t \mid L_{<t}, S; \theta) \quad (2.14)$$

としてモデル化する。ここで S は条件情報（制約）を表し、 θ はモデルパラメータである。

学習は、負の対数尤度を最小化することで行われる：

$$\mathcal{L} = - \sum_{t=1}^{|L|} \log P(L_t \mid L_{<t}, S; \theta). \quad (2.15)$$

LayoutFormer++ による制約直列化 レイアウトの生成においてはその制御性を高めるために様々な制約を入力として与えることが試みられてきた。要素種別、要素サイズ、要素間関係（上下・左右・大小関係）など、多様な制約である。既存研究では、制約をレイアウトと同一形式で与える方法や、制約ごとに専用のモデル設計を行う方法が取られてきたが、これらは柔軟性に欠け、新たな制約設定への拡張が困難であった。Transformer ベースの手法である LayoutFormer++ [14] は、これらの課題に対し、制約直列化（**constraint serialization**）という枠組みを導入した。これは、異なる種類の制約をすべて「トークン列」として統一的に表現する手法である。

例えば、要素種別制約、サイズ制約、要素間関係制約は、それぞれ次のような系列として表現される：

$$S_{\text{type}} = \langle \text{SOS} \rangle c_1 \mid c_2 \mid \dots \mid c_N \langle \text{EOS} \rangle, \quad (2.16)$$

$$S_{\text{size}} = \langle \text{SOS} \rangle c_1 w_1 h_1 \mid \dots \mid c_N w_N h_N \langle \text{EOS} \rangle, \quad (2.17)$$

$$S_{\text{rel}} = \langle \text{SOS} \rangle c_i i r_{i,j} c_j j \mid \dots \langle \text{EOS} \rangle. \quad (2.18)$$

これらを一定の順序で連結することで、複数制約を同時に扱う入力系列 S が構成される。この設計により、LayoutFormer++ はレイアウト補完、洗練、関係条件付き生成など、異なるタスクを単一の Transformer モデルで統一的に扱うことが可能となった。

制約付きデコード (**Decoding Space Restriction**) さらに LayoutFormer++ は、推論時において制約付きデコード と呼ばれる戦略を導入している。各時刻 t において、Transformer デコーダが出力する確率分布 P_t に対し、以下の二段階の剪定を行う：

1. 制約違反を確実に引き起こすトークンの除外
2. 低確率トークンの除外

この結果得られる制限付き分布 P'_t からトークンをサンプリングすることで、生成品質を維持しつつ、制約違反の発生を抑制する。また、すべての候補が除外された場合には、過去の時刻に戻るバックトラッキング機構を導入し、生成の安定性を確保している。

拡散モデルによるレイアウト生成

一方、系列モデルである Transformer とは異なる生成パラダイムとして、近年では拡散モデル [31] を用いたアプローチも台頭している。拡散モデルは、データ分布からの生成を「ノイズ付加による前向き過程」と「ノイズ除去による逆過程」の逐次推定として定式化する生成モデルである。近年の画像生成で顕著な成功を収めた枠組みを背景に、レイアウト生成においても、複雑な要素間依存を段階的に回復するという性質が有効に働くことが示されている。

連続拡散モデルの基本定式化 まず連続値を対象とする代表的枠組みとして、連続拡散モデルを概観する。データ $x_0 \sim q(x_0)$ に対し、前向き過程 $q(x_{1:T} | x_0)$ は段階的にガウスノイズを付与するマルコフ連鎖として定義される：

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I), \quad (2.19)$$

$$q(x_{1:T} | x_0) = \prod_{t=1}^T q(x_t | x_{t-1}), \quad (2.20)$$

ここで $\{\beta_t\}_{t=1}^T$ はノイズスケジュールである。このとき x_t は閉形式で

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t)I), \quad \alpha_t = 1 - \beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^t \alpha_s \quad (2.21)$$

と書けるため、

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (2.22)$$

として直接サンプリングできる。

生成は逆過程 $p_\theta(x_{0:T})$ を学習することで行い、一般に

$$p_\theta(x_{0:T}) = p(x_T) \prod_{t=T}^1 p_\theta(x_{t-1} | x_t), \quad p(x_T) = \mathcal{N}(0, I) \quad (2.23)$$

と定義される。逆遷移 $p_\theta(x_{t-1} | x_t)$ はガウス分布で近似され、平均 $\mu_\theta(x_t, t)$ (あるいはノイズ予測器 $\epsilon_\theta(x_t, t)$) を学習する。典型的にはノイズ予測損失

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, x_0, \epsilon} \left[\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2 \right] \quad (2.24)$$

が用いられ、 T ステップの反復により $x_T \rightarrow x_0$ を復元することで生成を行う。

レイアウト生成における「離散拡散」への動機 レイアウトは、要素カテゴリ c_i と量子化された座標・サイズ (x_i, y_i, w_i, h_i) のように、しばしば離散値 (トークン) として表現されるのは前述の通り。そのため、連続拡散を直接適用するよりも、語彙集合 $\mathcal{V}$ 上のカテゴリ分布遷移としてノイズ付加を定義する離散拡散を用いる設計が自然となる。

離散拡散では、各時刻 t の状態 z_t を $K = |\mathcal{V}|$ 通りのカテゴリ変数とし、前向き過程をマルコフ連鎖として

$$q(z_{1:T} | z_0) = \prod_{t=1}^T q(z_t | z_{t-1}) \quad (2.25)$$

で定義する。D3PM [32] 等の枠組みでは、各ステップの遷移は遷移行列 $Q_t \in \mathbb{R}^{K \times K}$ を用いて

$$q(z_t | z_{t-1}) = \text{Cat}(z_t; z_{t-1} Q_t) \quad (2.26)$$

と書ける (ここで z_{t-1} は one-hot とみなす)。このとき、 t ステップ後の周辺分布は累積遷移 $\bar{Q}_t := \prod_{s=1}^t Q_s$ を用いて

$$q(z_t | z_0) = \text{Cat}(z_t; z_0 \bar{Q}_t) \quad (2.27)$$

と表される。

逆過程は、ニューラルネットワークによる条件付き分布

$$p_\theta(z_{t-1} | z_t) = \text{Cat}(z_{t-1}; \pi_\theta(z_t, t)) \quad (2.28)$$

で近似され、 $z_T \rightarrow z_0$ を段階的に復元することで生成を行う。さらに、変分下限に基づく学習では、各時刻での posterior $q(z_{t-1} | z_t, z_0)$ が重要となる。マルコフ性とベイズ則から、

$$q(z_{t-1} | z_t, z_0) \propto q(z_t | z_{t-1}) q(z_{t-1} | z_0) \quad (2.29)$$

であり、行列表現を用いると (one-hot の積として)

$$q(z_{t-1} | z_t, z_0) \propto (z_t Q_t^\top) \odot (z_0 \bar{Q}_{t-1}) \quad (2.30)$$

の形で計算できる ($\odot$ は要素積)。レイアウトではさらに、(1) カテゴリ (要素種別) のような非順序 (nominal) 属性と、(2) 座標・サイズのような順序 (ordinal) 属性が混在するため、前向き遷移 Q_t の設計が生成品質を大きく左右する点が重要である。

LayoutDM : 離散状態空間拡散による統一的レイアウト生成 LayoutDM [13] は、レイアウトを離散表現として扱い、離散状態空間拡散に基づく単一モデルで多様なレイアウト生成タスクを統一的に扱う枠組みを提案した。基本的な発想は、レイアウトを構成する属性（カテゴリ、座標、サイズなど）をそれぞれ語彙集合上のカテゴリ変数として扱い、属性（modality）ごとに拡散ノイズを設計する点にある。

(i) マスク置換型 **forward** 遷移の定式化 LayoutDM は D3PM 系の離散拡散をベースとし、語彙 $\{1, \dots, K\}$ に加えて特殊トークン MASK を導入した **mask-and-replace** の前向き遷移を用いる。各ステップの遷移行列 Q_t を

$$Q_t = \begin{bmatrix} (1 - \beta_t)I_K & \beta_t \mathbf{1}_K \\ \mathbf{0}_K^\top & 1 \end{bmatrix}, \quad (2.31)$$

のように定義することで、通常トークンは確率 β_t で MASK に遷移し、MASK は吸収状態 (absorbing state) として保持される。ここで I_K は $K \times K$ 単位行列、 $\mathbf{1}_K$ は長さ K のベクトル (MASK への遷移成分を表す) である。この設計により、カテゴリを他カテゴリへランダムに崩すのではなく、「不確かさ」を MASK として明示的に表現できるため、構造化データ (レイアウト) に対して安定なノイズ付加が可能となる。

(ii) 逆過程のパラメータ化 (**posterior mixing**) 逆過程では、Transformer Encoder 等のネットワークで $\tilde{p}_\theta(\tilde{z}_0 | z_t)$ (元トークンの事後分布) を推定し、これを posterior $q(z_{t-1} | z_t, \tilde{z}_0)$ と混合して

$$p_\theta(z_{t-1} | z_t) \propto \sum_{\tilde{z}_0} q(z_{t-1} | z_t, \tilde{z}_0) \tilde{p}_\theta(\tilde{z}_0 | z_t) \quad (2.32)$$

と構成する。これは「 z_0 を直接当てる」予測器を用いつつ、拡散過程に整合した z_{t-1} の分布へ落とし込む D3PM の代表的パラメータ化であり、変分下限に基づく学習 (KL 項の最小化) と相性が良い。

(iii) 条件付き生成 (制約注入) の数式化 LayoutDM は、条件付き生成を「再学習」ではなく推論時操作として扱える点を特徴とする。例えば、既知トークン集合 Ω (部分レイアウト、固定属性など) に対し、逆過程サンプリングの確率を

$$p'_\theta(z_{t-1} | z_t) \propto p_\theta(z_{t-1} | z_t) \prod_{j \in \Omega} \mathbb{I}[z_{t-1}^{(j)} = \hat{z}^{(j)}] \quad (2.33)$$

のように「固定 (masking)」することで、指定部分を常に満たすサンプリングが可能になる。また、制約違反候補の logit を減衰させる logit adjustment は、

$$\log \pi'_\theta(v | z_t, t) = \log \pi_\theta(v | z_t, t) - \lambda \mathcal{C}(v) \quad (2.34)$$

のように、制約コスト $\mathcal{C}$ を用いて候補トークン v の確率を抑制する形で記述できる (λ は強さ)。このような推論時制御により、要素種別条件、部分補完、属性条件など複数の条件付きタスクを単一の拡散モデルで統一的に扱えることを示した。

LayoutDiffusion: zhang ら [33] による LayoutDiffusion は、レイアウトを異種混在な離散トークン列として表現し、離散拡散過程で生成する点では LayoutDM と同系統である。一方で、カテゴリ (nominal) と座標 (ordinal) が混在する場合、前向き遷移を一樣混合のように設計すると近傍ステップ間の差分が過大になり、復元 (denoise) が困難になることを指摘する。そこで同手法は、**穏やかな (mild) 拡散過程** を実現するための設計原理として *legality* (不正トークン遷移の回避), *coordinate proximity* (座標近傍性の保持), *type disruption* (カテゴリ攪乱の制御) を掲げ、それを満たす前向き遷移行列の構成を与える。

(i) **ブロック単位の forward 遷移行列** LayoutDiffusion では、時刻 t の遷移行列を、座標 (ordinal) とカテゴリ (nominal) 等を分離したブロック構造として設計する：

$$Q_t = \begin{bmatrix} Q_t^{\text{coord}} & 0 & 0 \\ 0 & Q_t^{\text{type}} & 0 \\ 0 & 0 & Q_t^{\text{spec}} \end{bmatrix}. \quad (2.35)$$

この形により、座標トークンがカテゴリトークンへ遷移する等の明らかに不正な遷移を排除し (legality), 属性ごとに適切なノイズ設計を行える。

(ii) **座標 (ordinal) 用：離散ガウス近傍遷移** 座標トークンは順序性を持つため、現在値 k の近傍へ高確率で遷移する離散化ガウス分布に基づく遷移が用いられる。具体的には、座標語彙サイズを M とし、標準偏差 (ノイズ強度) σ_t を用いて、

$$Q_{t,k,l}^{\text{coord}} = \begin{cases} \frac{P(l) - P(l-1)}{P(M-1) - P(-1)}, & l = 0, \\ \frac{P(l) - P(l-1)}{P(M-1) - P(-1)}, & 0 < l < M-1, \\ \frac{P(M-1) - P(M-2)}{P(M-1) - P(-1)}, & l = M-1, \end{cases} \quad (2.36)$$

のように、累積確率 $P(\cdot)$ (連続ガウスの CDF を離散区間に積分したもの) を用いて近傍遷移を定義する。この設計により、小さな t では「少しだけ」座標が揺らぎ、大きな t では徐々に広がるという *coordinate proximity* を満たすノイズスケジュールを構成できる。

(iii) **カテゴリ (nominal) 用：吸収状態による type disruption 制御** カテゴリ属性は順序を持たないため、他カテゴリへの一樣遷移を許すと意味が急激に破壊される。LayoutDiffusion はこれを避けるため、カテゴリを他カテゴリへ直接遷移させず、確率 p_t で MASK へ遷移する吸収型の遷移を導入する：

$$Q_t^{\text{type}} = \begin{bmatrix} (1-p_t)I_K & p_t\mathbf{1}_K \\ \mathbf{0}_K^\top & 1 \end{bmatrix}. \quad (2.37)$$

ここで p_t は時刻依存の攪乱強度であり、type disruption を直接制御する役割を担う。この結果、カテゴリの意味を保ちながら不確実性のみを段階的に増やすことができ、denoise の難易度を緩和できる。

(iv) 逆過程と推論時制約 逆過程は、Transformer 等により $p_\theta(z_{t-1} | z_t)$ を近似し、 T ステップの反復で $z_T \rightarrow z_0$ を復元する。また LayoutDiffusion も、推論時のトークン固定や候補抑制により条件付き生成へ拡張可能であることが示されている。これらの設計により、PubLayNet [7] や RICO [6] 等で既存法を上回る性能が報告され、前向き過程の設計が離散拡散レイアウト生成の鍵であることを示した。

2.1.3 LLM を用いたレイアウト生成

前節までで述べた深層生成モデルは、レイアウトを座標やサイズの数値列として扱い、その確率分布を学習するアプローチが主流であった。これに対し近年、自然言語処理分野における LLM の発展に伴い、レイアウト生成においてもレイアウトを言語的・記号的な表現へと変換し、LLM の持つ知識や推論能力を活用する試みが活発化している [15, 34, 35, 3, 2]。

数値生成から言語生成への転換 GAN, VAE, Transformer, 拡散モデルといった従来手法では、レイアウトは主に

$$(c_i, x_i, y_i, w_i, h_i)$$

のような数値属性の集合あるいは系列として表現され、モデルはこれらの値を直接予測してきた。この枠組みは、幾何的整合性の学習には有効である一方、

- 条件や制約の設計が人手に依存する
- 新しい制約形式への拡張が難しい
- 意味的意図を明示的に扱いにくい

といった課題を抱えていた [36, 37]。

一方、LLM は自然言語を通じて、階層構造、優先度、役割分担といった抽象概念を柔軟に扱う能力を有する。この特性に着目し、レイアウト生成を言語生成問題あるいは言語を介した構造生成問題として再定式化する研究が提案されている。

LayoutPrompter LayoutPrompter [15] は、LLM をレイアウト生成に利用する代表的研究である。この手法では、要素種別や要素間関係といった制約を自然言語プロンプトとして記述し、LLM によってレイアウト仕様を生成させる。

例えば、

“A large title should be placed at the top, with an image below it, and text blocks aligned under the image.”

のようなプロンプトから、レイアウト要素の構造記述を生成し、それを後段の数値生成器に変換する。この設計により、制約設計を数式や専用フォーマットではなく、人間にとって直感的な言語表現で記述

できる点が特徴である。

LayoutGPT LayoutGPT [34] は、レイアウト生成を完全に言語生成問題として扱う点で一歩踏み込んだ手法である。この研究では、レイアウトを HTML や JSON 形式のテキストとして表現し、LLM によって直接生成する。

例えば、

```
<div class="container">
  <h1 style="top:0px">Title</h1>
  <img style="top:80px"/>
  <p style="top:300px"/>
</div>
```

のような構造化テキストを生成対象とすることで、LLM が持つコード生成能力を活用してレイアウト構造と配置を同時に記述する。

この枠組みでは、生成モデルは

$$p_{\theta}(T \mid S)$$

として、条件 S (プロンプト) に基づきテキスト列 T (レイアウト記述) を生成する。ここで、幾何情報は数値であるものの、その生成は言語トークン列の一部として扱われる。

LayoutNUWA : マルチモーダル条件付き生成 LayoutNUWA [35] は、LLM ベースの生成をさらに拡張し、テキスト条件だけでなく、画像やキャンバス情報を含むマルチモーダル条件付きレイアウト生成を提案した。レイアウトは依然として言語的記述として生成されるが、視覚特徴を条件として入力することで、背景画像や内容との整合性を考慮した配置が可能となる。

この方向性は、要素を抽象化することなくその要素の内容までを考慮するレイアウト生成 content-aware layout generation と LLM を融合する試みとして位置づけられる。

PosterLlama : ポスター生成における LLM の活用 PosterLlama [3] は、ポスターという実応用性の高い媒体を対象に、LLM によるレイアウト生成を検討した研究である。この手法では、ポスターを HTML に変換して扱い、LLM によって構造・配置・階層関係を同時に生成する。

特に、PosterLlama は

- レイアウトを数値列ではなく文書構造として捉える
- LLM の「デザイン常識」や事前知識を活用する

点を強調しており、ポスター制作のような意味的判断が重要なタスクとの親和性を示している。

SciPostLayout SciPostLayout [2] は、科学ポスターという特定媒体に着目し、レイアウト解析と生成のためのデータセットを整備した研究である。同研究では、LayoutFormer++ や LayoutPrompter, PosterLlama などの手法を比較し、LLM 系手法が「意味構造の理解」には優れる一方で、数値的精度や幾何的厳密性には課題を残すことを指摘している。

2.1.4 制約付き・条件付きレイアウト生成の整理

前節までは、主にレイアウト生成モデルのアルゴリズムやアーキテクチャの発展について述べた。本節では、これらの手法が具体的にどのような媒体を対象とし、どのような制約（条件）を入力として扱ってきたかという観点から、既存研究を整理する。

レイアウト生成が対象としてきたのは、雑誌表紙、Web/UI、プレゼンテーションスライド、バナー広告、ドキュメント組版など、多様なデザイン媒体における視覚要素の配置である [6, 7, 2, 37, 22]。近年は、これらの応用領域の拡大に伴い、ユーザの意図を反映した編集可能性（controllability）を備えることが重要視され、無条件生成と条件付き生成を区別して整理する枠組みが広く用いられる。無条件生成はデータ分布からもっともらしいレイアウトを直接サンプリングする設定であり、条件付き生成はユーザが指定する制約（条件）を満たす範囲でレイアウトを生成する設定である。

応用領域（対象媒体）の多様化 レイアウト生成研究は、媒体固有の目的関数や制約の違いを背景として、複数のアプリケーション領域で並行して発展してきた。例えば、(1) **UI レイアウト**（モバイルアプリ等）は、タップ可能性や可読性、情報密度といった機能要件が強く、RICO [6] を代表とするデータセットとともに研究が進展した。(2) **ドキュメント組版・文書レイアウト**では、段組みや図表配置などの規則性が強く、PubLayNet [7] などのデータセットを中心に、解析と生成の両面から研究が蓄積された [38, 39, 40, 41]。(3) **雑誌表紙・広告・ポスター**は、視線誘導や視覚的バランスに加えて、背景画像や商品画像などキャンバスに含まれるコンテンツとの調和が重要であり、内容を考慮した（content-aware）生成が主要な論点となる [42, 43, 44, 3]。(4) **プレゼンテーションスライドや科学ポスター**は、文章・図表・セクションといった異種要素が混在し、強いマルチモーダル性を持つため、媒体特有のデータ整備と評価が重要となる [2]。

これらの媒体は共通して「要素の集合／列」を扱う一方、要素種別の語彙や制約の性質（規則性の強さ、背景画像の有無、ユーザ編集の頻度）が異なるため、条件付き生成における制約設計の整理が不可欠となる。

条件付き生成における制約の類型 既存研究では、条件付きレイアウト生成で扱う制約は大きく以下に分類できる [36]。

1. 要素種別（Gen-T）条件

生成する要素カテゴリ集合 $\{c_i\}_{i=1}^N$ (例: `title`, `text`, `image`) のみを与え, それらを配置する設定である. 形式的には, 条件 S_{type} を

$$S_{\text{type}} = (c_1, \dots, c_N) \quad (2.38)$$

とし, モデルは

$$p_{\theta}(L \mid S_{\text{type}}) \quad (2.39)$$

を学習する. 初期の GAN/VAE 系や Transformer 系の多くは, この条件を基本形として採用する [45, 30].

2. 要素種別 + サイズ (Gen-TS) 条件

要素種別に加えて, 幅・高さなどのサイズ情報 (w_i, h_i) を条件として与える設定である.

$$S_{\text{size}} = \{(c_i, w_i, h_i)\}_{i=1}^N, \quad p_{\theta}(L \mid S_{\text{size}}) \quad (2.40)$$

のように定式化され, 配置の自由度を減らすことで, 実務上のワークフロー (素材サイズが先に決まる等) に近づける [29].

3. 要素間関係 (Gen-R) 条件

「A は B の上」「A は B より左」「A は B と整列」といった関係制約を条件として与える設定である. 典型的には,

$$S_{\text{rel}} = \{(i, r_{ij}, j)\} \quad (2.41)$$

を用いて, 関係集合を満たすレイアウトを生成する [46, 14]. これは, 人間のデザイン意図を比較的解釈可能な形で入力できる利点を持つ一方, 関係集合の設計が人手に依存しやすい [47, 46].

4. 補完 (layout completion)

部分レイアウト L_{partial} を条件として, 欠損要素や欠損属性を補完する設定である.

$$p_{\theta}(L_{\text{missing}} \mid L_{\text{partial}}) \quad (2.42)$$

を学習し, インタラクティブ編集や途中状態からの生成を支援する [25].

5. 洗練 (layout refinement)

既存レイアウト L を入力として, 重なりや整列の改善など, 品質を向上させたレイアウト L' を生成する設定である.

$$p_{\theta}(L' \mid L) \quad (2.43)$$

の学習として定式化され, デザイン支援ツールとしての実用性と親和性が高い [48].

内容考慮 (content-aware) 制約：背景画像・テキスト内容との整合 上記の制約は主に「要素の幾何属性とカテゴリ」を中心に記述されるが、ポスターや広告などでは、背景画像やキャンバス内容との調和（可読性・視覚的バランス）が性能を大きく左右する。この観点は content-aware layout generation として位置づけられ、画像特徴とテキスト内容を併用して配置を決定する試みが継続的に提案されてきた [42, 3, 49]。特に PosterLlama [3] は、レイアウト要素を数値列として扱うだけでは「意味的關係」を捉えにくいという問題意識から、HTML 形式への変換により言語モデルの知識を活用し、さらに視覚内容も入力に含めることで、視覚的コンテキストを考慮したポスター生成を目指している。

本研究との接続：制約の設計から制約の生成へ 以上より、条件付きレイアウト生成は、「どの制約を与えるか」を設計して可制御性を高める方向で発展してきたと言える。一方、既存研究で条件として扱われる制約は、要素種別・サイズ・関係・部分レイアウトなど、多くの場合 人手で与えられる構造化条件である。本研究が対象とする漫画ネーム生成では、そもそも「制約」を脚本（物語）から獲得し、その制約を入力としてレイアウト／演出を生成する必要がある。したがって、本研究は、条件付きレイアウト生成が確立してきた枠組みを踏まえつつ、物語文脈から条件（制約）を内部的に自動生成する点に焦点を置くことで、既存の条件付き生成研究を一段上の「意味条件付き生成」へ拡張する位置づけにある。

2.1.5 本研究の位置づけ

本節で述べたように、レイアウト生成は、(1) ルール・最適化による制約充足としての定式化、(2) GAN/VAE による分布学習、(3) Transformer による系列モデリングと制約直列化、(4) 拡散モデルによる反復的洗練、という方向で発展し、多様な媒体（UI、文書組版、広告・ポスター等）へ応用が拡大してきた。とりわけ近年の手法は、要素間関係や部分補完などを同一枠組みで扱うことにより、編集可能性 (controllability) と生成品質を両立しつつ、実デザイン作業に近い条件付き生成を実現している [14, 13, 15]。しかし、既存研究で中心的に扱われてきた「条件（制約）」は、要素種別、サイズ、幾何関係、部分レイアウトなど、主として 幾何構造に関する明示的・構造化された条件である。これらの条件は、ユーザが外部から与える（あるいはデータから直接得る）ことを前提に設計されており、「なぜその配置になるべきか」という意味的根拠はモデルの外側に置かれがちであった。近年は LLM を用い、自然言語からレイアウト記述 (HTML/JSON 等) を生成する試みも活発化しており、これらは「言語で意図を与える」点で条件設計を大きく前進させたが、多くはポスターや UI のような、ユーザが意図・要件を明示的に記述できる状況を主に想定している。

一方で、本研究では物語（脚本）に内在する出来事・感情・関係などの推移が、コマ割りや視点、情報提示順序といったレイアウトの決定にいかに関与を与えるかという問題を取り上げており、物語文脈に内在する暗黙知的なレイアウト制約の獲得に焦点を置いている。この点において本研究は既存のレイ

アウト生成の研究とは異なる。

2.2 ビジュアルストーリーテリング

画像列から、そこに内在する出来事の連なりや文脈的關係を抽出し、言語として表現する研究は、視覚情報と言語情報を統合的に扱うマルチモーダル分野の研究の一つとして発展してきた。このような研究は、画像系列に基づく物語理解・生成という観点から、一般にビジュアルストーリーテリングとしても整理されている [8]。

本節では、その基盤技術である画像キャプション生成研究から出発し、画像系列を対象とした物語生成への拡張、さらに近年の LVLM による技術的發展までを、モデル構造および学習手法の観点から体系的に概観する。

2.2.1 画像キャプション生成

画像キャプション生成は、単一画像を入力として、その内容を自然言語文として記述するタスクであり、視覚と言語を結び付ける最も基本的な課題の一つである。深層学習に基づく初期の手法では、畳み込みニューラルネットワーク (CNN) と再帰型ニューラルネットワーク (RNN) を組み合わせたエンコーダ・デコーダ構造が標準的な枠組みとして用いられてきた [50, 51]。

CNN は入力画像 $\mathbf{I}$ を畳み込み演算によって処理し、局所的な視覚特徴から高次の意味表現を抽出する。第 l 層における特徴マップ $\mathbf{F}^{(l)}$ の各要素は、前層の特徴マップ $\mathbf{F}^{(l-1)}$ と畳み込みカーネル $\mathbf{W}^{(l)}$ を用いて、一般に次式で表される：

$$\mathbf{F}_{i,j}^{(l)} = \sigma \left(\sum_{u,v} \mathbf{W}_{u,v}^{(l)} \cdot \mathbf{F}_{i+u,j+v}^{(l-1)} + b^{(l)} \right), \quad (2.44)$$

ここで $b^{(l)}$ はバイアス項、 $\sigma(\cdot)$ は ReLU などの非線形活性化関数である。最終層の出力は、画像全体を表す特徴ベクトル $\mathbf{v} = \text{CNN}(\mathbf{I})$ として得られる。

言語生成を担うデコーダには、RNN が用いられ、時刻 t における隠れ状態 $\mathbf{h}_t$ は、直前の状態 $\mathbf{h}_{t-1}$ 、入力単語 x_t 、および画像特徴 $\mathbf{v}$ に基づいて更新される：

$$\mathbf{h}_t = \phi(\mathbf{h}_{t-1}, x_t, \mathbf{v}). \quad (2.45)$$

モデルは、正解キャプション $Y = \{y_1, \dots, y_T\}$ に対する条件付き尤度を最大化するように学習される：

$$\mathcal{L} = \sum_{t=1}^T \log P(y_t | y_{<t}, \mathbf{I}). \quad (2.46)$$

この枠組みにより、画像内の主要な物体や行為を言語化することは可能となったが、RNN に基づく

逐次生成は、長距離依存関係の保持が難しく、複雑な構造や関係性を明示的に表現する点には限界があった。

2.2.2 画像系列からの物語生成

画像キャプション生成を拡張し、複数の画像 $\{I_1, \dots, I_N\}$ を入力として一貫した物語文を生成する課題が、ビジュアルストーリーテリングとして提案された [8]。この課題では、各画像の内容記述に加え、画像間の時間的推移や因果関係を補完し、静的な描写を動的な物語構造へと統合する能力が求められる。

初期研究では、各画像から抽出された特徴ベクトル $\mathbf{v}_n = \text{CNN}(I_n)$ を入力とし、階層的に構成された RNN によりローカルな文脈と物語全体の文脈を分離して扱う手法が提案された [52, 9]。物語レベルの状態更新は、概念的には次式で表される：

$$\mathbf{h}_t^{\text{story}} = \phi_{\text{global}}(\mathbf{h}_{t-1}^{\text{story}}, \mathbf{v}_{\tau(t)}), \quad (2.47)$$

ここで $\tau(t)$ は、生成中の単語が対応する画像インデックスを表す。

しかし、RNN による逐次的な状態更新では、系列が長くなるにつれて情報が圧縮されやすく、物語全体の整合性を安定して維持することが困難であった。この課題に対し、自己注意機構を用いる Transformer アーキテクチャが導入され、長距離依存関係のモデリング能力が大きく向上した。

2.2.3 LVLM への発展

画像と言語を同時に扱う視覚言語モデルは、エンコーダ・デコーダ型の枠組みから、Transformer に基づく大規模事前学習へと発展する中で、表現能力と汎用性を高めてきた。特に、(1) 視覚特徴を系列として扱う表現の統一、(2) 視覚と言語を同一空間へ整合させる学習、(3) 生成モデルとして視覚条件付き言語生成を可能にする統合、という段階を経ることで、現在の LVLM へと至っている。以下では、この発展を主要なモデル構造ごとに整理する。

Vision Transformer による視覚表現の系列化

初期の視覚言語モデルでは、視覚特徴は CNN により抽出され、固定長ベクトルあるいは粗い空間特徴として言語側へ渡されることが多かった。しかし、物体間関係や広域文脈の統合には、局所演算を積み重ねる CNN のみでは限界があり、視覚側にも「系列としての表現」と「長距離依存を捉える機構」を導入することが重要になった。

dosovitskiy ら [53] は Vision Transformer (ViT) により、画像を固定サイズのパッチに分割し、それらを系列として扱うことで、自己注意機構により画像全体の関係性を直接モデル化する手法を提案した。

入力画像 $\mathbf{I} \in \mathbb{R}^{H \times W \times C}$ を $P \times P$ のパッチに分割し、各パッチをフラット化したベクトル $\mathbf{x}_i$ に写像する：

$$\mathbf{x}_i = \text{Flatten}(\mathbf{I}_i)W_E + \mathbf{e}_i, \quad (2.48)$$

ここで W_E は線形射影行列、 $\mathbf{e}_i$ は位置埋め込みである．これらを Transformer Encoder に入力し、自己注意機構

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right)V \quad (2.49)$$

により特徴を更新する．この枠組みにより、視覚情報も言語と同様に「系列」として扱えることが示され、後続の視覚言語統合モデルにおいて、視覚側表現を Transformer と親和的に設計する土台が整った．

対照学習による視覚と言語の表現空間統合

視覚表現を系列化できるようになったとしても、視覚特徴とテキスト特徴が「同じ意味空間」で対応づけられていなければ、両者を一貫した形で扱うことは難しい．この課題に対し、大量の画像・テキスト対を用いて対応するペアは近く、対応しないペアは遠くなるように学習する対照学習が有効であることが示された．

視覚と言語を同一の意味空間に埋め込む手法として、CLIP [54] や ALIGN [55] が提案された．これらのモデルでは、画像エンコーダ f_{img} とテキストエンコーダ f_{text} を独立に学習し、対応する画像・テキスト対 $(\mathbf{I}_i, \mathbf{T}_i)$ の埋め込み類似度を最大化する．

正規化された埋め込みを

$$\mathbf{v}_i = \frac{f_{\text{img}}(\mathbf{I}_i)}{\|f_{\text{img}}(\mathbf{I}_i)\|}, \quad \mathbf{t}_i = \frac{f_{\text{text}}(\mathbf{T}_i)}{\|f_{\text{text}}(\mathbf{T}_i)\|} \quad (2.50)$$

とすると、学習目的は InfoNCE 損失として

$$\mathcal{L} = - \sum_i \log \frac{\exp(\mathbf{v}_i^\top \mathbf{t}_i / \tau)}{\sum_j \exp(\mathbf{v}_i^\top \mathbf{t}_j / \tau)} \quad (2.51)$$

で与えられる．

この枠組みは、ゼロショット分類や検索において強力であり、「視覚と言語の意味対応」を大規模データから獲得できることを示した．一方で、CLIP/ALIGN は本質的に alignment の学習であり、物語生成のような 長文生成・推論を伴う生成的タスクに対しては、別途「生成モデルとしての統合」が必要になるという課題が残った．

クロスモーダル注意による生成モデル

生成的タスクに対応するには、視覚表現を参照しながら言語を逐次生成できることが重要となる．この方向性では、視覚特徴を言語デコーダへ条件として与え、言語側の生成過程で必要に応じて視覚情報

を参照する設計が採用されてきた。

生成タスクへの対応として、視覚特徴を言語生成に条件付けるモデルが提案された。BLIP [56] や Flamingo [57] は、視覚エンコーダと LLM を結合し、クロスモーダル注意機構によって視覚情報を言語生成に注入する。

言語デコーダにおけるクロスアテンションは、

$$\text{CrossAttn}(Q, K_V, V_V) = \text{softmax}\left(\frac{QK_V^\top}{\sqrt{d}}\right) V_V \quad (2.52)$$

として定義され、クエリ Q は言語トークン、キー・バリュー (K_V, V_V) は視覚特徴から構成される。この構造により、モデルは画像内容を参照しながら文章を生成でき、画像キャプション生成や VQA といった生成タスクが大きく前進した。

ただし、クロスアテンションで「視覚を条件として参照する」設計では、視覚と言語が依然として異なる処理経路に分かれており、多段推論や長い文脈統合の観点では、より統一的な表現・処理が望まれるようになった。

統合型 LVLM への発展

こうした背景から、視覚特徴を言語トークンと同等の単位へ変換し、単一の Transformer により処理する統合型モデルが提案されている。この設計は、視覚と言語の相互作用を「クロスアテンションでの参照」に限定せず、自己注意の枠組みで同等に扱える点に特徴がある。

近年では、視覚特徴を言語トークンと同等に扱い、単一の Transformer により処理する統合型 LVLM が提案されている。LLaVA [58] などは、視覚エンコーダで得た特徴 $\mathbf{V}$ を、線形射影により言語埋め込み空間へ写像し、

$$\tilde{\mathbf{V}} = \mathbf{V}W_P \quad (2.53)$$

として得られた視覚トークン列を、テキストトークン列と連結することで、

$$\mathbf{X} = [\tilde{\mathbf{V}}_1, \dots, \tilde{\mathbf{V}}_M, \mathbf{T}_1, \dots, \mathbf{T}_N] \quad (2.54)$$

という単一系列として入力し、自己注意により統合的に処理する。この枠組みは、視覚と言語を跨ぐ推論や長い文脈統合を促進し、物語生成や複雑な指示理解といった高次タスクにおける性能向上につながっている。

2.2.4 Visual Prompting

LVLM は、自然画像を対象とした事前学習により、画像理解・推論・言語生成において高い性能を示している。一方で、特定ドメインに固有の視覚構造や記号体系を持つ入力に対しては、モデルのパラ

メータを直接更新する fine-tuning を行わずに適応させることが求められる場合も多い。

このような背景のもと、入力の与え方を工夫することでモデルの推論挙動を制御する枠組みとして、**Prompting**、およびその視覚領域への拡張である **Visual Prompting** が注目されている。本節では、Prompting の概念的背景から、視覚タスクにおける Visual Prompting の発展に付いて整理する。

Prompting と In-Context Learning

Prompting は、LLM に対して、明示的なパラメータ更新を行うことなく、入力文（プロンプト）の設計によってタスク遂行を誘導する手法である。特に GPT-3 [59] によって示された **In-Context Learning** は、少数の例示や指示文を入力に含めるだけで、新たなタスクに適応可能であることを明らかにした。

数理的には、Prompting は、モデルが学習済みの条件付き確率分布

$$P(y \mid x) \quad (2.55)$$

に対し、追加の文脈 p を与えることで、

$$P(y \mid x, p) \quad (2.56)$$

として再条件付けを行う操作とみなすことができる。ここで x は入力、 p はプロンプト、 y は出力である。この枠組みは、パラメータ空間ではなく入力空間を操作することで推論挙動を制御する点に特徴がある。

視覚タスクにおける Prompting の拡張

Prompting の概念は、言語モデルに限らず、視覚タスクにも拡張されてきた。その初期例として、セグメンテーションや検出において、点、バウンディングボックス、スクリブルなどの人為的な視覚的手がかりを入力として与える研究が挙げられる [60, 61]。

これらの手法では、視覚的手がかり p_{vis} を追加することで、推論対象領域を明示的に制約し、

$$P(y \mid x) \rightarrow P(y \mid x, p_{\text{vis}}) \quad (2.57)$$

という条件付き推論を実現している。この考え方は、モデルの能力そのものを変更するのではなく、探索空間を縮小するという点で、Prompting と本質的に共通している。

Visual Prompting の定義と特徴

Visual Prompting は、この入力操作の考え方を、視覚言語モデルに体系的に適用する枠組みである。Chen ら [62] は、Visual Prompting を「モデルのパラメータを固定したまま、入力画像に視覚的変換を施すことで、下流タスクへの適応を実現する手法」と定義している。

代表的な Visual Prompting の形式には、以下が含まれる：

- 画像へのマーキング（枠線、番号、強調表示）
- マスクやオーバーレイの付与
- 空間的構造を明示する補助情報の重畳

これらは、画像 x に対して視覚的プロンプト p_{vis} を付与し、

$$x' = \mathcal{T}(x, p_{\text{vis}}) \quad (2.58)$$

という変換を施した上で、モデルに入力する操作と捉えられる。ここで $\mathcal{T}$ は視覚的変換操作である。

LVLMM における Visual Prompting の役割

LVLMM は、視覚トークンとテキストトークンを統合的に処理する能力を持つ一方、入力画像内のどの情報を推論に用いるべきかについては、必ずしも明示的な誘導を持たない。そのため、複雑な構造や非自然画像的な表現を含む入力では、推論が不安定になることが報告されている [63]。

Visual Prompting は、この問題に対し、モデルの注意機構が参照すべき情報を視覚的に明示するという役割を果たす。すなわち、Visual Prompting は、LVLMM の能力を拡張するというよりも、既存の能力を適切に引き出すためのインターフェース設計として位置づけられる。

本研究における位置づけ

ビジュアルストーリーテリング研究は、画像系列を入力として、その内容に内在する出来事の推移や文脈関係を捉え、自然言語による物語文を生成することを目的として発展してきた。近年では、大規模視覚言語モデル（LVLMM）の導入により、長距離依存関係のモデリングや高次の意味推論が可能となり、生成される物語文の一貫性や表現力は大きく向上している。

このような性能向上を背景として、ビジュアルストーリーテリングの出力は、単に物語として自然であることに加え、出来事、登場人物、役割分担、関係性といった情報をより明示的に整理した形で扱うことが可能になってきた。すなわち、物語文を出来事や演出の単位に分解可能な構造化表現として捉える視点が、現実的な選択肢として成立しつつある。

本研究は、このような技術的進展を踏まえ、ビジュアルストーリーテリングを「物語文の生成」ととどめるのではなく、後段の制作工程と接続可能な構造化中間表現の獲得へと拡張する立場を取る。特に漫画という媒体において、物語理解とレイアウト・演出設計が密接に結び付いている点に着目し、LVLMM を用いて抽出した物語情報および演出情報を、脚本やネーム生成へ接続する枠組みを構築する。

2.3 漫画を対象とした研究

漫画は、コマ割りによる時間・空間の離散化、吹き出し内テキストの高密度な配置、誇張表現や記号表現（漫符）など、自然画像とは異なる視覚言語体系の上に成立する媒体である。そのため、漫画を対象とした画像理解・物語理解研究では、一般物体認識や自然画像キャプション生成で前提とされる「写実的外観」「連続的時間」「単一視点」を仮定できず、媒体固有の構造を明示的に扱う必要がある。

本節では、(i) 漫画を対象とする代表的データセット、(ii) 漫画読解が難しい理由（多段タスク構造）と、それを評価する近年のベンチマーク、の順に整理し、本研究が扱う「脚本に基づくネーム生成」へと接続する。

2.3.1 漫画理解を支えるデータセット

漫画理解研究を推進する上で、コマ・吹き出し・テキスト・キャラクターといった構造の注釈付きデータは不可欠である。とりわけ漫画は、作品・作者・掲載誌により画風や記号表現が大きく変化するため、多様なスタイルを含むデータ整備は、汎用的な読解能力の獲得と評価の前提となる。

eBDtheque Guérin ら [64] による eBDtheque は、合計 100 ページの漫画画像からなるデータセットである。例えばバージョン 3 では、100 ページに対し、850 のコマ領域、1081 のセリフ吹き出し領域、4,693 行のセリフ文字列、1,620 のキャラクター描画といった粒度で整備されている。

COMICS 大規模データとしては、Iyyer ら [65] の *COMICS* が代表的であり、これは 120 万以上のコマに対して自動のテキスト認識を付与したデータセットである。同データは、複数パネル文脈に基づくテキストや視覚の穴埋めタスクを通じ、「コマ間の欠落を推論して物語を接続する」能力を評価するベンチマークを築いている。

Manga109Dataset 日本語漫画に特化した代表的データセットとして、Matsui ら [11] による Manga109Dataset がある。Manga109Dataset は、1990 年代から 2000 年代にかけて出版された日本の商業漫画 109 冊を収録し、著作者許諾のもと研究利用を目的に公開されている合計 21,142 ページからなる大規模な漫画画像データセットである。少年漫画・少女漫画・青年漫画など異なるジャンルが網羅的に収録され、特定の作品・作家・画風に依存しない汎用的な漫画理解の獲得に適したデータであるといえる。各ページには複数のアノテーションが付与されており、キャラクター領域、セリフ領域、コマ領域のバウンディングボックスに加え、セリフ文字列や話者 ID など整備されている。図 2.1 に Manga109Dataset の例を示す。

Manga109 派生データ：物語文・属性注釈への拡張 Manga109 を基盤として、擬音語や漫符など漫画特有表現に関する研究も進められており、COO (Comic Onomatopoeia Dataset) [66] は、漫画に描画された擬音語領域のデータセットを提供し、その検出が漫画固有の課題として困難なものであるこ




図 2.1: Manga109Dataset [11] に含まれる漫画画像の例 (『ARMS』© 加藤 雅基／東京三世社)

とを指摘している。

Manga109Dialog [67] は, Manga109 におけるセリフと話者領域の関係性を紐づけたデータセットであり, 従来の「セリフに最も近い人物が話者」という規則ベースが複雑な例で破綻し得ることを指摘している. コマの読解順序といった漫画固有の構造を考慮しなければ, LVLMM でも安定した推定が難しいことが示唆された.

また近年では, ページ画像に対して物語文を付与する方向の整備も進んでおり, Manga109Story は Manga109 の一部に対してストーリー記述データを構築する試みとして報告されている [68]. ただし, Manga109Story の物語文は散文的記述であり, 本研究が意図する実制作上の「脚本形式の記述」とは目的・粒度が異なる点に留意が必要である.

2.3.2 漫画読解の多段構造と評価ベンチマーク

近年の LVLMM の発展により, 自然画像を対象とする VQA やキャプション生成, 画像推論は著しい性能向上を示している. 一方で漫画読解は, 二次元レイアウト構造と文字情報と物語推論が強く結合しており, 単一画像・単一視点を前提とする一般的な視覚理解の枠組みでは扱いにくい. とりわけ, 漫画を「読む」行為は単一タスクでは完結せず, 複数の処理を段階的に積み上げる必要がある点に本質的な難しさがある.

多段タスクとしての漫画読解 漫画読解に必要な処理は、典型的には以下のサブタスク群として整理できる。これらは独立ではなく、上流の誤りが下流に伝播するため、全体としての頑健な読解を難しくする。

- テキスト検出と意味理解：セリフや効果音などの言語情報を抽出し内容を解釈することは、物語内容を把握するうえで漫画の読解に不可欠である。
- 読解順序の推定：テキスト情報は単体ではなく物語の流れの中で意味を持つため、会話の流れや因果関係を正しく捉えるうえで読解順序を推定することは漫画の読解に不可欠である。
- 話者推定・対応付け：各発話を適切な話者へ対応付けられなければ、意図された人物関係や出来事理解が崩れるため、話者推定は漫画の読解に不可欠である。
- キャラクター同一性認識：デフォルメや部分遮蔽が頻発する条件下でも同一キャラクターを同定・追跡することは、行動や視点の連続性を把握するうえで漫画の読解に不可欠である。

このように漫画読解は、複数のサブタスクの同時要求として理解でき、LVLM の進歩にもかかわらず依然として困難なタスクとして残っている。

漫画理解におけるベンチマークの整備 このような漫画の読解困難性を示す定量的な死票として近年では漫画理解に必要な能力を細分化し評価するベンチマークが整備されつつある。MangaUB [69] は、単一パネルの内容認識に閉じない評価を目指し、複数パネルをまたいだ理解を含む多面的な評価枠組みを提示している。これにより、最新の LVLM のモデルでも、認識としては強いが、複数パネルにまたがる感情・情報の理解は難しいといった弱点を可視化している。

より包括的な評価の方向として、CoMix [63] は、検出（パネル・人物・テキスト等）、対応付け（話者同定・キャラクター再同定等）、読解順などの計算的タスクに加え、「誰が何を言ったか」を順序付きで書き起こすような統合タスクまで含む総合ベンチマークを提示している。ベースライン評価では LVLM と人手との差が大きいことが報告されており、漫画の読解が依然として困難な課題であることを示した。

プロンプト設計による漫画読解の工夫 一方で、このギャップを直接埋める方向として、既存 LVLM を追加学習で作置き替えるのではなく、推論時の工夫により漫画理解を押し上げる試みも現れている。ComiCap [70] はその代表例であり、既存の LVLM を用いてコミックパネルの dense captioning を生成するパイプラインを提案している。同研究は、単に自由文キャプションを生成するのではなく、出力を属性を保持した記述へと誘導し、さらに記述と領域の対応付けを行い漫画の内容理解を段階的に外在化する方針を示している [70]。この観点は、漫画の読解における多段タスク構造において何を出力すべきかを段階的に明示し、途中表現を構造化して積み上げることで全体の頑健性を高める戦略として重要である。

本研究との接続 以上より、漫画の読解は多段タスクであり、特に複数パネルの意味的な整序を伴う統合やキャラクター認識、セリフなどの結びつきにおいて依然として困難なタスクであるといえる。本研究はこの課題を前提として、LVLM を基盤にしつつ、(1) キャラクター識別子 (ID) の付与による同一性の明示、(2) 読解順序の明示的付与、(3) 段階的な問い・入力設計 (Visual Prompting) による中間表現の構造化、を通じて、多段構造の誤り伝播を抑えながら、漫画画像から物語文および演出情報を抽出し構造化することで脚本に基づくネーム生成へ接続することに取り組んだ。本研究が対象としたのは、Manga109Dataset であり、これは、そのジャンルの多様性から汎用性の高いデータの構築およびモデルの学習が可能であることを考慮して選択したものである。

第 3 章 Manga109ScriptDataset

本章では，本研究の第一段階において構築した，漫画画像に紐づく脚本データセット Manga109ScriptDataset について，その構築手法や統計量，評価アノテーション手法の詳細を述べる．

序論で定義したとおり，本研究では漫画の「ネーム」を，幾何学的な「要素配置 (Layout)」と「演出情報 (Direction)」を統合した，物語と作品とを接続する中間表現として位置づける．このネームを物語に基づいて生成する取り組みに先立ち，第一段階では，物語としての「脚本 (Script)」と「要素配置 (Layout)」の対応関係の学習に焦点を当て，Manga109ScriptDataset を構築した．

構築においては，漫画画像を，OpenAI API を介して GPT-4o [71] に入力し，描画内容を脚本として記述させる手法を基本方針とした．本章では，この生成プロセスにおいて，モデルが複雑な文脈を正確に理解するために導入した画像加工やチャットフローの活用といった具体的な技術詳細について記述する．

本章の構成は以下の通りである．まず 3.1 節では，本データセットの基本設計である脚本形式の定義について述べる．続く 3.2 節では，正確な脚本生成を可能にするため LVLM のキャラクター認識精度の向上を図り実装した Visual Prompting について述べる．3.3 節では，画像間にまたがる連続的な文脈理解の精度を高めるため設計した，LVLM とのチャットフローについて示す．3.4 節では，構築したデータセットの統計量を示し，最後に 3.5 節では，人手によるアノテーションに基づく脚本の品質評価手法と，その結果について論じる．

3.1 脚本形式の定義

本研究において採用した物語文の形式は，日本の映像制作現場において標準的に用いられる脚本形式に準拠する．脚本は，テキストから視覚的イメージを具体化することを主目的として設計された記述様式であり，その「視覚化のための物語文」というフォーマットは，ネーム生成というタスクにおいて親和性が高い．本研究では，将来的な制作支援応用を見据え，プロの作家や編集者が違和感なく扱える実用性を考慮し，日本国内で標準的な形式をそのまま採用した．その形式は，以下の 3 つの主要な構成要素から成る．

1. 柱: 物語の場面・場所を示す情報. 行頭に記号「○」を付記し, その後に「場所」や「時間帯」を記述する (例: ○ 公園・昼).
2. ト書き: キャラクターの動作, 表情, 視線, および周囲の環境音や状況説明を記述する文章. 視認性を高めるため, 全角 3 文字分の字下げを行って記述する. これは, コマ割りや構図, カメラワークを示唆する重要な情報源となる.
3. セリフ: キャラクターの発話内容. 「話者名『セリフ内容』」の形式で記述する.

本データセットの構築においては, プロンプトに形式に関する詳細な説明を加えるとともに, Few-shot Learning の形で数例提示することで, モデルからの出力を脚本形式に制御した. 実際にプロンプトに含めた Few-shot の例を図 3.1 に示す.

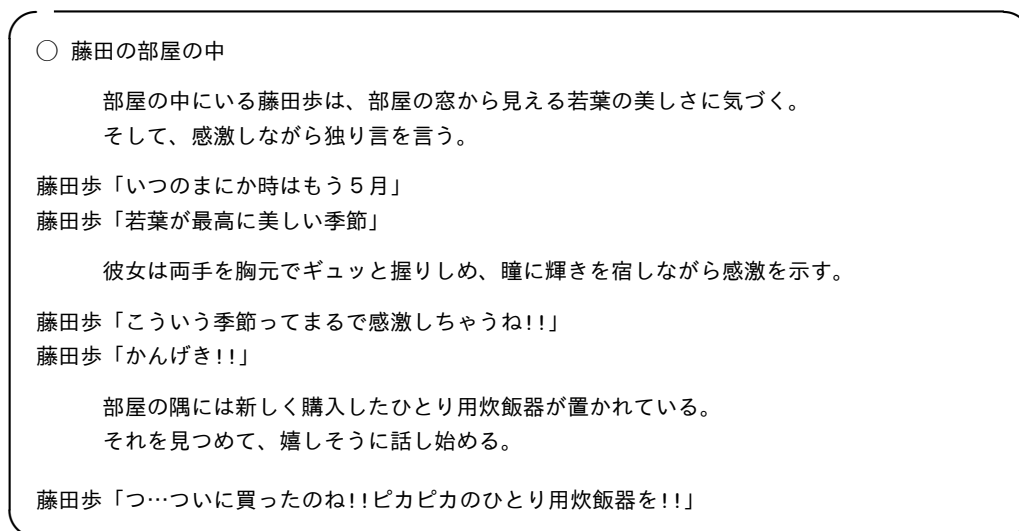


図 3.1: 脚本生成プロンプトにおける Few-shot の例

3.2 Visual Prompting

本節では, LVLM の画像認識能力を補助し, 正確な脚本生成を実現するために導入した Visual Prompting について述べる.

Manga109ScriptDataset の構築において, 最も重要な要件の一つは, 生成される脚本内で動作主や話者を正確に特定することである. しかし, 第 2 章で述べた通り, 漫画画像は白黒の線画表現であり, しばしばキャラクターが著しくデフォルメされるといった独自のドメイン特性を持つため, GPT-4o などの最新 LVLM であっても, そのまま適用するだけでは正確な認識, 特にキャラクターの識別は十分になされない [63]. そこで本研究では, 登場人物を取り違え, 物語の整合性を著しく損なうハルシネーションを抑制するための手段として, 画像内に視覚的な手がかりを直接埋め込む Visual Prompting を採用した. キャラクターの顔を色のついた円で囲い, 視覚的な識別補助を与える手法である.

Manga109Dataset には、キャラクターの顔領域を示す Bounding Box が付与されており、各領域は作品内で一意のキャラクター ID と紐付いている。本研究ではこの情報を利用し、以下の手順で画像に加工を施した。まず、作品内に登場するキャラクター ID ごとに、HSV 色空間上で等間隔となるよう識別性の高い色を動的に割り当てる。次に、各顔領域に対して、割り当てた色で顔を囲う円を描画した。円の色とキャラクター名を紐づける情報をプロンプト内で提示することで、キャラクターの識別を促した。図 3.2 に加工後の画像を示す。



図 3.2: Visual Prompting の例 (漫画:『犯罪交渉人 峰岸英太郎』©記伊 孝/講談社).

このアプローチは、Shtedritski ら [12] の手法を漫画ドメイン向けに適応させたものである。この処理により、LVLMM はデフォルトされた顔の識別といった高難度なタスクを色の識別という単純な視覚タスクへ置き換えることが可能となる。結果として、複雑な線画や類似したキャラクターが混在するシーンにおいても、モデルは視覚的アンカーを手がかりとして強固にキャラクターの識別能力を向上させた。

3.3 画像間文脈理解のためのチャットフロー

本節では、ページ間の文脈を考慮し、物語の一貫性を担保するために設計したチャットフローについて述べる。

3.3.1 整序したセリフの入力

前節で述べた Visual Prompting に加え、モデルがキャラクターの同一性ととも物語の文脈を正しく理解するためには、正確なテキスト情報とその読み順が不可欠である。そこで本研究では、以下の 2 つの外部情報を利用し、漫画画像内の一連のセリフを整序した形でプロンプト内に提示した。

1. セリフテキストと話者名: 各フキダシ内のテキスト内容およびその話者名については、セリフと話者キャラクターが対応付けられた既存のデータセット Manga109Dialog [67] を利用した。
2. セリフの順序: コマおよびフキダシの読み順決定には、Sachdeva ら [72] により提案された Manga Whisperer の読み順ソートアルゴリズムを採用した。

読み順ソートの概要: Manga Whisperer における読み順ソートは、各コマおよびフキダシのバウンディングボックス情報に基づき、コマとセリフを紐づけ、2 つのコマの間に垂直線、水平線が引けるまでコマを縮小していき、引けた段階でそれらの読み順を決定するルールベース手法である。

我々の予備実験においては、GPT-4o に画像のみを与え読み順を推定させたところ、サンプリングした 109 ページ中、正解したのはわずか 26 ページに留まった。対照的に、ルールベースの読み順ソートアルゴリズムを用いた場合、96 ページにおいて正確な順序が得られた。より正確に定められた順序を明示的に与えることで、読み順推定に対する課題を補完し、脚本生成の精度を向上させた。

3.3.2 文脈理解のための 3 段階のインタラクション

複数ページにわたる連続した物語を矛盾なく記述するため、本研究では GPT-4o に対して単純な 1 往復の指示を与えるのではなく、各ページ i の生成において以下の 3 つのコンポーネント (α, β, γ) から成る構造化されたインタラクションプロセスを構築した。上述の内容にある事前整備した情報は、このプロセスにおいて適切な組み合わせのもと利用した。

- $\alpha(i)$: 一連のセリフを用いた大域的文脈の理解

脚本生成の対象となるページ i が含まれるエピソード全体の一連のセリフをモデルに入力するインタラクション。モデルからの応答を「完了」の肯定的応答としてシミュレートすることで、チャット内における文脈理解状態を確立させた。

- $\beta(i)$: ページ i の脚本生成

脚本を生成させるインタラクション。入力として、「Visual Prompting を施したページ i の画像」、「ページ i の一連のセリフ」、および「直前のステップ $\gamma(i-1)$ で生成された物語の要約」を与える。過去の要約を与えることにより、前ページまでの展開を踏まえた一貫性のある物語の生成を促進する。

- $\gamma(i)$: 文脈情報の要約と更新

次ページ $i + 1$ の生成に備え、ここまでの物語の展開を要約させるインタラクション。生成された脚本と対話履歴に基づき、物語の現状を要約として出力させ、これを次のステップ $\beta(i + 1)$ の入力として利用する。

上記 3 つのインタラクションを組み合わせ、各ページ i の脚本生成を以下のシーケンスにより実行した。ここで、矢印は同一チャットセッション内での対話の遷移を示している。

- 先頭ページ ($i = 1$) の場合

過去の文脈が存在しないため、以下の順序で実行する。

$$\alpha(1) \rightarrow \beta(1)$$

- 第 2 ページ以降 ($i \geq 2$) の場合

直前のページの生成結果を履歴として保持しつつ、以下の順序で実行する。

$$\alpha(i) \rightarrow \beta(i - 1) \rightarrow \beta(i)$$

このように、脚本生成 $\beta(i \geq 2)$ においては常に一つ前のやり取りを履歴に残し、物語の一貫性を保持する工夫とした。また、次ページへの文脈受け渡し用として要約を生成する際は、以下のシーケンスへと拡張した。

- 先頭ページ ($i = 1$) の場合

$$\alpha(1) \rightarrow \beta(1) \rightarrow \gamma(1)$$

- 第 2 ページ以降 ($i \geq 2$) の場合

$$\alpha(i) \rightarrow \beta(i - 1) \rightarrow \beta(i) \rightarrow \gamma(i)$$

各作品に対し、この一連のインタラクションを最終ページまで反復的に適用することで、Manga109ScriptDataset の全データを構築した。入力とした漫画画像と生成された脚本データの一例を図 3.3 に示す。

3.4 データセットの統計量

上述した方法により、本研究では、109 作品・計 19,555 ページに対し、約 2 万 7 千件の柱、約 14 万件のト書き、および約 13 万件のセリフを含む脚本データを構築した。その詳細な統計量を表 3.1 に示す。

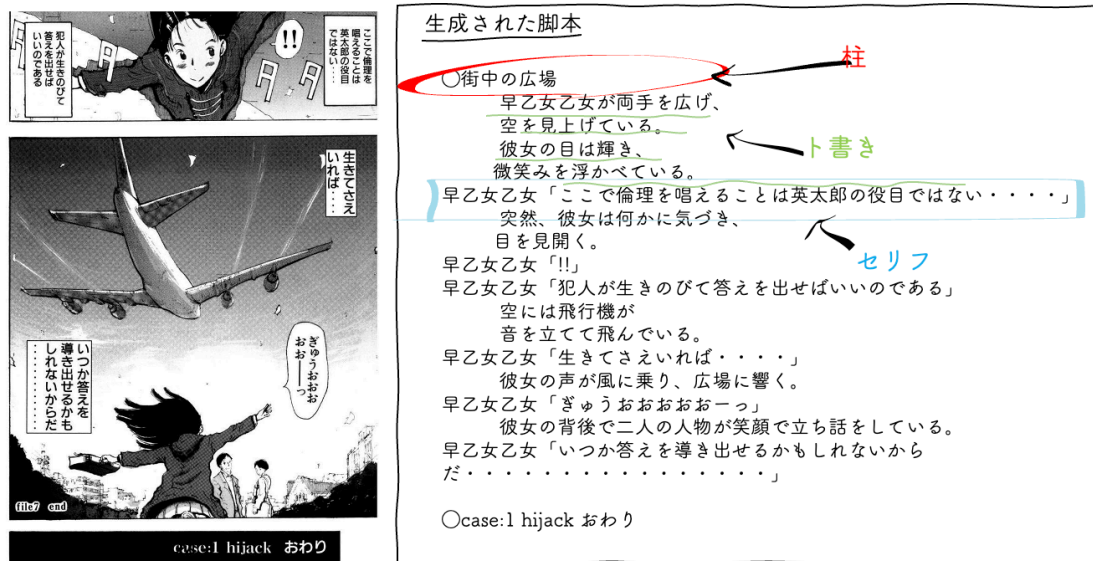


図 3.3: 入力に利用した漫画画像 (左:『犯罪交渉人 峰岸英太郎』©記伊 孝/講談社) と生成された脚本データ (右) の例。

表 3.1: Manga109ScriptDataset の統計量。

要素	総数	平均 (/頁)
レイアウト要素		
総ページ数	19,555	—
コマ数	103,850	5.31
キャラクターの描画数	157,865	8.70
ページごとのキャラクターの種類数	60,812	3.11
フキダシ数	146,549	7.49
話者種類数	55,778	2.85
脚本要素		
柱	26,931	1.38
ト書き	138,890	7.04
セリフ	134,901	7.10
総文字数	6,703,063	342.78

3.5 品質評価

本研究では、構築された脚本データの品質を検証するため、人手による評価アノテーションを実施した。

3.5.1 評価死票

一般的な画像キャプションの生成タスクとは異なり、本研究で生成する脚本には正解データが存在しない。また、脚本として漫画画像の物語を抽出することは、単純な画像の言語化ではなく、前後の文脈的な整合性やより複雑な状況の記述が求められるため、BLEU [73] や CIDEr [74] といった既存の自動評価指標の適用は困難である。そこで本研究では、各要素ごとに評価単位を定義し、人手による正誤判定に基づいて算出される 5 つの指標を用い、脚本データの品質を定量的に評価した。

1. 柱の再現率: 対象ページの漫画画像に含まれる場所・シーンの数を分母とし、それらが生成された脚本内で「柱」として正しく言及されている数を分子として算出する再現率。各ページごとに算出した値を全ページで平均した
2. 柱の適合率: 生成された脚本内の各「柱」を評価単位とし、その記述が対象ページの漫画画像に実際に描かれている場所・シーンに対応しているかを人手で正誤判定した。正と判定された柱の割合を柱の適合率とし、その平均値を用いた。
3. ト書きの適合率: 各ト書きを評価単位とし、対象ページに対応するト書きと、ランダムに抽出した他ページのト書きを混在させた候補集合を提示し、評価者が正しく対象ページのト書きを識別できたかを判定した。ト書きごとの正答率を算出し、その平均値をト書きの適合率とした。
4. 文脈外ト書きの検出精度: 他ページから混入させた無関係なト書きを評価単位とし、それらを対象ページのものではないと正しく棄却できた割合を算出した。
5. セリフの再現率: 対象ページの漫画画像内に存在するフキダシ中のセリフ数を分母とし、それらが生成された脚本内に漏れなく転記されている数を分子として算出する再現率。

3.5.2 評価の実施設定と結果

評価データとして、Manga109ScriptDataset に含むの各作品から物語の連続性を確保する目的で、連続した 10 ページをランダムに抽出し、合計 1,000 ページを評価対象とした。この 1,000 ページを 500 ページごとの 2 セットに分割し、計 6 名の評価者が 2 グループに別れ評価を行った（各ページにつき 3 名が重複して評価を実施）。評価者はアノテーション企業に所属する専門のアノテーターであり、事前に脚本形式および評価指標の説明を受けた上で評価を行った。

評価の結果、各指標の平均スコアは以下の通りとなった。

柱の再現率および適合率がいずれも 0.8 前後の値を示したことは、複数のコマを含む漫画ページ全体から、場面としての場所や時間帯、あるいは場面転換といった大域的な文脈情報が一定程度一貫して抽出されていることを示唆している。漫画画像から場面の場所を認識する関連研究として、Ikuta ら [75] による MangaUB では、単一のコマ画像を入力に屋内・屋外を判別するタスクが設定されている。このタスクにおいては、LVLM が高い性能を示すことが報告されている。本研究で扱う柱の抽出は、この

表 3.2: 人手による品質評価の結果

評価指標	
柱の再現率	0.793
柱の適合率	0.838
ト書きの適合率	0.664
文脈外ト書きの検出精度	0.910
セリフの再現率	0.988

ような場面認識と関心を共有しつつも、単一コマではなく複数のコマを含むページ全体を対象とし、さらにその結果を脚本として言語化する点で、前提とする情報の粒度や統合の条件が異なる。そのような設定の違いを踏まえた上で、柱に関する指標が一定の値を示したことは、ページ全体を対象とした場面理解が大きく破綻することなく行われていることを示す結果といえる。

一方で、ト書きはキャラクターの動作や視線、周囲の状況といったより細粒度な情報を記述する要素であり、ページ内外の文脈理解や状況把握をより強く要求するため、柱と比較して評価値が低くなる傾向が見られた。この点は、複数コマにまたがる理解や状況把握が単純な認識タスクに比べて困難であることを指摘した既存研究 [75] とも整合的である。それにもかかわらず、ト書きの適合率が一定水準を維持していることは、脚本としての状況理解が致命的に破綻することなく行われていることを示唆している。

これらの結果は、Visual Prompting によるキャラクター識別の補助や、セリフ情報を明示的に整序して与えるチャットフロー、ならびにページ間文脈を保持するインタラクション設計といった、本研究で導入した複数の工夫が、脚本生成時の文脈理解を安定化させた可能性を示すものと考えられる。一方で、特にト書きに関しては、より高精度な状況理解を実現する余地が依然として残されており、今後の課題である。

本節の評価結果から、本研究で構築した脚本データは、後続のモデル学習に用いる基礎データとして、実用上十分な整合性と妥当性を有していると判断し、本データセットを用いて、脚本に基づくレイアウト生成モデルの学習および検証を行った。

第4章 脚本に基づく漫画のレイアウト生成

本章では、前章で構築した Manga109ScriptDataset を用い、脚本に基づいて漫画ページ内のレイアウトを生成する手法 (Script2Layout) について述べる。ここで扱うレイアウト生成とは、コマ、キャラクター、およびセリフを要素とし、それらの平面上での配置をページ単位で予測するタスクである。

本研究における漫画のネーム生成は、脚本に基づいてレイアウトおよび演出情報を生成する問題として位置づけている。そのうち本章は、物語内容を含む脚本情報が、要素配置という幾何学的なレイアウト決定に対してどの程度有効に機能するかを検証することを目的とする。これは、後続章で扱う演出情報を含むネーム生成に先立ち、脚本情報を条件とした生成モデルの基礎的な挙動を明らかにする段階に相当する。

本章の構成は以下の通りである。まず 4.1 節では、脚本に基づく漫画レイアウト生成タスクの問題設定を定式化する。次に 4.2 節において、脚本情報を入力に利用するレイアウト生成手法 (Script2Layout) の概要を述べる。4.3 節では、使用したデータセット、評価指標、および比較手法を含む実験設定について説明する。続いて 4.4 節で定量的な評価および定性的な評価の結果を示し、これらについて考察する。

4.1 漫画のレイアウト生成における問題設定

本章では、脚本に基づく漫画レイアウト生成を、漫画ページ内に配置される各要素の二次元平面上での位置と大きさを予測する問題として定式化する。ここで扱うレイアウト要素は、キャラクター、セリフのフキダシ、およびコマであり、これらはいずれも漫画のネームの中で物語内容に応じて配置が設計される主要な構成要素である。

漫画ページ上のレイアウトは、 $N \in \mathbb{N}$ 個の要素からなる集合として表され、これを

$$\ell = \{(c_1, \mathbf{b}_1), \dots, (c_N, \mathbf{b}_N)\} \quad (4.1)$$

と定義する。ここで c_i は i 番目の要素を識別するカテゴリを表し、本研究においては、キャラクター、セリフのフキダシ、コマを基本要素種別とし、さらにキャラクターとセリフにおいてはそれらがどのキャラクターに属するかという区別まで含んだ識別子として定義される。つまり、 c_i は、要素の基本種

別とキャラクター種別に基づいて定義されるカテゴリ集合 $\mathcal{C}$ の要素であり, $\mathcal{C}$ は

$$\mathcal{C} = \{\text{panel}\} \cup \{\text{character}_k\} \cup \{\text{speech}_k\} \quad (4.2)$$

と表されるものとする. ここで character_k はページ内に登場する第 k 番目のキャラクターに対応するキャラクター要素を表し, speech_k は同キャラクターによる発話に対応するセリフのフキダシ要素を表す. $\mathbf{b}_i$ はその要素に対応するバウンディングボックスであり, ページ平面上における位置と大きさを表す矩形領域として定義される.

以上の定義のもと, 本研究におけるレイアウト生成タスクは, 要素数 N と対応するカテゴリ集合 $\{c_i\}_{i=1}^N$ が与えられたとき, それぞれの要素に対応するバウンディングボックス $\{\mathbf{b}_i\}_{i=1}^N$ を予測する問題として定式化される. この設定は, 漫画制作において, 物語の決定とともに各ページに登場するキャラクターやセリフが定まり, それらをどのように配置するか設計するネーム作成の工程に対応している.

既存のレイアウト生成手法では, このようなカテゴリが事前に記号的なラベルとして与えられることを前提としていた. これに対し本研究では, キャラクター名やセリフ内容といった脚本に含まれる言語情報を入力に利用し, それらを条件としてレイアウトを生成する設定を採用する. このように, 物語内容を含む脚本情報を条件としたレイアウト生成を扱うことで, 物語的意図がページ上の配置決定にどのように反映され得るかを検証する.

以下では, この問題設定に基づき, 脚本情報を直接入力として利用するレイアウト生成手法 (Script2Layout) について述べる.

4.2 脚本に基づく漫画のレイアウト生成手法

本節では, 脚本情報を条件として漫画ページのレイアウトを生成する手法 Script2Layout の概要を述べる. 図 4.1 に, 本研究で扱う手法の全体像を示す.

本研究における Script2Layout は, 脚本に基づく漫画レイアウト生成タスクに対し, LLM を教師あり学習によりファインチューニングする形で構築した.

前節で定義した通り, 漫画ページのレイアウトは, カテゴリとバウンディングボックスの組からなる集合

$$\ell = \{(c_1, \mathbf{b}_1), \dots, (c_N, \mathbf{b}_N)\} \quad (4.3)$$

として表される. 本研究では, ページ単位の脚本を自然言語列 S とし, 脚本に基づく漫画のレイアウト生成タスクを, S に対応するレイアウト ℓ を生成する条件付き生成問題として定式化する. すなわち, 脚本 S が与えられたもとの, レイアウトを構成する各要素のカテゴリに対応した配置情報を出力する写像を学習する.

LLM による生成および学習を可能にするため, レイアウト集合 ℓ に含まれる各要素 $(c_i, \mathbf{b}_i)$ を, あ

Script2Layout

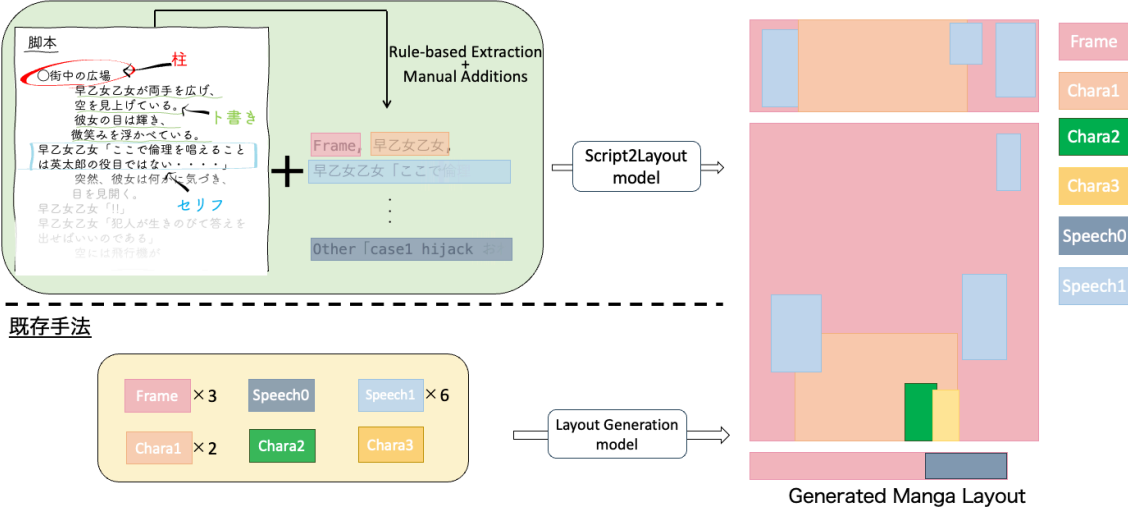


図 4.1: Script2Layout による脚本条件付きレイアウト生成の概略図。上段は、本研究で提案する手法であり、自然言語として記述された脚本を直接入力として扱いつつ、キャラクター、セリフ、およびコマに対応する要素を抽出し、Fine-tuned LLM によりページ全体のレイアウトを生成する。下段は、既存のレイアウト生成手法の例であり、要素数やカテゴリといった構造化情報を入力としてレイアウトを生成する点で異なる。

あらかじめ定めた順序に従って線形化し、トークン列として表現する。具体的には、

$$L = (l_1, l_2, \dots, l_T) \quad (4.4)$$

をレイアウト列とし、各トークン l_t は単一のレイアウト要素に対応するものとして

$$l_t = (c_{\pi(t)}, \mathbf{b}_{\pi(t)}) \quad (4.5)$$

と定義する。ここで $\pi(t)$ は、集合 ℓ に含まれる要素を系列上の位置 t に対応付ける写像であり、ページ内の全要素を一度ずつ列挙するため、 $T = N$ が成り立つ。

各要素に対応するバウンディングボックス $\mathbf{b}_i = (x_i, y_i, w_i, h_i)$ は、ページ平面上での位置と大きさを表す連続値である。本研究では、これらをあらかじめ定義した二次元の格子点上に量子化し、有限語彙上の離散トークンとして表現する。これにより、レイアウト生成は有限語彙上の系列生成問題として定式化され、LLM の自己回帰的な生成枠組みと直接的に対応付けて扱うことが可能となる。

入力となる脚本 S には、柱、ト書き、およびセリフを含むページ単位の脚本全文を自然言語としてそのまま与える。本研究では、キャラクター名を正規化することを行わず、脚本中に現れる表記をそのまま入力として用いる。一方で、セリフは「話者名『発話内容』」の形式で記述されているため、モデルは話者と発話内容の対応関係や、ト書きに記述された振る舞いを条件情報として利用できる。これにより、どのキャラクターがページ内で中心的であるか、どのキャラクターに発話が集中しているかといった物語構造が、レイアウト生成の手がかりとしてモデルに与えられる。

学習時には、脚本列 S と、それに対応する正解レイアウト列 L からなる教師データを用い、LLM に

よる条件付き確率

$$p_{\theta}(L | S) = \prod_{t=1}^T p_{\theta}(l_t | l_{<t}, S) \quad (4.6)$$

を最大化するように、モデルパラメータ θ を最適化する．具体的には、次トークン予測に基づくクロスエントロピー損失

$$\mathcal{L} = - \sum_{t=1}^T \log p_{\theta}(l_t | l_{<t}, S) \quad (4.7)$$

を最小化することで、脚本とレイアウトとの対応関係をモデル内部に学習させる．

このような教師ありファインチューニングを通じて、LLM は、自然言語として記述された物語情報と、漫画ページ上の幾何的な配置との対応関係を、明示的なルール設計に依存することなく獲得する．既存のレイアウト生成手法の多くが、要素カテゴリやサイズといった構造化された入力を前提としていたのに対し、本研究では、脚本そのものを入力として利用し、LLM の言語理解能力を介して配置決定を行う点に特徴がある．

以上のように、LLM を脚本条件付きのレイアウト生成器として教師ありでファインチューニングすることで、物語内容に基づく配置設計を一貫した生成モデル、Script2Layout として実現する．

4.3 漫画のレイアウト生成における実験設定

本節では、前節で述べた Script2Layout 手法の有効性を検証するために行った実験設定を述べる．具体的には、データセット分割、比較手法、制約条件、評価指標、実装詳細を順に説明する．

4.3.1 データセット分割

実験には本研究において構築した Manga109ScriptDataset を用いる．制約条件、特に要素間関係を用いる設定において計算量が大きくなるケースを避けるため、ページ内の総要素数が 50 を超えるページを除外し、残る 19,465 ページを実験対象とした．

データは作品単位で分割し、同一作品が訓練用・検証用・テスト用データにまたがらないようにした．分割比は 8:1:1 とし、訓練用データを 15,386 ページ、検証用データを 2,183 ページ、テスト用データを 1,896 ページ用いた．訓練用データは Script2Layout のファインチューニングおよび比較手法の学習に用い、検証用データは学習の早期終了等のモデル選択に用いた．最終的な性能評価はテスト用データ上で行った．

4.3.2 比較手法

Script2Layout は脚本を条件としてレイアウトを生成するのに対し、既存のレイアウト生成手法は、要素カテゴリが記号的ラベルとして与えられることを前提とする．そこで比較実験では、既存手法に合

わせて各ページ内の要素カテゴリをラベル化し、同一の入出力形式で性能比較を行った。

既存手法の入力カテゴリは、ページ内のコマを **Panel**, キャラクターを **Character_k** ($k = 1, \dots, 25$), セリフのフキダシを **Speech_k** ($k = 0, \dots, 25$) として定義する。ここで k はページ内で区別されるキャラクター種別を表し, **Speech_k** は **Character_k** による発話に対応する。また $k = 0$ は独立したナレーション等話者が特定できないものを表す。キャラクター種別数の最大値を 25 としたのは、本データセットで単一ページ内に登場するキャラクター種別数の最大値が 22 であることから余裕をもたせたものである。

比較対象として, LayoutDM [13], LayoutFormer++ [14], LayoutPrompter [15] の 3 手法を採用した。LayoutDM と LayoutFormer++ は学習型モデルであり, 本データセットの訓練分割を用いて 0 から学習させた。LayoutPrompter は GPT-4o を利用するプロンプトベースの手法であり, 学習は行わず推論のみを用いた。なお LayoutPrompter は入力長の制約のため脚本全文を条件として与えない設定で評価した。

4.3.3 制約条件

既存の手法が扱う制約条件からは以下のものを採用した。

- **Gen-T (types 条件)** : 各要素のカテゴリ (**Panel**, **Chara_k**, **Speech_k**) のみを与え, バウンディングボックスを生成する条件。本章の基本設定とする。
- **Gen-TS (types+sizes 条件)** : 各要素のカテゴリに加え, バウンディングボックスのサイズ (幅・高さ) を与え, 位置のみを生成する条件。

一方 Script2Layout では, 前節の通り脚本を自然言語として入力に含めることができる。脚本条件の効果を検証するため, Script2Layout は入力形式を以下の 2 通り比較した。

- **Without Script**: 脚本全文は入力に含めず, キャラクター名やセリフ内容といった各要素のテキスト情報のみを入力として用いる条件。この条件においても, Script2Layout モデルは同一の学習データを用いて教師ありでファインチューニングされている
- **With Script**: ページ単位で脚本全文を自然言語としてそのまま与える条件。

それぞれの条件を, 比較手法の Gen-T, Gen-TS と組み合わせて実験を行った。

4.3.4 評価指標

漫画レイアウトは同一脚本に対しても複数の妥当な解が存在し得るため, 単一の観点だけで生成品質を評価することは難しい。そこで本研究では, (1) 生成結果の分布としての近さ, (2) 要素単位での

位置精度, (3) ページ単位での集合としての幾何的一致, (4) データ集合としての幾何的一致をそれぞれ測るため, Fréchet Inception Distance(FID), Mean Intersection over Union (mIoU), Layout Transportation Similarity (LTSim) [16], LTSim Maximum Mean Discrepancy (LTSim-MMD) [16] の 4 指標を用いる. 特に LTSim は最適輸送に基づく柔軟な要素対応付けにより, 要素数やカテゴリの差異を含むレイアウト対も比較可能な指標として提案されている [16]. また, FID は分布比較に広く用いられる一方で, 知覚品質と必ずしも一致しない可能性も指摘されているため [16], 本研究では LTSim 系指標を併用して多面的に評価する.

FID 生成レイアウトと実レイアウトの分布の近さを測るため, Fréchet Inception Distance (FID) を用いる. FID は, レイアウトを特徴空間へ写像した後, 生成分布と実分布をそれぞれ多変量正規分布として近似し, その間の Fréchet 距離として定義される:

$$\text{FID} = \|\boldsymbol{\mu}_g - \boldsymbol{\mu}_r\|_2^2 + \text{Tr} \left(\boldsymbol{\Sigma}_g + \boldsymbol{\Sigma}_r - 2(\boldsymbol{\Sigma}_g \boldsymbol{\Sigma}_r)^{1/2} \right), \quad (4.8)$$

ここで $(\boldsymbol{\mu}_g, \boldsymbol{\Sigma}_g)$ および $(\boldsymbol{\mu}_r, \boldsymbol{\Sigma}_r)$ は, それぞれ生成レイアウトと実レイアウトから抽出した特徴の平均および共分散行列である. 特徴抽出器には LayoutDM [13] に倣い FIDNetV3 を用いる.

mIoU 生成された各レイアウト要素と正解要素をカテゴリごとに一対一で対応付け, それらの Intersection over Union (IoU) を評価する. 要素 i に対する IoU は, 生成バウンディングボックス $\mathbf{b}_i^{(g)}$ と正解バウンディングボックス $\mathbf{b}_i^{(r)}$ に対して

$$\text{IoU}_i = \frac{\text{area}(\mathbf{b}_i^{(g)} \cap \mathbf{b}_i^{(r)})}{\text{area}(\mathbf{b}_i^{(g)} \cup \mathbf{b}_i^{(r)})} \quad (4.9)$$

として定義される. 同一カテゴリ内で IoU が最大となる対応を貪欲に選択し, 全要素に対する平均値

$$\text{mIoU} = \frac{1}{N} \sum_{i=1}^N \text{IoU}_i \quad (4.10)$$

を最終的な指標として算出する.

LTSim ページ単位での幾何的一致を評価するため, 最適輸送に基づく Layout Transportation Similarity (LTSim) [16] を用いる. LTSim は, 生成レイアウト $\hat{\ell}$ と正解レイアウト ℓ に含まれる要素集合を, 一対一に対応付けるのではなく, 要素間の類似度に基づく重み付きの多対多対応 (ソフト対応) として扱う点に特徴がある.

具体的には, 正解レイアウト $\ell = \{(c_i, \mathbf{b}_i)\}_{i=1}^N$ と生成レイアウト $\hat{\ell} = \{(c_j, \hat{\mathbf{b}}_j)\}_{j=1}^{\hat{N}}$ の間に, 輸送行列 $\gamma \in \mathbb{R}_+^{N \times \hat{N}}$ を導入し, 各要素対 (i, j) の対応の強さを $\gamma_{i,j}$ として表す. γ は各要素の総重みを保存する制約のもとで最適化され, 要素数やカテゴリが完全に一致しない場合でも対応付けが可能である.

このとき、対応に基づく輸送コスト（Earth Mover’s Distance; EMD）は

$$\text{EMD}(\ell, \hat{\ell}) = \sum_{i=1}^N \sum_{j=1}^{\hat{N}} \gamma_{i,j}^* \mu((c_i, \mathbf{b}_i), (c_j, \hat{\mathbf{b}}_j)) \quad (4.11)$$

として定義される．ここで γ^* は輸送コストを最小化する最適輸送行列であり， $\mu(\cdot, \cdot)$ は要素間のコスト関数である．本研究では， μ としてバウンディングボックス間の幾何的差異を表す Generalized IoU (GIoU) と，カテゴリ一致の有無を組み合わせたコストを用いる [16]．これにより，位置関係と要素種類の両方を考慮した対応付けが実現される．

EMD に基づき，LTSim は次式で定義される：

$$\text{LTSim}(\ell, \hat{\ell}) = \exp\left(-\frac{\text{EMD}(\ell, \hat{\ell})}{\sigma}\right). \quad (4.12)$$

σ はスケールパラメータであり，EMD の大きさを類似度に変換する際の感度を制御する．本研究では，1 ページ全体を 1 つのレイアウトとして比較する layout-level の設定に従い， $\sigma = 1$ とする [16]．

LTSim-MMD 生成レイアウト集合と実レイアウト集合の分布的一致を評価するため，LTSim をカーネル関数とする Maximum Mean Discrepancy (MMD) に基づく LTSim-MMD [16] を用いる．

MMD は，2 つの集合が同一の分布から生成されたかどうかを評価する指標であり，集合内および集合間の平均類似度の差に基づいて定義される．本研究では，ページ単位のレイアウト間類似度として LTSim を用い，これをカーネル関数 $k(\ell, \hat{\ell}) = \text{LTSim}(\ell, \hat{\ell}; \sigma)$ として用いる．

正解レイアウト集合 $\mathcal{L} = \{\ell_i\}_{i=1}^s$ と生成レイアウト集合 $\hat{\mathcal{L}} = \{\hat{\ell}_j\}_{j=1}^t$ に対し，LTSim-MMD は

$$\text{MMD}^2(\mathcal{L}, \hat{\mathcal{L}}) = \frac{1}{s(s-1)} \sum_{i \neq j} k(\ell_i, \ell_j) + \frac{1}{t(t-1)} \sum_{i \neq j} k(\hat{\ell}_i, \hat{\ell}_j) - \frac{2}{st} \sum_{i,j} k(\ell_i, \hat{\ell}_j) \quad (4.13)$$

として定義される．第 1 項と第 2 項はそれぞれ正解集合内および生成集合内の平均類似度を表し，第 3 項は正解集合と生成集合間の平均類似度を表す．生成分布が正解分布に近いほど，集合内類似度と集合間類似度が近づき，MMD の値は小さくなる．

これにより，個々のページにおける幾何的一致度（LTSim）に加えて，生成結果全体が実データ分布としてどの程度整合しているかを定量的に評価できる．

定性的評価 定量指標に加え，Gen-T 条件下での生成結果と正解レイアウトを可視化し，既存手法との違い，脚本条件の有無による配置傾向の違いを観察する．

4.3.5 レイアウト生成の学習および実装詳細

Script2Layout は，複数の LLM をベースモデルとして用い，教師あり学習により Script2Layout へ適応させた．具体的には，Swallow-13B [76]，Sarashina-13B [77]，および DeepSeek-R1-Distill-Qwen-

14B-Japanese [78, 79] を用いた。選定は、これらが高い日本語性能を有しており、日本語で記述された脚本の入力に対応できることと、オープンソースモデルであり自由にファインチューニングが可能であることを理由とした。

座標のグリッド表現については、既存のレイアウト生成タスクにならう形で 32×32 のグリッドを用い、離散トークンとして扱い学習を行った。

ファインチューニングには、事前学習済みモデルの大部分を固定したまま、少数の追加パラメータのみを学習する Low-Rank Adaptation (LoRA) を採用した。これにより、大規模 LLM に対しても計算資源を抑えつつ安定した学習が可能となる。実装には Hugging Face Transformers および Parameter-Efficient Fine-Tuning (PEFT) ライブラリを用いた。

学習および推論は NVIDIA H100 (1 枚) 上で行った。LoRA の設定、学習率、バッチサイズなどの詳細なハイパーパラメータは付録 A.1 に示す。

4.4 漫画のレイアウト生成における結果と考察

本節では、前節で述べた実験設定に基づき、Gen-T 条件化における定量評価結果および生成レイアウトの可視化結果、Gen-TS 条件化における定量評価結果を用いて Script2Layout 手法の有効性について考察する。特に、既存手法との比較および脚本の有無による比較を通じて、脚本情報がレイアウト生成性能に与える影響を分析する。

以下ではまず、Gen-T 条件下での結果を示し、脚本条件が配置精度やページ全体の幾何的一貫性に与える効果を考察する。続いて、要素サイズを既知とする Gen-TS 条件下での結果を示し、幾何的制約が強まった場合における脚本情報の影響について議論する。最後に、考察のまとめと手法の課題を述べる。

4.4.1 Gen-T 条件下でのレイアウト生成結果と考察

本小節では、Gen-T 条件（要素のカテゴリを既知とする条件）におけるレイアウト生成結果について、定量評価結果および生成レイアウトの可視化に基づき考察する。

Gen-T 条件下の定量評価の結果と考察: 表 4.1 に、Gen-T 条件（要素のカテゴリを既知とする条件）におけるレイアウト生成の定量評価結果を示す。まず、既存手法と Script2Layout の性能差に着目し、続いて Script2Layout 内における脚本情報 (Script) の有無による違いを考察する。

表 4.1 より、既存手法と Script2Layout の違いに注目すると、ページ単位の評価指標である mIoU および LTSim では Script2Layout のすべてのモデルにおいて既存手法を一貫して上回る結果を示している。例えば mIoU では、既存手法の最高値が LayoutFormer++ の 0.1499 であるのに対し、Script2Layout はいずれも 0.150 を超え、Script2Layout(With Script) の Sarashina モデルでは

表 4.1: Gen-T 条件下におけるレイアウト生成の定量評価の結果.

Model	Page-level metrics		Distribution-level metrics	
	mIoU $\uparrow$	LTSim $\uparrow$	FID $\downarrow$	LTSim-MMD ($\times 10^{-2}$) $\downarrow$
<i>Existing Methods</i>				
LayoutDM	0.1238	0.7263	19.779	0.614
LayoutFormer++	0.1499	0.7145	36.479	3.126
LayoutPrompter	0.1368	0.7213	62.728	1.343
<i>Script2Layout (Without Script)</i>				
DeepSeek	0.1740	0.7471	21.953	0.467
Sarashina	<u>0.1939</u>	<u>0.7542</u>	22.464	0.586
Swallow	0.1540	0.7373	33.235	0.881
<i>Script2Layout (With Script)</i>				
DeepSeek	0.1809	0.7495	<u>19.849</u>	0.343
Sarashina	0.1983	0.7550	22.569	0.396
Swallow	0.1728	0.7452	21.824	<u>0.391</u>

0.1983 に達している．これは既存手法同士の性能差が 0.030 に満たないことを考慮すると顕著な改善であるといえる．また，LTSim の結果から，Script2Layout モデルは既存モデルと比較し，正解とのカテゴリー一致を強く矯正しない柔軟な要素対応付けに基づく評価においても，正解となる表現との高い幾何的一貫性を実現していることが分かる．また，分布レベル評価においても，Script2Layout は有利な傾向を示している．FID では LayoutDM が最良値を示すものの，Script2Layout (With Script) の DeepSeek はほぼ同等の値 (19.849) を達成している．さらに，LTSim-MMD においては，Swallow を除き，すべての Script2Layout がいずれの既存手法よりも良好 (小さい) な値を示しており，生成分布全体として実データにより近いレイアウトを生成できていることが分かる．これらの結果から，Script2Layout は，単一ページの配置精度と生成結果全体の分布的一貫性の両面において，既存手法よりも優れた性能を示しているといえる．

次に，Script2Layout において Script を入力しない条件と Script を入力する条件を比較する．表 4.1 より，Sarashina の FID を除いたいずれの指標においても，Script 条件を付与した場合に改善が見られることが分かる．この結果から，Script 条件の付与は，要素配置の精度やページ全体の幾何的一致，さらには生成分布全体の妥当性に対して，総合的かつ安定した改善効果をもたらしていることが分かる．重要な点に，これらの改善傾向が特定のモデルに依存せず，多くの Script2Layout モデルに共通して観測されていることがあげられる．すなわち，Script 条件の導入は，モデル構造や規模の違いに関わらず，多くの評価指標において一貫した性能向上に寄与しているといえる．以上より，Script 条件は，レイアウト生成における有効な補助情報として機能しており，Script2Layout における性能向上の重要な

要因の一つであると結論付けられる。

Gen-T 条件下におけるレイアウト生成例の可視化と考察: 図 4.2 に, Gen-T 条件下におけるレイアウト生成の可視化結果を示す。




図 4.2: Gen-T 条件下におけるレイアウト生成の可視化結果. 各行に対して, 左から順に正解レイアウト, 既存手法の生成例, Script2Layout の生成例, が並び, Script2Layout では上段に Script 条件なし, 下段に Script 条件ありの結果を示す. (漫画: 上段『ヒーリング・プラネット』©桜野 みねね/エニックス, 下段『ドールガン』©出口 竜正/秋田書店)

まず, 既存手法と Script2Layout の生成結果を比較すると, コマ (水色の領域) の配置が, Script2Layout の方がより正解に近しい傾向が見てとれる. 例えば, 1 行目の例では, 正解のレイアウトにおいてコマがページを上段中段下段に分割するよう配置されているが, 既存手法ではこれが再現されていない. 一方で, Script2Layout ではこの傾向がより正確に捉えられている. また, 目立たせるべきキャラクターの大きさについても, Script2Layout の方が正解に近しい傾向がみられる. 例えば 2 行目の例では, 正解レイアウトにおいて右下のキャラクター (オレンジ色の領域) が大きく描かれているが, 既存手法ではこれが反映されていない. 一方で, Script2Layout では配置の点では違いがみられ

るものの、このキャラクターを画面に大きく目立たせようとする傾向は見取れる。セリフやキャラクター名の情報がこのようなコマ割りやキャラクターの重要度に関する配置設計に有効に働いた可能性を示唆している。

次に、Script2Layout における Script 条件の有無による違いを比較すると、Script 条件ありの方がキャラクター配置の点で、わずかに正解に近い傾向が見てとれる。例えば、2 行目の例では、正解レイアウトにおいてオレンジ色の領域をもつキャラクターが、ページの上から順に登場しているが、Script 条件ありの生成例ではこれが再現されているようにみてとれる。一方で、Script 条件なしの生成例では、このキャラクターが特にページ下部に集中して配置されている。これは脚本情報にある文脈からこのキャラクターの登場を把握し、ページ全体にわたって適切に分散配置することが可能になったためと考えられる。

4.4.2 Gen-TS 条件下での結果と考察:

以下では、Gen-TS 条件下における定量的結果について考察する。本条件では、各要素の大きさがあらかじめ与えられているため、Gen-T 条件と比較して幾何的制約が強く、主に要素配置の相対位置関係の予測精度が問われる設定となっている。そのため、生成結果の視覚的差異が相対的に小さくなり、定性的比較から得られる追加的な知見は限定的であると考えられる。また、漫画の制作を考慮してもこのような条件化での生成は実応用性が限定的であると考えられる。以上を踏まえ、Gen-TS 条件においては定量評価結果を中心に考察を行い、生成結果の可視化による定性的評価は行わない。

表 4.2 に、Gen-TS 条件（要素のカテゴリとサイズを既知とする条件）におけるレイアウト生成の定量評価結果を示す。

まず、既存のレイアウト生成手法と Script2Layout の mIoU および LTSim に着目すると、Gen-TS 条件下においても Script2Layout がすべての既存手法を大きく上回っていることが分かる。例えば、mIoU では既存手法の最高値が LayoutFormer++ の 0.2034 であるのに対し、Script2Layout はいずれのモデルにおいても 0.3100 以上を達成している。サイズ情報が与えられた状況下においても、Script2Layout がより正確な要素配置を実現できていることが示されている。また、LTSim においても同様に、Script2Layout は 0.800 を超える高い値を示しており、ページ全体としての幾何的一貫性が大きく改善されている。一方、FID に関しては、LayoutDM が最良値を示していることがわかる。しかし、LTSim-MMD に関してはいずれの Script2Layout も既存手法よりも良好な結果を示しており、生成分布全体のもっともらしさについても既存手法には劣らないことが示唆される。

次に、Script2Layout における Script 条件の有無の影響を比較する。Gen-TS 条件下では、Script の有無による差は Gen-T 条件ほど顕著ではないが、多くの指標において Script あり条件が Script なし条件と同等、あるいはわずかに良好な値を示している。特に LTSim-MMD においては、すべてのモデルで Script あり条件がより良好な値を示しており、生成分布全体の安定性が向上していることが分

表 4.2: Gen-TS 条件下におけるレイアウト生成の定量評価結果.

Model	Page-level metrics		Distribution-level metrics	
	mIoU $\uparrow$	LTSim $\uparrow$	FID $\downarrow$	LTSim-MMD ($\times 10^{-2}$) $\downarrow$
<i>Existing Methods</i>				
LayoutDM	0.1890	0.7432	17.554	0.263
LayoutFormer++	0.2034	0.7525	<u>18.058</u>	0.378
LayoutPrompter	0.1326	0.7046	80.477	1.053
<i>Script2Layout (Without Script)</i>				
DeepSeek	<u>0.3435</u>	<u>0.8145</u>	19.981	0.052
Sarashina	0.3165	0.8049	22.422	0.112
Swallow	0.3139	0.8042	20.977	0.108
<i>Script2Layout (With Script)</i>				
DeepSeek	0.3429	0.8143	19.497	<u>0.057</u>
Sarashina	0.3461	0.8154	19.426	0.078
Swallow	0.3431	0.8143	21.028	0.068

かる。この結果は、サイズ情報という強い幾何的制約が与えられた状況では、Script が要素配置の直接的な精度向上に与える影響は限定的となる一方で、生成結果全体のばらつきを抑え、分布としての一貫性を高める効果を依然として持つことを示唆している。

Gen-T 条件との比較による考察 Gen-T 条件と比較すると、Script2Layout、既存手法によらず、多くのモデルが Gen-TS 条件において mIoU および LTSim が大きく向上している。これは、要素サイズ情報がレイアウト生成において極めて重要な役割を果たしていることを示唆する。一方で、Gen-TS 条件下では、Script 条件の有無による性能差が相対的に縮小していることから、強い幾何的制約が与えられることで、言語情報が果たす役割が補助的なものへと移行することが分かる。

以上より、Script2Layout は、幾何的制約が弱い場合（Gen-T）には Script 情報を積極的に活用して配置精度を向上させ、幾何的制約が強い場合（Gen-TS）においては、生成分布の安定化という形で Script 情報の効果を発揮する柔軟な手法であることが示唆される。

4.4.3 考察のまとめと手法の課題

本節では、脚本に基づく漫画レイアウト生成手法 Script2Layout について、Gen-T および Gen-TS 条件下での定量的・定性的評価を通じて、その有効性を検証した。実験の結果、脚本情報を条件として与えることで、要素配置の精度やページ全体の幾何的一貫性が向上すること、またその効果がモデル構造に依存せず一貫して観測されることを確認した。

一方、本研究の結果から、脚本情報の効果は与えられる制約条件によって異なる形で現れることも

明らかになった。Gen-T 条件のように幾何的制約が弱い設定では、脚本情報が要素の重要度や配置のバランスに強く寄与し、配置精度および分布的一貫性の双方を改善する傾向が見られた。これに対し、Gen-TS 条件のように要素サイズが既知である場合には、脚本情報による配置精度の向上は限定的となり、主に生成分布の安定化という形で効果が現れることが確認された。このことは、強い幾何的制約が与えられた状況では、言語情報が果たす役割が補助的なものへと移行する可能性を示唆している。

以上のように脚本情報の有効性は確認されたものの、脚本中のどの要素（キャラクターの登場頻度、セリフ量、ト書きの内容など）がレイアウト決定にどの程度寄与しているかについては、本研究では十分に分析できていない。脚本内の情報と生成結果との対応関係をより詳細に可視化・解析することは、Script2Layout の挙動理解を深める上で今後の重要な課題である。

第 5 章 Manga109NameDataset

本章では、本研究の第二段階として構築した、漫画ネームデータセット Manga109NameDataset について述べる。本データセットは、漫画画像に紐づく脚本情報に加え、詳細な演出情報を体系的に付与したものであり物語から漫画作品へと至る過程を、より高次の構造として捉えることを目的としている。

前章では、Manga109ScriptDataset を用いた脚本に基づく漫画レイアウト生成手法を検討し、脚本情報が要素配置の精度やページ全体の幾何的一貫性に寄与することを示した。しかし、序論で述べたとおり、漫画制作におけるネームは、単なる要素の配置結果ではなく、視線誘導や強調、感情表現といった演出上の意思決定が統合された、より複合的な中間表現である。そのため、レイアウト生成のみを対象とした前章の設定では、ネームが本来担う表現的側面を十分に扱うことはできない。本来の漫画制作におけるネームは、作画に先立つ下書きとして描かれる視覚的な表現であるが、本研究では、このネームを画像そのものとして直接扱うのではなく、その中に含まれる本質的な設計要素を抽出し、要素の幾何学的配置を表すレイアウト情報と、演出上の意図を言語的に記述した演出情報とに分解する。そして、これらを統合した構造化表現としてネームを定義する。この抽象化は、ネームが担う配置設計および演出上の意思決定を保持しつつ、脚本からネーム生成へ至る過程を計算機上で段階的に扱うための、本研究における操作的定義である。

以上を踏まえ、本研究では、近年の LVLMM の性能向上を背景として、漫画画像から脚本情報を改めて抽出し直すとともに、キャラクターの振る舞いや表情、カメラワークといった演出情報を新たに獲得し、これらを構造的に整理した Manga109NameDataset を構築した。本研究では、このデータセットを、後続章で扱う脚本に基づくネーム生成モデルの学習および評価に適した基盤データとして位置づける。

本章の構成は以下の通りである。まず 5.1 節において、取り扱う演出情報に触れながら、Manga109NameDataset の概要とそのデータ構造を説明する。続いて 5.2 節において、データセットの構築にあたって整備した読み順アノテーションおよび独自の Visual Prompting の詳細、データセット構築の実行手順を説明する。次に 5.3 節で、構築したデータセットの統計量を示し、最後に 5.4 節で構築したデータの可視化例を示す。

5.1 Manga109NameDataset の概要

図 5.1 に, Manga109NameDataset における 1 サンプル分のデータ構造の概略を示す.




図 5.1: Manga109NameDataset における 1 サンプル分のデータ構造の概略

Manga109NameDataset は, 漫画のネームを, 要素の幾何学的配置を表すレイアウト情報と, 脚本形式の記述を含む物語文章および演出情報を構造化したデータセットである. 本データセットでは, 漫画の見開きページ一つを基本単位とし, その内部に含まれるコマ, キャラクター, セリフといった要素をノードとして定義するとともに, それらの包含関係, 参照関係, 順序関係, および相互作用をエッジとして明示的に表現する. これにより, ネームを構成要素と関係性の集合として捉え, 配置設計と演出上の意思決定を計算機上で扱いやすい形式へと整理している. なお, 見開き単位でデータを取得したのは, 漫画の紙面構造上, 見開きを一枚絵として捉え演出が設計されることが多いためである.

このように構成されたグラフにおいては, 図 5.1 に示すように見開き全体に対応する **Spread** ノードを物語および演出の文脈を担う最上位ノードとして位置づけている. Spread ノードには, 当該場面の内容を要約した概要文や脚本記述, 場面全体の雰囲気や演出上の補足といったグローバルな物語情報

が付与される。これらは、配下に接続される各コマやキャラクター、セリフといった要素を、個別の配置や表現としてではなく、場面全体の流れや意図の中で解釈するための上位文脈として機能する。

Spread ノードの下位には、見開き内の各コマに対応する **Panel** ノードが配置される。Panel ノードは、漫画における最小の視覚的・演出的単位として、物語の進行や演出上の役割を担う要素である。各 Panel ノードには、当該コマの内容を簡潔に記述した要約文に加え、対話、反応、間（ま）といった物語上の役割、コマ形状やカメラ距離・アングルといった演出に関わる属性が付与される。これにより、コマ単体の意味内容と、見開き全体における役割とを分離して記述することが可能となり、レイアウト設計および演出制御の双方を明示的に扱える構造となっている。

登場人物に関しては、物語上の人物そのものを表す **Character** ノードと、特定のコマ内に描かれた具体的な出現を表す **Character Instance** ノードを分離して定義している。Character ノードには、人物名や性格、物語上の立ち位置といった作品全体で共有される属性が付与される。一方、Character Instance ノードは、特定のキャラクターの描写を表すノードであり、姿勢、動作、感情といった視覚的・演出的な具体像が記述される。この分離により、同一人物が複数のコマに異なる表情や振る舞いで登場する状況を、構造的に自然な形で表現できる。

セリフは、吹き出し単位で **Speech** ノードとして管理される。Speech ノードには、発話内容のテキスト情報に加え、発話の種類や、どのキャラクター・どのコマに紐づくかといった参照関係が付与される。これにより、言語表現と視覚要素との対応関係を明示的に扱うことが可能となっている。

これらの各ノード間には、包含関係、参照関係、順序関係、および相互作用を表す複数種のエッジが定義されている。これにより、漫画ネームに内在する空間的構造、時間的順序、および物語の関係性を、単一のグラフ構造として統合的に表現している。また、直接的に紙面に描画される要素であるノード、Panel ノード、Character Instance ノード、Speech ノードには、バウンディングボックスの値を持たせ、レイアウト情報を表現している。

以上のように、Manga109NameDataset では、見開き、コマ、キャラクター、セリフといった各要素をグラフ上のノードとして整理し、それぞれに対応する描画内容や場面における詳細な情報を集約することで、漫画ネームに内在する演出上の意思決定を構造化された形で表現している。この構造により、脚本に基づくネーム生成やレイアウト生成といった後続の処理において、物語文脈、演出意図、および配置情報を統合的に扱うことが可能となる。

5.2 データセット構築手法

Manga109NameDataset の構築は、Manga109ScriptDataset の構築と同様に、LVLM を用いて漫画画像から必要な情報を抽出することを基本方針としている。一方で、本データセットの構築では、データの取得単位をページ単位ではなく見開き画像単位へと拡張し、より高次の文脈および演出情報を扱う

点で設定が異なる。使用した LVLM は、Gemini 3 [80] および GPT-5.2 [81] であり、いずれも API を介して利用した。

漫画画像の読解における困難さについては、Manga109ScriptDataset の構築過程において既に議論したとおりであり、特に読み順の推定やキャラクターの識別は、LVLM にとって依然として難しい課題である。Manga109NameDataset の構築においても、これらの問題は引き続き重要であり、加えて見開き単位での処理に伴う文脈の拡張や要素数の増加が新たな難点となる。

そこで本研究では、ScriptDataset 構築時の知見を踏まえ、読み順の明示的な付与や、キャラクター識別を補助するための情報付加など、複数の追加的工夫を導入することで、これらの課題に対処した。以下では、Manga109NameDataset の構築に際して新たに導入した各手法について順に説明する。

5.2.1 読み順アノテーションの付与

漫画の内容理解において、コマおよびセリフの読み順は、物語構造を復元するための最も基本的な前提条件である。Manga109ScriptDataset の構築においても、読み順の推定が LVLM にとって困難であること、既存手法による自動推定では誤りが残ることを確認している。この問題は、見開き単位で物語と演出を統合的に扱う Manga109NameDataset においては、より深刻な影響を及ぼす。

特に本データセットでは、コマ間の時間的順序だけでなく、セリフ間の発話順、さらには演出上の「間（ま）」や反応の連なりを正確に復元する必要がある。そのため、既存の自動推定結果や推論に依存するのではなく、読み順を明示的な正解情報として与えることが不可欠であると判断した。

そこで本研究では、Manga109Dataset に含まれる全コマ 103,850 枚および全セリフ 144,875 件に対して、人手による読み順アノテーションを新たに付与した。アノテーションは、見開き内における読み進め順を基準として、コマおよびセリフに一意な順序を割り当てる形で行った。

アノテーション作業にあたっては、効率的かつ一貫した作業を行うため、本研究独自のアノテーションツールを開発した。開発したツールを操作画面を図 5.2 に示す。

本ツールでは、見開き画像を表示しながら、コマおよびセリフを選択し、直感的に順序を指定できるインタフェースを備えている。実作業は、筆者が中心となって進めるとともに、一部については産業技術総合研究所の技術支援者の協力を得て実施した。

このようにして付与された読み順アノテーションは、後述するビジュアルプロンプティングにおいて LVLM に与える重要な手がかりとして利用されるほか、データセット全体の構造的整合性を保証する基盤情報として機能する。

既存手法との読み順の差異 読み順推定手法として知られる Manga Whisperer [72] のアルゴリズムについて、本研究では、人手アノテーションとの順序一致率を比較評価した。その結果、見開き画像単位で順序が完全一致しなかった割合は、コマについて 1,121 / 10,122 (11.87%)、セリフについて 2,609




図 5.2: 読み順アノテーションツールの操作画面 (漫画:『ARMS』©加藤 雅基/東京三世社)

/ 10,043 (25.98%) であった。本研究では、コマ単位やセリフ単位での部分的な誤りの定義が困難であることから、順序が完全一致しなかった見開き画像の割合を指標としている。

図 5.3, 5.4 に、それぞれコマとセリフの読み順が一致しなかった見開き画像の例を示す。

コマの読み順について、Magi による自動推定が正しく行えなかった事例を分析した結果、図 5.3 に示すように、長方形近似に基づく配置推定の影響や、左上と右下に配置されたコマ同士の比較において内容理解を要する場合、さらに吹き出しによる視線誘導がコマの幾何学的配置による優先順位を凌駕する場合などが確認された。これらの事例では、単純な空間配置に基づく規則のみでは、実際の読解順を適切に復元できないことが分かる。

一方、セリフの読み順についても、自動推定が困難となる特徴的な状況が観察された。具体的には、図 5.4 に示したようなセリフの順序が帰属するコマの順序に強く制約される場合や、本来的に明確な帰属先コマを持たない「宙に浮いた」セリフが存在する場合である。後者のようなケースでは、アルゴリズム上、最も近傍のコマに機械的に割り当てられることで順序が決定されるため、実際の読解順と乖離が生じやすい。また、左上と右下に配置されたセリフ同士の順序関係はセリフ内容の意味理解に依存する場合も確認された。

以上の分析から、漫画における読み順は、コマ配置、吹き出しによる視線誘導、内容理解、演出的意図といった複数の要因が複合的に関与して決定されることが多く、その自動推定は本質的に困難な課題であることが明らかとなった。本研究では、これらの問題に対処するため、人手により付与した読み順アノテーションを正解情報として利用し、後続のデータ取得および LVLM による読解性能の基準として用いている。




図 5.3: コマの読み順が一致しなかった見開き画像の例. 本来は 4, 5 と読み進めるべきコマの順序が, 自動推定で逆転してしまった (漫画:『空っぽハイスクール』© 高口 里純/角川書店).

5.2.2 ID 情報を付記する独自 Visual Prompting

本研究では, 付与した読み順アノテーションを LVLMM による漫画理解および情報抽出に効果的に反映させるため, コマおよびセリフに一意な ID を付与し, それを視覚的に画像上へ埋め込む独自の Visual Prompting 手法を導入した. 図 5.5 に実際に使用した Visual Prompting の例を示す.

Manga109ScriptDataset の構築においては, ページ単位で漫画画像を入力し, そのページ全体に対応する脚本を一つのテキストとして生成すれば十分であった. そのため, 生成された脚本と画像内の個々のコマやセリフとの厳密な対応関係を明示的に管理する必要はなかった.

これに対し, Manga109NameDataset では, 見開き内に含まれる各コマ, 各キャラクター, 各セリフといった描画要素ごとに, 演出情報や構造的な属性を個別に抽出・整理することを目的としている. すなわち, 本データセットの構築では, 「見開き全体から一つの脚本を得る」のではなく, 「見開き内の各描画要素からそれぞれに対応する情報を取得する」という, より細粒度な対応付けが必要となる.

このような設定では, LVLMM が生成した記述と, 元画像上の具体的なコマやセリフ, さらにはキャラクターの出現とを正確に対応付けることが不可欠である. しかし, 画像内に多数の要素が混在する漫画




図 5.4: セリフの読み順が一致しなかった見開き画像の例。本来は 6 番のコマに帰属するセリフは、5 番のコマに帰属する 2 つのセリフの間で読まれるべきであるが、自動推定では 5 番のコマの 2 つのセリフよりも後に推定されてしまった (漫画:『ヒーリング・プラネット』©桜野 みねね/ エニックス)。



図 5.5: ID を付記した Visual Prompting の例 (漫画:『愛さずにはいられない』©よし まさこ/集英社)。

表現において、自然言語による参照や位置関係の暗黙的な推論のみに依存すると、対応関係が曖昧になりやすい。

そこで本研究では、読み順アノテーションに基づき、各コマおよび各セリフに連番の ID を付与するとともに、これらの ID を漫画画像上に直接描画した画像を LVLM への入力として用いた。具体的には、見開き画像全体に加え、各コマを個別に切り出した画像を読み順に従って入力し、それぞれの画像内に対応するコマ ID やセリフ ID を明示的に表示した。ID の表示は描画対象の画像領域に対する 6% の面積を占める小さな枠内に配置し、小さくなりすぎて認識されなくなることを防ぐため、最小フォントサイズを 12pt に設定した。

この ID 表示は、単なるデータ管理上の識別子ではなく、LVLM に対して「どの要素を指しているのか」を視覚的にアンカーする役割を果たす。これにより、生成される脚本記述や演出情報を、特定のコマやセリフ、さらにはキャラクターの具体的な出現と一対一に対応付けることが可能となった。また、ID を介した参照により、キャラクター名の誤同定や、セリフと話者の取り違えといった問題の発生を大きく抑制できることを確認している。

さらに、画像入力の構成についても工夫を行った。近年の LVLM においては入力可能なトークン数が大幅に増加していることから、本研究では、対象とする見開き画像に加え、当該見開き内の全コマを個別画像として切り出し、読み順に並べて入力する方式を採用した。この際、ID 表示は各コマ画像側に付与し、見開き全体像と局所的な詳細情報とを同時に参照できる構成とした。

このような ID 情報を視覚的に付与する Visual Prompting により、LVLM は、漫画における空間配置と読み順、物語的な対応関係、キャラクター識別をより安定して理解できるようになり、これはネーム構造の抽出精度向上に大きく寄与した。

図 5.6 に、付記した ID により、キャラクターの識別及び状況の理解が適切に行われた生成結果の例を示す。

5.2.3 超解像度処理による認識性能の向上

漫画画像には、小さなコマや細密な描写が多く含まれており、LVLM による内容理解において、視認性の低さが性能低下の一因となる。特に本研究では、コマやセリフに ID ラベルを付記した画像を入力として用いるため、これらのラベルが本来の描画内容を遮蔽し、かえって視覚的理解を妨げるオクルージョンの問題が生じる。そこで本研究では、小さなコマの理解精度向上と、ID ラベルによる視認性低下の抑制を目的として、漫画画像に対する超解像度処理を導入した。

具体的には、オープンソースの超解像モデルである DRCT [82] を用い、元画像に対して $\times 4$ の超解像処理を施した。これにより、細部の線画や文字情報が明瞭化され LVLM による視覚的理解の安定化と、また ID が付記できるスペースを生み Visual Prompting の効果を高めることが可能となった。例えば、オクルージョンの問題を解決する手段としては、単純にフォントサイズを画像比率にあわせ縮小



panel_9

Attribute	Value / Description
<i>Narrative Context</i>	
ID	panel.9
Summary	ご飯が炊けたことを踊って祝うあゆみと、それをドアの陰から見ているあさみ。
Emotion	Joy (あゆみ) vs Confusion (あさみ)
<i>Cinematic & Visuals</i>	
Shot	Long Shot (LS), Eye-level
Composition	手前のあさみから、奥のあゆみへの視線誘導 (Split depth)
<i>Graph Structure (w/ IDs)</i>	
Characters	ci_7: あゆみ (Dancing) ci_5: あさみ (Watching)
Speech	s_12: 歌唱・チャント (あゆみ) s_13: 思考 (あさみ)
Action Edge	ci_5 (あさみ) $\xrightarrow{\text{observing}}$ ci_7 (あゆみ)

図 5.6: ID ラベルによりキャラクターの識別等状況が正確に構造化された例。画像内の ID タグである ci (Character Instance) はキャラクターを、s (Speech) はセリフを一意に識別しており、これらが右側の構造化データとして正しく対応付けられている (漫画:『愛さずにはいられない』©よし まさこ/集英社)。

する方法も考えられるが、コマ画像のサイズによっては、描画できる最小フォントサイズに満たない場合もしばしば存在した。図 5.7 に示すように、超解像度処理を施すことでこのような画像に対しても適度なサイズで ID ラベルを描画することが可能となった。

一方で、単純に高解像度化した画像をそのまま LVLM に入力すると、API の入力制約やタイル分割方式の影響により、通常の画像であれば認識可能である 12pt 程度のフォントサイズであっても、相対的に埋め込み領域が狭くなり、ID ラベルが正しく認識されなくなる問題が確認された。

この問題に対処するため、本研究では、 $\times 4$ の超解像画像に対して、線形輝度空間へ変換した上で平均化処理を伴うダウンサンプリングを行い、解像度を $\times \frac{1}{2}$ に縮小する手法も採用した。この処理により、元画像比で $\times 2$ 相当の解像度を持つ画像を生成し、元画像の大きさや ID ラベルのサイズに応じて、最も認識精度が高くなる超解像度設定を選択できるようにした。

具体的な運用条件としては、LVLM の API における 1 タイルが 512×512 ピクセルであるタイル分割方式を考慮し、各コマ画像の超解像度化後の画像が最大 4 タイル内で処理可能となるよう画像サイズを調整した。この条件下において、ID ラベルの最小フォントサイズを 12pt 以上に維持しつつ、描画内容へのオクルージョンが最も小さくなる超解像度設定および入力コマ画像の選択を行った。

図 5.8 に、ID ラベルの最小フォントサイズの縮小に伴う遮蔽率の変化と超解像度処理に伴う遮蔽率の




図 5.7: 超解像度処理による ID ラベルの視認性が向上した例。左が最小フォントサイズを 12pt に設定した画像，中央が画像比率にあわせ最小フォントサイズを設定した画像，右が超解像度処理を施し 12pt のフォントサイズを設定した画像である。左は画像全体にオクルージョンが生じ，中央はラベル自体が付記できていないが，右は適度なサイズで ID ラベルを描画できている (漫画:『うるとら★イレブン』©やぶの てんや, 渡辺達也/集英社)。

比較を示す。これより，フォントサイズのを縮小する操作に比べると，2 倍の超解像度処理でさえ，十分に遮蔽率の低減に優れた効果があることがわかる。




図 5.8: ID ラベルの最小フォントサイズの縮小に伴う遮蔽率の変化と超解像度処理に伴う遮蔽率の比較。Normal の最小フォントサイズは 12pt で設定され，Small は 9pt，Extra Small は 6pt に設定された。SuperRes(Half) は 2 倍の超解像度処理画像，SuperRes(Full) は 4 倍の超解像度処理画像を表す。

以上の超解像度処理により，小さなコマや細部表現の可読性が向上するとともに，ID ラベルの付記が漫画内容の理解を妨げる影響を効果的に抑制できた。この処理は，後続の LVLMM による演出情報およびネーム構造の抽出を安定して行うための重要な前処理として機能している。

5.2.4 文脈理解を促進する画像・セリフの入力

漫画における演出や物語理解は、単一の見開きやコマの内容のみから完結するとは限らない。特に、キャラクターの関係性や感情の変化、ギャグや伏線といった表現は、前後の展開を踏まえて初めて正しく解釈される場合が多い。そのため、対象とする見開き画像のみを LVLM に入力した場合、文脈依存の表現に対して誤った解釈や表層的な記述が生成されることが確認された。

そこで本研究では、対象見開きに関する情報抽出に先立ち、当該場面の前後文脈を LVLM に明示的に与えることで、漫画全体の流れを踏まえた理解を促進する入力構成を採用した。具体的には、対象とする見開き画像に加え、過去 9 ページ分の見開き画像、および次の 1 ページ分の見開き画像を併せて入力として与えた。これにより、直前までの展開や、次に起こる反応を含めた時間的連続性を視覚的に参照可能とした。

さらに、視覚情報だけでなく、テキスト情報としても物語文脈を補強するため、過去ページに含まれる全セリフを、付与済みの読み順アノテーションに基づいて正しい順序で入力した。加えて、それらのセリフ内容を LVLM に要約させたテキストを併用し、長距離文脈を簡潔に保持できるようにした。この要約は、対象見開きに至るまでの物語状況やキャラクター関係を高次の文脈として与える役割を果たす。

このように、見開き画像、個別コマ画像、過去・未来ページの視覚情報、および読み順付きセリフとその要約を組み合わせて入力することで、LVLM は、単一ページに閉じた解釈ではなく、物語全体の流れを踏まえた理解を行えるようになる。実際に、対象見開きの概要文 (Spread summary) には、前段の出来事を前提とした記述や、キャラクターの感情的変化を反映した表現が含まれるようになり、キャラクター名の誤同定や関係性の取り違えも大きく減少することを確認している。

以上の文脈情報を付与した入力構成は、後続の演出情報およびネーム構造の抽出において、場面理解の一貫性と記述の安定性を高める上で重要な役割を果たしている。

図 5.9 は、文脈付与入力により、見開き単体では読解困難な、過去のシーンの状況の理解が必要な場面で生成された概要分の抜粋を示す。このシーンでは、過去に登場した田中重夫という呼称に理解がないと読解できないが、文脈付与入力により正しく状況を理解することができている。

5.3 Manga109NameDataset の統計的特性

本節では、構築した Manga109NameDataset の規模および構成要素の分布について、各ノード種別および付与した属性の統計量を示す。以下では、まずデータセット全体の規模を示し、続いて各ノードに付与された情報の分布について、ノード種別ごとに詳細を述べる。



図 5.9: 文脈付与入力により、見開き単体では理解が困難な場面で、過去の状況を正しく盛り込み正確な理解で summary が生成された例 (漫画:『愛さずにはいられない』©よし まさこ/集英社)。

5.3.1 データセット全体の規模

表 5.1 に、Manga109NameDataset に含まれる見開き (Spread) ノード数、および各ノード種別の総数と、1 Spread あたりの平均数を示す。

表 5.1: Manga109NameDataset に含まれる各ノード種別の総数と 1 Spread あたりの平均数。なお Character ノードについても Spread ごとに集計した数を示す。

ノード種別	総数	平均
Spread	9,827	1.00
Panel	102,600	10.44
Character	39,478	4.02
Character Instance	153,844	15.66
Speech	144,875	14.75

表 5.1 に示された通り、本データセットは、Manga109Dataset に含まれる全見開き画像のうち、内部にコマ (Panel) を有するすべての画像を対象に構築されており、合計 9,827 見開き分のデータを含む。Manga109Dataset に含まれるすべてのコマの数は、全 103,850 コマであり、本データセットの構築においては、その 98.8% のコマに対して情報が抽出されたことを確認した。

5.3.2 Spread ノードに付与された物語情報の統計

表 5.2 に、Spread ノードに付与された概要文 (summary) の文字数分布に関する統計量を示す。

平均で約 110 文字程度の概要文が付与されており、見開き単位での物語内容や文脈を簡潔かつ情報量

表 5.2: Spread ノードに付与された summary の文字数の統計.

項目	数値
Spread の総数	9,827
平均文字数	112.81
中央値文字数	94.00
最小文字数	12
最大文字数	702
標準偏差	79.07

を保った形で記述できていることを確認した.

5.3.3 Panel ノードに付与された構成要素と演出属性の統計

次に, Panel ノードに付与された構成要素と演出属性の統計を示す.

Panel の summary の文字数統計 表 5.3 に, Panel ノードに付与された概要文 (summary) の文字数統計を示す. summary は, 各コマの視覚内容を簡潔に言語化したものであり, 大多数のコマに対して付与されている.

表 5.3: Panel ノードに付与された summary の文字数統計.

項目	数値
Panel の総数	102,600
平均文字数	79.20
中央値文字数	81.00
最小文字数	0
最大文字数	326
標準偏差	37.44

summary の文字数が 0 となったコマは, 全体の 2,058 / 102,600 コマ (約 2.01%) に相当する. これらの多くは, 間 (ま) やリズムを演出することを主目的とした装飾的・演出的性格の強い空白コマであり, その内容自体には summary として記述すべきものが見られないコマであった. 平均すると約 79 文字程度の summary が付与されており, その内容も十分な情報量を含んでいることを確認した.

物語上の役割と形状の分布 各 Panel ノードには, 当該コマが物語の中で果たす役割を示す役割属性が付与されており, また, その形状を示す形状属性が付与されている. 表 5.4, 表 5.5 に, 付与されたすべての役割属性および形状属性それぞれの出現頻度を示す. 役割属性については, 対話 (dialogue_exchange) や反応 (reaction) といった人物中心の役割に加え, 間 (pause_or_ma) や視線誘導

(bridge_or_eye_guidance) など、漫画特有の演出機能を担うコマが多数含まれていることが確認できた。また、コマ形状の属性を見ると、標準的なコマ形状に加え、インセット (inset) や横長・縦長といった多様なレイアウト表現が数多く抽出されていることが確認できた。

表 5.4: 役割属性の分布

役割属性	数
dialogue_exchange	29,993
reaction	29,904
exposition	23,113
showcase_or_impact	21,937
comedic	21,666
pause_or_ma	19,179
action	18,830
transition	17,202
bridge_or_eye_guidance	17,006
romance_or_introspection	13,876
setting_or_background	9,074
hook_or_intro	8,965
time_progression	5,068
flashback	1,591

表 5.5: コマ形状の分布

コマ形状属性	数
inset	45,591
horizontal_yokogoma	22,952
standard	17,951
vertical_tategoma	15,394
double_spread	552
splash_full_bleed	160

カメラ距離およびアングルの分布 Panel ノードには、演出上の視点を表す属性として、カメラ距離およびアングルが付与されている。表 5.6 および表 5.7 に、それぞれの分布を示す。目線高さ (eye_level) を基準とした自然な構図が多数を占める一方で、角度や距離の変化による演出表現も幅広く含まれており、本データセットが多様な視覚的演出を内包していることが確認できた。

表 5.6: カメラ距離の分布

カメラ距離属性	数
MS	29,572
CU	26,226
MCU	16,181
LS	15,249
ECU	5,728
establishing	2,238
XLS	1,780
MLS	1,502
XCU	671

表 5.7: カメラアングルの分布

カメラアングル属性	数
eye_level	66,468
low	7,343
profile_side	7,313
level	6,699
high	5,697
top_shot	2,513
dutch_tilt	2,225
back_view	1,663
bird_eye	223
worm_eye	76

5.3.4 Character ノードの統計的特性

次に, Character ノードの統計的特性を示す. Character ノードは, 物語中に登場する人物そのものを表すノードであり, Panel や Speech のように見開き単位で生成されるのではなく, 作品全体を通して一貫して定義される点に特徴がある. 本データセットでは, Manga109Dataset に含まれる各作品に登場する人物を統合し, 合計 5,375 人のユニークなキャラクターが定義されている.

人物プロフィール記述の統計 Character ノードには, 人物の性格や背景, 物語上の立ち位置を記述したプロフィール文 (profile) が付与される. 表 5.8 に, profile の文字数分布に関する統計量を示す.

表 5.8: Character ノードに付与された profile の文字数統計.

項目	値
キャラクター総数	5,375
平均文字数	71.78
中央値文字数	71.00
最小文字数	0
最大文字数	153
標準偏差	28.24

profile が空であるキャラクターは 21 体 (全体の 0.39%) 存在するが, これらのキャラクターの多くは, 作品にほとんど関与しないモブキャラであることが確認できている. 平均文字数はおよそ 72 文字で, そのキャラクターのプロフィールを表す言語情報が適切に付与されていることを確認した.

Character ノードには, 物語における役割や重要度を表す属性が付与されている. これらの分布を表 5.9 および表 5.10 に示す. 表 5.9 より, 主人公 (protagonist) や副主人公 (deuteragonist) など, 物語の中心人物に相当する役割に加え, 支援者 (supporting) や背景キャラクター (background) など, 補助的・周辺的な役割を担うキャラクターの描写についても属性の抽出が行えていることが確認できた. また, 表 5.10 に示される重要度分布では, main, sub, minor が広く分布しており, 少数の主要キャラクターを軸としつつ, 多数の準主要・脇役キャラクターが物語を構成している典型的な漫画作品の構造が確認できた. このような重要度の階層性は, キャラクターごとの描写密度や演出上の扱いの違いを学習・分析する上で重要な情報となる.

以上より, Manga109NameDataset における Character ノードは, 人物像を表す自由記述と, 物語構造を反映した複数の属性を併せ持つことで, 後続の演出解析やネーム生成において物語的整合性を保持するための基盤情報として機能する.

表 5.9: Character role の分布

役割属性	数
protagonist	9,008
supporting	4,711
background	4,515
deuteragonist	4,443
ally	4,255
antagonist	3,218
love_interest	2,131
mentor	1,561
rival	1,278
family	1,206
tritagonist	1,194
authority	1,113
comic_relief	654
narrator	183
unknown	27

表 5.10: Character importance の分布

重要度属性	数
main	21,455
sub	9,655
minor	8,281
cameo	81
unknown	25

5.3.5 Character Instance ノードの統計的特性

次に, Character Instance ノードの統計的特性を示す. Character Instance ノードは, 特定のコマ内におけるキャラクターの具体的な描写を表すノードであり, 姿勢・動作・感情といった視覚的および演出的な情報を担う. 同一の Character ノードが複数のコマに登場する場合でも, それぞれの描写は独立した Character Instance として定義されるため, 本ノードはデータセット内で最も出現数の多いノード種別となっている. 本データセットでは, 合計 153,867 個の Character Instance ノードが含まれている.

自由記述属性（姿勢・動作・感情）の文字数分布 Character Instance ノードには, 描画内容を言語的に記述した自由記述属性として, 姿勢の記述, 行動の記述, 感情の記述の 3 項目が付与されている. 表 5.11 に, 各属性の文字数分布に関する統計量を示す.

2,687 体 (全体の約 1.75%) の描画は, 姿勢, 行動, 感情のいずれも空白であったが, これらの多くはキャラクターが背景として小さく描かれている場合などであることを確認した. 平均文字数もそれぞれの項目を記述するのに十分な長さであることを確認した.

姿勢・動作・感情に関する離散属性の分布 自由記述に加え, Character Instance ノードには, 姿勢・動作・感情を離散的なカテゴリとして表現する属性が付与されている. また加えて, その描画が顔を中心としているか, それとも体を中心としているかを表す属性も付与されている. これらの属性は, 自然

表 5.11: Character Instance ノードに付与された自由記述属性の文字数統計

姿勢		行動		感情	
項目	値	項目	値	項目	値
平均文字数	38.69	平均文字数	44.31	平均文字数	21.46
中央値文字数	41.00	中央値文字数	48.00	中央値文字数	23.00
最小文字数	0	最小文字数	0	最小文字数	0
最大文字数	178	最大文字数	218	最大文字数	97
標準偏差	19.68	標準偏差	27.95	標準偏差	10.90

言語記述を補完する構造化情報として機能する。表 5.12, 表 5.13, 表 5.14, 表 5.15, に, 各属性値の分布を示す。

これらの分布から, Character Instance に付与された離散属性は, 漫画表現において頻出する描画様式や行動・感情を幅広くカバーできていることを確認した。姿勢属性 (表 5.12) では, head_shot や upper_body といった顔や上半身を中心とした描写が多く, 感情表現や対話を重視する漫画的演出の傾向が反映されていることが確認できた。行動属性 (表 5.13) においては, speak, watch, listen など, 会話や相互注視に関わる行動が高頻度で現れており, キャラクター間の関係性が物語進行の中心となっていることが読み取れる。感情属性 (表 5.14) では, anxious, neutral, shocked, happy といった物語展開上重要な感情状態が多く含まれていることが確認できた。さらに, face_body 属性 (表 5.15) より, 顔と身体の両方を含む描写が大半を占める一方で, 顔のみ・身体のみの描写も一定数存在し, 演出上の強調や省略が構造的に表現されていることを確認した。

以上より, Character Instance ノードは, 詳細な自然言語記述と多様な離散的属性を併せ持つことで, コマ内におけるキャラクター表現を多角的に捉えるための情報構造を形成していることが確認できた。

5.3.6 Speech ノードの統計的特性

次に, Speech ノードの統計的特性を示す。Speech ノードは, 漫画における吹き出しや文字表現を単位として, 発話内容およびその機能的役割を表すノードである。発話内容は Manga109Dataset に含まれている値をそのまま用いて, 本データセットの構築においては, 機能的な役割を付与した。各 Speech ノードは, 特定のコマおよびキャラクターインスタンスと結び付けられる。本データセットには, 合計 141,879 個の Speech ノードが含まれている。

発話テキストの文字数分布 Manga109Dataset に含まれる発話内容をそのまま格納したテキスト属性についてその統計量を表 5.16 に示す。

表 5.12: 姿勢属性の分布

姿勢属性	数
head_shot	31,905
upper_body	22,865
partial_body	12,073
profile	8,536
standing	7,649
back_view	5,642
leaning	3,366
sitting	3,087
full_body	2,166
walking	1,132
dynamic	1,093
running	813
background	643
lying_down	486
falling	352
crouching	304
silhouette	228
floating	199
jumping	165
lying_prone	131
lying_back	93
chibi	59
all_fours	44
split	38
leg_up	35
restrained	16
backbend	13
lying_side	5
kneeling	4
straddling	3
crossed_legs	1
other	48,022

表 5.13: 行動属性の分布

行動属性	数
speak	30,012
watch	23,271
object_handling	6,057
listen	4,770
stand	3,497
interact	2,806
perform	2,604
move	2,523
consume	2,152
ask	2,152
fight	1,992
gesture	1,991
think	1,910
walk	1,902
explain	1,861
physical_response	1,712
run	1,611
sit	1,586
fall	1,226
chase	1,012
sleep	864
wait	862
cheer	798
defend	747
smile	638
hide	479
laugh	405
fly	379
greet	352
cry	332
tremble	280
other	48,385

表 5.14: 感情属性の分布

感情属性	数
anxious	21,546
neutral	12,933
shocked	9,579
happy	9,338
calm	6,603
afraid	6,216
angry	5,972
sad	5,335
surprised	5,315
determined	5,283
confused	3,895
excited	3,815
confident	3,345
serious	3,060
frustrated	2,448
worried	2,318
curious	2,106
desperate	1,405
tired	1,146
affectionate	955
hostile	900
disgusted	761
embarrassed	698
suspicious	672
thoughtful	572
bored	102
other	34,850

表 5.15: face_body 属性の分布

face_body 属性	数
face&body	113,740
body_only	39,191
face_only	936

表 5.16: Speech ノードに付与された発話テキストの文字数統計

項目	値
平均文字数	13.79
中央値文字数	11.00
最小文字数	1
最大文字数	273
標準偏差	10.87

発話種別の分布 次に, Speech ノードに付与した, 発話の機能や性質を表す離散的な属性, 発話種別属性についてその分布を表 5.17 に示す.

表 5.17: Speech ノードにおける発話種別属性の分布

発話種別属性	数
dialogue	85,563
shout_reaction	29,534
inner_monologue	12,475
narration	6,702
sound_effect	1,567
broadcast	1,534
other	1,148
ambient_text	1,002
signage	971
meta_commentary	921
song_or_chant	462

対話 (dialogue) が全体の過半数を占める一方で, 感嘆や反応を表す `shout_reaction`, 内面描写を担う `inner_monologue`, 場面説明を行う `narration` など, 多様な発話機能が含まれていることが分かる. また, 擬音語や環境音を表す `sound_effect`, 標識や看板などの `signage` も明示的に区別されており, 漫画特有の文字表現を幅広く網羅できていることが確認できた.

以上より, Speech ノードは, 短い会話から説明的テキストまでを包含する多様な言語表現を保持しており, 視覚表現と結び付いた物語構造を解析する上で重要な役割を果たす.

5.3.7 キャラクター間相互作用を表す Action Edge の統計

Action Edge は, 同一コマ内あるいは連続するコマ内において, キャラクターインスタンス同士がどのような相互作用を持つかを, 自由記述形式で表現したエッジである. これらは, 視線の向き, 接触, 攻撃, 援助といった明示的な行動関係が記述されている.

表 5.18 に, Action Edge に付与された記述文の文字数に関する統計量を示す. 本データセットには, 合計 38,633 件の Action Edge が含まれており,

このような記述長の分布から, 相互作用が「誰が誰に何をしているか」という最小限の意味単位として安定して抽出されていることが確認できた. Action Edge は, キャラクター配置や視線関係, 対話構造といった情報と組み合わせることで, ネーム全体の演出的関係性をグラフ構造上で補完する役割を果たす.

表 5.18: Action Edge に付与された相互作用記述の文字数統計

項目	値
Action Edge 総数	38,633
最小文字数	6
最大文字数	86
平均文字数	32.90
中央値文字数	34.00

5.4 構造化データの可視化例

本節では、図 5.10 に示す一つの見開き漫画を入力として、本研究の手法により段階的に抽出・構造化された Manga109NameDataset における 1 サンプルデータの可視化の具体例を示す。




図 5.10: 本節で例示する Manga109NameDataset の入力見開き画像 (漫画:『あっけら貫刃帖』©小林 ゆき/集英社).




図 5.11: 構築された階層構造の例. Inst は CharacterInstance ノードを表す.

Spread (Count: 1)

#0
spread_82

TEXT EMBED

Sum: 須磨一成が「悪の忍者」と疑う谷尾周に対し、自作の「50センチ...

+

Scr: 【SPREAD spread_82】 【PANEL pane...

+

Note: Issei's attack successfully la...

図 5.12: Spread ノードの例.

Panel (Count: 6)




図 5.13: Panel ノードの例.

Speech (Count: 5)




図 5.14: Speech ノードにの例.




図 5.15: キャラクターインスタンス間の相互作用 (Action Edge) の例. C_inst は CharacterInstance ノードを表す.




図 5.16: 同一ページ内の Panel 間の参照関係の例. Pnl は Panel ノードを表す.




図 5.17: CharacterInstance と CharacterNode 間の参照関係の例. C_inst は CharacterInstance ノードを表し, Globalchar は Character ノードを表す.




図 5.18: Speech と Character Instance および Character を結ぶ参照関係の例. C_inst は CharacterInstance ノードを表し, Sp は Speech ノードを, Globalchar は Character ノードを表す.

第 6 章 脚本に基づく漫画のネーム生成

本章では、構築した Manga109NameDataset を用いて、脚本に基づき漫画のネームを生成する手法について述べる。

本研究では、ネームを、要素の幾何学的な配置を表すレイアウト情報 (Layout) と演出情報 (Direction) が統合された、物語と作品とを結ぶ中間表現として定義する。Manga109NameDataset は、この定義に基づき、漫画画像に由来するネーム情報を構造化データとして整理・構築したものである。

第 4 章で扱った脚本に基づくレイアウト生成では、物語内容がコマや要素の配置にどのように反映されるかに着目していた。これに対し本章では、Manga109NameDataset を用いて配置そのものに加え、カメラワークやキャラクターの感情、場面の雰囲気といった演出情報を含むより包括的なネーム生成を対象とする。

すなわち本研究では、脚本 (Script) を入力とし、演出情報 (Direction) およびレイアウト情報 (Layout) を生成することで、脚本からネームへ至る生成過程を計算機上で明示的に扱うことを目的とする。

本章の構成は以下の通りである。まず 6.1 節では、脚本・演出情報・レイアウト情報からなるネーム生成タスクの問題設定を整理し、定式化を行う。次に 6.2 節において、脚本からネームを生成するための手法の概要を述べ、演出情報およびレイアウト情報をどのように扱うかを説明する。6.3 節では、実験設定および評価方法について述べ、最後に 6.4 節で、定量的および定性的な評価結果を示し、脚本に基づくネーム生成の有効性について考察する。

6.1 漫画のネーム生成における問題設定

本節では、本研究における漫画のネーム生成タスクの問題設定を整理する。特に、脚本 (Script)・演出情報 (Direction)・レイアウト情報 (Layout) からなる三層構造の観点から、本研究が対象とする生成問題を脚本 (Script) を入力とし、演出情報 (Direction) およびレイアウト情報 (Layout) を生成する問題として定式化する。図 6.1 にその概略図を示す。




図 6.1: 脚本に基づく漫画ネーム生成タスクの概略図

6.1.1 ネーム表現の定義

本研究では、第 4 章第 4.1 節で述べたレイアウト表現を拡張し、漫画のネームを、 $N \in \mathbb{N}$ 個の構成要素と、場面全体に関わる演出情報からなる表現として定義する。具体的には、ネーム n を

$$n = (\mathbf{d}^{\text{global}}, \{(c_1, \mathbf{d}_1, \mathbf{b}_1), \dots, (c_N, \mathbf{d}_N, \mathbf{b}_N)\}) \quad (6.1)$$

と定義する。

ここで c_i は i 番目の要素のカテゴリを表し、 $\mathbf{d}_i$ はその要素に対応する局所的な演出情報、 $\mathbf{b}_i$ はページ平面上における位置と大きさを表すバウンディングボックスである。また、 $\mathbf{d}^{\text{global}}$ は、見開き全体や場面単位で共有されるグローバルな演出情報を表す。

カテゴリ c_i は、コマ、キャラクター、セリフといった基本要素種別に基づくカテゴリ集合 $\mathcal{C}$ の要素であり、 $\mathcal{C}$ は

$$\mathcal{C} = \{\text{panel}\} \cup \{\text{character}_k\} \cup \{\text{speech}_k\} \quad (6.2)$$

として定義される。

局所的な演出情報 $\mathbf{d}_i$ には、キャラクターの姿勢や感情、カメラ距離やアングルといった要素単位で定義される演出属性が含まれる。一方、グローバルな演出情報 $\mathbf{d}^{\text{global}}$ には、主にノード間の関係において現れるエッジ情報に紐づく演出情報が含まれる。レイアウト情報 $\mathbf{b}_i$ は、各要素のページ上での配置を表す幾何学的情報である。

6.1.2 ネーム生成タスクの定式化

以上の定義のもと、本研究におけるネーム生成タスクは、脚本情報 s が与えられたとき、対応するネーム n を生成する条件付き生成問題として定式化される。すなわち、

$$f: s \mapsto (\mathbf{d}^{\text{global}}, \{(c_i, \mathbf{d}_i, \mathbf{b}_i)\}_{i=1}^N) \quad (6.3)$$

を学習することが目的である。

第 4 章で扱った脚本に基づくレイアウト生成では、 $\mathbf{b}_i$ のみを生成対象としていたのに対し、本章では、局所およびグローバルな演出情報 $\mathbf{d}_i$, $\mathbf{d}^{\text{global}}$ とレイアウト情報 $\mathbf{b}_i$ を統合的に生成する点が異なる。これにより、脚本に含まれる物語的文脈が、配置設計だけでなく、場面全体および要素単位の演出上の意思決定にどのように反映されるかを明示的に扱うことが可能となる。

6.2 脚本に基づく漫画のネーム生成手法

本節では、前節で定式化した脚本に基づく漫画のネーム生成タスクに対し、本研究で用いた生成手法の概要を述べる。本研究では、脚本 (Script) を入力とし、演出情報 (Direction) およびレイアウト情報 (Layout) を自然言語系列として出力する LLM に基づくネーム生成手法を構築した。

基本的な枠組みは、第 4 章で述べた脚本に基づくレイアウト生成手法と同様に、LLM を教師あり学習によりファインチューニングするものである。すなわち、脚本表現をトークン列として入力し、対応するネーム表現を自己回帰的に出力するモデルを構築した。

入力となる脚本 S は、柱、ト書き、およびセリフを含む見開き単位の脚本全文に加え、脚本に登場するキャラクターのプロフィールや役割といったキャラクター設定を含む自然言語列として与えられる。これにより、モデルは物語の進行だけでなく、キャラクターの性格や立場といった文脈情報を条件として利用できる。

ネーム生成においては、LLM による生成および学習を可能にするため、入力および出力をあらかじめ定めた JSON 形式に基づいて線形化し、トークン列として表現する。

具体的には、ネームの構造を表す JSON テンプレートを事前に定義し、コマ、キャラクターインスタンス、セリフといった各要素に対応するフィールドを所定の位置に配置する。モデルは、このテンプレ

レート構造を条件として、演出情報 (Direction) およびレイアウト情報 (Layout) に対応するフィールドを逐次生成する。

このとき、ネームを構成する要素集合 $\{(c_i, \mathbf{d}_i, \mathbf{b}_i)\}_{i=1}^N$ は、JSON 構造に沿って列挙され、系列

$$\mathcal{N} = (\nu_1, \nu_2, \dots, \nu_T) \quad (6.4)$$

として表現される。各トークン ν_t は、単一の要素に対応する

$$\nu_t = (c_{\pi(t)}, \mathbf{d}_{\pi(t)}, \mathbf{b}_{\pi(t)}) \quad (6.5)$$

として定義され、 $\pi(t)$ はネームを構成する全要素を一度ずつ列挙する写像である。

演出情報 $\mathbf{d}_i$ は、キャラクターの姿勢や感情、カメラ距離やアングル、コマの役割といった要素単位で定義される演出属性の集合であり、自然言語または離散的な記号列として表現される。また、見開き全体や場面単位で共有されるグローバルな演出情報 $\mathbf{d}^{\text{global}}$ についても、同様に JSON テンプレート内の所定の位置に配置し、系列生成の一部として扱う。

レイアウト情報 $\mathbf{b}_i$ は、各要素のページ平面上での位置と大きさを表すバウンディングボックス $\mathbf{b}_i = (x_i, y_i, w_i, h_i)$ として定義され、脚本に基づくレイアウト生成と同様に、あらかじめ定義した格子上に量子化された離散トークンとして出力される。

学習時には、漫画のレイアウト生成手法と同様に、脚本列 S と、それに対応する正解ネーム列 $\mathcal{N}$ からなる教師データを用い、LLM による条件付き確率

$$p_{\theta}(\mathcal{N} | S) = \prod_{t=1}^T p_{\theta}(\nu_t | \nu_{<t}, S) \quad (6.6)$$

を最大化するように、モデルパラメータ θ を最適化する。損失関数としては、次トークン予測に基づくクロスエントロピー損失を用いる。

以上のように、本研究では、キャラクター設定を含む脚本を入力とし、演出情報およびレイアウト情報を構造化された形式で生成することで、物語内容と演出設計とを統合したネーム生成を、LLM による条件付き系列生成として実現する。

6.3 漫画のネーム生成における実験設定

本節では、脚本に基づくネーム生成手法の有効性を検証するために行った実験設定について述べる。具体的には、実験に用いた Manga109NameDataset に含まれる脚本 (Script)、演出情報 (Direction)、レイアウト情報 (Layout) の構成を整理した上で、これらの情報をどのように入力・出力として扱うかを定義する生成設定を説明する。さらに、データセット分割、比較に用いたモデル、学習および実装条件、ならびに評価方法について順に述べる。

6.3.1 データセットと入力・出力の整理

本研究では、脚本からネームを生成する過程を扱うにあたり、まずデータセット内に含まれる情報を、脚本 (Script)、演出情報 (Direction)、およびレイアウト情報 (Layout) という三層構造の観点から整理する。これは、どの情報を入力として与え、どの情報を生成対象とするかを明確に定義するための前提となる。

Manga109NameDataset に含まれる主要なノードおよび属性を、この三層構造に基づいて分類した結果を表 6.1 に示す。Script 層には、見開き全体の脚本本文に加え、登場キャラクターのプロフィールや役割といったグローバルな物語文脈に関わる情報が含まれる。Direction 層には、各コマやキャラクターインスタンスに対応する演出上の意思決定を表す属性、ならびにコマ間・キャラクター間の関係を表す構造的情報が含まれる。Layout 層は、これらの要素がページ平面上でどの位置・大きさに配置されるかを表す幾何学的情報から構成される。

表 6.1: Manga109NameDataset における Script/Direction/Layout 構成の整理

層	ノード	フィールド	内容
Script	Spread	summary, script, mood, notes	見開き全体の要約・脚本 (柱/ト書き/セリフ)・雰囲気・補足
	Character	name, profile, role, importance, alignment, relation_to_protagonist	キャラクター設定 (プロフィール、役割、重要度、主人公との関係など)
	Speech	text, speaker_id	セリフ本文と話者識別 ID
	Structure	panel_ids	脚本中で言及されるパネル ID 列
Direction	Panel	summary	各コマの内容要約 (視覚的説明)
	Panel	roles (categorical)	コマの役割 (dialogue, reaction 等)
	Panel	shape_type	コマ形状 (standard, inset 等)
	Panel	cinematic.distance, cinematic.angle	カメラ距離・アングル
	Char. Inst.	pose, action, emotion	姿勢・動作・感情 (自由記述テキスト)
	Char. Inst.	pose, action, emotion, face.body	姿勢・動作・感情・描写範囲 (離散カテゴリ)
		(all categorical)	

次ページへ続く...

表 6.1: Manga109NameDataset における主要フィールドの構成 (続き)

層	ノード	フィールド	内容
	Speech	type (categorical)	セリフ種別 (dialogue, monologue 等)
	Edges	panel_edges	コマ間関係 (順序や同一ページ判定)
	Edges	action_edges	キ ャ ラ ク タ ー 間 相 互 作 用 (source/target/action)
	Edges	anchored_to	セリフのアンカー (Speech $\rightarrow$ Character)
	Edges	contains (pred.)	Panel $\rightarrow$ Speech/Character の包含関係 (予測)
	Panel	bbox	バウンディングボックス $\mathbf{b}_i = (x, y, w, h)$
	Char. Inst.	bbox	同上 (キャラクター位置)
Layout	Speech	bbox	同上 (セリフ位置)

このように Script / Direction / Layout を整理した上で、本研究では、脚本からネームを生成する際の情報生成の関係性を検証するため、入力と出力の組み合わせが異なる複数の生成設定を比較した。表 6.2 に、本研究で検討した 4 つの生成設定を示す。これらの設定は、脚本のみを入力としてレイアウトを生成する設定から、演出情報とレイアウトを同時に生成する設定、さらに演出情報を中間表現として経由する段階的生成設定まで、ネーム生成における生成粒度と生成順序が異なる点で区別される。特に、Script2(Direction+Layout) は演出情報とレイアウト情報を統合的に生成する設定であり、Script2Direction2Layout は演出情報を明示的な中間表現として導入することで、段階的生成の有効性を検証するための設定である。

表 6.2: 脚本に基づくネーム生成の比較設定。GNN は Graphical Neural Network を表す。

設定名	入力	出力	モデル構成
Script2Layout	Script	Layout	LLM
Script2(Direction+Layout)	Script	Direction + Layout	LLM
(Script+Direction)2Layout	Script + Direction	Layout	LLM
Script2Direction2Layout	Script	Direction $\rightarrow$ Layout	LLM + GNN

本研究では、これらの設定に基づき、脚本からネーム生成へ至る過程を異なる情報分解および生成順序の観点から比較する。これらの生成設定は、実際の漫画制作において、演出を先に検討する場合や、配置設計と演出を同時に検討する場合など、制作工程や作家の作業スタイルに応じてネームの設計手順が異なる状況を抽象化したものである。このような複数の生成設定を通じて、脚本からネームを構築す

る際に、演出情報をどの段階でどのように扱うことが有効であるかを体系的に検証する。

6.3.2 データセット分割

学習に用いた Manga109NameDataset は、作品単位で分割し、同一作品が訓練用・検証用・テスト用データにまたがらないようにした。分割比は 8:1:1 訓練用データ 7,937 見開き、検証用データ 1,113 見開き、テスト用データ 991 見開きを用いた。

訓練用データは各生成設定におけるモデルの学習に、検証用データは学習の早期終了およびモデル選択に用い、最終的な性能評価はテスト用データ上で行った。なお、データセット分割および前処理の方針は、第 4 章のレイアウト生成実験と同一である。

6.3.3 比較手法

脚本に基づくネーム生成手法の有効性の検証においても第 4 章のレイアウト生成実験と同様、既存のレイアウト生成手法との比較を行った。比較に用いた手法も同じく、LayoutDM [13], LayoutFormer++ [14], LayoutPrompter [15] の 3 手法である。これらの既存手法は、ネーム生成における比較においても、要素カテゴリ情報を入力条件として与える Gen-T 条件での生成に用い、脚本を条件とする生成条件にあわせてレイアウト生成性能の比較に用いた。

ほか学習の設定や推論の設定は、グリッド条件を見開き単位に対応させることを除いて第 4 章のレイアウト生成実験と同様である。

6.3.4 ネーム生成における学習設定および実装詳細

本節では、表 6.2 に示した各生成設定において用いたモデル構成と学習条件、ならびに実装上の設定について述べる。LLM による生成設定である Script2Layout / Script2Name (Joint) / (Script+Direction)2Layout では、教師ありファインチューニングを行った。一方、段階的生成設定 Script2Direction2Layout では、演出情報の生成に LLM をファインチューニングし、レイアウト生成にはグラフニューラルネットワーク (GNN) を用いた。

LLM の選定 本実験では、LLM として GPT-OSS-20b [83], Qwen3-14B [84], Llama-3.1-8B [85] を選定した。これらはいずれも公開モデルの中で比較的新しく、汎用的な言語能力において高い評価を得ていることから採用した。複数の基盤モデルを用いることで、モデル規模や事前学習の差異がネーム生成性能に与える影響を検証した。学習は、各見開きの脚本（および条件に応じて演出情報）を入力とし、JSON 形式に線形化した出力列を教師信号として、次トークン予測に基づくクロスエントロピー損失を最小化することで行った。学習手順は、第 4 章のレイアウト生成と同様である。詳細な学習設定は付録 A.2 に示す。

GNN によるレイアウト生成 (Script2Direction2Layout) 段階的生成設定 Script2Direction2Layout では、まず LLM により脚本から演出情報 (Direction) を生成し、得られた Direction を条件として GNN によりレイアウト (BBox) を推定した。GNN は、見開きを表す異種グラフを入力とする HeteroConv に基づくモデルとして実装し、ノード種別は Spread / Panel / Character / Character Instance / Speech とした。エッジには、キャラクターインスタンス間の相互作用 (action edges), Panel と Character Instance の包含関係, Speech の読順関係など, Manga109NameDataset に含まれる主要な関係情報を用いた。各ノードには、対応するテキスト特徴および演出属性を付与し、メッセージパッシングによって特徴を更新した後, Panel, CharacterInstance, Speech の各ノードに対して混合密度ネットワーク (MDN) を用いてバウンディングボックスを推定した。詳細なアーキテクチャについては付録 A.3 に示す。

レイアウト表現の量子化と座標系 レイアウト情報は、各要素のバウンディングボックス $\mathbf{b}_i = (x_i, y_i, w_i, h_i)$ として表現される。LLM および GNN による生成を可能にするため、これらの連続値座標は、あらかじめ定義した格子上に量子化された離散トークンとして扱った。

第 4 章のレイアウト生成ではページ単位の生成を対象としていたため、座標系を 32×32 の格子として定義していたのに対し、本章では見開き単位のネーム生成を扱うことから、横方向の表現範囲を拡張し、 64×32 の格子を用いた。これにより、見開き全体を一貫した座標系で表現しつつ、既存のレイアウト生成手法との整合性を保った。

6.3.5 評価方法

本研究では、脚本に基づくネーム生成手法の有効性を検証するため、主としてレイアウト生成結果に対する定量評価を行った。レイアウトに関する評価指標および評価手順は、第 4 章で用いたものと同一であり、mIoU, FID, LTSim, LTSim-MMD を用いた。これらの指標により、要素の位置や大きさといった幾何的配置の再現性を、正解レイアウトとの比較に基づいて評価した。そのため、本章では各評価指標の詳細な定義については省略する。

一方で、演出情報 (Direction) については、直接的な定量評価は行っていない。これは、Direction がカメラワーク、感情表現、場面の雰囲気といった高次の意味的・主観的要素を含むため、単一の数値指標として妥当な正解度を定義することが現時点では困難であるためである。

そこで本研究では、演出情報の生成結果について、二つの観点から評価を行った。第一に、生成された Direction をノードおよび関係からなるグラフ構造として可視化し、対応する正解データと比較することで、キャラクター配置関係や演出上の役割分担が脚本内容と整合しているかを定性的に分析した。

第二に、段階的生成設定 Script2Direction2Layout においては、Direction を入力としてレイアウトを生成するグラフニューラルネットワーク (GNN) を評価器として用い、生成された Direction の妥

当性を間接的に評価した。具体的には、同一の GNN に対して、正解 Direction および LLM により生成された Direction をそれぞれ入力し、得られたレイアウト結果を正解レイアウトと比較することで、Direction がレイアウト生成に提供する構造的情報の再現性を評価した。この評価は、Direction の意味内容そのものを直接測定するものではないが、下流タスクであるレイアウト生成に対してどの程度有効な情報を保持しているかを定量的に比較するための指標として位置づけられる。

以上の評価方法により、本研究では、ネーム生成におけるレイアウトの幾何的再現性と、演出情報の構造的妥当性の双方について、定量的および定性的な観点から分析を行った。演出情報に対するより直接的な定量評価指標の設計については、今後の課題とする。

6.4 漫画のネーム生成における結果と考察

本節では、前節で述べた各生成設定に基づく実験結果をもとに、既存のレイアウト生成手法との比較や、演出情報の統合方法の違いについて考察する。

6.4.1 ネーム生成におけるレイアウト生成性能の定量的評価

まず、表 6.3 に、ネーム生成に伴うレイアウト生成の定量的結果を示す。

既存レイアウト生成手法との比較 まず、カテゴリ既知条件下で動作する既存のレイアウト生成手法 (LayoutDM, LayoutFormer++, LayoutPrompter) と、脚本を入力としてネーム生成を行う本研究の手法を比較する。表 6.3 に示すように、mIoU や LTSim といった、正解の見開きとの一対一対応で評価する指標では、Llama をベースモデルとしたものを除き、多くの場合同等かそれ以上の性能を示した。特に、LTSim では、GPT-OSS-20B, Qwen3-14B をベースモデルとした手法は、入出力の設定の違いに関わらず、既存手法を上回る性能を示した。また、FID や LTSim-MMD といった、正解レイアウトとの分布の類似度を評価する指標では、特に FID で大きな性能差が見られ、既存手法同士の差の最大値が (LayoutDM と LayoutPrompter の差)10.8 程度であるのに対し、提案手法では、既存手法の最高性能である LayoutDM の値 (54.095) を、30 以上の差をもって精度が向上する設定が多く見られた。これは、入力に脚本情報を含め、LLM を通してレイアウトを生成することで、その文脈に応じたより正確なレイアウトの生成が可能になったことを示唆する。

演出情報の統合方法の違いによる比較 次に、演出情報 (Direction) をどの段階でレイアウト生成に統合するかの違いに注目する。表 6.3 に示す結果から、演出情報を脚本と結合し条件として与える設定 ((Script + Direction) $\rightarrow$ Layout) は、多くの指標において最も高い性能を示していることが分かる。特に Qwen3-14B を用いた場合には、LTSim, FID, LTSim-MMD の指標で他の設定を上回る結果が得られた。これらの結果は、演出情報を明示的な条件として与えることが、レイアウト生成においては有効であることを示唆しており、これは演出情報とレイアウト情報が密接な関係にあることを

表 6.3: 脚本に基づくネーム生成におけるレイアウト生成の定量評価結果.

Model	Spread-level metrics		Distribution-level metrics	
	mIoU $\uparrow$	LTSim $\uparrow$	FID $\downarrow$	LTSim-MMD ($\times 10^{-2}$) $\downarrow$
<i>Existing layout generation methods (Category-conditioned)</i>				
LayoutDM	0.0989	0.7064	54.095	<u>0.645</u>
LayoutFormer++	0.0325	0.5632	56.520	5.258
LayoutPrompter	0.0964	0.6739	64.941	1.912
<i>Script2Layout (Fine-tuned LLM)</i>				
GPT-OSS-20B	0.1177	0.7333	18.88	1.239
Llama-3.1-8B	0.0142	0.4165	166.84	64.060
Qwen3-14B	0.1269	0.7421	<u>18.72</u>	0.869
<i>Script $\rightarrow$ (Direction + Layout) (Fine-tuned LLM)</i>				
GPT-OSS-20B	<u>0.1201</u>	0.7360	19.76	1.041
Llama-3.1-8B	0.0140	0.4154	168.78	64.681
Qwen3-14B	0.1254	0.7434	19.72	0.903
<i>(Script + Direction) $\rightarrow$ Layout (Fine-tuned LLM)</i>				
GPT-OSS-20B	0.1086	<u>0.7484</u>	14.52	0.712
Llama-3.1-8B	0.0162	0.4212	165.30	64.174
Qwen3-14B	0.1178	0.7711	9.21	0.499
<i>Script2Direction2Layout (Fine-tuned LLM $\rightarrow$ GNN)</i>				
GPT-OSS-20B	0.0851	0.7123	78.45	2.192
Llama-3.1-8B	0.0772	0.7055	105.10	3.753
Qwen3-14B	0.0822	0.7106	74.97	2.350

示唆する。また、演出情報をレイアウトと同時に生成する統合設定 (Script $\rightarrow$ (Direction + Layout)) と、演出情報を明示的に扱わない設定 (Script2Layout) を比較すると、その差は比較的小さく、特に FID では、Llama-3.1-8B をベースモデルとした場合を除き、どちらの設定においても既存手法よりも大きな性能の向上を示している。このことから、演出情報の出力の有無という難易度の差は、脚本に基づくレイアウト生成の性能に与える影響が小さく、演出情報とレイアウトのどちらも脚本情報をもとに、その出力の傾向を推定できることを示唆する。一方で、演出情報を中間表現とし、レイアウトまでを段階的に生成する設定 (Script2Direction2Layout) に着目すると、基盤モデルによって性能変化の傾向が異なることが分かる。具体的には、Llama-3.1-8B をベースモデルとした場合には性能が向上する一方、GPT-OSS-20B および Qwen3-14B をベースモデルとした場合には、性能が低下する傾向が見られた。Llama-3.1-8B をベースモデルとしたものは、多くの設定で、既存手法よりも精度が悪く、GPT-OSS-20B、Qwen3-14B とは異なる傾向を持っている。このように、レイアウト生成における出力精度の差異が近づくよう性能が変化したことから、GNN によるレイアウト生成が、入力される演出

情報のばらつきを吸収し、出力を一定の構造に収束させる可能性を示唆する。GNN が構造的制約を課すことでレイアウトの一貫性や安定性を向上させる効果を持つ一方、すでに高い精度でレイアウトを生成することが可能な LLM に対しては、その自由度を制限する方向に働き、結果として性能低下として観測された可能性がある。

ベースモデル間の性能の比較 最後に、使用する基盤モデルの違いがネーム生成におけるレイアウトの生成性能に与える影響について考察する。表 6.3 に示すように、mIoU や LTSim といった見開き単位での対応関係を評価する指標、および FID や LTSim-MMD といった分布レベルの指標のいずれにおいても、Qwen3-14B および GPT-OSS-20B を基盤モデルとした手法は、多くの生成設定で安定して高い性能を示している。一方で、Llama-3.1-8B を基盤モデルとした場合には、すべての生成設定において mIoU および LTSim が低く、また FID や LTSim-MMD においても分布の乖離が大きい。この傾向は、演出情報を明示的に扱うか否か、あるいは段階的生成を行うかといった設定の違いに関わらず一貫して観測されており、レイアウト生成性能の差が生成設定よりも基盤モデルの特性に強く依存していることを示唆している。この結果は、脚本からネームを生成するというタスクが、単なる言語生成にとどまらず、複数要素間の空間的・構造的整合性を暗黙的に推論する能力を要求することと関係していると考えられる。Qwen3-14B や GPT-OSS-20B は、このような構造化出力を伴う生成において比較的高い一貫性を保っているのに対し、Llama-3.1-8B は、JSON 形式で表現された複雑なレイアウト情報の生成において誤差が蓄積しやすい傾向を持つ可能性がある。また、モデルの大きさの違いに着目すると、本タスクにおいては、より大きなモデルが適しており、高い表現力を要するタスクであることが示唆される。

以上より、脚本に基づくネーム生成では、LLM のファインチューニングモデルが多くの設定で高い性能を有していることが確認され、また生成設定の工夫に加えて、構造的制約を内包した出力を安定して生成できる基盤モデルの選択が重要であることが示唆される。

6.4.2 GNN を用いた演出情報生成の間接的評価

本研究では、演出情報 (Direction) そのものに対する直接的な定量評価指標を設計していないため、生成された Direction の妥当性をレイアウト生成結果を通じて間接的に評価する。具体的には、GNN によるレイアウト生成を演出情報の構造的整合性を測る評価器として位置づけ、入力される Direction の違いが最終的なレイアウト性能に与える影響を比較した。表 6.4 に、Ground Truth (GT) Direction、および各 LLM により生成された Direction を入力として同一の GNN を用いてレイアウトを生成した場合の定量評価結果を示す。

まず、正解 (GT) Direction を入力とする理想的設定では、すべての指標において最良な結果を示しており、少なくとも本 GNN が、Direction に含まれる関係情報や演出属性から一定程度妥当なレイア

表 6.4: GNN によるレイアウト生成性能を指標とした、演出情報 (Direction) 生成品質の間接的評価結果。正解 (GT) Direction を用いた 理想的設定 と、各 LLM により生成された Direction を用いた場合を比較する。

Direction Source	Spread-level metrics		Distribution-level metrics	
	mIoU $\uparrow$	LTSim $\uparrow$	FID $\downarrow$	LTSim-MMD ($\times 10^{-2}$) $\downarrow$
<i>Oracle setting (GT Direction)</i>				
Ground Truth	0.1066	0.7310	73.94	2.062
<i>Predicted Direction (Script2Direction2Layout)</i>				
GPT-OSS-20B	<u>0.0851</u>	<u>0.7123</u>	78.45	<u>2.192</u>
Llama-3.1-8B	0.0772	0.7055	105.10	3.753
Qwen3-14B	0.0822	0.7106	<u>74.97</u>	2.350

ウトを復元できていることを示しており、Direction がレイアウト生成にとって有効な中間表現となり得ることを示唆する。

一方、各 LLM が生成した Direction を入力とする場合には、いずれのモデルでも GT 条件から性能が低下しており、Direction 生成誤差がレイアウト推定へ伝播していることが示唆される。なかでも GPT-OSS-20B と Qwen3-14B は、mIoU (0.0851/0.0822) および LTSim (0.7123/0.7106) で比較的近い値を示し、Llama-3.1-8B は mIoU=0.0772, LTSim=0.7055 と低い。分布指標でも同様の傾向が見られ、特に Llama-3.1-8B は FID=105.10, LTSim-MMD=0.0375 と大きく悪化しており、生成された Direction のばらつきや構造的不整合が GNN の出力分布を崩している可能性が高いと考えられる。これに対し Qwen3-14B は FID=74.97 と GT に近い値を示しており、分布レベルでは GT Direction に近い傾向の Direction を出力していることが示唆される。

GNN によるレイアウト生成性能は、あくまで「GNN が利用可能な形で Direction が構造化されているか」を測る評価である点に留意が必要であるが、それでも、GT 条件と予測条件のギャップが一貫して観測されたことから、Direction の品質差を反映する間接指標として一定の感度を持つと考えられる。

6.4.3 ネーム生成における生成されたレイアウトの可視化と考察

図 6.2 に、ネーム生成において生成されたレイアウトの可視化の例を示す。

生成されたレイアウトが並ぶ列の最左列は、既存のレイアウト生成手法の生成結果を示しているが、これらの多くは、コマの領域 (水色の領域) が連続的に並んでいない、あるいは、見開きをまたぐ中間地点にコマが配置されるなどしており、漫画における可読性の点において不十分な結果であることがわかる。一方、脚本に基づくネーム生成により生成されたレイアウトの結果では、GPT-OSS, Qwen-3 による生成結果が Direction の取り扱いによる生成設定によらず、漫画の見開きに適した左右に分かれた配置がなされ、また、それぞれのページをコマで満たすというより漫画らしい要件を満たしていることが




図 6.2: ネーム生成におけるレイアウト生成結果の定性的比較. 左の列から順に, 正解となる漫画画像, 既存手法の生成結果, Script2Layout の生成結果, Script $\rightarrow$ (Direction + Layout) の生成結果, (Script + Direction) $\rightarrow$ Layout の生成結果, Script2Direction2Layout の生成結果. を示し, それぞれの列で各行は, モデルの違いに対応している. Scr は Script を, Dir は Direction を, Lyt は Layout を表す (漫画: 上段『うるとら☆イレブン』© やぶの てんや, 渡辺 達也/集英社, 下段『永遠のウィズ』© みやうち 沙矢/講談社).

確認できる. ただし, Llama-3.1 は, 出力結果が中心によるなど配置に崩壊が見られ, また, Direction の生成を介し GNN のレイアウト生成へと接続する Script2Durection2Layout による結果においても要素の配置パターンの学習が不十分であることが見て取れる. この結果は, 事前学習済みの LLM の性能が十分であれば, 直接レイアウトを生成する際に脚本の効果が引き出され, 生成結果がより漫画らしいものにできることを示唆する. また, 下段に示した漫画の例において, GPT-OSS および Qwen-3 の (Script+Direction)2Layout の結果では, 右下に犬の描画 (赤い領域) が配置されている点や, そのとなりにオレンジの領域が配置されている点, 左の上に大きな緑色の領域が配置されている点など, 多くの点で, 正解となる漫画の例と近い配置を示していることがわかる. Direction の効果は, 細部にわたるレイアウトの調整に寄与する可能性を示唆する. 以上の定性的結果から, 脚本に基づくネーム生成は, 単なる要素配置にとどまらず, 漫画特有の可読性や構成原理を反映したレイアウトの生成を可能にすることが示唆される.

6.4.4 ネーム生成において推定された演出情報の可視化と考察

ここでは、脚本に基づくネーム生成において推定された演出情報について、コマに与えられた演出情報の可視化とキャラクターの描画同士の相互作用 (action edge) の可視化の例を示し考察する。

コマに与えられた演出情報の可視化 図 6.3 に、脚本に基づくネーム生成において推定された演出情報のうち、コマ画像に対する演出情報の可視化の例を示す。

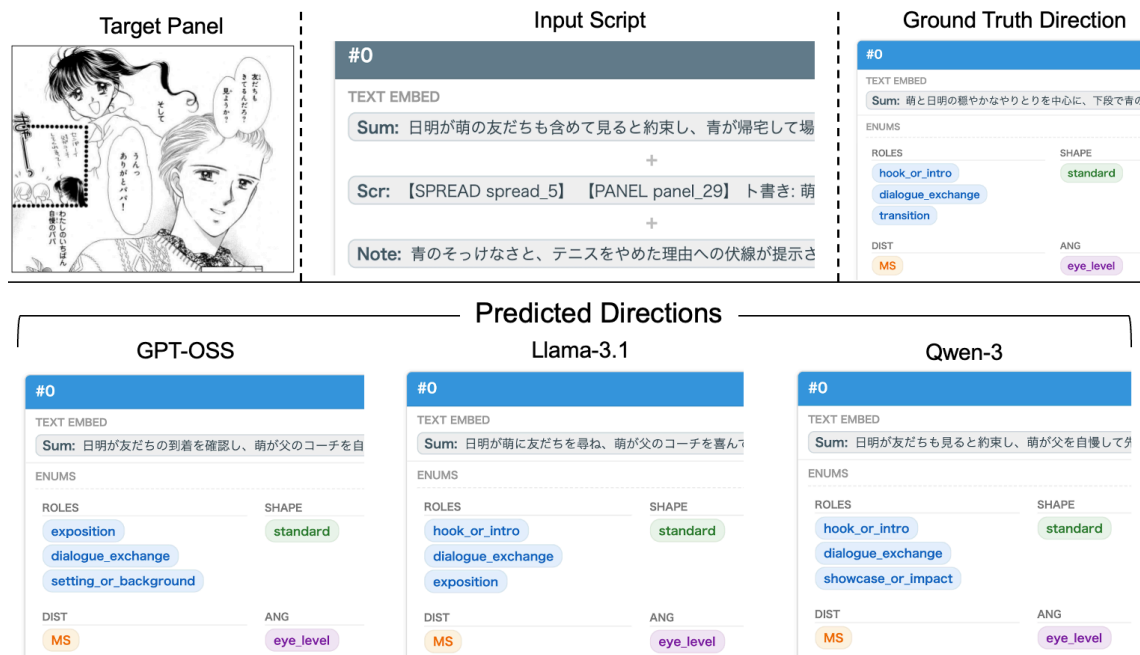


図 6.3: 脚本に基づくネーム生成において推定されたコマに対する演出情報の可視化の例。上段左が対象となったコマ画像、上段中央が、対象のコマを含んだ見開きに対する入力に用いられた脚本情報 (Input Script)、上段右 Ground Truth (GT) となる演出情報 (Direction)、下段が、Script を入力に推定された Direction を示す。Input Script を示すパネルには、見開き全体の要約文 (Sum) と脚本 (Scr)、注意書き (Note) が途中で示され、Direction を示すパネルには、そのパネルにおける要約文 (Sum) および、役割 (ROLES)、形状 (SHAPE)、カメラ距離 (DIST)、カメラ角度 (ANG) がカテゴリ情報として示されている (漫画: 『太陽にスマッシュ!』 ©あゆみ ゆい/講談社)。

図 6.3 より、いずれのモデルもこのコマの形状 (SHAPE)、カメラ距離 (DIST)、カメラ角度 (ANG) が、Ground Truth の演出情報と同じ値を推定していることがわかる。これは、対象となっているコマが、一番初めに読まれるということや脚本内の情報に基づき演出のパターンの推定がおこなわれていることを示唆している。一方で、コマの役割 (ROLES) については、Ground Truth と同一の dialogue_exchange がいずれのモデルにおいても推定されていることが確認できるものの、一部には異なるカテゴリが推定されているケースも見られる。しかし、演出情報は本質的に多義的であり、脚本の解釈や表現意図に応じて複数の妥当な選択肢が存在し得る。そのため、Ground Truth と異なる値が生成されたこと自体をもって、本モデルの有用性が直ちに否定されるものではない。この結果は、本モデルが、脚本の文脈に整合した演出候補を一定程度の精度で提示しつつ、その上で多様なパターンを示せ

る可能性を示唆するものであり、実際の制作効率の向上に寄与できる可能性を示唆するものである。

キャラクターの描画同士の相互作用 (**action edge**) の可視化 次に、図 6.4 に、脚本に基づくネーム生成において推定された演出情報のうち、キャラクターの描画同士の相互作用を表す action edge の可視化の例を示す。




図 6.4: 脚本に基づくネーム生成において推定された action edge の可視化の例。上段左側が対象となった見開き、上段中央が、対象の見開きに対する入力に用いられた脚本情報 (Input Script)、上段右 Ground Truth (GT) となる Action Edge、下段が、Script を入力に推定された Action Edge を示す。Input Script を示すパネルには、見開き全体の要約文 (Sum) と脚本 (Scr)、注意書き (Note) が途中まで示され、Action Edge 内に示された C_inst は Character Instance ノードを表す (漫画:『太陽にスマッシュ!』©あゆみ ゆい/講談社)。

図 6.4 に示す action edge の可視化結果より、いずれのモデルにおいても、脚本情報のみに基づいて、キャラクターの描画 (Character Instance: C_inst) 間の相互作用が複数本推定されていることが確認できる。Ground Truth と同一の action edge (C_inst7- $\rightarrow$ C_inst1 や C_inst9- $\rightarrow$ C_inst15 など) も見られるが、本数や接続関係は Ground Truth と完全には一致しておらず、一部には過剰あるいは不足した相互作用の推定も見られる。しかし、キャラクター間の相互作用は、演出上の解釈や表現意図に依存する要素が大きく、必ずしも一意に定まるものではない。そのため、Ground Truth との不一致は、直ちに誤りを意味するものではなく、脚本に基づく別の妥当な解釈として捉えることができる。この結果は、本手法が、脚本情報のみに基づいて、キャラクター描画間に相互作用を割り当てるという処理を実行できていることを示す結果である。すなわち、どのキャラクターの描画同士に脚本上の相互作用を与えるべきかという判断を、少なくとも構造的には成立させ、脚本を入力とした演出関係推定の具体例を与えるモデルとなっていることを示唆するものである。

これまで見てきた通り，脚本に基づくネーム生成において推定された演出情報は，脚本情報のみを入力とした場合でも，ある程度の精度で推定されることが確認でき，脚本に基づく別の妥当な解釈として捉えることができる．しかし，演出情報の多義性は許容され得る考えられる一方で，明らかに文脈と乖離した演出や，制作上不適切な相互作用が生成される可能性を抑制する必要もある．そのため，本研究で示したような可視化や間接評価に加えて，演出情報の妥当性や一貫性を定量的に捉える評価指標の設計が，今後の重要な課題である．

第 7 章 結論

本研究では、漫画制作工程において重要な役割を担う「ネーム」を、作品の下書き画像そのものではなく、物語文脈と演出意図を内包した構造化された中間表現として捉え直し、脚本に基づく漫画ネーム生成という新たな課題設定を提示した。従来のレイアウト生成研究が、主として機能的媒体や要素配置の最適化を対象としてきたのに対し、本研究は、物語性や演出上の意思決定と不可分な漫画特有の配置問題を扱う点に特徴がある。

この課題に取り組むため、本研究では、大規模視覚言語モデル (LVLM) を活用し、漫画画像に紐づく物語情報および演出情報を体系的に抽出・構造化した Manga109ScriptDataset および Manga109NameDataset を構築した。特に、人手による読み順アノテーションと独自の Visual Prompting 手法を組み合わせることで、LVLM 単体では困難であった漫画特有の物語構造や演出情報の記述を可能にし、脚本およびネーム生成のための学習基盤を整備した。

さらに、構築したデータセットを用いて、脚本を入力とし、演出情報およびレイアウト情報を生成する漫画ネーム生成モデルを提案した。大規模言語モデル (LLM) を基盤とした複数の生成設定を比較した結果、脚本情報を明示的に入力として与えることで、既存のレイアウト生成手法を上回る性能が得られることを定量的・定性的に示した。また、演出情報をどの段階で統合するかという設計の違いなどを複数検討し設計指針を整理した。

一方で、演出情報は本質的に多義的であり、単一の正解に基づく評価が難しいという課題も明らかとなった。本研究では、GNN を用いた間接評価や可視化分析を通じて、演出情報の品質を検討したが、明らかに文脈と乖離した演出や、制作上不適切な生成結果を抑制するためには、演出情報の妥当性や一貫性をより定量的に捉える評価指標の設計が今後必要である。

脚本を条件としてネームを生成するという枠組みは、最終成果物を直接生成するのではなく、制作工程の中核に位置する意思決定を支援するという点で、創作者の創造性を尊重しつつ、制作効率の向上に寄与し得る可能性をもつと考えられる。本研究で示したデータセット、モデル設計、および評価結果は、脚本に基づく漫画ネーム生成という新たな研究領域における基礎的なベースラインとなるものであり、今後の発展的研究や実制作支援への応用に向けた重要な足がかりとなることを期待する。

謝辞

本研究を行うにあたり，主任指導教員である栗原聡教授には多大なご指導を承りました．橋本敦史訪問准教授，電気通信大学稲葉通将准教授には，研究の指針となるお言葉や技術的な御助言を数多く頂き，また精神的な面においても支えていただきました．心より感謝申し上げます．

本研究は，産業技術総合研究所の覚醒プロジェクトの支援を受けて実施されました．産総研 AI センター社会知能研究チーム長大西正輝先生，主任研究員唐木田亮先生には，本プロジェクトの PM として研究を様々な面でご支援頂きました．また，岩崎弥優氏には，アノテーション作業において，非常に丁寧に作業を進めて頂き，大変感謝しております．覚醒プロジェクトにおいて関わってくださったメンバーの皆様に厚く御礼申し上げます．

栗原研究室の皆様には，研究の面においても生活の面においても大変お世話になりました．特に，畠山太郎氏，北川峻氏，岡田湧路氏，伊藤亮史氏，小菅雷太郎氏には，多くの面でご助力頂きました．心より感謝申し上げます．

最後になりましたが，家族の支えにも感謝します．

改めまして，本研究に関わってくださった全ての皆様に心より感謝申し上げます．

参考文献

- [1] Yo Fukaya and Tokyo Nametank. *Motto Miseru, Omoshiroku Suru Tamashii ni Hibiku Manga Komawari Kyoushitsu*. In Japanese. Tokyo, Japan: Sotechsha Co.,Ltd., 2019.
- [2] Hao Wang, Shohei Tanaka, and Yoshitaka Ushiku. “SciPostLayout: A Dataset for Layout Analysis and Layout Generation of Scientific Posters”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*. IEEE/CVF, June 2024, pp. 8136–8141.
- [3] Jaejung Seol, Seojun Kim, and Jaejun Yoo. “PosterLlama: Bridging Design Ability of Language Model to Content-Aware Layout Generation”. In: *Computer Vision – ECCV 2024*. Vol. 15140. Lecture Notes in Computer Science. Springer, 2024, pp. 451–468. DOI: [10.1007/978-3-031-73007-8_26](https://doi.org/10.1007/978-3-031-73007-8_26).
- [4] Shunan Guo, Zhuochen Jin, Fuling Sun, Jingwen Li, Zhaorui Li, Yang Shi, and Nan Cao. “Vinci: An Intelligent Graphic Design System for Generating Advertising Posters”. In: *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. CHI ’21. New York, NY, USA: Association for Computing Machinery, May 2021, pp. 1–17. ISBN: 978-1-4503-8096-6. DOI: [10.1145/3411764.3445117](https://doi.org/10.1145/3411764.3445117). URL: <https://dl.acm.org/doi/10.1145/3411764.3445117> (visited on 04/12/2025).
- [5] K. Kikuchi, M. Otani, K. Yamaguchi, and E. Simo - Serra. “Modeling Visual Containment for Web Page Layout Optimization”. en. In: *Computer Graphics Forum* 40.7 (Oct. 2021), pp. 33–44. ISSN: 0167-7055, 1467-8659. DOI: [10.1111/cgf.14399](https://doi.org/10.1111/cgf.14399). URL: <https://onlinelibrary.wiley.com/doi/10.1111/cgf.14399> (visited on 04/12/2025).
- [6] Biplab Deka, Zifeng Huang, Chad Franzen, Joshua Hirschman, Daniel Afergan, Yang Li, Jeffrey Nichols, and Ranjitha Kumar. “Rico: A Mobile App Dataset for Building Data-Driven Design Applications”. In: *Proceedings of the 30th Annual ACM Symposium on User Interface Software and Technology*. UIST ’17. New York, NY, USA: Association for Computing Machinery, Oct. 2017, pp. 845–854. ISBN: 978-1-4503-4981-9. DOI: [10.1145/3126594.3126651](https://doi.org/10.1145/3126594.3126651). URL: <https://dl.acm.org/doi/10.1145/3126594.3126651> (visited on 11/18/2024).

- [7] Xu Zhong, Jianbin Tang, and Antonio Jimeno Yepes. “PubLayNet: Largest Dataset Ever for Document Layout Analysis”. In: *2019 International Conference on Document Analysis and Recognition (ICDAR)*. Sydney, Australia: IEEE, Sept. 2019, pp. 1015–1022. DOI: [10.1109/ICDAR.2019.00166](https://doi.org/10.1109/ICDAR.2019.00166).
- [8] Ting-Hao Kenneth Huang, Francis Ferraro, Nasrin Mostafazadeh, Ishan Misra, Aishwarya Agrawal, Jacob Devlin, Ross Girshick, Xiaodong He, Pushmeet Kohli, Dhruv Batra, C. Lawrence Zitnick, Devi Parikh, Lucy Vanderwende, Michel Galley, and Margaret Mitchell. “Visual Storytelling”. In: *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Ed. by Kevin Knight, Ani Nenkova, and Owen Rambow. San Diego, California: Association for Computational Linguistics, June 2016, pp. 1233–1239. DOI: [10.18653/v1/N16-1147](https://doi.org/10.18653/v1/N16-1147). URL: <https://aclanthology.org/N16-1147/>.
- [9] Md. Sultan Al Nahian, Tasmia Tasrin, Sagar Gandhi, Ryan Gaines, and Brent Harrison. “A Hierarchical Approach for Visual Storytelling Using Image Description”. In: *Interactive Storytelling (ICIDS 2019)*. Ed. by Rogelio E. Cardona-Rivera, Anne Sullivan, and R. Michael Young. Vol. 11869. Lecture Notes in Computer Science. Cham: Springer, 2019, pp. 304–317. DOI: [10.1007/978-3-030-33894-7_30](https://doi.org/10.1007/978-3-030-33894-7_30). URL: https://link.springer.com/chapter/10.1007/978-3-030-33894-7_30.
- [10] Li Yang, Zhiding Xiao, Wenxin Huang, and Xian Zhong. “StoryLLaVA: Enhancing Visual Storytelling with Multi-Modal Large Language Models”. In: *Proceedings of the 31st International Conference on Computational Linguistics*. Ed. by Owen Rambow, Leo Wanner, Marianna Apidianaki, Hend Al-Khalifa, Barbara Di Eugenio, and Steven Schockaert. Abu Dhabi, UAE: Association for Computational Linguistics, Jan. 2025, pp. 3936–3951. URL: <https://aclanthology.org/2025.coling-main.266/> (visited on 03/19/2025).
- [11] Yusuke Matsui, Kota Ito, Yuji Aramaki, Azuma Fujimoto, Toru Ogawa, Toshihiko Yamasaki, and Kiyoharu Aizawa. “Sketch-based Manga Retrieval Using Manga109 Dataset”. In: *Multimedia tools and applications* 76 (2017), pp. 21811–21838. DOI: <https://doi.org/10.1007/s11042-016-4020-z>.
- [12] Aleksandar Shtedritski, Christian Rupprecht, and Andrea Vedaldi. “What does CLIP know about a red circle? Visual prompt engineering for VLMs”. In: *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*. Paris, France: IEEE, Oct. 2023, pp. 11953–11963. ISBN: 979-8-3503-0718-4. DOI: [10.1109/ICCV51070.2023.01101](https://doi.org/10.1109/ICCV51070.2023.01101). URL: <https://ieeexplore.ieee.org/document/10376723/> (visited on 04/19/2024).

-
- [13] Naoto Inoue, Kotaro Kikuchi, Edgar Simo-Serra, Mayu Otani, and Kota Yamaguchi. “LayoutDM: Discrete Diffusion Model for Controllable Layout Generation”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE/CVF, 2023, pp. 10167–10176. DOI: [10.1109/CVPR52688.2023.00980](https://doi.org/10.1109/CVPR52688.2023.00980). URL: https://openaccess.thecvf.com/content/CVPR2023/papers/Inoue_LayoutDM_Discrete_Diffusion_Model_for_Controllable_Layout_Generation_CVPR_2023_paper.pdf.
- [14] Zhaoyun Jiang, Jiaqi Guo, Shizhao Sun, Huayu Deng, Zhongkai Wu, Vuksan Mijovic, Zijiang James Yang, Jian-Guang Lou, and Dongmei Zhang. “LayoutFormer++: Conditional Graphic Layout Generation via Constraint Serialization and Decoding Space Restriction”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE/CVF, 2023, pp. 18403–18412. DOI: [10.1109/CVPR52688.2023.01799](https://doi.org/10.1109/CVPR52688.2023.01799). URL: https://openaccess.thecvf.com/content/CVPR2023/papers/Jiang_LayoutFormer_Conditional_Graphic_Layout_Generation_via_Constraint_Serialization_and_Decoding_CVPR_2023_paper.html.
- [15] Jiawei Lin, Jiaqi Guo, Shizhao Sun, Zijiang Yang, Jian-Guang Lou, and Dongmei Zhang. “LayoutPrompter: Awaken the Design Ability of Large Language Models”. In: *Advances in Neural Information Processing Systems (NeurIPS 2023)*. Ed. by A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, and S. Levine. Curran Associates, Inc., 2023, pp. 43852–43879. URL: https://proceedings.neurips.cc/paper_files/paper/2023/file/88a129e44f25a571ae8b838057c46855-Paper-Conference.pdf.
- [16] Mayu Otani, Naoto Inoue, Kotaro Kikuchi, and Riku Togashi. “LTSim: Layout Transportation-based Similarity Measure for Evaluating Layout Generation”. In: *CoRR* abs/2407.12356 (2024). DOI: [10.48550/arXiv.2407.12356](https://doi.org/10.48550/arXiv.2407.12356). URL: <https://arxiv.org/abs/2407.12356>.
- [17] Simon Lok and Steven Feiner. *A Survey of Automated Layout Techniques for Information Presentations*. Tech. rep. New York, NY, USA: Department of Computer Science, Columbia University, 1999.
- [18] Mei C. Chuah, Steven F. Roth, John Kolojejchick, Joe Mattis, and Octavio Juarez. *SageBook: Searching Data-Graphics by Content*. Tech. rep. Pittsburgh, PA, USA: School of Computer Science, Carnegie Mellon University, 1995.
- [19] Thomas Kamps. “A Constraint-Based Layout System for Graphical User Interfaces”. PhD thesis. University of Dortmund, 1999.

- [20] Steven F. Roth, John Kolojejchick, and Joe Mattis. “Data characterization for automated presentation design”. In: *Information Visualization* (1994).
- [21] Steven K. Feiner and Kathleen R. McKeown. “A Constraint-Based System for Automatic Generation of Graphics”. In: *IEEE Computer Graphics and Applications* 8.2 (1988), pp. 30–42.
- [22] Yong Shi, Mengyu Shang, and Zhiquan Qi. “Intelligent layout generation based on deep generative models: A comprehensive survey”. In: *Information Fusion* 100 (Dec. 2023), p. 101940. ISSN: 1566-2535. DOI: [10 . 1016 / j . inffus . 2023 . 101940](https://doi.org/10.1016/j.inffus.2023.101940). URL: <https://www.sciencedirect.com/science/article/pii/S1566253523002567> (visited on 02/02/2025).
- [23] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. “Generative adversarial nets”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2014.
- [24] Diederik P. Kingma and Max Welling. “Auto-Encoding Variational Bayes”. In: *Proceedings of the 2nd International Conference on Learning Representations (ICLR 2014)*. 2014. URL: <https://openreview.net/forum?id=33X9fd2-9FyZd>.
- [25] Jianan Li, Jimei Yang, Aaron Hertzmann, Jianming Zhang, and Tingfa Xu. “LayoutGAN: Generating Graphic Layouts with Wireframe Discriminators”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE, 2019, pp. 2988–2997. DOI: [10.1109/ICCV.2019.00308](https://doi.org/10.1109/ICCV.2019.00308).
- [26] Akash Abdu Jyothi, Thibaut Durand, Jiawei He, Leonid Sigal, and Greg Mori. “LayoutVAE: Stochastic Scene Layout Generation From a Label Set”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE/CVF, 2019, pp. 9895–9904. DOI: [10.1109/ICCV.2019.00999](https://doi.org/10.1109/ICCV.2019.00999). URL: https://openaccess.thecvf.com/content_ICCV_2019/html/Jyothi_LayoutVAE_Stochastic_Scene_Layout_Generation_From_a_Label_Set_ICCV_2019_paper.html.
- [27] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. “Attention Is All You Need”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30. 2017.
- [28] Kamal Gupta, Justin Lazarow, Alessandro Achille, Larry S. Davis, Vijay Mahadevan, and Abhinav Shrivastava. “LayoutTransformer: Layout Generation and Completion With Self-Attention”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2021, pp. 1004–1014.

- [29] Xiang Kong, Lu Jiang, Huiwen Chang, Han Zhang, Yuan Hao, Haifeng Gong, and Irfan Essa. “BLT: Bidirectional Layout Transformer for Controllable Layout Generation”. In: *Computer Vision – ECCV 2022*. Ed. by Shai Avidan, Gabriel Brostow, Moustapha Cissé, Giovanni Maria Farinella, and Tal Hassner. Vol. 13677. Lecture Notes in Computer Science. Cham: Springer, 2022, pp. 474–490. DOI: [10.1007/978-3-031-19790-1_29](https://doi.org/10.1007/978-3-031-19790-1_29). URL: https://link.springer.com/chapter/10.1007/978-3-031-19790-1_29.
- [30] Jianan Jiang, Jiajun Tang, Rui Huang, and Xiangyang Xue. “LayoutFormer: Layout Generation with Structured Representation”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2023.
- [31] Jonathan Ho, Ajay Jain, and Pieter Abbeel. “Denoising Diffusion Probabilistic Models”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33. 2020.
- [32] Emiel Hoogeboom, Didrik Nielsen, Zachary Nado, and Tim Salimans. “Denoising Diffusion Probabilistic Models for Discrete Data”. In: *Advances in Neural Information Processing Systems* 34 (2021).
- [33] Junyi Zhang, Jiaqi Guo, Shizhao Sun, Jian-Guang Lou, and Dongmei Zhang. “LayoutDiffusion: Improving Graphic Layout Generation by Discrete Diffusion Probabilistic Models”. In: *2023 IEEE/CVF International Conference on Computer Vision (ICCV)* (Oct. 2023). Conference Name: 2023 IEEE/CVF International Conference on Computer Vision (ICCV) ISBN: 9798350307184 Place: Paris, France, pp. 7192–7202. DOI: [10.1109/ICCV51070.2023.00664](https://doi.org/10.1109/ICCV51070.2023.00664). URL: <https://ieeexplore.ieee.org/document/10377876/> (visited on 10/12/2024).
- [34] Weixi Feng, Wanrong Zhu, Tsu-Jui Fu, Varun Jampani, Arjun R. Akula, Xuehai He, Sugato Basu, Xin Eric Wang, and William Yang Wang. “LayoutGPT: Compositional Visual Planning and Generation with Large Language Models”. In: *Advances in Neural Information Processing Systems 36: Annual Conference on Neural Information Processing Systems 2023, NeurIPS 2023, New Orleans, LA, USA, December 10 - 16, 2023*. Ed. by Alice Oh, Tristan Naumann, Amir Globerson, Kate Saenko, Moritz Hardt, and Sergey Levine. 2023. URL: http://papers.nips.cc/paper_files/paper/2023/hash/3a7f9e485845dac27423375c934cb4db-Abstract-Conference.html.
- [35] Zecheng Tang, Chenfei Wu, Juntao Li, and Nan Duan. “LayoutNUWA: Revealing the Hidden Layout Expertise of Large Language Models”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2024.
- [36] Yang Shi, Tian Gao, Xiaohan Jiao, and Nan Cao. “Understanding Design Collaboration Between Designers and Artificial Intelligence: A Systematic Literature Review”. In: *Proc.*

- ACM Hum.-Comput. Interact.* 7.CSCW2 (Oct. 2023), 368:1–368:35. DOI: [10.1145/3610217](https://doi.org/10.1145/3610217). URL: <https://dl.acm.org/doi/10.1145/3610217> (visited on 02/02/2025).
- [37] Danqing Huang, Jiaqi Guo, Shizhao Sun, Hanling Tian, Jieru Lin, Zheng Hu, Chin-Yew Lin, Jian-Guang Lou, and Dongmei Zhang. *A Survey for Graphic Design Intelligence*. arXiv:2309.01371 [cs]. Sept. 2023. DOI: [10.48550/arXiv.2309.01371](https://arxiv.org/abs/2309.01371). URL: <http://arxiv.org/abs/2309.01371> (visited on 02/02/2025).
- [38] Minghao Li, Yu Xu, Lei Cui, Furu Wei, and Zhoujun Li. “DocBank: A Benchmark Dataset for Document Layout Analysis”. In: *Proceedings of the 28th International Conference on Computational Linguistics (COLING)*. 2020.
- [39] Minghao Li, Lei Cui, Shaohan Huang, Furu Wei, Ming Zhou, and Zhoujun Li. “TableBank: Table Benchmark for Image-based Table Detection and Recognition”. In: *Proceedings of the 12th International Conference on Language Resources and Evaluation (LREC)*. 2020.
- [40] Yupan Huang, Tengchao Lv, Lei Cui, Furu Wei, and Ming Zhou. “LayoutLMv3: Pre-training for Document AI with Unified Text and Image Masking”. In: *Proceedings of the 30th ACM International Conference on Multimedia*. 2022.
- [41] Minghao Li, Yu Xu, Yang Xu, Furu Wei, and Ming Zhou. “DiT: Self-supervised Pre-training for Document Image Transformer”. In: *Proceedings of the 30th ACM International Conference on Multimedia*. 2022.
- [42] Jianan Yang, Peiran Ren, Jun-Yan Zhang, and James Hays. “Content-aware Generative Modeling of Graphic Design Layouts”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2019.
- [43] Wenbin Li, Zhe Chen, and Zhaohui Wu. “CGL-GAN: A Conditional Generative Adversarial Network for Graphic Layout Generation”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. 2020.
- [44] Yitao Xu, Yanwei Pang, Yu Zhang, and Jingdong Li. “LayoutGAN++: Generating Graphic Layouts with Wireframe Discriminators”. In: *IEEE Transactions on Image Processing*. 2020.
- [45] Hsin-Ying Lee, Lu Jiang, Irfan Essa, Phuong B. Le, Haifeng Gong, Ming-Hsuan Yang, and Weilong Yang. “Neural Design Network: Graphic Layout Generation with Constraints”. In: *European Conference on Computer Vision (ECCV)*. Springer, 2020, pp. 491–506.
- [46] Kotaro Kikuchi, Edgar Simo-Serra, Mayu Otani, and Kota Yamaguchi. “Constrained Graphic Layout Generation via Latent Optimization”. In: *Proceedings of the 29th ACM International Conference on Multimedia (MM ’ 21)*. Association for Computing Machinery, Inc., 2021,

- pp. 88–96. DOI: [10.1145/3474085.3475497](https://doi.org/10.1145/3474085.3475497). URL: <https://doi.org/10.1145/3474085.3475497>.
- [47] Jianan Li, Jimei Yang, Jianming Zhang, Chang Liu, Christina Wang, and Tingfa Xu. “Attribute-Conditioned Layout GAN for Automatic Graphic Design”. In: *IEEE Transactions on Visualization and Computer Graphics* 27.10 (2021), pp. 4039–4048.
- [48] Soliha Rahman, Vinoth Pandian, and Matthias Jarke. “RUIte: Refining UI Layout Aesthetics Using Transformer Encoder”. In: *Proceedings of the 26th International Conference on Intelligent User Interfaces Companion*. 2021, pp. 81–83.
- [49] Daichi Horita, Naoto Inoue, Kotaro Kikuchi, Kota Yamaguchi, and Kiyoharu Aizawa. “Retrieval-Augmented Layout Transformer for Content-Aware Layout Generation”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. June 2024, pp. 67–76. URL: https://openaccess.thecvf.com/content/CVPR2024/html/Horita_Retrieval-Augmented_Layout_Transformer_for_Content-Aware_Layout_Generation_CVPR_2024_paper.html.
- [50] Oriol Vinyals, Alexander Toshev, Samy Bengio, and Dumitru Erhan. “Show and Tell: A Neural Image Caption Generator”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015, pp. 3156–3164.
- [51] Andrej Karpathy and Li Fei-Fei. “Deep Visual-Semantic Alignments for Generating Image Descriptions”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015, pp. 3128–3137.
- [52] Licheng Yu, Mohit Bansal, and Tamara L. Berg. “Hierarchically-Attentive RNN for Album Summarization and Storytelling”. In: *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*. Copenhagen, Denmark: Association for Computational Linguistics, 2017, pp. 966–971. URL: <https://aclanthology.org/D17-1101/>.
- [53] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2021.
- [54] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. “Learning Transferable Visual Models From Natural Language Supervision”. In: *Proceedings of the 38th International Conference on Machine Learning*. PMLR, July 2021,

- pp. 8748–8763. URL: <https://proceedings.mlr.press/v139/radford21a.html> (visited on 06/19/2025).
- [55] Chao Jia, Yinfei Yang, Ye Xia, Yi-Ting Chen, Zarana Parekh, Hieu Pham, Quoc V. Le, Yun-Hsuan Sung, Zhen Li, and Tom Duerig. “Scaling Up Visual and Vision-Language Representation Learning With Noisy Text Supervision”. In: *Proceedings of the International Conference on Machine Learning (ICML)*. 2021.
- [56] Junnan Li, Dongxu Li, Caiming Xiong, and Steven Hoi. “BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation”. In: *Proceedings of the International Conference on Machine Learning (ICML)*. 2022.
- [57] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katie Millican, Malcolm Reynolds, Roman Ring, Eliza Rutherford, Serkan Cabi, David Budden, Alhussein Fawzi, Piotr Stanczyk, Tom Hennigan, Alexander Novikov, Alex Graves, Koray Kavukcuoglu, and Karen Simonyan. “Flamingo: a Visual Language Model for Few-Shot Learning”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2022.
- [58] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. “Visual Instruction Tuning”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024.
- [59] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. “Language Models are Few-Shot Learners”. In: *Advances in Neural Information Processing Systems*. Vol. 33. 2020, pp. 1877–1901.
- [60] Ning Xu, Brian Price, Scott Cohen, Jimei Yang, and Thomas Huang. “Deep Interactive Object Selection”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, pp. 373–381.
- [61] Kevis-Kokitsi Maninis, Sergi Caelles, Jordi Pont-Tuset, and Luc Van Gool. “Deep Extreme Cut: From Extreme Points to Object Segmentation”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018, pp. 616–625.
- [62] Tianlong Chen, Zhenyu Li, Yang Yang, Mengdi Wang, and Cho-Jui Hsieh. “Visual Prompting via Learnable Prompts”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2023, pp. 6352–6362.
- [63] Emanuele Vivoli, Marco Bertini, and Dimosthenis Karatzas. “CoMix: A Comprehensive Benchmark for Multi-Task Comic Understanding”. en. In: *Advances in Neural Informa-*

- tion Processing Systems* 37 (Dec. 2024), pp. 140828–140846. URL: https://proceedings.neurips.cc/paper_files/paper/2024/hash/fe79898dcf078ec54b6feeea10ebb751-Abstract-Datasets_and_Benchmarks_Track.html (visited on 09/30/2025).
- [64] Clément Guérin, Christophe Rigaud, Jean-Pierre Mercier, Farida Ammar-Boudjelal, Karell Bertet, Anne Bouju, Jean-Christophe Burie, Guillaume Louis, and Jean-Marc Ogier. “eBDtheque: A Representative Database of Comics”. In: *Proceedings of the International Conference on Document Analysis and Recognition (ICDAR)*. IEEE, 2013, pp. 1145–1149.
- [65] Mohit Iyyer, Varun Manjunatha, Anupam Guha, Yogarshi Vyas, Jordan Boyd-Graber, Hal Daumé, and Larry Davis. “The Amazing Mysteries of the Gutter: Drawing Inferences Between Panels in Comic Book Narratives”. In: *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. July 2017, pp. 6478–6487. DOI: [10.1109/CVPR.2017.686](https://doi.org/10.1109/CVPR.2017.686). URL: <https://ieeexplore.ieee.org/document/8100169> (visited on 09/04/2025).
- [66] Jeonghun Baek, Yusuke Matsui, and Kiyoharu Aizawa. “COO: Comic Onomatopoeia Dataset for Recognizing Arbitrary or Truncated Texts”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022.
- [67] Yingxuan Li, Kiyoharu Aizawa, and Yusuke Matsui. “Manga109Dialog: A Large-Scale Dialogue Dataset for Comics Speaker Detection”. In: *2024 IEEE International Conference on Multimedia and Expo (ICME)*. July 2024, pp. 1–6. DOI: [10.1109/ICME57554.2024.10687709](https://doi.org/10.1109/ICME57554.2024.10687709). URL: <https://ieeexplore.ieee.org/document/10687709> (visited on 06/19/2025).
- [68] Siyu Chen, Dengjie Li, Zenghao Bao, Yao Zhou, Lingfeng Tan, Yujie Zhong, and Zheng Zhao. *Manga Generation via Layout-controllable Diffusion*. arXiv:2412.19303 [cs]. Dec. 2024. DOI: [10.48550/arXiv.2412.19303](https://doi.org/10.48550/arXiv.2412.19303). URL: <http://arxiv.org/abs/2412.19303> (visited on 01/09/2025).
- [69] Hikaru Ikuta, Leslie Wohler, and Kiyoharu Aizawa. “MangaUB: A Manga Understanding Benchmark for Large Multimodal Models”. In: *IEEE MultiMedia* (2025), pp. 1–10. ISSN: 1941-0166. DOI: [10.1109/MMUL.2025.3550451](https://doi.org/10.1109/MMUL.2025.3550451). URL: <https://ieeexplore.ieee.org/document/10924761/> (visited on 09/04/2025).
- [70] Edoardo Vivoli, Danilo Croce, and Valerio Basile. “ComiCap: A Vision-Language Model Pipeline for Dense Captioning of Comics”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. 2024.
- [71] OpenAI. *GPT-4o System Card*. <https://openai.com/index/gpt-4o-system-card/>. Accessed: 2026-01-27. 2024.

- [72] Ragav Sachdeva and Andrew Zisserman. “The Manga Whisperer: Automatically Generating Transcriptions for Comics”. en. In: *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Seattle, WA, USA: IEEE, June 2024, pp. 12967–12976. ISBN: 979-8-3503-5300-6. DOI: [10.1109/CVPR52733.2024.01232](https://doi.org/10.1109/CVPR52733.2024.01232). URL: <https://ieeexplore.ieee.org/document/10657631/> (visited on 09/30/2025).
- [73] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. “Bleu: a Method for Automatic Evaluation of Machine Translation”. In: *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*. Ed. by Pierre Isabelle, Eugene Charniak, and Dekang Lin. Philadelphia, Pennsylvania, USA: Association for Computational Linguistics, July 2002, pp. 311–318. DOI: [10.3115/1073083.1073135](https://doi.org/10.3115/1073083.1073135). URL: <https://aclanthology.org/P02-1040> (visited on 02/21/2024).
- [74] Ramakrishna Vedantam, C. Lawrence Zitnick, and Devi Parikh. “CIDEr: Consensus-Based Image Description Evaluation”. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015, pp. 4566–4575.
- [75] Hikaru Ikuta, Leslie Wöhler, and Kiyoharu Aizawa. “MangaUB: A Manga Understanding Benchmark for Large Multimodal Models”. In: *IEEE MultiMedia* 32.2 (2025), pp. 33–43. DOI: [10.1109/MMUL.2025.3550451](https://doi.org/10.1109/MMUL.2025.3550451). URL: <https://doi.org/10.1109/MMUL.2025.3550451>.
- [76] Kazuki Fujii, Taishi Nakamura, Mengsay Loem, Hiroki Iida, Masanari Ohi, Kakeru Hattori, Hirai Shota, Sakae Mizuki, Rio Yokota, and Naoaki Okazaki. “Continual Pre-Training for Cross-Lingual LLM Adaptation: Enhancing Japanese Language Capabilities”. In: *First Conference on Language Modeling*. 2024. URL: <https://openreview.net/forum?id=TQdd1VhWbe>.
- [77] sbintuitions. *Sarashina-13B*. <https://huggingface.co/sbintuitions/sarashina1-13b>. Accessed: 2025-09-20. 2024.
- [78] DeepSeek-AI. “DeepSeek-R1: Incentivizing Reasoning Capability in Large Language Models”. In: *arXiv preprint arXiv:2401.06066* (2024). URL: <https://arxiv.org/abs/2401.06066>.
- [79] Jinze Bai, Shuai Bai, Yunfei Chu, Zeyu Cui, Kai Dang, Xiaodong Deng, Yang Fan, Wenbin Ge, Yu Han, Fei Huang, Binyuan Hui, Luo Ji, Mei Li, Junyang Lin, Runji Lin, Dayiheng Liu, Gao Liu, Chengqiang Lu, Keming Lu, Jianxin Ma, Rui Men, Xingzhang Ren, Xuancheng Ren, Chuanqi Tan, Sinan Tan, Jianhong Tu, Peng Wang, Shijie Wang, Wei Wang, Shengguang Wu, Benfeng Xu, Jin Xu, An Yang, Hao Yang, Jian Yang, Shusheng Yang, Yang Yao, Bowen Yu, Hongyi Yuan, Zheng Yuan, Jianwei Zhang, Xingxuan Zhang, Yichang Zhang, Zhenru Zhang, Chang Zhou, Jingren Zhou, Xiaohuan Zhou, and Tianhang Zhu. *Qwen Technical*

- Report*. Tech. rep. Alibaba Cloud / Qwen Team, 2023. URL: https://qianwen-res.oss-cn-beijing.aliyuncs.com/QWEN_TECHNICAL_REPORT.pdf.
- [80] Josh Woodward. *Gemini 3 brings upgraded smarts and new capabilities to the Gemini app*. Google Blog. Nov. 2025. URL: <https://blog.google/products/gemini/gemini-3-gemini-app/> (visited on 01/27/2026).
- [81] OpenAI. *Introducing GPT-5.2*. OpenAI. 2025. URL: <https://openai.com/lt-LT/index/introducing-gpt-5-2/> (visited on 01/27/2026).
- [82] Chih-Chung Hsu, Chia-Ming Lee, and Yi-Shiuan Chou. “DRCT: Saving Image Super-Resolution Away from Information Bottleneck”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*. June 2024, pp. 6133–6142.
- [83] OpenAI. *GPT-OSS: Open-Source Large Language Models*. Tech. rep. OpenAI, 2024. URL: <https://openai.com/research>.
- [84] Qwen Team. *Qwen3 Technical Report*. Tech. rep. Technical report (public PDF in official repository). Alibaba Cloud, 2025. URL: https://github.com/QwenLM/Qwen3/blob/main/Qwen3_Technical_Report.pdf.
- [85] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Al-Haj Ali, et al. *The LLaMA 3 Herd of Models*. 2024. arXiv: [2407.21783](https://arxiv.org/abs/2407.21783) [cs.CL]. URL: <https://arxiv.org/abs/2407.21783>.

研究業績一覧

国内論文誌

- (i) 渡邊 謙吾, 有井 知真, 伊藤 亮史, 栗原 聡, 『『ブラック・ジャック』を題材とした物語構造分析に基づく LLM のプロット創作支援システムの実践』, 情報処理学会論文誌, Vol. 67, No. 2, 掲載決定 (2025 年 11 月 12 日).

国内会議

- (i) 渡邊 謙吾, 岡田 湧路, 北川 峻, 稲葉 通将, 橋本 敦史, 栗原 聡, 「Manga109Script: 漫画レイアウト生成モデルのための脚本データセット」, 第 39 回人工知能学会全国大会, 大阪国際会議場, 2025 年 5 月 27 日.
- (ii) 岡田 湧路, 北川 峻, 渡邊 謙吾, 稲葉 通将, 橋本 敦史, 栗原 聡, 「MANGA109 に姿勢情報を追加したデータセットの構築による姿勢を制御した漫画キャラクター画像生成」, 第 39 回人工知能学会全国大会, 大阪国際会議場, 2025 年 5 月 28 日.
- (iii) 北川 峻, 岡田 湧路, 渡邊 謙吾, 稲葉 通将, 橋本 敦史, 栗原 聡, 「迷惑属性に頑健な画像多様性評価指標の提案」, 社会システムと情報技術研究ウィーク, ホテルラフォーレ那須, 2025 年 2 月 28 日.
- (iv) 岡田 湧路, 北川 峻, 渡邊 謙吾, 稲葉 通将, 橋本 敦史, 栗原 聡, 「Manga109 Pose データセットの構築による姿勢を制御した漫画キャラクター画像生成」, 社会システムと情報技術研究ウィーク, ホテルラフォーレ那須, 2025 年 3 月 1 日.
- (v) 渡邊 謙吾, 川村 天, 小林 伶央, 有井 和真, 伊藤 亮史, 栗原 聡, 「物語構造分析に基づく LLM を活用した創作支援を目的とするインタラクティブストーリー生成システム」, 第 38 回人工知能学会全国大会, アクトシティ浜松, 2024 年 5 月 28 日.
- (vi) 有井 和真, 安部 玲央, 伊藤 亮史, 川村 天, 小林 伶央, 笹田 和希, 渡邊 謙吾, 栗原 聡, 「LLM によるアフォーダンス獲得のための知識ネットワーク構築手法の提案」, 社会システムと情報技術研究ウィーク, ルスツリゾート, 2024 年 3 月 4 日.

- (vii) 伊藤 亮史, 安部 玲央, 小林 伶央, 有井 和真, 川村 天, 笹田 和希, 渡邊 謙吾, 栗原 聡, 「LLM を用いた自律エージェントの階層的な行動系列抽出手法の提案」, 社会システムと情報技術研究ウィーク, ルスツリゾート, 2024 年 3 月 4 日.
- (viii) 川村 天, 渡邊 謙吾, 小林 伶央, 有井 和真, 伊藤 亮史, 栗原 聡, 「創造性支援を目的とした物語構造分析に基づくインタラクティブなストーリー生成システムの提案」, 社会システムと情報技術研究ウィーク, ルスツリゾート, 2024 年 3 月 4 日.
- (ix) 笹田 和希, 小林 伶央, 安部 玲央, 有井 和真, 伊藤 亮史, 渡邊 謙吾, 栗原 聡, 「自律エージェントの道徳に基づく動作を可能とする行動選択メカニズムの提案」, 社会システムと情報技術研究ウィーク, ルスツリゾート, 2024 年 3 月 2 日.
- (x) 渡邊 謙吾, 川村 天, 小林 伶央, 有井 和真, 伊藤 亮史, 栗原 聡, 「物語構造分析に基づく LLM を用いたインタラクティブストーリー生成システムによる創作支援」, データ指向構成マイニングとシミュレーション研究会 (SIG-DOCMAS), 慶應義塾大学矢上キャンパス, 2023 年 11 月 25 日.

第 A 章 学習および実装の詳細

A.1 Script2Layout の LoRA ファインチューニングの学習設定およびハイパーパラメータ

表 A.1: Script2Layout の LoRA ファインチューニングに用いた学習ハイパーパラメータ

項目	設定内容
データ設定	最大トークン長 = 4096
モデル設定	計算精度 = <code>torch.float16</code> Attention 実装 = FlashAttention 2 トークナイザ設定 = right padding, EOS 付与 ^a
LoRA 設定	Rank $r = 8$, $\alpha = 16$, dropout = 0.1 対象モジュール = <code>q_proj</code> , <code>v_proj</code> Bias = <code>none</code> , タスク種別 = <code>CAUSAL_LM</code>
学習設定	バッチサイズ = 1 / device (学習・評価) 勾配累積ステップ数 = 32 学習エポック数 = 20 最適化手法 = <code>adamw_torch_fused</code> 学習率 = 2×10^{-4} , スケジューラ = cosine Mixed precision = FP16 ログ出力間隔 = 100 ステップごと 評価頻度 = 100 ステップごと (系列長でグループ化) モデル保存 = 各エポック終了時 実験管理 = Weights & Biases (W&B)

^a トークン化時に EOS トークンを付与し、パディングは右詰めとした。

A.2 Script2Name の LoRA ファインチューニングの学習設定およびハイパーパラメータ

表 A.2: Script2Name の LoRA ファインチューニング設定（再現用ハイパーパラメータ）

項目	設定内容
計算環境	PBS: select=1, ncpus=8, mem=120GB, ngpus=1 実行: <code>torchrun (--nproc_per_node=1)</code> GPU: NVIDIA H200 × 1 量子化: 4-bit 読み込み (<code>--load-in-4bit</code>) 精度: BF16 (<code>--bf16</code>) Attention 実装: FlashAttention 2 (<code>--attn-impl flash_attention_2</code>)
ベースモデル	<code>unsloth/gpt-oss-20b</code>
データ	形式: JSONL (<code>prompt, response</code>) 学習: <code>layout_m_coarse_json/train.jsonl</code> 検証: <code>layout_m_coarse_json/valid.jsonl</code>
入力長	学習最大長: 23552 (<code>--max-length</code>) 評価最大長: 12288 (<code>--eval-max-length</code>) 評価サンプル上限: 64 (<code>--max-eval-samples</code>)
最適化	学習率: 2×10^{-4} (<code>--learning-rate</code>) バッチサイズ: 1 / device (<code>train, eval</code>) 勾配累積: 16 (<code>--gradient-accumulation-steps</code>) エポック数: 20 (<code>--num-train-epochs</code>) 最大ステップ数: 20000 (<code>--max-steps</code>)
LoRA	有効化: <code>--use-lora</code> dropout: 0 (<code>--lora-dropout 0</code>) rank r : 16 (default) ^a α : 32 (default) ^a 対象モジュール: <code>q_proj, k_proj, v_proj, o_proj, up_proj, down_proj, gate_proj</code> (default) ^a
チェックポイント	保存間隔: 700 steps (<code>--save-steps</code>) 保存上限: 30 (<code>--save-total-limit</code>) 評価間隔: 700 steps (<code>--eval-steps</code>) ログ間隔: 20 steps (<code>--logging-steps</code>)
DDP / ログ	<code>ddp_find_unused_parameters=false</code> rank0 のみ保存: <code>--save-on-rank0</code> W&B: 有効 (<code>--wandb</code>), rank0 のみログ (<code>--wandb-on-rank0</code>)

^a CLI で明示指定されていないため、学習コード (`train_layout_llm.py`) のデフォルト値が適用される。

A.3 GNN によるレイアウト推定モデルの詳細

表 A.3: Script2Direction2Layout における GNN (HeteroConv) モデル構成 (実装に基づく)

項目	設定
入力グラフ	見開き単位の異種グラフ (Heterogeneous graph)
ノード種別	Spread / Panel / Character / Character Instance / Speech
エッジ種別 (例)	action edges (Character Instance 間), Panel-Character Instance (包含), Speech の読順関係 (順序) など
ノード特徴	テキスト特徴 (Tokenizer による入力), および列挙型の演出属性 (pose/action/emotion 等) ^a
テキストエンコーダ	scratch Transformer または pretrained HF モデル (QLoRA 対応) ^b
GNN 本体	HeteroConv によるメッセージパッシング, 層数 = <code>num_layers</code> (既定 3)
出力ノード	Panel / Character Instance / Speech
出力形式	混合密度ネットワーク (MDN) により $\mathbf{b} = (x, y, w, h)$ を推定
混合数	ガウス混合数 $K = \text{num_gaussians}$ (既定 5)
損失関数	MDN の負の対数尤度 (NLL)

^a 実装では `node type` ごとに列挙特徴 (例: Character Instance の pose/action/emotion 等) を付与する (`extract_enum_features`)。

^b 事前学習テキストエンコーダ使用時は `text_encoder_freeze` と `text_encoder_qlora` により凍結・QLoRA を切替可能。

表 A.4: GNN (Script2Direction2Layout) 学習設定 (実装の既定値)

項目	値	備考
バッチサイズ	4	<code>--batch-size</code>
隠れ次元	512	<code>--hidden-dim</code>
層数 (GNN)	3	<code>--num-layers</code>
学習率	1×10^{-3}	Adam
最大学習エポック	10	<code>--epochs</code>
最大学習ステップ/epoch	なし	<code>--max-steps</code> (未指定)
評価間隔	なし	<code>--eval-steps</code> (未指定)
チェックポイント間隔	10 epoch	<code>--save-interval</code>
混合数 (MDN)	5	<code>--num-gaussians</code>
Concept bottleneck	off	<code>--concept-only</code> で text を無効化
テキストエンコーダ種別	scratch	<code>--text-encoder</code>
Pretrained encoder	gemma-3-270m	QLoRA 有効時の既定
QLoRA	on	<code>--text-encoder-qlora</code> (既定 true)
LoRA rank / alpha / dropout	8 / 16 / 0.05	<code>--text-encoder-lora-*</code>
Flip augmentation	visual_flip	<code>--x-flip-mode</code>
Cinematic source	gt	<code>--cinematic-source</code>
トークン長 (Spread)	3072	<code>--spread-max-length</code>
トークン長 (Speech)	256	<code>--speech-max-length</code>
トークン長 (Panel/Char/Inst)	160	各 <code>--*-max-length</code>