

修士論文

2024 年度

顔画像集合に対する
迷惑属性に頑健な多様性評価指標の提案

北川 峻
(学籍番号：82317888)

指導教員 教授 栗原聡

2025 年 3 月

慶應義塾大学大学院理工学研究科
開放環境科学専攻

論文要旨

近年、拡散モデルをはじめとする画像生成技術の進歩により、手軽に高品質な画像を生成できるようになった。条件付け画像生成モデルには、生成条件で指定された要素を正確に表現することが求められるのと同時に、指定されていない要素について多様な表現が求められる。既存の画像多様性評価指標は、生成条件で指定された要素の多様性までも評価対象に含めてしまい、指定されていない要素の多様性を評価したい場合に適切な多様性評価を行えないという問題がある。本研究では、生成条件によって指定された要素を「迷惑属性」、指定されていない要素を「本質属性」と位置付ける。本質属性にのみ着目し、迷惑属性の影響を除去した多様性評価指標を構築することを目指す。具体的には、既存指標の評価対象となる特徴量には迷惑属性を表現する特徴量と本質属性を表現する特徴量が混在している点に注目した。そこで、独立成分分析と特徴量寄与度評価指標を組み合わせた迷惑属性フィルタリングモジュールを提案し、特徴量を迷惑属性を表現する特徴量と本質属性を表現する特徴量に解析的に分離する。これを用いて、画像集合に対して本質属性のみを評価対象とした多様性評価を行う、迷惑属性に頑健な多様性評価指標を提案する。実験では、まず提案した迷惑属性フィルタリングモジュールによって、特徴量を正確に分離できることを示す。次に、提案指標が既存指標に比べて迷惑属性の多様性に影響されず、本質属性の多様性を評価できることを確認した。最後に、ControlNetを用いた条件付け画像生成が本質属性の多様性にどう影響を与えるか評価した。その結果、ControlNetの使用が本質属性の多様性を向上させる場合があることを示した。本研究の貢献としては、(1) 独立成分分析と寄与度評価を組み合わせた理論的裏付けのある特徴量分離手法 (迷惑属性フィルタリングモジュール) の提案、(2) 迷惑属性の影響に頑健な多様性評価指標の提案、(3) ControlNetの使用の有無による本質属性の多様性への影響評価を行った点が挙げられる。

Thesis Abstract

A Robust Diversity Evaluation Metric Against Nuisance Attributes for Face Datasets

In recent years, advances in image generation technologies, such as diffusion models, have enabled easy creation of high-quality images. Users expect conditioned image generation models to represent elements specified by generation conditions precisely and to allow diverse expressions of elements not specified by generation conditions. Existing image diversity evaluation metrics have the problem of including the diversity of specified elements in their evaluation. As a result, they are not suitable for appropriately assessing the diversity of unspecified elements. This study defines specified elements by generation conditions as “nuisance attributes” and unspecified elements as “intrinsic attributes”. We aim to develop a diversity metric that focuses only on intrinsic attributes and removes the effects of nuisance attributes. We note that features used in existing metrics mix those representing nuisance attributes and those representing intrinsic attributes. To address this, we propose a “nuisance attribute filtering module” that combines independent component analysis (ICA) and feature contribution evaluation. This module analytically separates features tied to nuisance attributes from those tied to intrinsic attributes. Using this approach, we propose a diversity evaluation metric that evaluates the diversity of only intrinsic attributes in an image dataset. Through experiments, we first show that the nuisance attribute filtering module accurately separates the two types of features. Next, we confirm that our metric is less influenced by nuisance attributes than existing metrics and can measure intrinsic attribute diversity. Finally, we evaluate how the use of ControlNet in image generation affects intrinsic attribute diversity. Our results indicate that ControlNet can sometimes enhance intrinsic attribute diversity. The main contributions of this study are: (1) proposing a theoretically grounded feature separation method, the nuisance attribute filtering module, (2) introducing a diversity metric robust to nuisance attributes, and (3) evaluating how ControlNet usage influences intrinsic attribute diversity.

目次

第 1 章 序論	7
第 2 章 関連研究	10
2.1 画像生成手法	10
2.1.1 拡散モデル	10
2.1.2 テキスト条件付け画像生成	16
2.1.3 画像条件付け画像生成	23
2.2 画像生成評価指標	25
2.2.1 Inception Score	26
2.2.2 Fréchet Inception Distance	27
2.2.3 CLIPScore	28
2.2.4 画像多様性評価指標	29
2.3 特徴量分離手法	31
2.4 特徴量寄与度評価指標	33
2.4.1 Shapley Value	33
2.4.2 Shapley Additive Global importanceE	33
2.4.3 SHAP と SAGE の比較	34
第 3 章 提案手法	36
3.1 問題設定	36
3.2 提案指標	38
3.2.1 特徴抽出モジュール	39
3.2.2 迷惑属性フィルタリングモジュール	42
3.2.3 多様性評価モジュール	45

第 4 章 実験	46
4.1 迷惑属性フィルタリングモジュールの性能評価	46
4.1.1 実験設定	46
4.1.2 実験結果	51
4.1.3 考察	63
4.2 多様性評価指標の迷惑属性への頑健性評価	65
4.2.1 実験設定	65
4.2.2 実験結果	72
4.2.3 考察	75
4.3 ControlNet の多様性への影響評価	76
4.3.1 実験設定	76
4.3.2 実験結果	85
4.3.3 考察	93
第 5 章 結論	96
謝辞	98
研究業績	105
付 録 A	106
A.1 実験における生成画像例	106
A.2 追加実験	116

表 目 次

4.1 既存指標と提案指標の比較	72
4.2 既存指標と提案指標の比較	72
4.3 男性を示すプロンプトの穴埋め候補	83
4.4 女性を示すプロンプトの穴埋め候補	83
4.5 ControlNet(CN) の有無による多様性評価値の比較	86
4.6 ControlNet(CN) の条件ランドマーク画像の違いによる多様性評価値の比較	86

目 次

1.1	既存指標と提案指標による多様性評価の違い	8
2.1	拡散過程によりデータからノイズへ変換し、逆拡散過程によりノイズからデータを生成する 手順	11
2.2	DDPM によるモデル学習	15
2.3	条件付き生成におけるノイズ推定方法	17
2.4	Classifier Guidance を用いたノイズ推定方法	18
2.5	Classifier-Free Guidance を用いたノイズ推定方法	19
2.6	LDM におけるモデル学習の概念図	20
2.7	LDM における推論の概念図	20
2.8	Stable Diffusion 3 による生成画像の例	22
2.9	ControlNet のアーキテクチャ	23
2.10	ControlNet を用いた生成画像例	25
2.11	Inception Score が高くなる識別分布の例	27
2.12	CLIP の学習方法 [1]	29
3.1	問題設定の具体例	37
3.2	多様性評価指標に対する評価尺度で用いる顔画像集合の例	38
3.3	既存指標と提案指標による多様性評価の違い	39
3.4	提案指標による多様性評価の流れ	39
3.5	顔画像特徴量に迷惑属性が含まれている具体例	41
3.6	各成分に対するラベリングの基準	43
3.7	本質属性ラベルを用いた迷惑属性フィルタリングモジュールの流れ	44
3.8	迷惑属性ラベルを用いた迷惑属性フィルタリングモジュールの流れ	44

4.1	MUCT に含まれる顔画像の例 [2]	47
4.2	MUCT における撮影アングルの詳細 [2]	48
4.3	MUCT における各 ID に含まれる画像の種類 [2]	49
4.4	顔画像の前処理 (顔切り出し・アラインメント・リサイズ)	50
4.5	独立成分数と本質成分数の関係	52
4.6	独立成分数と迷惑成分数の関係	53
4.7	独立成分数と本質成分割合の関係	54
4.8	独立成分数と迷惑成分割合の関係	55
4.9	独立成分数と ID クラス分類モデル精度の関係	56
4.10	独立成分数と顔の向きクラス分類モデル精度の関係	57
4.11	独立成分数と $\cos$ 類似度の関係 (y 軸の範囲は 0% から 100% に設定)	58
4.12	独立成分数と $\cos$ 類似度の関係 (y 軸の範囲は 80% から 100% に設定)	59
4.13	本質成分数と ID クラス分類モデル精度の関係	60
4.14	本質成分数と顔の向きクラス分類モデル精度の関係	61
4.15	本質成分数と $\cos$ 類似度の関係 (y 軸の範囲は 0% から 100% に設定)	62
4.16	本質成分数と $\cos$ 類似度の関係 (y 軸の範囲は 80% から 100% に設定)	63
4.17	本質属性の多様性は等しく迷惑属性の多様性に差がある 2 つのデータセットの作成方法	66
4.18	ヒストグラムの例	69
4.19	カーネル密度推定の結果を示すグラフの例	70
4.20	箱ひげ図の例	70
4.21	バイオリン図の例	71
4.22	スウォーム図の例	71
4.23	ヒストグラムによる既存指標と提案指標の比較	73
4.24	カーネル密度推定の結果を示すグラフによる既存指標と提案指標の比較	73
4.25	箱ひげ図による既存指標と提案指標の比較	74
4.26	バイオリン図による既存指標と提案指標の比較	74
4.27	スウォーム図による既存指標と提案指標の比較	75
4.28	Realistic Vision V6.0 による生成画像の例	77
4.29	Face Landmark ControlNet による画像生成の例	77

4.30 FFHQ に含まれる顔画像の例	79
4.31 LFW に含まれる顔画像の例 [3]	81
4.32 ランドマークデータセット作成の流れ	82
4.33 3 種類のランドマークデータセットの違い	84
4.34 t-SNE による各ランドマークデータセットの可視化	87
4.35 t-SNE による各ランドマークデータセットの可視化 (FFHQ と LFW の比較)	88
4.36 t-SNE による各ランドマークデータセットの可視化 (LFW と生成顔画像集合の比較)	89
4.37 t-SNE による各ランドマークデータセットの可視化 (FFHQ と生成顔画像集合の比較)	90
4.38 t-SNE による各ランドマークデータセットの可視化 (FFHQ)	91
4.39 t-SNE による各ランドマークデータセットの可視化 (LFW)	92
4.40 t-SNE による各ランドマークデータセットの可視化 (生成顔画像集合)	93
A.1 生成条件として使用したプロンプトの例	107
A.2 ControlNet を使用せずに生成した顔画像の例	108
A.3 生成顔画像から抽出したランドマーク画像の例	109
A.4 ControlNet を使用して生成した顔画像の例 (条件画像：生成顔画像から抽出したランドマーク画像)	110
A.5 ランドマーク抽出対象となった FFHQ の顔画像の例	111
A.6 FFHQ から抽出したランドマーク画像の例	112
A.7 ControlNet を使用して生成した顔画像の例 (条件画像：FFHQ から抽出したランドマーク画像)	113
A.8 ランドマーク抽出対象となった LFW の顔画像の例	114
A.9 LFW から抽出したランドマーク画像の例	115
A.10 ControlNet を使用して生成した顔画像の例 (条件画像：LFW から抽出したランドマーク画像)	116
A.11 ランダムに特徴量分離を行った場合の独立成分数と ID クラス分類モデル精度の関係	118
A.12 ランダムに特徴量分離を行った場合の独立成分数と顔の向きクラス分類モデル精度の関係	119
A.13 ランダムに特徴量分離を行った場合の独立成分数と cos 類似度の関係 (y 軸の範囲は 0% から 100% に設定)	120
A.14 ランダムに特徴量分離を行った場合の独立成分数と cos 類似度の関係 (y 軸の範囲は 70% から 90% に設定)	121

第1章 序論

近年、拡散モデルの発展により画像生成技術が大きく進歩している。[4][5] 画像生成モデルには生成条件への追従性と同時に、創造性や公平性といった観点から、その条件で指定されていない要素についての多様性が求められる。そのためモデルに対して、生成画像の多様性を測ることが1つの重要な評価指標となる。生成条件により指定されている要素には多様性は不要である。一方で、指定されていない要素の多様性は高いほうが望ましい。しかし、既存の多様性評価指標 [6][7] ではこれらの両方が混在したままの多様性しか評価できないという問題があった。例として、条件付け画像生成を用いて生成された2つの画像集合を考える。1つ目は単一の条件で生成されており、2つ目は多様な条件で生成されている。これらの画像集合における生成条件で指定されていない要素の多様性を測りたいとする。この場合に既存指標を用いると、指定されていない要素に加えて生成条件で指定された要素の多様性も多様性評価の対象に含めてしまう。

本研究では生成条件で指定された要素を多様性評価における迷惑属性と位置付ける。また、指定されていない要素を多様性評価における本質属性と位置付ける。迷惑属性の多様性の多寡による影響を受けず、本質属性の多様性を測る多様性評価指標を構築することを目標とする。これにより、先の例における2つの画像集合に対して生成条件で指定されていない要素の多様性を測ることができる。特に本研究では、研究対象をランドマークによる条件付けを行う ControlNet を用いた顔画像生成とし、迷惑属性をランドマークによって決まる顔の向き、本質属性を ID とする。

既存指標である Vendi Score[6] や VariFace で提案された Face Vendi Score[7] では、エンコーダを用いて画像集合から特徴量を抽出し、その特徴量に対して多様性評価を行う。この時、エンコーダが完全に本質属性のみを表現する特徴量 (本質特徴量) を抽出しない限り、特徴量には迷惑属性を表現する特徴量 (迷惑特徴量) も含まれる。ArcFace をはじめとする既存の顔認識モデル [8][9] では完全な本質特徴量を抽出することが難しいため、既存指標では評価対象に迷惑属性の多様性も含まれる。この特徴量に特徴量分離手法を適用し、本質特徴量と迷惑特徴量を分離することも考えられる。しかし、最新の特徴量分離手法 [10][11][12] は深層学習をベースとしており、評価指標の一部として組み込むには説明性が不十分である。そこで本研究では、理論的な裏付けのある解析的な手法によって元特徴量を迷惑特徴量と本質特徴量に分離する迷惑属性フィルタリングモジュールと、それを用いて本質特徴量の多様性評価を行う評価指標を提案する。迷惑

属性フィルタリングモジュールでは、評価対象が閉集合であることを利用し、独立成分分析 [13] と特徴量寄与度評価指標 [14][15] を導入する。未知のサンプルの特徴量も分離可能である独立成分分析の特性を活かし、各成分の独立性を高める。さらに特徴量寄与度評価指標により、各成分が迷惑属性に寄与する成分 (迷惑成分) か本質属性に寄与する成分 (本質成分) かを判別する。最後に本質成分から本質特徴量を構築し、その特徴量に対して多様性評価を行うことで目標を達成できる。これにより、既存指標は迷惑属性の多様性の多寡に影響されてしまうという課題を解決する。既存指標と提案指標の違いを図 1.1 に示す。




図 1.1: 既存指標と提案指標による多様性評価の違い

実験では、まず迷惑属性フィルタリングモジュールを用いることで特徴量を本質特徴量と迷惑特徴量に分離できることを示す。次に、提案指標が既存指標に比べて迷惑属性の多様性の多寡に影響を受けず本質属性の多様性評価を行えることを示す。最後に、ControlNet[16] による条件付けにより、条件付けられていない要素の多様性がどのように変化するかは評価されたことがない。そこで、ControlNet の使用の有無により本質属性の多様性にはどのような影響があるのか評価した。その結果、ControlNet の使用が本質属性の多様性を向上させる場合があることを示した。

本研究の貢献は以下のようにまとめられる。

- 独立成分分析と特徴量寄与度評価指標を組み合わせることで、説明性があり高品質な特徴量分離が可能である迷惑属性フィルタリングモジュールを提案した。
- 迷惑属性フィルタリングモジュールを用いた多様性評価指標を提案した。これにより、迷惑属性の多様性の多寡に頑健な多様性評価を世界で初めて実現した。

-
- 提案指標を用いた実験を通じて、ControlNet の使用が生成画像の本質属性の多様性を向上させる場合があることを示した.

本論文の構成は以下のとおりである. 第 2 章では関連研究を紹介する. 第 3 章では, 迷惑属性フィルタリングモジュール及びそれを用いた多様性評価指標を提案する. 第 4 章では, 迷惑属性フィルタリングモジュール及び提案指標を用いた実験及び考察と, ControlNet の生成画像の多様性への影響評価及び考察を行う. 最後に, 第 5 章で結論を述べる.

第2章 関連研究

この章では本研究の関連研究について説明する。まず、2.1 節では現在主流の画像生成モデルである拡散モデル及び拡散モデルを基盤とした条件付け画像生成手法について説明する。次に、2.2 節ではテキストやポーズ画像を用いた条件付け画像生成について説明する。次に、2.2 節では画像生成モデルを評価する指標について説明する。次に、2.3 節では本研究の提案手法で用いる多変量解析手法について説明する。最後に、2.3 節では本研究の提案手法で用いる特徴量寄与度可視化手法について説明する。

2.1 画像生成手法

近年、拡散モデル [17] を基盤とした画像生成モデル [4][5] が急速に発展している。これらのモデルは非常に高品質な画像生成を実現する。さらに、テキストや画像による条件付け生成が可能である。本節では拡散モデルを基盤とした画像生成手法の詳細を説明する。まず 2.1.1 項では、拡散モデルの理論的な背景について説明する。次に、2.1.2 項では、拡散モデルを基盤としたテキスト条件付け画像生成技術について説明する。最後に、2.1.3 項では、画像条件付け画像生成技術について説明する。

2.1.1 拡散モデル

本項では多くの最新の画像生成モデルの要素技術となっている拡散モデルについて説明する。図 2.1 に示すように、拡散モデルは、観測データに徐々に少量のノイズを加えて最終的に完全なノイズへ変換する拡散過程と、その逆をたどる逆拡散過程から構成される。逆拡散過程では、完全にランダムなガウシアンノイズからノイズを徐々に除去することで、元のデータを再構成できる。具体的には、ノイズの除去をディープニューラルネットワークで段階的に実行することで、ガウシアンノイズから元のデータを生成可能にする。本項では、多くの拡散モデルの基盤となる Denoising Diffusion Probabilistic Models (以降 DDPM)[17] について説明する。




図 2.1: 拡散過程によりデータからノイズへ変換し、逆拡散過程によりノイズからデータを生成する手順

定式化

拡散過程は、時刻 0 から T までの T ステップでデータをノイズへと変換する手順である。時刻 t におけるデータを x_t とすると、時刻 $t-1$ から t へのノイズ付加は以下の式で与えられる。

$$x_t = \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t \quad (2.1)$$

ここで、 β_t は時刻 t におけるノイズ量の強さを示すハイパーパラメータであり、 ϵ_t は平均 0、分散 1 のガウシアンノイズである。データ x_0 が与えられたとき、ノイズ付与を t 回繰り返せば x_t をサンプリングできる。

$$\begin{aligned} x_t &= \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon_t \\ &= \sqrt{1 - \beta_t} \left(\sqrt{1 - \beta_{t-1}} x_{t-2} + \sqrt{\beta_{t-1}} \epsilon_{t-1} \right) + \sqrt{\beta_t} \epsilon_t \\ &= \sqrt{(1 - \beta_t)(1 - \beta_{t-1})} x_{t-2} + \sqrt{1 - (1 - \beta_t)(1 - \beta_{t-1})} \epsilon' \\ &= \dots = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon_t \end{aligned} \quad (2.2)$$

ただし、 $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ 、 $\alpha_t = 1 - \beta_t$ とし、 ϵ' と ϵ_t は標準正規分布に従う独立なノイズである。また、正規分布の再生性から $a\epsilon_t + b\epsilon_{t-1} \sim \mathcal{N}(0, (a^2 + b^2)\mathbf{I})$ となるため、 $\sqrt{a^2 + b^2} \epsilon'$ と書き換え可能である。これにより、 x_0 を固定したときの x_t は平均が $\sqrt{\bar{\alpha}_t} x_0$ 、分散が $(1 - \bar{\alpha}_t)\mathbf{I}$ の正規分布になることがわかる。また、 T が十分大きく、時刻 T における $\bar{\alpha}_T$ がほぼ 0 のとき、 x_T は完全なガウシアンノイズとみなせる。

続いて、この拡散過程を逆方向にたどる逆拡散過程を考える。逆拡散過程では、 x_T のようなノイズから少しずつノイズを除去し、最終的に x_0 を得る。拡散過程において極めて小さなノイズを段階的に加えると、逆拡散過程も正規分布によって近似できることが知られている。ここで、逆拡散過程の正規分布の平均と分

散をモデルによって推定するとし、モデルのパラメータを θ 、その推定対象となる平均および分散をそれぞれ $\mu_\theta(x_t, t)$ 、 $\sigma_\theta(x_t, t)$ と定義する。すると、 x_t が与えられたときの x_{t-1} の分布は次式となる。

$$p_\theta(x_{t-1}|x_t) = \mathcal{N}(\mu_\theta(x_t, t), \Sigma_\theta(x_t, t)) \quad (2.3)$$

ここで x_T は完全なガウシアンノイズなので、もし μ_θ と Σ_θ を正しく推定できれば、この正規分布から順次サンプリングすることで x_0 を復元可能となる。

学習と損失関数

生成モデルの学習においては、観測データが従う真の分布 $p_{\text{data}}(x)$ と、学習によって得られるモデル分布 $p_\theta(x)$ との距離を最小化することが目標となる。ここでは距離の指標として KL ダイバージェンス [18] を用い、次式によりモデルのパラメータを最適化する。

$$\begin{aligned} \theta^* &= \underset{\theta}{\operatorname{argmin}} D_{KL}(p_{\text{data}}(x) \parallel p_\theta(x)) \\ &= \underset{\theta}{\operatorname{argmin}} \left[\mathbb{E}_{x \sim p_{\text{data}}} \log p_{\text{data}}(x) - \mathbb{E}_{x \sim p_{\text{data}}} \log p_\theta(x) \right] \\ &= \underset{\theta}{\operatorname{argmin}} \mathbb{E}_{x \sim p_{\text{data}}} [-\log p_\theta(x)] \end{aligned} \quad (2.4)$$

すなわち、観測データの負の対数尤度を最小化すればよいことになる。観測データ x_0 の尤度 $p_\theta(x_0)$ は、逆拡散過程での同時確率から潜在変数を積分することで得られる。

$$p_\theta(x_0) = \int p_\theta(x_{0:T}) dx_{1:T} \quad (2.5)$$

しかしながら、この積分は直接的には計算量が膨大であり実用的でない。そこで、変分法を用いて対数周辺尤度の下限（Evidence Lower Bound；ELBO）を最大化することで、尤度を近似的に評価する。最小化問題として扱うため、負の変分下限（Variational Lower Bound；VLB）を導入し、これを最小化する。

$$\begin{aligned}
-\log p_\theta(x_0) &= -\log \left(\int p_\theta(x_{0:T}) dx_{1:T} \right) \\
&= -\log \left(\int q(x_{1:T}|x_0) \frac{p_\theta(x_{0:T})}{q(x_{1:T}|x_0)} dx_{1:T} \right) \\
&\leq \mathbb{E}_{q(x_{1:T}|x_0)} \left[-\log \frac{p_\theta(x_{0:T})}{q(x_{1:T}|x_0)} \right] \\
&= \mathbb{E}_{q(x_{1:T}|x_0)} \left[-\log \frac{p_\theta(x_0|x_1) \cdots p_\theta(x_{T-1}|x_T) p_\theta(x_T)}{q(x_T|x_{T-1}) \cdots q(x_1|x_0)} \right] \\
&= \mathbb{E}_{q(x_{1:T}|x_0)} \left[-\log p_\theta(x_T) - \sum_{t \geq 1} \log \frac{p_\theta(x_{t-1}|x_t)}{q(x_t|x_{t-1})} \right] =: \mathcal{L}_{\text{VLB}}(\theta)
\end{aligned} \tag{2.6}$$

ここで拡散過程 $q(x)$ のマルコフ性から $q(x_t|x_{t-1}) = q(x_t|x_{t-1}, x_0)$ が成り立つこと、およびベイズの定理を用いると、 $\mathcal{L}_{\text{VLB}}(\theta)$ は次のように変形できる。

$$\begin{aligned}
\mathcal{L}_{\text{VLB}}(\theta) &= \mathbb{E}_{q(x_{1:T}|x_0)} \left[-\log p(x_T) - \sum_{t \geq 1} \log \frac{p_\theta(x_{t-1}|x_t)}{q(x_t|x_{t-1})} \right] \\
&= \mathbb{E}_{q(x_{1:T}|x_0)} \left[-\log p(x_T) - \sum_{t \geq 1} \log \frac{p_\theta(x_{t-1}|x_t)}{q(x_t|x_{t-1})} - \log \frac{p_\theta(x_0|x_1)}{q(x_1|x_0)} \right] \\
&= \mathbb{E}_{q(x_{1:T}|x_0)} \left[-\log p(x_T) - \sum_{t \geq 1} \log \frac{p_\theta(x_{t-1}|x_t)}{q(x_t|x_{t-1}, x_0)} - \log \frac{p_\theta(x_0|x_1)}{q(x_1|x_0)} \right] \\
&= \mathbb{E}_{q(x_{1:T}|x_0)} \left[-\log \frac{p(x_T)}{q(x_T|x_0)} - \sum_{t \geq 1} \log \frac{p_\theta(x_{t-1}|x_t)}{q(x_{t-1}|x_t, x_0)} - \log p_\theta(x_0|x_1) \right] \\
&= D_{\text{KL}}(q(x_T|x_0) \parallel p_\theta(x_T)) + \sum_{t \geq 1} \mathbb{E}_{x_t \sim q(x_t|x_0)} \left[D_{\text{KL}}(q(x_{t-1}|x_t, x_0) \parallel p_\theta(x_{t-1}|x_t)) \right] \\
&\quad - \mathbb{E}_{x_1 \sim q(x_1|x_0)} [\log p_\theta(x_0|x_1)]
\end{aligned} \tag{2.7}$$

右辺第1項は、 x_T が完全ガウシアンノイズであり、かつパラメータ θ に依存しないため無視できる。第2項は KL ダイバージェンスの期待値であり、(2.2) 式を用いて $q(x_t|x_0)$ は容易にサンプリングできるため、ランダムにサンプリングした x_t に対してこの KL ダイバージェンスを評価し、繰り返し平均をとればよい。ここで $p_\theta(x_{t-1}|x_t)$ は正規分布で、もう一方の $q(x_{t-1}|x_t, x_0)$ はマルコフ性とベイズの定理から次のように書ける。

$$q(x_{t-1}|x_t, x_0) = \frac{q(x_t|x_{t-1}, x_0) q(x_{t-1}|x_0)}{q(x_t|x_0)} = \frac{q(x_t|x_{t-1}) q(x_{t-1}|x_0)}{q(x_t|x_0)} \tag{2.8}$$

この式中の $q(x_t|x_{t-1}), q(x_{t-1}|x_0), q(x_t|x_0)$ はすべて正規分布であるため、結果として

$$q(x_{t-1}|x_t, x_0) = \mathcal{N}(\tilde{\mu}_t(x_t, x_0), \tilde{\beta}_t \mathbf{I}) \quad (2.9)$$

$$\tilde{\mu}_t(x_t, x_0) = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}} \beta_t}{1 - \bar{\alpha}_t} x_0, \quad \tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t \quad (2.10)$$

が得られる．よって，(2.7) 式 の第 2 項は正規分布間の KL ダイバージェンスに帰着する．さらに，DDPM では分散 $\sigma_t^2 = \beta_t$ とするハイパーパラメータ σ_t を用いて $\Sigma_\theta(x_t, t) = \sigma_t^2 \mathbf{I}$ を固定するため，(2.7) 式 の第 2 項を正規分布の平均間の二乗誤差として単純化できる．

$$L_t(x_0, x_t | \theta) := D_{\text{KL}}(q(x_{t-1}|x_t, x_0) \parallel p_\theta(x_{t-1}|x_t)) = \frac{1}{2\sigma_t^2} \|\mu_\theta(x_t, t) - \tilde{\mu}_t(x_t, x_0)\|_2^2 + C \quad (2.11)$$

ただし， C は σ_t に依存しない定数である．また，(2.7) 式 の第 3 項は，第 2 項を $t = 1$ から T まで総和をとる形で置き換えても大きな問題は生じないことが経験的に知られている [?].

以上から，DDPM の学習は次の最適化問題に帰着する．

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \mathbb{E}_{x_0 \sim p_{\text{data}}, x_t \sim q(x_t|x_0)} [L_t(x_0, x_t | \theta)] \quad (2.12)$$

さらに，学習対象をノイズ推定へ切り替えることで，(2.2) 式 と (2.10) 式 を用いて (2.12) 式 を次の形に書き換えることができる．ここで，モデルが推定するのは $\tilde{\mu}_t$ ではなく，観測データに加わったノイズ ϵ_t であり， ϵ_θ を学習する設定である．

$$L_t(x_0, \epsilon, t | \theta) - C = \frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)} \|\epsilon_\theta(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) - \epsilon\|^2 \quad (2.13)$$

DDPM では，この 2 乗誤差の係数を無視し，より単純な形の損失関数を用いることが提案されている．

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \mathbb{E}_{x_0 \sim p_{\text{data}}, t \sim \mathcal{U}(1, T), \epsilon \sim \mathcal{N}(0, \mathbf{I})} [L_{\text{simple}}(x_0, \epsilon, t | \theta)] \quad (2.14)$$

$$L_{\text{simple}}(x_0, \epsilon, t | \theta) = \|\epsilon_\theta(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) - \epsilon\|_2^2 \quad (2.15)$$

この最適化問題は，観測データにランダム時刻 t に応じたノイズを重畳し，そのノイズを推定器 (ノイズ

予測ネットワーク)で推定するという, 図 2.2 に示すような単純な二乗誤差の学習問題として解釈できる.

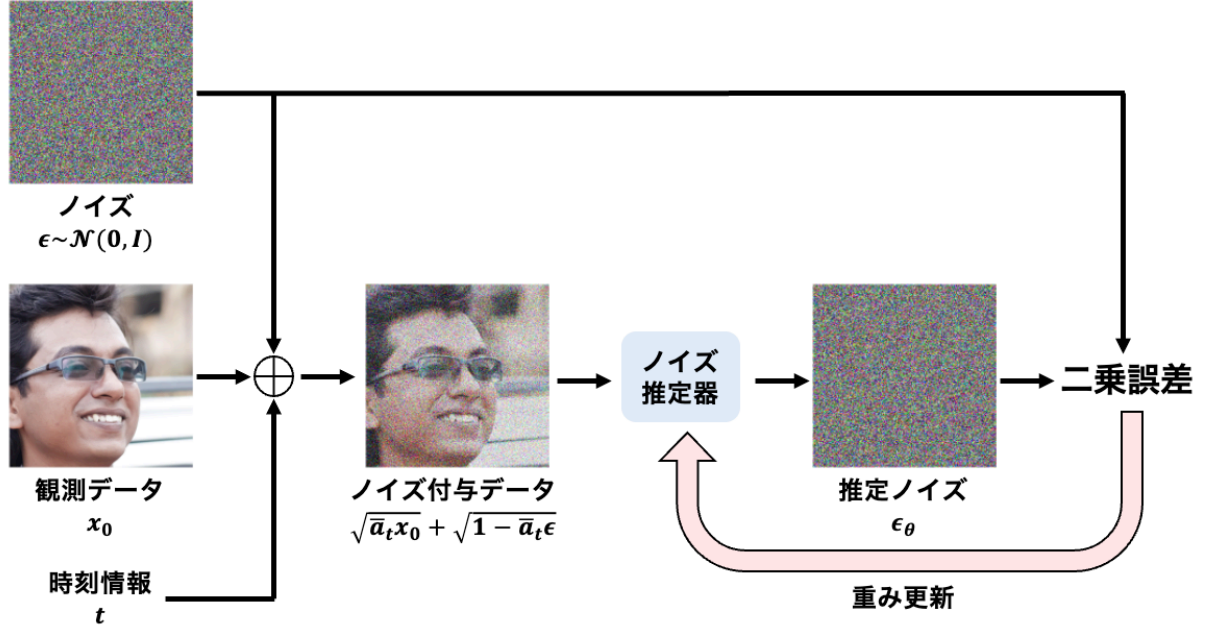


図 2.2: DDPM によるモデル学習

データ生成

(2.3) 式に示すように, 逆拡散過程ではガウシアンノイズに相当する x_T からサンプリングを繰り返すことで, データ x_0 を得ることが可能である. ここで, Σ_θ は固定されているが, μ_θ は ϵ_θ を用いて算出する必要がある. (2.2) 式から x_0 の推定値 $\hat{x}_0$ を導くと, 以下の式が得られる.

$$\hat{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)) \quad (2.16)$$

さらに, (2.10) 式において x_0 の代わりに $\hat{x}_0$ を用いると, μ_θ は次のように書ける.

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{1 - \beta_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) \quad (2.17)$$

これらの μ_θ と Σ_θ をもとに, (2.3) 式で定義される各時刻の逆拡散ステップを計算することで, 最終的にデータ x_0 を生成することが可能である.

2.1.2 テキスト条件付け画像生成

DDPM では、逆拡散過程を時刻ごとに行うノイズ除去の問題として捉え、各時刻のノイズ付き画像を入力として、その時刻に取り除くノイズを U-Net [19] で推定する。ただし、DDPM に用いられる U-Net はグループ正規化 [20] とアテンション機構 [21] を組み合わせたアーキテクチャになっている。Nichol と Dhariwal [22] は、従来の DDPM で固定していた分散を学習可能なパラメータとし、ノイズのスケジューリング手法を線形スケジュールからコサインスケジュールへ変更するなど、いくつかの改善を加えることで生成品質を向上させた。また、この改善により推論時の逆拡散過程のステップ数を削減しても十分に高い品質が得られることを示した。さらに、Dhariwal と Nichol [23] は U-Net のネットワークをより大規模化し、グループ正規化を適応的グループ正規化 (Adaptive Group Normalization ; AdaGN) [24] に置き換えることで、より高い品質を実現する Ablated Diffusion Model (ADM) を提案した。現在、多くの拡散モデルがこの ADM の U-Net アーキテクチャをベースに構築されている。

テキストからの画像生成は一般的な条件付き生成の一種である。拡散モデルは時刻 t を条件としてノイズを推定する仕組みであるため、時刻情報に加えてテキストなどの追加情報をモデルへ入力することで条件付けが可能となる。そのため、式 2.3 に条件情報 c を組み込み、以下のような確率分布を考える。

$$p_{\theta}(x_{t-1} | x_t, c) = \mathcal{N}(\mu_{\theta}(x_t, c, t), \Sigma_{\theta}(x_t, c, t)) \quad (2.18)$$

ここで、条件情報 c はテキスト以外にも、画像などさまざまな形式が考えられる。図 2.3 に示すように、通常はあらかじめ学習済みのエンコーダを用いて条件情報を埋め込みベクトルへ変換した上で、U-Net の適切な層へ入力する手法が取られる。

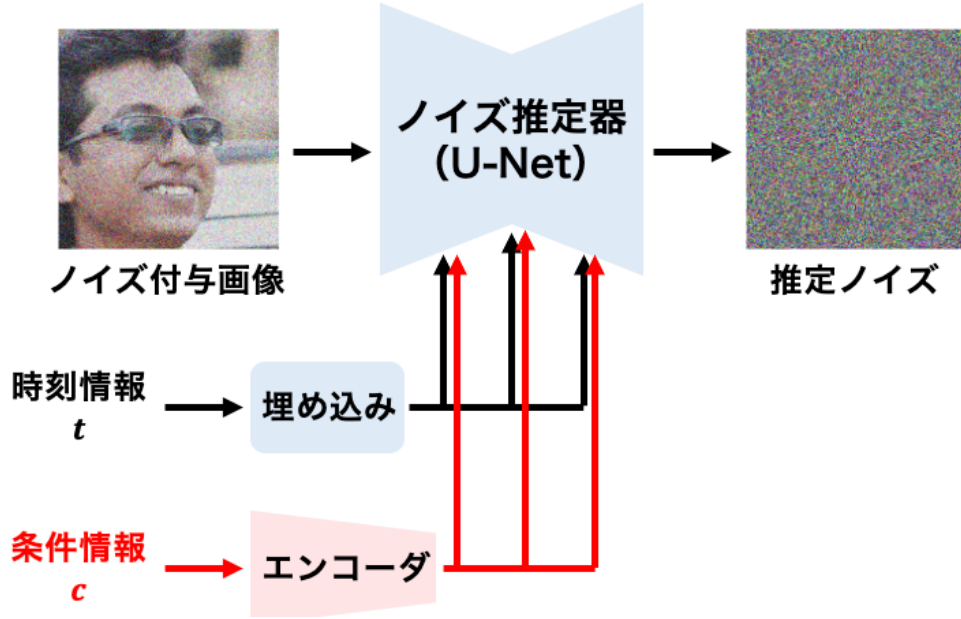


図 2.3: 条件付き生成におけるノイズ推定方法

上記の方法では、学習時に明示的に条件情報を与えたモデルを訓練するが、拡散モデルの推論過程には多段階のノイズ除去が含まれる。この特徴を利用すれば、学習時に条件情報を使わなくても条件付き生成を行うことが可能である。Classifier Guidance [23] は、逆拡散過程の各時刻で画像を所望のクラスへ近づけるよう修正する。Classifier Guidance では、ノイズ付き画像に対してクラス識別を行うモデル $p_\phi(y | x_t)$ を事前に用意し、各時刻の推定ノイズを以下のように修正することで、目的とするクラスに誘導する。

$$\hat{\epsilon}_{\theta,\phi}(x_t, y, t) = \epsilon_\theta(x_t, t) - w \sqrt{1 - \bar{\alpha}_t} \nabla_{x_t} \log p_\phi(y | x_t) \quad (2.19)$$

ただし、 w はハイパーパラメータであり、値を大きくするほど所望のクラスに合致しやすくなるが、同時に生成画像の多様性は損なわれやすい。 $w > 1$ の場合に所望のクラスへ強く誘導できる。

Classifier Guidance はノイズ付き画像に対してクラス識別が行えるモデル $p_\phi(y | x_t)$ を必要とするが、多様なテキスト条件に対応するために、あらゆるノイズ付き画像とクラスの対応関係を学習するのは難しい。そこで、クラス識別器を持たずに条件付き生成を行う Classifier-Free Guidance [25] が提案された。Classifier-Free Guidance では、学習時に一定の確率でクラス条件 y を与えずに学習することで、条件無しでも生成できるモデル $\epsilon_\theta(x_t, y, t)$ を得る。逆拡散過程では、Classifier Guidance と同様に各時刻のノイズを以下のように修正し、クラスへの誘導を実現する。

$$\begin{aligned}
\hat{\epsilon}_{\theta}(x_t, y, t) &= \epsilon_{\theta}(x_t, y, t) - w(\epsilon_{\theta}(x_t, \emptyset, t) - \epsilon_{\theta}(x_t, y, t)) \\
&= (1 + w) \epsilon_{\theta}(x_t, y, t) - w \epsilon_{\theta}(x_t, \emptyset, t)
\end{aligned}
\tag{2.20}$$

ここで、 $\emptyset$ は空のクラス条件を表す。式からわかるように、条件を考慮した場合としない場合の推定ノイズの差分を調整することで、所望のクラスへ誘導している。条件付き生成モデルが既に用意されている場合でも、条件の忠実度と多様性のバランスを取るために、この Classifier-Free Guidance が多く利用される。生成したくない要素を指定するネガティブプロンプト（negative prompt）という技法もあり、Classifier-Free Guidance における $\emptyset$ に生成を抑制したい情報を与えることで実現可能である。

Classifier Guidance と Classifier-Free Guidance の概念を図 2.4 と図 2.5 に示す。




図 2.4: Classifier Guidance を用いたノイズ推定方法




図 2.5: Classifier-Free Guidance を用いたノイズ推定方法

拡散モデルは他の画像生成モデルと比べて計算コストが高いことが課題となる。GAN や VAE では潜在変数を 1 度生成器に入力すれば画像を得られるのに対し、拡散モデルは逆拡散過程で何度もノイズ除去を行う必要があり、並列化も難しいため時間がかかる。Latent Diffusion Model (以降 LDM) [4] では、低次元の潜在空間に対して拡散過程と逆拡散過程を適用することで計算負荷を低減し、学習および推論を高速化する。従来の拡散モデルでは画像空間で直接拡散・逆拡散過程を実行するが、LDM では図 2.6 のように、まず学習済みの VAE や VQGAN [26] のエンコーダを用いて低次元の潜在空間へ変換した後、その潜在空間上で拡散・逆拡散を行う。推論時には、図 2.7 に示すようにノイズ相当の潜在変数を逆拡散し、最終的に得られる時刻 0 の潜在変数 z_0 をデコーダに通すことで画像を生成する。エンコーダによる変換では画像の縦・横をそれぞれ $1/n$ に縮小し、RGB 画像が $H \times W \times 3$ のサイズであれば潜在変数は $H/n \times W/n \times C$

の大きくなる。条件付き生成を行うために、LDM の U-Net にはクロスアテンションが導入されており、テキスト条件を与える場合は CLIP[1] のテキストエンコーダで得た埋め込みをクロスアテンションへ入力する。

LDM のエンコーダ・デコーダに VQGAN を用いる場合、そのアーキテクチャは VQGAN と比較して、トランスフォーマーベースの自己回帰モデルの代わりに U-Net ベースの逆拡散過程を採用しているという点が大きな違いであると考えられる。

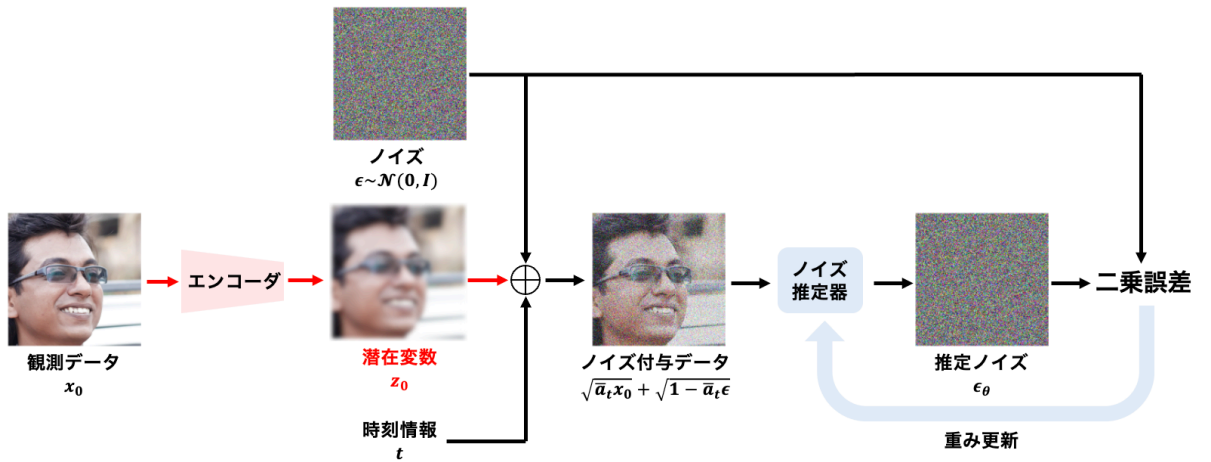


図 2.6: LDM におけるモデル学習の概念図




図 2.7: LDM における推論の概念図

LDM は現在幅広く用いられているテキスト条件付き画像生成モデルである Stable Diffusion[4] の基盤技術である。Stable Diffusion 以外にも高品質なテキスト生成モデルは数多く存在するが、その多くは詳細が発表されておらず、研究目的であってもモデルのパラメータにはアクセスできない場合が多い。一方、Stable Diffusion はオープンソースであるため、研究のみならず様々な用途で利用されており、拡散モデルを基盤とした画像生成技術は Stable Diffusion をベースに発展している。本研究の実験においても、Stable Diffusion をベースとした画像生成モデルを使用する。図 2.8 に最新の Stable Diffusion 3[27] による生成画

像の例を示す.

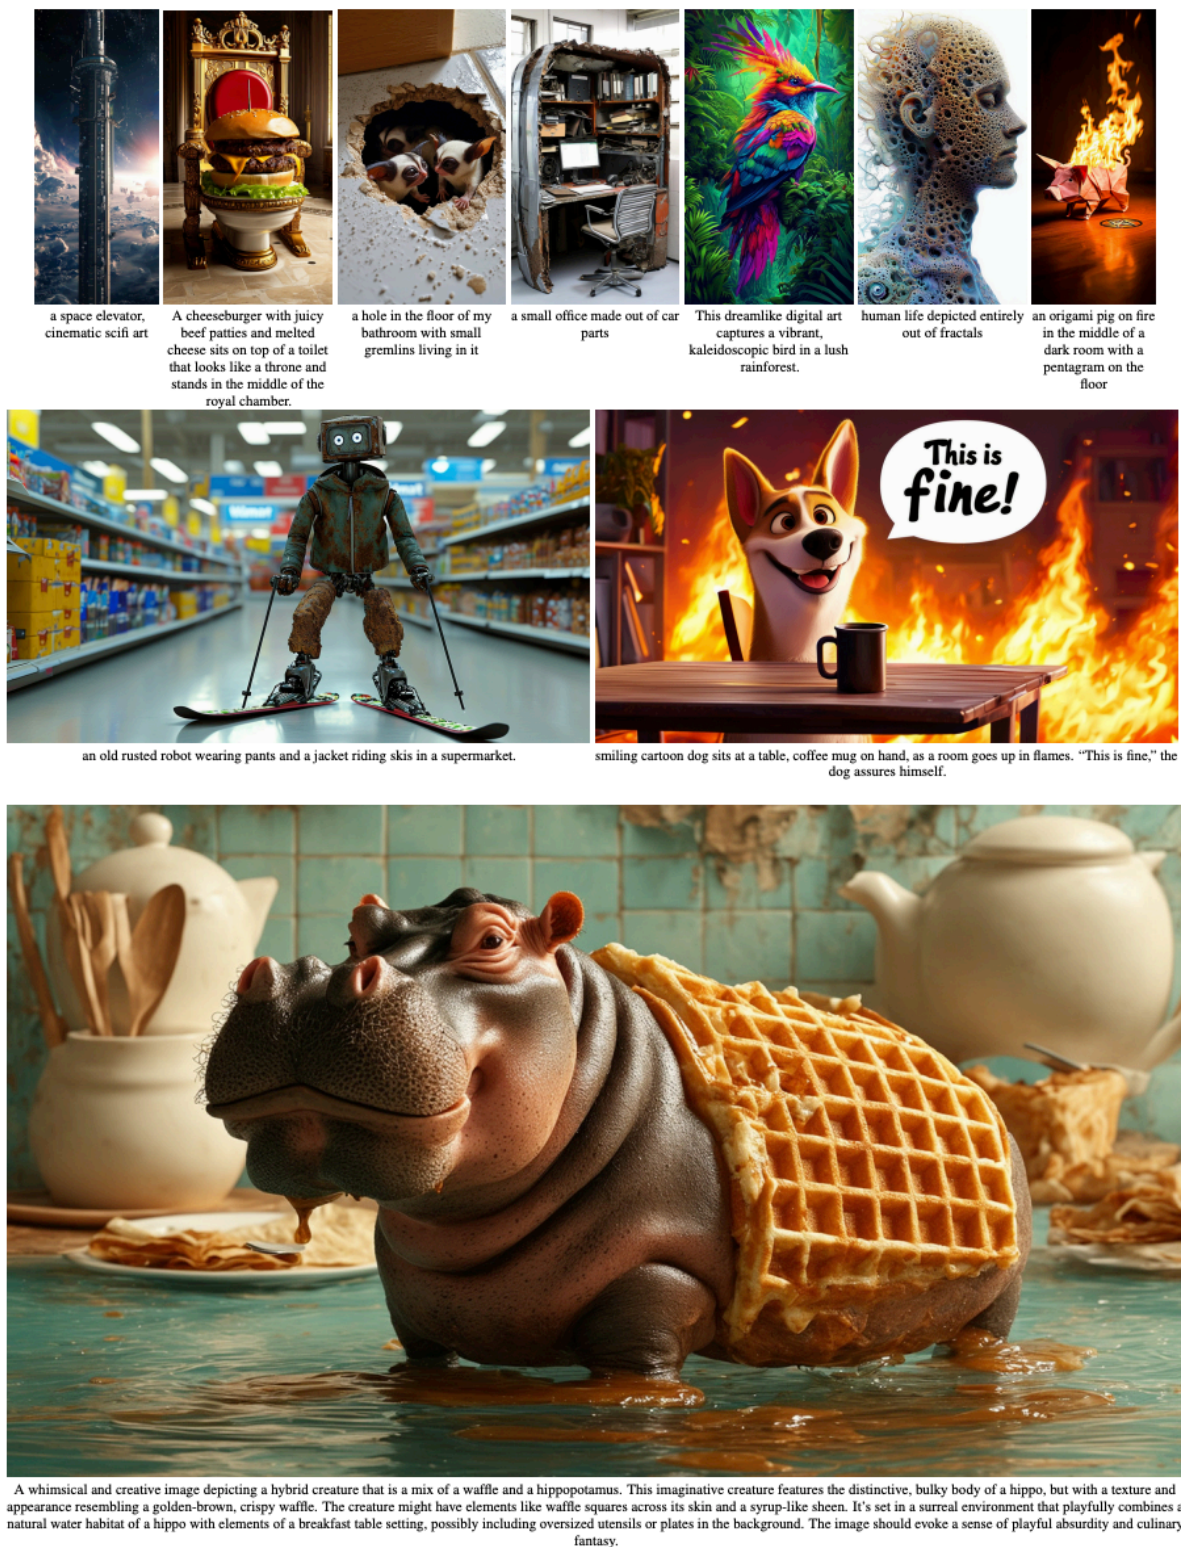


図 2.8: Stable Diffusion 3 による生成画像の例 [27]. 各生成画像の下にはそれぞれ条件となったテキストが示されている。

2.1.3 画像条件付け画像生成

この項では、Stable Diffusion をベースに高品質な画像条件付け画像生成を可能にした ControlNet[16] を紹介する。ControlNet は Stable Diffusion の挙動を制御する外部モデルであり、テキストに加えて画像 (ポーズ画像やエッジ画像など) を条件に加えることができる。具体的には、図 2.9 に示す流れで画像条件付け画像生成を行う。Stable Diffusion(U-Net) のエンコーダ部分をコピーし、学習可能な外部モデル (ControlNet) とする。推論時、Stable Diffusion の推論に対して画像条件が入力された ControlNet の出力が加わることで、画像条件に沿った画像生成が可能となる。学習時、元の Stable Diffusion の重みはロックする。Stable Diffusion を直接学習しない理由として、過学習を避けることと、大規模モデルが持つ性能を保持することが挙げられる。Stable Diffusion と ControlNet は、ControlNet の各層の出力が 0 初期化された畳み込み層を通じて Stable Diffusion のデコーダの各層に入力されることで接続されている。0 初期化された畳み込み層を用いる理由として、学習初期は ControlNet の出力が 0 になり、通常のファインチューニングの容量で学習でき、学習が安定することが挙げられる。




図 2.9: ControlNet のアーキテクチャ

次に数式で ControlNet の処理を示す。まず、Stable Diffusion のエンコーダ層を $F(x; \Theta)$ とし、 x を入力特徴量、 Θ を固定されたエンコーダの重みとする。この場合、出力は次式で表される：

$$y = F(x; \Theta), \quad (2.21)$$

ここで y はエンコーダからの出力特徴量である。

次に, ControlNet の処理を考える. ControlNet は学習可能なコピーを持ち, その重みを Θ_c , 条件付け情報を c とする. このとき, 条件付け情報はゼロ初期化された畳み込み層 $Z(c; \Theta_{z1})$ を通じて変換される.

$$z_c = Z(c; \Theta_{z1}). \quad (2.22)$$

この条件付け特徴量 z_c を x に加え, 学習可能なエンコーダコピー $F(x; \Theta_c)$ を用いて処理する.

$$z_f = F(x + z_c; \Theta_c). \quad (2.23)$$

さらに, z_f はゼロ初期化された畳み込み層 $Z(z_f; \Theta_{z2})$ を通じて変換され, Stable Diffusion の出力 y に統合される. この結果, ControlNet の出力 y_c は次式で定義される.

$$y_c = F(x; \Theta) + Z(F(x + Z(c; \Theta_{z1}); \Theta_c); \Theta_{z2}). \quad (2.24)$$

ここで, 学習初期段階においては Θ_{z1} と Θ_{z2} がゼロに初期化されているため, ControlNet の出力は元の Stable Diffusion の挙動を保持しつつ, 条件付け情報 c を追加する形で徐々に学習が進行する.

ControlNet による画像条件付け画像生成の例を図 2.10 に示す.



図 2.10: ControlNet を用いた生成画像例 [16]. 左列は条件画像である. 中央列はプロンプト条件を “a high-quality, detailed, and professional image”, 画像条件を左列の画像にした場合の生成結果である. 右列はプロンプト条件を画像の下テキスト, 画像条件を左列の画像にした場合の生成結果である.

テキストや画像を用いた条件付き画像生成において, 一般的に条件で指定された要素 (迷惑属性) には多様性が不必要である一方, 創造性や公平性の観点から, 指定されていない要素 (本質属性) には多様性が求められる. 本研究では, 条件付き画像生成モデルの性能をより正確に測るため, 迷惑属性の影響を除去し本質属性のみの多様性を評価する評価指標を提案する.

2.2 画像生成評価指標

本節では画像生成分野 [28][29] におけるモデルの評価を行う評価指標について説明する. 一般的に, 生成画像の品質と多様性を定量的に測る評価指標として, Inception Score や Fréchet Inception Distance が広く用いられている. また, 生成画像のテキスト条件に対する追従性を定量的に測る評価指標として CLIPScore が一般的に用いられる. まず 2.2.1 項では Inception Score について説明する. 次に, 2.2.2 項では Fréchet Inception Distance について説明する. 次に, 2.2.3 項では CLIPScore について説明する. 最後に, 2.2.4 項では, 生成画像の多様性評価に注目した評価指標について説明する.

2.2.1 Inception Score

Inception Score(IS)[30] は、画像生成モデルによる生成画像の多様性と品質を評価する指標である。IS では ImageNet [31] を学習データとした画像認識モデルである Inception Net [32] を用いる。生成画像に対して Inception Net で画像分類を行い、得られるラベルが均等に広がっていれば生成画像の多様性が高いとみなし、また、各推論結果において特定のラベルに対する確信度が高いほど生成画像の質が高いとみなす。そのため、ラベル数が豊富でかつ識別が容易なデータセットに対する IS の値は高くなるように設計されている。

IS は以下のように計算される。 x_i を i 番目の画像、 y をラベルとして、Inception Net に画像 x_i を入力したときに得られるラベル y の確率を $p(y | x_i)$ とする。生成画像に関して識別ラベルが均等に広がっていることは、 $p(y | x_i)$ を x_i 全体で周辺化した分布 $p(y)$ のエントロピーが大きいことを意味し、一方で各推論結果において特定のラベルに対する確信度が高いことは、条件付き分布 $p(y | x_i)$ のエントロピーが小さいことを表す。そこで、これら 2 種類の分布間の乖離を KL ダイバージェンスで測り、すべての $x_i \in X$ について平均した後に指数を取ったものを IS と定義する。ただし、 X は IS を計算する際に用いる全画像の集合、 N はその総数である。IS は次式で与えられる。

$$\exp \left(\frac{1}{N} \sum_{x_i \in X} D_{\text{KL}}(p(y | x_i) \| p(y)) \right) \quad (2.25)$$

KL ダイバージェンスは分布間の距離を計算する。図 2.11 に示すように、 $p(y)$ が比較的広い分布をとり、 $p(y | x_i)$ が特定のラベル周辺で尖った分布になるほど、IS の値が大きくなる。




図 2.11: Inception Score が高くなる識別分布の例

ただし、IS は学習データ (実画像) の分布を一切考慮していないという課題がある。また、ImageNet で学習した Inception Net をそのまま利用することに対する問題点も指摘されている。[33]

2.2.2 Fréchet Inception Distance

IS における学習データの分布を考慮していないという課題を解決するために、Fréchet Inception Distance(FID)[34]が提案された。FID は、実画像と生成画像の分布間距離を測る指標であり、その距離が小さいほど実画像に近い高品質な生成が行われているとみなす。よって、FID の値が小さいほど生成画像の多様性と質が実画像に近いと認識できる。

FID の計算にも Inception Net を用いる。ImageNet を学習データとした Inception Net の最終プーリング層から得られる特徴量が多変量正規分布に従うと仮定し、実画像と生成画像の特徴量分布間の Fréchet 距離を計算する。実画像の平均と共分散行列を μ_r, Σ_r 、生成画像の平均と共分散行列を μ_g, Σ_g とすると、FID は以下の式で定義される。

$$\|\mu_r - \mu_g\|_2^2 + \text{tr}\left(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{\frac{1}{2}}\right) \quad (2.26)$$

FID は人間による評価と高い相関を示し、IS よりもノイズに対して頑健であることが報告されている [34]。なお、FID を計算する際には最終プーリング層の 2048 次元特徴ベクトルを用いるため、実画像と生成画像のいずれも少なくとも 2048 枚以上を用意する必要がある。また、IS 同様、ImageNet で学習済みの Inception Net を使用している点には留意が必要である。

2.2.3 CLIPScore

CLIPScore [35] は、画像とテキストとの関係性を学習した 大規模モデルである CLIP [1] を利用して、画像とそれに対するキャプションの類似度を測る画像キャプションタスクの評価指標である。従来の画像キャプション評価では、人間が作成した複数の参照文と生成文との類似度を BLEU [36] などを用いて評価する参照ベース評価が主流であった。しかし、この手法では参照文を用意する手間が大きいことや、適切だが参照文にない表現が生成ぶんに含まれた場合に不利になるなどの問題がある。CLIPScore では、CLIP を用いることで参照文を必要とせず、画像とキャプションの類似度を直接評価できる。

図 2.12 に示すように、CLIP は画像とテキストをそれぞれ別のエンコーダでベクトル化し、対照学習によって画像と正解テキストの類似度を高め、それ以外のテキストとの類似度を低くするように学習する。CLIPScore は、CLIP で得られる画像埋め込み v とテキスト埋め込み c のコサイン類似度を計算し、定数倍した値を指標とする。式で書くと、以下のようになる。

$$\text{CLIPScore}(c, v) = w \times \max(\cos(c, v), 0) \quad (2.27)$$

コサイン類似度は理論的には $[-1, 1]$ の範囲を取るが、経験則的に画像とテキストのコサイン類似度が概ね 0 から 0.4 程度の範囲に収まることがわかったため、0 未満は 0 に丸め、 $w = 2.5$ としてスコアを $[0, 1]$ の範囲にするよう調整している。

CLIPScore は参照文を必要としないため、従来の参照ベース評価で問題となっていた部分を回避できる。また、CLIPScore と人間の評価との相関が高いことが報告されており、画像キャプションタスクに限らず、画像とテキストの関係性を測るさまざまなタスクで応用可能である。したがって、画像生成タスクでも、条件付けテキストに対する生成画像の追従性を評価する評価指標として広く用いられている。




図 2.12: CLIP の学習方法 [1]

2.2.4 画像多様性評価指標

現在画像生成モデルの多様性評価で広く用いられている FID は参照する画像集合と生成された画像集合の分布間距離の近さにより、生成モデルの多様性と品質を同時に評価する。これに対して、生成モデルが持つべき重要な性能の一側面として生成結果の多様性を独立に評価する指標も提案されてきた [6][7][?]. その先駆けである Vendi Score[6] では、画像集合をエンコーダに入力し、抽出した特徴量の多様性を計算する。これにより、参照画像を必要とせず生成画像の多様性を独立して定量評価可能にした。Vendi Score では特徴量に対する多様性の計算方法として、類似度行列の固有値に基づくシャノンエントロピーを採用している。類似度行列のシャノンエントロピー以外にも、分散共分散行列のトレースを計算することで同等の性能の多様性評価を実現できることが報告されている。[?] また、VariFace[7] では Vendi Score のエンコーダに ArcFace を用いて学習された iResNet を用いることで、顔画像集合の多様性を評価する Face Vendi Score を提案している。以下に、類似度行列のシャノンエントロピー (Vendi Score) と分散共分散行列のトレースの計算式をそれぞれ示す。

初めに Vendi Score で用いられる類似度行列のシャノンエントロピーの計算による特徴量の多様性評価方法を示す。入力となる特徴量を z , 出力となる多様性評価値を D とする。まず, 画像集合の i, j 番目の画像をエンコーダに入力することで得た特徴量を z_i, z_j として, 類似度行列 K を構築する。

$$K_{i,j} = k(z_i, z_j) \quad (2.28)$$

次に, 類似度行列 K を正規化する。ここで, 画像集合における画像枚数を n とする。

$$\tilde{K} = \frac{K}{n} \quad (2.29)$$

次に正規化類似度行列 $\tilde{K}$ の固有値 $\lambda_1, \lambda_2, \dots, \lambda_n$ を計算する。ここで, i 番目の固有ベクトルを $\mathbf{v}_i$ とする。

$$\tilde{K}\mathbf{v}_i = \lambda_i\mathbf{v}_i \quad (\forall i) \quad (2.30)$$

最後に, 固有値 λ からシャノンエントロピー H を算出し, 指数関数に入力することで多様性評価値 D を得る。ここで指数関数を用いる理由は, 確率分布の分散を表すエントロピーを指数関数に入力することで「効果的な異なる要素の数」に変換することができるためである。

$$H = -\sum_{i=1}^n \lambda_i \log \lambda_i \quad (2.31)$$

$$D = \exp(H) \quad (2.32)$$

続いて, 分散共分散行列のトレースの計算による特徴量の多様性評価方法を示す。入力となる特徴量を z , 出力となる多様性評価値を D とする。まず, 特徴量 z の平均ベクトル μ を計算する。ここで, 画像集合における画像枚数を n とする。

$$\mu = \frac{1}{n} \sum_{i=1}^n z_i \quad (2.33)$$

次に, 分散共分散行列 Σ を計算する。

$$\Sigma = \frac{1}{n} \sum_{i=1}^n (z_i - \mu)(z_i - \mu)^\top \quad (2.34)$$

最後に、分散共分散行列 Σ のトレース $\text{tr}(\Sigma)$ を計算し、多様性評価値 D とする。行列の対角成分の総和として定義されるトレースは、特徴量の次元ごとの分散の総和に対応し、データ集合の広がり測定する。

$$D = \text{tr}(\Sigma) = \sum_{j=1}^d \Sigma_{j,j} \quad (2.35)$$

従来の画像多様性評価指標では条件付き生成の有無を考慮していないため、迷惑属性と本質属性を分離して多様性評価することができなかった。本研究ではそれらを分離して、本質属性の多様性を評価する指標を提案する。

2.3 特徴量分離手法

特徴量分離の分野 [37] では、観測データに含まれる要因を独立した特徴量として分離・表現することを目指して、多様な手法が提案されている。初期研究では、主に統計的手法である独立成分分析 [13] が活用されてきた。独立性分析では、統計的独立性を仮定し、観測データを線形的に分離する。理論的背景が強く、初期の特徴量分離の基盤を形成した。その後、VAE や GAN などの生成モデルが利用されるようになった。これらの手法では観測データを再構成する潜在変数を分離することで特徴量の分離を行う。損失関数に正則化項を追加することで潜在変数の独立性を強化するアプローチ betavaeinfoGAN が用いられる。近年では、拡散モデルのような最新の生成モデルを利用する手法 disdiff が登場し、生成能力と分離性能の両立を図っている。

本研究では特徴量を迷惑属性を表現する特徴量と本質属性を表現する特徴量に分離する方法として特徴量分離を使用する。最新の特徴量分離手法としては VAE, GAN, 拡散モデルなどの生成モデルを用いた手法が主流である。しかし、これらの手法は損失関数設計に基づいて分離する特徴量の独立性を誘導するため、理論的に完全な独立性を保証するわけではない。そのため、分離後の特徴量間に依存関係が残る可能性がある。[37] また深層学習をベースとするため、評価指標として用いるとブラックボックス性から説明性が損なわれるうえに、計算コストが高い。

そこで、我々は特徴量分離手法として独立成分分析 [13] を採用する。独立成分分析は観測データを統計的に独立した複数の源信号に分解する手法である。統計的独立性を仮定しており、線形分離が可能な場合には、出力された成分の独立性が理論的には厳密に保証される。以下に独立成分分析における解析の流れと数式を示す。

独立成分分析は、観測データ $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ を統計的に独立した複数の源信号 $\mathbf{s} = [s_1, s_2, \dots, s_m]^T$

に分解する手法である。ICA の基本的なモデルは以下のように記述される。ここで、 $\mathbf{x}$ は観測データベクトル、 $\mathbf{s}$ は独立な源信号ベクトル、 $\mathbf{A}$ は混合行列である。

$$\mathbf{x} = \mathbf{A}\mathbf{s}, \quad (2.36)$$

ICA の目的は、観測データ $\mathbf{x}$ のみから混合行列 $\mathbf{A}$ および源信号 $\mathbf{s}$ を推定することである。このとき、次の3つの仮定を置く。1つ目は、源信号 $\mathbf{s}$ の各成分が統計的に独立であるという仮定である。2つ目は、各源信号 s_i が非ガウス性を持つという仮定である。ただしこの時、全ての成分が非ガウス性を持つ必要はなく、少なくとも1つの信号が非ガウス性を持てば良い。3つ目は、混合が線形であり、混合行列 $\mathbf{A}$ が正則であるという仮定である。

ICA では、観測データから源信号を分離するために、逆変換を次のように定義する。ここで、 $\mathbf{W}$ は分離行列である。

$$\mathbf{s} = \mathbf{W}\mathbf{x}, \quad (2.37)$$

分離行列 $\mathbf{W}$ を適切に学習することで源信号 $\mathbf{s}$ を復元する。分離行列 $\mathbf{W}$ の学習には、非ガウス性を最大化する基準が用いられる。非ガウス性を測る指標としては、尖度、負のエントロピー、対数尤度などが一般的である。例えば、負のエントロピーを用いる場合、次の目的関数を最大化する形で分離行列 $\mathbf{W}$ を推定する。ここで、 $H(s_i)$ は信号 s_i のエントロピー、 $H(\tilde{s}_i)$ は正規分布に従う信号のエントロピーである。

$$J(\mathbf{W}) = \sum_{i=1}^m [H(s_i) - H(\tilde{s}_i)], \quad (2.38)$$

以上の手法に基づき、独立成分分析では、解析的に観測データ $\mathbf{x}$ を統計的に独立した源信号 $\mathbf{s}$ に分離する。

既存の独立成分分析を深層特徴量に適用し、特徴量分離を行った既存研究 [38][39] では、混合行列の値の平均(重み)が小さい成分をノイズとして除去している。しかし、この方法では実際にその成分が本質成分か迷惑成分かを確かめることができない。そこで我々は、独立成分分析後に各成分が本質成分か迷惑成分か判別し、迷惑成分を除去するアルゴリズムを提案する。

2.4 特徴量寄与度評価指標

本研究では、独立成分分析により解析した各成分に対して迷惑成分または本質成分の判別を行うため、特徴量寄与度評価指標を用いた。特徴量寄与度評価指標は、各特徴量がモデルの推論にどれほど寄与しているか定量的に評価する手法のことである。本節では、代表的な2つの特徴量寄与度評価指標を紹介し、比較する。2.4.1項ではShapley Valueを、2.4.2項ではShapley Additive Global importanceを紹介する。

2.4.1 Shapley Value

代表的な特徴量寄与度評価指標としてShapley Value(以降SHAP)[15]がある。SHAPはゲーム理論に基づき、全ての特徴量の組み合わせを考慮することで、各特徴量がモデル予測にどの程度寄与しているか定量化する。以下に、SHAP値の算出方法と計算式を示す。

特徴量集合を F 、特徴量の部分集合を S 、特徴量集合の要素数を $|F|$ 、特徴量の部分集合の要素数を $|S|$ 、特徴量 x を入力とした場合のモデルの予測値を $f(x)$ とすると、特徴量 i に対するSHAP値 ϕ_i は以下の数式で表せる。

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)], \quad (2.39)$$

この式は、特徴量 i がモデル予測に与える寄与度を、全ての特徴量との組み合わせにおいて平均的に評価するものである。具体的には、 S という特徴量の部分集合に i を加えたときのモデル予測値 $f(S \cup \{i\})$ と、 i を加える前の予測値 $f(S)$ の差を計算し、それを全体の重み付き平均で評価する。SHAP値の計算は、全ての特徴量の組み合わせに対してモデルを評価する必要があり計算コストが高い。よって、一般的にはKernel SHAP[15]などの近似アルゴリズムが用いられる。

2.4.2 Shapley Additive Global importance

SAGE (Shapley Additive Global importance) [14]は、モデルの予測性能における特徴量の寄与度を定量化する方法であり、損失関数を用いる点でSHAPとは異なる。SAGEは、特徴量のグローバルな重要度を特徴付けるために、SHAP値をモデルの予測能力を表す関数に適用することで計算される。以下に、SAGE値の算出方法と計算式を示す。

まず、損失関数 ℓ を用いてモデル f の特徴量部分集合 S におけるリスク削減量 $v_f(S)$ を以下のように定義する。ここで、全ての特徴量を除外した場合のモデルの予測 (データ全体の平均予測値) を $f_\emptyset$ 、特徴量 S のみを用いたモデルの予測を f_S とする。

$$v_f(S) = \mathbb{E}[\ell(f_\emptyset(X_\emptyset), Y)] - \mathbb{E}[\ell(f_S(X_S), Y)], \quad (2.40)$$

データ全体の平均予測値と正解データの損失に対して、 S を用いた予測値と正解データの損失がより小さくなれば、リスク削減量 $v_f(S)$ は大きくなる。

次に、リスク削減量 $v_f(S)$ を用いて特徴量 i に対する SAGE 値 ϕ_i は以下の式で計算される。ここで、特徴量集合を F 、特徴量の部分集合を S 、特徴量集合の要素数を $|F|$ 、特徴量の部分集合の要素数を $|S|$ とする。

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [v_f(S \cup \{i\}) - v_f(S)], \quad (2.41)$$

この式は、特徴量 i がモデルの予測能力に与える寄与度を全ての特徴量の組み合わせに基づいて評価するものである。損失関数として一般に用いられるのは、交差エントロピー損失や平均二乗誤差 (MSE) であり、それぞれの損失関数に基づいて SAGE 値を導出することで、特徴量の重要性を計測する。

2.4.3 SHAP と SAGE の比較

以上より、SHAP と SAGE はどちらもゲーム理論に基づいた手法であり、特徴量がモデルの出力にどの程度寄与しているかを評価する手法である。しかし、それぞれの手法には計算方法や解釈における違いが存在する。

SHAP では、各特徴量の寄与度をモデルの予測値に基づいて計算する。具体的には、SHAP 値の絶対値が大きいほど、特徴量がモデルの出力に大きな影響を与えていることを示す。ただし、SHAP 値の正負は、特徴量が出力を増加させるか減少させるかを示すため、SHAP 値の正負からモデルへの寄与の有無を判断することは難しい。

これに対して、SAGE は損失関数を用いて、特徴量がモデルの性能に与える影響を測定する。SAGE 値は、特徴量がグローバルな損失削減にどれほど寄与しているかを直接示す。よって SAGE 値が正であればその特徴量はモデルに寄与することを、負であれば寄与がないどころかモデルの性能を損なう可能性がある。

ることを示す。このように、SAGE では正負がより明確な意味を持つため、特徴量の評価が直感的であると言える。また、SAGE では閾値を 0 とすることで、特徴量をモデルに寄与する特徴量と寄与しない特徴量に分離することができる。

計算コストについては、SHAP と SAGE の双方が組み合わせ爆発の問題を抱えているが、SHAP は Kernel SHAP などの近似アルゴリズムを利用することで効率化が図られている。一方、SAGE は全体的な損失を評価するため、モデルを損失関数の観点から多数回評価する必要がある、SHAP に比べて計算コストがさらに高い傾向にある。

以上より、SHAP は SAGE に比べて計算コストが小さく寄与度を評価できる一方、SHAP 値の正負からモデルへの寄与の有無を判断することはできない。SAGE は SAGE 値の正負からモデルへの寄与の有無を判断することができる一方、SHAP に比べて計算コストが大きい。使用用途によって使い分ける必要があるそれぞれ一長一短の手法である。

本研究では、SHAP および SAGE を活用して、独立成分分析で得られた各成分が迷惑属性に寄与する成分か本質属性に寄与する成分か判断する。

第3章 提案手法

画像集合に対する迷惑属性に頑健な多様性評価指標を提案する。まず 3.1 節では、問題設定を整理する。次に 3.2 節では、説明性があり高品質な特徴量分離を行う迷惑属性フィルタリングモジュールを提案する。さらに、迷惑属性フィルタリングモジュールを組み込んだ迷惑属性に頑健な多様性評価指標を提案する。

3.1 問題設定

条件付け画像生成に対する多様性評価を目的に、画像集合の本質属性の多様性を測る評価指標を開発する。ここで、本質属性とは画像における多様性評価の対象とする要素であり、迷惑属性とは多様性評価の対象としない要素である。条件付け画像生成において、生成条件により指定されておらず多様性が必要な要素が本質属性、指定されており多様性が不要な要素が迷惑属性と想定される。また、特徴量のうち本質属性に寄与する特徴量を本質特徴量、迷惑属性に寄与する特徴量を迷惑特徴量とする。さらに、独立成分分析で得られた成分のうち本質属性に寄与する成分を本質成分、迷惑属性に寄与する成分を迷惑成分とする。また本研究では、画像集合の各画像に対して、本質属性か迷惑属性のどちらかのラベルを推定・付与できることを前提としている。どちらのラベルも推定不可能である場合、本質属性と迷惑属性を分離することができない。

特に本研究では、研究対象をランドマークによる条件付けを行う ControlNet を用いた顔画像生成とする。迷惑属性をランドマークによって決まる顔の向き、本質属性を ID として、顔画像集合に対する ID の多様性評価を行う。この問題設定では、顔画像集合に対して顔の向きの多様性の多寡に影響を受けず、ID の多様性評価を行うことが望ましい。入力として任意の枚数の顔画像集合が与えられ、出力として顔画像集合に対する ID の多様性評価値を返す。また、任意の顔画像について既存の顔の向き推定器¹を用いることで、迷惑属性である顔の向きのラベルを各顔画像に付与することができる。問題設定の例を図 3.1 に示す。①は各画像で ControlNet の生成条件となるランドマーク画像が異なる 1000 枚の生成顔画像集合である。②は各画像で ControlNet の生成条件となるランドマーク画像が同じ 1000 枚の生成顔画像集合である。これら

¹<https://github.com/yinguobing/head-pose-estimation>

の顔画像集合における顔の向きが多様性の影響を除去した ID の多様性を比較することが問題設定の具体例となる。




図 3.1: 問題設定の具体例. ①多様なランドマークを条件に生成された顔画像集合と②単一のランドマークを条件に生成された顔画像集合に対して、それぞれ迷惑属性の影響を除去した本質属性 (ID) の多様性評価を行い、比較する。

この問題設定を前提とした多様性評価指標に対する評価尺度として以下の方法が考えられる。図 3.2 に示すような、明示的に本質属性 (ID) の多様性が同等で迷惑属性 (顔の向き) の多様性が異なる 2 つの顔画像集合を用意する。この 2 つの顔画像集合に対する多様性評価値の差を統計的に測る。この差が小さければ迷惑属性の多様性の影響に頑健であり、大きければ迷惑属性の多様性の影響を受けてしまっていると評価できる。




図 3.2: 多様性評価指標に対する評価尺度で用いる顔画像集合の例

3.2 提案指標

既存の画像多様性評価指標では、エンコーダで抽出した特徴量に対して直接多様性評価を行っていた。しかし、この方法では特徴量に迷惑属性が含まれているため、多様性評価値も迷惑属性の多様性に影響を受けてしまう。そこで、本研究では特徴量を迷惑特徴量と本質特徴量に分離し本質特徴量のみを抽出する迷惑属性フィルタリングモジュールを提案する。さらに、これを既存の多様性評価指標に組み込んだ多様性評価指標を提案する。既存指標と提案指標による多様性評価の比較の例を図 3.3 に示す。




図 3.3: 既存指標と提案指標による多様性評価の違い。同じ ID・枚数で顔の向きが多様な①と顔の向きが同じ②の 2 つの顔画像集合に対して多様性評価を行う。既存指標では評価対象とする顔画像特徴量に顔の向き (迷惑属性) の多様性が含まれているため、①の方が高い多様性評価値となる。提案指標では、迷惑属性フィルタリングモジュールにより顔画像特徴量から迷惑属性の影響を除去した本質特徴量を得る。本質特徴量に対して多様性評価を行うことで本質属性 (ID) の多様性を評価することができ、ID 多様性が等しい①と②は同じ多様性評価値となる。

提案指標による多様性評価の詳細な流れを図 3.4 に示す。以降、特徴抽出モジュール、迷惑属性フィルタリングモジュール、多様性評価モジュールについてそれぞれ詳しく説明する。

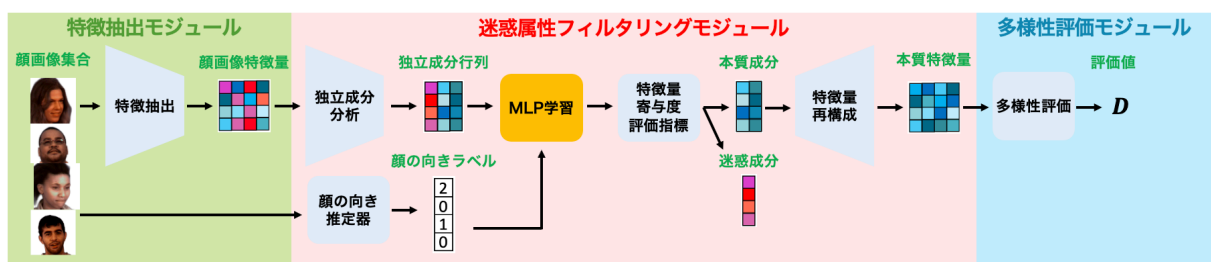


図 3.4: 提案指標による多様性評価の流れ。提案指標は特徴抽出モジュール、迷惑属性フィルタリングモジュール、多様性評価モジュールから構成される。

3.2.1 特徴抽出モジュール

特徴抽出モジュールでは、画像集合をエンコーダに入力し特徴量に変換する。ここで、エンコーダには画像集合からできるだけ本質属性に特化した特徴量を抽出することが求められる。そのため、エンコーダと

して顔認識モデルを用いてできるだけ ID に特化した特徴量を抽出する．具体的には，Face Vendi Score と同様に ArcFace[8] を用いて学習された iResNet[40] をエンコーダとして用いる．

エンコーダにより，画像集合を完全に本質属性のみを表現する特徴量に変換することができれば，既存指標でも迷惑属性の多様性の多寡に影響を受けず本質属性の多様性を評価することができる．しかし，一般的にエンコーダで完全な本質特徴量を抽出することは難しい．その具体例を図 3.5 に示す．




図 3.5: 顔画像特徴量に迷惑属性が含まれている具体例. 各顔画像は iResNet により特徴量化されて COS 類似度を計算している. 参照画像と同じ ID の顔画像 (上 3 つ) に関して, 顔の向きが異なるほど類似度が下がる. また, 参照画像と違う ID の顔画像 (下 3 つ) に関して, 顔の向きが異なるほど類似度が下がる. これより, 顔画像特徴量には ID だけでなく, 顔の向きの要素が含まれていることがわかる.

これより, 既存指標のように特徴抽出モジュールのみでは本質特徴量を抽出することが難しいことがわかる. そこで, 我々は特徴量を迷惑特徴量と本質特徴量に分離し, 本質特徴量を抽出する迷惑属性フィルタリ

ングモジュールを提案する。

3.2.2 迷惑属性フィルタリングモジュール

画像集合から特徴抽出モジュールを通じて得た特徴量に対して、迷惑属性フィルタリングモジュールでは迷惑特徴量と本質特徴量への分離を行い、本質特徴量を抽出する。2.3 節で示したように、最新の特徴量分離手法では深層学習を用いている。これらの手法は損失関数設計に基づいて独立性を誘導するため、理論的に完全な独立性を保証するわけではない。また、深層学習を用いるため説明性に欠けるうえに、計算コストが高い。そこで、本研究では評価対象である特徴量が閉集合であることを利用し、独立成分分析により解析的に特徴量分離を行う。独立成分分析は統計的独立性を仮定しており、線形分離が可能な場合には、出力された成分の独立性が厳密に保証される。よって、特徴量に対して独立成分分析を行い複数の独立成分を得る。ここで独立成分の数はハイパーパラメータとなる。

ここで、各成分が迷惑成分か本質成分かを判別する必要がある。そこで、2.4 節で示した特徴量寄与度評価指標を用いる。入力が独立成分行列、出力が本質属性ラベルまたは迷惑属性ラベルとなる MLP を学習し、そのモデルの推論に対する各成分の寄与度を数値化する。出力が本質属性ラベルの場合、寄与度が高い成分は本質成分、低い成分は迷惑成分と判別できる。出力が迷惑属性ラベルの場合、寄与度が高い成分は迷惑成分、低い成分は本質成分と判別できる。ここで成分分離を行うため、寄与度の閾値を決める必要がある。図 3.6 に示すように、本質成分で迷惑属性にも寄与する成分が存在するため、出力が本質属性ラベルか迷惑属性ラベルかによって閾値の設定方法が異なる。出力が本質属性ラベルの場合、モデルの推論に寄与する成分を全て本質成分、それ以外を迷惑成分と判別できる。一方、出力が迷惑属性ラベルの場合、迷惑属性に寄与する本質成分が存在するため、モデルの推論に寄与する成分が全て迷惑成分ではない。2.4.3 項で紹介した代表的な特徴量寄与度評価指標の SAGE と SHAP の違いとして、SAGE は元の値がモデルの推論への寄与度を示すのに対して、SHAP は絶対値がモデルの推論への寄与度を示す。また、モデル全体の損失を計算する SAGE は SHAP に比べて計算コストが大きい。よって SAGE のメリットはモデルの推論に寄与する特徴量と寄与しない特徴量を閾値 0 で判別できる点であり、SHAP のメリットは計算コストが小さいことである。これより出力が本質属性ラベルの場合、SAGE を用いて SAGE 値がプラスの独立成分を本質成分、マイナスの独立成分を迷惑成分と閾値を 0 に設定することで判別できる。一方、出力が迷惑属性ラベルの場合、閾値を SAGE 値における 0 に設定することは適切ではなく、0 より大きい適切な値に設定する必要がある。よって計算コストが小さい SHAP を用いて、ハイパーパラメータとして閾値を設定する

ことで, SHAP 値が閾値以上であれば迷惑属性, 閾値より小さければ本質属性と判別できる。




図 3.6: 各成分に対するラベリングの基準

迷惑属性フィルタリングモジュールを数式 (3.1) 式 (3.2) 式に表す。入力顔画像特徴量 z , 出力は本質特徴量 z_I とする。また, 独立成分分析によって得られる独立成分行列は S , 混合行列は A , 残差行列は E とする。さらに, 本質成分を S_I , それに対応する混合行列を A_I とする。最後に, 迷惑成分を S_N , それに対応する混合行列を A_N とする。迷惑属性フィルタリングモジュールでは, 独立成分分析と特徴量寄与度評価指標を用いて, 顔画像特徴量を本質成分と迷惑成分に分離する。独立成分行列の逆を辿って本質成分から本質特徴量を再構成する。

$$z_I = f(z), \quad \text{where } f(z) \text{ applies ICA processing;} \quad (3.1)$$

$$f(z) : \begin{cases} z = SA + E = S_I A_I + S_N A_N + E, \\ z_I = S_I A_I \end{cases} \quad (3.2)$$

提案した迷惑属性フィルタリングモジュールを本研究の問題設定に当てはめる。図 3.7 及び図 3.8 に本研究の問題設定に沿った迷惑属性フィルタリングモジュールの流れを示す。図 3.7 では, 顔画像集合から本質

属性ラベル (ID クラスラベル) を抽出する場合の流れを示す。また図 3.8 では、顔画像集合から迷惑属性ラベル (顔の向きラベル) を抽出する場合の流れを示す。




図 3.7: 本質属性ラベルを用いた迷惑属性フィルタリングモジュールの流れ。評価対象の顔画像集合に ID クラスラベルがアノテーションされていることが条件となる。まず、特徴抽出モジュールから受け取った顔画像特徴量に対して独立成分分析を行う。次に、入力を独立成分行列、出力を ID クラスラベルとして ID クラス推定を行う MLP を学習する。このモデルに対して SAGE で寄与度を計算し、寄与度がプラスの成分を本質成分、マイナスの成分を迷惑成分と判別する。最後に本質成分から独立成分分析の逆をたどり本質特徴量を再構築し、多様性評価モジュールに渡す。




図 3.8: 迷惑属性ラベルを用いた迷惑属性フィルタリングモジュールの流れ。既存の顔の向き推定モデルで顔の向きラベルを付与することができるため、アノテーションは不要である。まず、特徴抽出モジュールから受け取った顔画像特徴量に対して独立成分分析を行う。次に、入力を独立成分行列、出力を顔の向きラベルとして顔の向き推定を行う MLP を学習する。このモデルに対して SHAP で寄与度を計算し、寄与度が閾値以上の成分を迷惑成分、閾値より小さい成分を本質成分と判別する。ここで閾値はハイパーパラメータである。最後に本質成分から独立成分分析の逆をたどり本質特徴量を再構築し、多様性評価モジュールに渡す。

ここで使用する MLP は中間層 1 層の小型モデルである。また、生成された顔画像集合をはじめ一般的な顔画像集合には ID クラスラベルは付与されていないため、基本的には顔の向きクラスラベルを自動で検出する図 3.8 の流れで特徴量分離を行う。この場合独立成分数と寄与度の閾値は重要なハイパーパラメータと

なる。経験則的に、顔画像集合が 3000 枚程度の場合独立成分数は 400 程度が適切であることがわかった。また、全成分のうち 5-10%を迷惑成分とすることが適切であることがわかった。

最後に、迷惑属性フィルタリングモジュールによって得た本質特徴量に対して、多様性評価モジュールで多様性評価を行う。

3.2.3 多様性評価モジュール

多様性評価モジュールでは受け取った本質特徴量から多様性評価値を計算する。本研究では、2.2.4 節で紹介した分散共分散行列のトレースを採用する。特徴量に対して分散共分散行列のトレースを計算することで多様性評価値とする。多様性評価の計算方法を数式 (3.3) 式 (3.4) 式に表す。入力の本質特徴量 z_I ，出力は多様性評価値 D である。

$$\Sigma = \text{Cov}(z_I) = \mathbb{E}[(z_I - \mathbb{E}[z_I])(z_I - \mathbb{E}[z_I])^\top], \quad (3.3)$$

$$D = \text{Tr}(\Sigma), \quad (3.4)$$

他の多様性評価値の計算方法の選択肢として、2.2.4 節で紹介した類似度行列のシャノンエントロピーを計算する方法が考えられる。

第4章 実験

3章で提案した迷惑属性フィルタリングモジュール及び多様性評価指標の性能を評価し、提案した多様性評価指標を用いて ControlNet の使用による生成画像の多様性への影響評価を行う。まず 4.1 節で、迷惑属性フィルタリングモジュールによる本質特徴量の抽出精度を評価する。次に 4.2 節で、既存指標及び提案指標に対して多様性評価指標の迷惑属性への頑健性を評価する。最後に 4.3 節で、提案指標を用いて ControlNet の使用による生成画像の多様性への影響評価を行う。各実験では、実験設定、実験結果、結果に対する考察を記述する。

4.1 迷惑属性フィルタリングモジュールの性能評価

迷惑属性フィルタリングモジュールの性能評価を行う。具体的には、迷惑属性フィルタリングモジュールによって顔画像特徴量から迷惑属性 (顔の向き) の影響を除去し、ID を表現する本質特徴量を抽出できているか実験する。

4.1.1 実験設定

データセット

本実験ではデータセットとして The MUCT Landmarked Face Database(以降 MUCT) [2] を使用した。MUCT は 3755 枚の 480×640 pixel の実写顔画像から構成されているデータセットである。このデータセットの特徴は、同じ ID で顔の向きが異なる顔画像が複数枚含まれていることである。具体的には、276 人を被写体にそれぞれ 2-3 回光量を変えて、5 方向のカメラから撮影している。よって 276ID に対して、それぞれ 10 枚か 15 枚の顔の向きが異なる顔画像が含まれている。詳細には、光量が 2 種類で合計 10 枚の ID が 77ID、光量が 3 種類で合計 15 枚の ID が 199ID 含まれている。各画像の ID、光量、アングル情報は画像ファイル名にアノテーションされている。図 4.1 に MUCT に含まれる顔画像の例、図 4.2 に MUCT における撮影アングルの詳細、図 4.3 に MUCT における各 ID に含まれる画像の種類を示す。



図 4.1: MUCT に含まれる顔画像の例 [2]




図 4.2: MUCT における撮影アングルの詳細 [2]



図 4.3: MUCT における各 ID に含まれる画像の種類 [2]

FFHQ[41] や Celeba-HQ[42] といった一般的な顔画像データセットではなく MUCT を使用した理由として、本質属性 (ID) ラベルがアノテーションされていることと、明示的に多様な迷惑属性 (顔の向き) の顔画像が含まれているデータセットであることが挙げられる。各画像に本質属性ラベルが付与されていることで、迷惑属性フィルタリングモジュールで抽出した本質特徴量が正確に本質属性を表現できているか確認することができる。また、明示的に多様な迷惑属性の顔画像が含まれていることで、顔画像特徴量が迷惑属性の影響を強く受けやすくなる。

また図 4.4 に示すように、すべての顔画像に対して顔切り出し、アラインメント、リサイズを行い特徴抽出モジュールで用いる顔認識モデルの入力に適した顔画像に変換した。前処理には MTCNN[43] を使用した。




図 4.4: 顔画像の前処理 (顔切り出し・アラインメント・リサイズ)

実験方法

MUCT 全画像 (3755 枚) を評価対象として、特徴抽出モジュールで顔画像特徴量に変換し、迷惑属性フィルタリングモジュールで本質特徴量に変換する。このとき、元特徴量及び本質特徴量それぞれに迷惑属性と本質属性の影響がどれだけあるかを評価する。これにより、迷惑属性フィルタリングモジュールがどれだけ迷惑属性の影響を除去しつつ、本質属性の影響を保持しているか確認することができる。また、3.2.2 節で示したように迷惑属性フィルタリングモジュールには、本質属性ラベルから特徴量分離を行う方法と迷惑属性ラベルから特徴量分離を行う方法の 2 種類がある。これら両方に関して、実験を行う。本質属性ラベルを用いる方法では、SAGE の閾値を 0 として成分の判別を行う。よって重要なハイパーパラメータは独立成分分析の成分数のみとなる。一方、迷惑属性ラベルを用いる方法では、SHAP の閾値を特定の値に設定し成分の判別を行う。よって重要なハイパーパラメータとして独立成分数の他に、SHAP の閾値を設定する必要がある。そこで、初めに本質属性ラベルを用いる方法で実験を行い、独立成分数と特徴量分離の精度の関係を確認する。その結果から適切な独立成分数を決定し、迷惑属性ラベルを用いる方法で実験を行い、SHAP の閾値と特徴量分離の精度の関係を確認する。

評価方法

元特徴量及び本質特徴量それぞれに迷惑属性と本質属性の影響がどれだけあるかを評価する方法を説明する。評価方法は3種類ありそれぞれ、本質属性の影響を評価する方法、迷惑属性の影響を評価する方法、両方の影響を総合的に評価する方法となる。まず本質属性の影響を評価する方法として、元特徴量と本質特徴量それぞれを入力として、ID クラスラベル (276 クラス) を出力とした MLP を学習・評価し、その精度を比較する。この精度に差がなければ、本質特徴量は本質属性の情報を保持できているといえ、差が大きければ、本質特徴量は本質属性の情報を失っているといえる。次に迷惑属性の影響を評価する方法として、元特徴量と本質特徴量それぞれを入力として、顔の向きクラスラベル (5 クラス) を出力とした MLP を学習・評価し、その精度を比較する。この精度に差がなければ、本質特徴量は迷惑属性の情報を保持しているといえ、差が大きければ、本質特徴量は迷惑属性の情報を除去できているといえる。上記2つの評価方法において、MLP は中間層1層の小型モデルであり、データの割合は学習データ6割・検証データ2割・評価データ2割とする。最後に両方の影響を総合的に評価する方法として、元特徴量と本質特徴量それぞれについて、ID クラスラベルが同じで顔の向きクラスラベルが異なる画像ペアの $\cos$ 類似度平均を計算する。この値が大きい特徴量はより迷惑属性の影響を除去できおり本質属性の情報を保持しているといえる。

4.1.2 実験結果

まず、本質属性ラベルから特徴量分離を行う方法に対する実験結果を示す。

初めに実験における独立成分数と本質成分数の関係と、独立成分数と迷惑成分数の関係を表すグラフをそれぞれ図 4.5 と図 4.6 に示す。また、独立成分数と独立成分のうち本質成分が占める割合の関係と、独立成分数と独立成分のうち迷惑成分が占める割合の関係を図 4.7 図 4.8 に示す。




図 4.5: 独立成分数と本質成分数の関係




図 4.6: 独立成分数と迷惑成分数の関係




図 4.7: 独立成分数と本質成分割合の関係




図 4.8: 独立成分数と迷惑成分割合の関係

次に、元特徴量と本質特徴量それぞれを学習データとして、ID クラス分類モデルを学習した際の精度を示す。図 4.9 に独立成分数とモデル精度の関係を示す。元特徴量から ID クラス分類モデルを学習した場合、精度は 100%である。




図 4.9: 独立成分数と ID クラス分類モデル精度の関係. 元特徴量を学習データとした ID クラス分類モデル精度は独立成分数に関係ないため, 100%固定の黒色の点線としている. 赤色の折れ線グラフは独立成分数と本質特徴量を学習データとした ID クラス分類モデル精度の関係である.

次に, 元特徴量と本質特徴量それぞれを学習データとして, 顔の向きクラス分類モデルを学習した際の精度を示す. 図 4.10 に独立成分数と顔の向きクラス分類モデル精度の関係を示す. 元特徴量から顔の向きクラス分類モデルを学習した場合, 精度は約 69%である.




図 4.10: 独立成分数と顔の向きクラス分類モデル精度の関係. 元特徴量を学習データとした顔の向きクラス分類モデル精度は独立成分数に関係ないため, 約 69% 固定の黒色の点線としている. 赤色の折れ線グラフは独立成分数と本質特徴量を学習データとした顔の向きクラス分類モデル精度の関係である.

最後に, 元特徴量と本質特徴量における, 同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均を示す. 図 4.11 と図 4.12 に独立成分数と $\cos$ 類似度平均の関係を示す. 図 4.11 では y 軸の範囲が 0% から 100% に設定, 図 4.12 では y 軸の範囲が 80% から 100% に設定されている. 元特徴量における同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均は約 87% である.




図 4.11: 独立成分数と同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均の関係. (y 軸の範囲は 0% から 100% に設定) 元特徴量における異なる顔の向きの画像ペアの $\cos$ 類似度平均は独立成分数に関係ないため、約 87% 固定の黒色の点線としている. 赤色の折れ線グラフは独立成分数と本質特徴量における異なる顔の向きの画像ペアの $\cos$ 類似度平均の関係.




図 4.12: 独立成分数と同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均の関係. (y 軸の範囲は 80% から 100% に設定) 元特徴量における異なる顔の向きの画像ペアの $\cos$ 類似度平均は独立成分数に関係ないため、約 87% 固定の黒色の点線としている. 赤色の折れ線グラフは独立成分数と本質特徴量における異なる顔の向きの画像ペアの $\cos$ 類似度平均の関係.

続いて、迷惑属性ラベルから特徴量分離を行う方法に対する実験結果を示す. 本質属性ラベルから特徴量分離を行った結果から独立成分数は、特徴量分離が十分に可能な 420 に固定した. この実験では寄与度の閾値を変化させ、閾値と特徴量分離の精度の関係を確認した. 具体的には、本質成分数を 0 から 420 まで 10 ずつ増やし実験を行った. 逆に迷惑成分数は 420 から 0 まで 10 ずつ減ることになる. これにより本質成分数と本質特徴量の抽出精度の関係を確認する.

まず、元特徴量と本質特徴量をそれぞれ学習データとして、ID クラス分類モデルを学習した際の精度を示す. 図 4.13 に本質成分数と ID クラス分類モデル精度の関係を示す. 元特徴量から ID クラス分類モデルを学習した場合、精度は 100% である.




図 4.13: 本質成分数と ID クラス分類モデル精度の関係. 元特徴量を学習データとした ID クラス分類モデル精度は本質成分数に関係ないため, 100%固定の黒色の点線としている. 赤色の折れ線グラフは本質成分数と本質特徴量を学習データとした ID クラス分類モデル精度の関係.

次に, 元特徴量と本質特徴量をそれぞれ学習データとして, 顔の向きクラス分類モデルを学習した際の精度を示す. 図 4.14 に本質成分数と顔の向きクラス分類モデル精度の関係を示す. 元特徴量から顔の向きクラス分類モデルを学習した場合, 精度は約 69%である.




図 4.14: 本質成分数と顔の向きクラス分類モデル精度の関係. 元特徴量を学習データとした顔の向きクラス分類モデル精度は本質成分数に関係ないため, 約 69% 固定の黒色の点線としている. 赤色の折れ線グラフは本質成分数と本質特徴量を学習データとした顔の向きクラス分類モデル精度の関係.

最後に, 元特徴量と本質特徴量における, 同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均を示す. 図 4.15 と図 4.16 に本質成分数と $\cos$ 類似度平均の関係を示す. 図 4.15 では y 軸の範囲が 0% から 100% に設定, 図 4.16 では y 軸の範囲が 80% から 100% に設定されている. 元特徴量における同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均は約 87% である.




図 4.15: 本質成分数と同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均の関係. (y 軸の範囲は 0% から 100% に設定) 元特徴量における異なる顔の向きの画像ペアの $\cos$ 類似度平均は本質成分数に関係ないため、約 87% 固定の黒色の点線としている. 赤色の折れ線グラフは本質成分数と本質特徴量における異なる顔の向きの画像ペアの $\cos$ 類似度平均の関係.




図 4.16: 本質成分数と同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均の関係. (y 軸の範囲は 80% から 100% に設定) 元特徴量における異なる顔の向きの画像ペアの $\cos$ 類似度平均は本質成分数に関係ないため、約 87% 固定の黒色の点線としている. 赤色の折れ線グラフは本質成分数と本質特徴量における異なる顔の向きの画像ペアの $\cos$ 類似度平均の関係.

4.1.3 考察

まず、本質属性ラベルを用いた迷惑属性フィルタリングモジュールの性能について考察する.

図 4.5 図 4.6 図 4.7 図 4.8 より、独立成分数 270 までは独立成分は本質成分のみで構成されており、独立成分数 270 以降から迷惑成分が出現することがわかる. その後独立成分数が増えても本質成分数の増加は鈍く、迷惑成分が急激に増える. これは独立成分数 270 までは ID クラス識別モデルに対する SAGE 値が全ての成分でプラスで、270 以降 SAGE 値がマイナスの成分が出現することを示す. ここから、独立成分数 270 まではすべての独立成分に本質属性を表現する部分が含まれていることがわかる. また、独立成分数 270 以降からは本質属性を表現する部分が含まれていない迷惑成分が出現し、本質成分と迷惑成分に分

離できるようになると考える。

次に、図 4.9 より本質特徴量を学習データとした ID クラス分類モデルの精度は、独立成分数が 10 から 500 まで常にほぼ 100%を維持しており、元特徴量と同等の精度を保っていることがわかる。これは独立成分数 270 以降、迷惑特徴量を除去しても本質特徴量が本質属性の情報を保持できていることを示す。さらに、図 4.10 より本質特徴量を学習データとした顔の向きクラス分類モデルの精度は、独立成分数が 270 以降急激に下がり、独立成分数 400 以降横ばいになることがわかる。これは独立成分数 270 以降、元特徴量から迷惑特徴量を除去することで、本質特徴量に顔の向きを表現する特徴量が除去されていくことを示す。これより、除去した迷惑特徴量は迷惑属性を表現する特徴量であったことが確認できる。また、独立成分数が 400 以上になると本質成分と迷惑成分を表現するために十分な独立成分数に達したため、迷惑特徴量を除去しきり、顔の向き識別精度が横ばいになったと考えられる。最後に、図 4.11 図 4.12 より独立成分数 270 以降、本質特徴量における同 ID で異なる顔の向きの画像ペアの類似度平均は元特徴量のそれを上回り、成分数 400 以降横ばいになることがわかる。これは独立成分数 270 以降、元特徴量から迷惑特徴量が除去され本質特徴量における本質属性を表現する情報の純度が上昇したことを示す。さらに、成分数 400 以降、迷惑特徴量を除去しきったことで本質特徴量における本質属性を表現する情報の純度が横ばいになったと考える。

これらの結果は、本研究で提案した本質属性ラベルを用いた迷惑属性フィルタリングモジュールにより、元特徴量から迷惑特徴量を除去し本質特徴量を抽出できることを示す。

次に、事前アノテーションが不要な迷惑属性ラベルを用いた迷惑属性フィルタリングモジュールの性能について考察する。

図 4.13 より本質特徴量を学習データとした ID クラス分類モデルの精度は、本質成分数 0 から単調増加し 390 以上で元特徴量のそれと同等になる。これは、顔の向き識別モデルに対する SHAP 値下位 390 成分を本質成分とし、上位 30 成分を迷惑成分として除去した本質特徴量が十分に本質属性を表現できることを示す。また、図 4.14 より本質特徴量を学習データとした顔の向きクラス分類モデルの精度は、本質成分数 0 から徐々に増加し 390 から急激に増加する。これは、顔の向き識別モデルに対する SHAP 値上位 30 成分が顔の向き識別に重要な迷惑成分であることを示す。最後に、図 4.15 図 4.16 より本質成分数 390 以降、本質特徴量における同 ID で異なる顔の向きの画像ペアの類似度平均は元特徴量のそれを上回る。これは、顔の向き識別モデルに対する SHAP 値上位 30 成分が迷惑成分であり、それらを除去することで元特徴量よりも本質属性の情報に対する純度が高い本質特徴量を抽出できることを示す。

これらの結果は、本研究で提案した事前アノテーションが不要な迷惑属性ラベルを用いた迷惑属性フィルタリングモジュールが、適切な独立成分数及び SHAP 値に対する閾値を設けることで、元特徴量から迷

惑特徴量を除去し本質特徴量を抽出できることを示す。特に評価対象を MUCT 全画像とした今回の実験では、独立成分数を 420、そのうち SHAP 値上位 30 成分を迷惑成分、残り 390 成分を本質成分とする閾値を設定することで純度の高い本質特徴量を抽出できた。

4.2 多様性評価指標の迷惑属性への頑健性評価

続いて、既存の多様性評価指標と迷惑属性フィルタリングモジュールを導入した提案指標を比較する。具体的には、各評価指標による評価が迷惑属性の多様性の多寡にどの程度影響を受けるか評価する。

4.2.1 実験設定

データセット

本実験でも 4.1.1 項と同様に MUCT をデータセットとして用いる。これは、各評価指標の迷惑属性への頑健性の評価を行う上で、評価対象となる顔画像集合の本質属性の多様性と迷惑属性の多様性を明示的に操作するためである。具体的には、ID の多様性が同等で顔の向きが多様性が異なる 2 つの顔画像集合を評価対象として各評価指標の比較を行う。このため、全ての顔画像で ID が異なる FFHQ や Celeba-HQ などの一般的な顔画像データセットは適しておらず、各 ID に対して顔の向きが異なる複数枚の画像が含まれており、本質属性と迷惑属性の多様性を操作可能な MUCT が適している。また、前処理として 4.1.1 項と同様の処理をおこなっている。

実験方法

本質属性の多様性が同等で迷惑属性の多様性が異なる 2 つの顔画像集合を評価対象とした、各評価指標による評価結果の比較を行う。この 2 つの顔画像集合に対する多様性評価値の差が小さい場合、迷惑属性の影響に頑健であるといえ、差が大きい場合迷惑属性の影響を受けてしまっているといえる。

本質属性の多様性が明示的に同等で迷惑属性の多様性が明示的に異なる 2 つの顔画像集合の作成方法を示す。MUCT に含まれる全ての ID(276ID) を対象に、ランダムなアングルの顔画像集合と指定されたアングルを含めた顔画像集合を作成する。具体的には、各 ID・光量から 5 枚中 4 枚ずつ抽出し、2 つの ID の多様性が同等の顔画像集合を作成する。このとき、片方は全ての ID・光量でランダムなアングルの顔画像を抽出し、もう片方は統一されたアングルの顔画像を抽出する。これにより本質属性の多様性は同等のまま、

迷惑属性の多様性に差異を生む。以降、顔の向きを制限せず作成したデータセットを①，制限して作成したデータセットを②とする。データセット①とデータセット②の違いを図 4.17 に示す。




図 4.17: 本質属性の多様性は等しく迷惑属性の多様性に差がある 2 つのデータセットの作成方法。①は各 ID・各光量でアングル 5 種類のうち 4 種類をランダムに抽出。②は特定のアングルを除いた 4 種類のアングルを固定で抽出。

各評価指標において、この 2 つの顔画像集合に対する多様性評価値の差を統計的に測る。既存指標と提案指標を比較する。既存指標として、特徴抽出モジュールで得た顔画像特徴量に対して多様性評価を行う方法 [?] を採用する。多様性評価値の計算方法は提案指標と同様に、分散共分散行列のトレースである。この既存指標と提案指標を比較することで、迷惑属性フィルタリングモジュールを用いた特徴量分離により、迷惑属性を除去した多様性評価を実現できることを示す。

提案指標では、迷惑属性ラベルを用いた迷惑属性フィルタリングモジュールにより特徴量分離を行う。既存の顔の向き推定器¹を用いて顔画像集合から自動で迷惑属性ラベルを得る。提案指標のハイパーパラメータとして、顔の向きラベルのクラス数、独立成分数、迷惑成分数がある。顔の向きラベルのクラス数は MUCT に倣って 5 クラスとする。独立成分数は 370、迷惑成分数 30 とする。これは 4.1.2 項の実験結果などから経験的に決定した。

¹<https://github.com/yinguobing/head-pose-estimation>

評価方法

各評価指標を用いて、本質属性の多様性は等しく迷惑属性の多様性に差がある2つの顔画像集合を評価する。そして各評価指標間で、2つの顔画像集合に対する評価値の差を統計的に比較する方法を示す。評価方法として、各評価指標において、2つの顔画像集合に対する多様性評価値の分布を作成し、その分布の差異や距離を測る。異なる多様性評価指標間では、評価値のスケールが異なるため評価値をそのまま用いた比較は適切でない。そこで各評価指標において、2つの顔画像集合からそれぞれランダムに評価対象をサンプリングして評価を繰り返し、2つの評価値分布を作成する。各評価指標において、この2つの評価値分布間の差や距離がどの程度であるか統計手法により評価する。これにより、各指標において2つの顔画像集合の多様性が同等に評価されているのか、評価に差異があるのか確認できる。具体的には、各集合から250/276ID サンプリングし評価を50回繰り返し分布を作成する。既存指標による評価値分布が2つ、提案指標による評価値分布が2つの合計4つの分布を作成する。

分布作成後は大きく3つの方法でデータセット①とデータセット②の分布間の近さを測った。1つ目がt検定、2つ目が Jensen-Shannon Divergence[44]、3つ目がグラフプロットによる定性評価である。それぞれについて説明する。

1つ目のt検定について説明する。t検定は、2つの分布の平均値に有意な差があるかどうかを、p値を用いて統計的に検定する手法である。これにより、データセット①と②の分布間に統計的に有意な差があるかどうかを判断できる。しかし、「有意差がなかった」という結果は、「2つの分布が同一である」と証明したわけではなく、「差があると結論づける根拠が得られなかった」ことを示すにすぎない点に注意が必要である。本研究では、t検定の結果から得られる2つの分布間の差異を数値化し、ほかの指標との比較を可能にするため効果量を導入した。効果量としてはCohenの d を用いる。ただ、Cohenの d はサンプルサイズが評価値に影響する場合があります。分布間差異の絶対値としての使用は積極的には推奨されていない。[45]t検定の数式を(4.1)式(4.2)式に、Cohenの d の数式を(4.4)式(4.4)式に示す。ここで、 $\bar{x}_1, \bar{x}_2$ はそれぞれ群1および群2の平均値、 s_1^2, s_2^2 は群1および群2の分散、 n_1, n_2 は群1および群2のサンプルサイズ、 t はt検定におけるt値、 p はt検定におけるp値、 $T(t, \nu)$ は自由度 ν のt分布の累積分布関数、 s_{pooled} は群1および群2の分散のプール値、 d はCohenの効果量（標準化された平均差）を表す。

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \quad (4.1)$$

$$p = 1 - T(t, \nu) \quad (4.2)$$

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_{\text{pooled}}} \quad (4.3)$$

$$s_{\text{pooled}} = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}} \quad (4.4)$$

この手法を用いて、各評価指標において ① と ② の分布に有意な差があるか確かめ、その差がどの程度であるか評価する。効果量が小さい評価指標は、① と ② の多様性をより同等に評価した、迷惑属性に頑健な指標であるといえる。

2 つ目は Jensen-Shannon Divergence[44] である。Jensen-Shannon Divergence（以降 JSD）は、2 つの確率分布間の距離を測るための対称的な指標であり、Kullback-Leibler Divergence（以降 KLD）を基に定義される。JSD は次のように定義される：

$$JSD(P \parallel Q) = \frac{1}{2}KL(P \parallel M) + \frac{1}{2}KL(Q \parallel M), \quad (4.5)$$

ここで、 M は 2 つの分布 P, Q の中間分布であり、

$$M = \frac{1}{2}(P + Q), \quad (4.6)$$

また、Kullback-Leibler Divergence は以下のように定義される：

$$KL(P \parallel Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)}. \quad (4.7)$$

KLD は、2 つの分布間の類似度を測る際に非対称性があり、距離として扱えない問題がある。また、スケールが評価対象に依存するという課題もある。一方で、JSD では 2 つの分布の中間分布 M を用いることで、各分布と中間分布の KLD の平均を計算し、対称性を確保した。さらに、JSD の値はスケールを 0 から 1 の範囲に正規化されている。ここで、0 は 2 つの分布が完全に一致していることを示し、1 は 2 つの分布が全く異なることを示す。これにより、JSD は絶対的な距離として扱えるように設計されている。この手法を用いて、各評価指標における ① と ② の分布間距離を計算する。分布間距離が小さい評価指標は、① と ② の多様性をより同等に評価した、迷惑属性に頑健な指標であるといえる。

3つ目はグラフを用いた定性評価である。①と②の評価値分布をグラフにプロットして、各評価指標による結果を比較し定性評価を行う。具体的には、ヒストグラム・カーネル密度推定・箱ひげ図・バイオリン図・スウォーム図を用いる。分布が近ければ迷惑属性の影響に頑健、離れていれば迷惑属性の影響に脆弱と評価できる。各プロット図における、迷惑属性の影響に頑健な評価指標による評価値分布と、脆弱な評価指標による評価値分布の違いの例を図 4.18～図 4.22 に示す。




図 4.18: ヒストグラムによる迷惑属性の影響に頑健な評価指標による評価値分布と、脆弱な評価指標による評価値分布の違い。頑健な評価指標では①と②の分布が近く、脆弱な評価指標では離れている。




図 4.19: カーネル密度推定の結果を示すグラフによる迷惑属性の影響に頑健な評価指標による評価値分布と、脆弱な評価指標による評価値分布の違い。頑健な評価指標では①と②の分布が近く、脆弱な評価指標では離れている。




図 4.20: 箱ひげ図による迷惑属性の影響に頑健な評価指標による評価値分布と、脆弱な評価指標による評価値分布の違い。頑健な評価指標では①と②の分布が近く、脆弱な評価指標では離れている。




図 4.21: バイオリン図による迷惑属性の影響に頑健な評価指標による評価値分布と、脆弱な評価指標による評価値分布の違い。頑健な評価指標では①と②の分布が近く、脆弱な評価指標では離れている。




図 4.22: スウォーム図による迷惑属性の影響に頑健な評価指標による評価値分布と、脆弱な評価指標による評価値分布の違い。頑健な評価指標では①と②の分布が近く、脆弱な評価指標では離れている。

これらのグラフプロットを用いた可視化により、各評価指標の①と②に対する評価値分布の違いを定性的に評価することができる。

4.2.2 実験結果

まず、表 4.1 に本質属性の多様性は同等で迷惑属性の多様性に差異がある①と②の顔の向き (Yaw 値) の分散を示す。

表 4.1: 既存指標と提案指標の比較

顔画像集合①の顔の向き (Yaw 値) 分散	45.56
顔画像集合②の顔の向き (Yaw 値) 分散	51.73

次に、表 4.2 に定量的な実験結果を示す。既存指標と提案指標それぞれによる、①と②に対する評価値分布の平均値、分散、t 検定における p 値、効果量、JSD、特徴量を入力とした ID 分類精度平均、顔の向き分類精度平均を示す。分類精度に関して、既存指標では入力として①の元特徴量、提案指標では入力として①の本質特徴量を用いた。

表 4.2: 既存指標と提案指標の比較

	既存指標	提案指標
①評価値分布の平均値	0.9268	0.9043
②評価値分布の平均値	0.9275	0.9037
t 検定 p 値	4.712e-7	0.5852
効果量 (Cohen's d)	1.079	0.1095
JSD(Jensen-Shannon Divergence)	0.1994	0.0246
特徴量による ID 分類精度	100	99.4
特徴量による顔の向き分類精度	45	36

最後に、図 4.23～図 4.27 に分布をプロットしたグラフを示す。既存指標と提案指標それぞれによる、①と②に対する評価値分布を可視化した。




図 4.23: 既存指標による評価値分布と、提案指標による評価値分布のヒストグラムによる比較.




図 4.24: 既存指標による評価値分布と、提案指標による評価値分布のカーネル密度推定の結果を示すグラフによる比較.




図 4.25: 既存指標による評価値分布と，提案指標による評価値分布の箱ひげ図による比較.




図 4.26: 既存指標による評価値分布と，提案指標による評価値分布のバイオリン図による比較.




図 4.27: 既存指標による評価値分布と、提案指標による評価値分布のスウォーム図による比較。

4.2.3 考察

まず、表 4.1 より顔の向きの分散は、顔画像集合①よりも顔画像集合②の方が大きい。これより、顔画像集合①と②の本質属性の多様性は同等で、迷惑属性の多様性は①が小さく、②が大きいことがわかる。

次に、表 4.2 に示した結果を考察する。まず効果量 (Cohen's d) の結果について解釈する。データセット①と②の分布間の差異の大きさを表す効果量は、既存指標が 1.079、提案指標が 0.1095 となった。効果量は一般的に 0.2 以下であれば差異が小さく、0.8 以上であれば差異が大きいと判断できる。よって既存指標は分布間の差異が大きく、提案指標は分布間の差異が小さいといえる。続いて、JSD の結果について解釈する。データセット①と②の分布間距離 (JSD) において、提案指標は既存指標よりも小さな値となった。具体的には、提案指標は既存指標に対して約 $\frac{1}{8}$ 倍の値になった。これより、提案指標による①と②に対する評価値分布の差は既存指標のそれよりも小さく、提案指標は既存指標に比べてデータセット①と②を同等に多様性評価できているといえる。さらに、平均値と t 検定の p 値より、既存指標は有意に①に比べて②を多様性が高いと評価していることがわかる。迷惑属性の多様性は①が小さく、②が大きいことから、既存指標は迷惑属性の多様性の影響を受けてしまっていることがわかる。最後に、既存指標の顔画像特徴量を入力とした ID・顔の向きクラス分類精度及び、提案指標の本質特徴量を入力とした ID・顔の向きクラス分類精度の結果について解釈する。ID クラス分類精度は既存指標と提案指標どちらもほぼ 100%であるのに対して、顔の向きクラス分類精度は 9%の差がある。ここから、提案指標の迷惑属性フィルタリングモ

ジュールにより迷惑属性の影響を除去できていることがわかる。

最後に図 4.23～図 4.27 に示した結果を考察する。全てのグラフにおいて、既存指標と提案指標による結果を比べると、既存指標による評価値分布では①と②の差異が大きく、提案指標による評価値分布では①と②の差異が小さいことがグラフから読み取れる。よって定性的に、既存指標に比べて提案指標では①と②を同等に多様性評価できているといえる。

これらの結果と考察から、提案指標は既存指標に比べて迷惑属性に頑健な多様性評価を実現できることがわかった。

4.3 ControlNet の多様性への影響評価

4.2 章で迷惑属性の多様性に頑健であることを示した提案指標を用いて、条件付け画像生成の多様性への影響評価を行う。ControlNet[16] による条件付けにより、条件付けられていない要素の多様性がどのように変化するかは評価されたことがない。そこで、ControlNet の使用の有無により本質属性の多様性にはどのような影響があるのか提案指標により評価した。具体的には、顔画像生成におけるランドマークを条件とした ControlNet の使用の有無による、生成画像の ID の多様性への影響を評価した。

4.3.1 実験設定

モデル・データセット

まず、顔画像生成に用いる画像生成モデルと ControlNet のモデルを示す。画像生成モデルとして Realistic Vision V6.0²を用いた。これは stable diffusion V1.5³をベースモデルとしてファインチューニングされた実写画像生成に特化したモデルである。Realistic Vision V6.0 による生成画像の例を図 4.28 に示す。

²https://huggingface.co/SG161222/Realistic_Vision_V6.0_B1_noVAE

³<https://huggingface.co/stable-diffusion-v1-5/stable-diffusion-v1-5>



図 4.28: Realistic Vision V6.0 による生成画像の例

ランドマークを条件画像として条件付け顔画像生成を行う ControlNet のモデルとして Face Landmark ControlNet⁴を用いた。これは stable diffusion V1.5 をベースモデルとして、学習されたランドマーク画像を条件として顔画像を生成する ControlNet である。学習データとして Flickr-Faces-HQ と Celeba-HQ を使用している。Face Landmark ControlNet を用いた顔画像生成の例を図 4.29 に示す。



元画像 → ランドマーク → 生成画像

図 4.29: Face Landmark ControlNet による画像生成の例。元画像からランドマーク検出器によりランドマーク画像を作成し、Face Landmark ControlNet でランドマークに沿った画像生成を行っている。

次に使用する顔画像データセットを示す。生成条件として用いるランドマーク画像を抽出する顔画像データセットとして、Flickr-Faces-HQ(FFHQ) と Labeled Faces in the Wild(LFW) を採用した。ランドマー

⁴<https://huggingface.co/georgefen/Face-Landmark-ControlNet>

ク画像を抽出する上で多様な顔画像が入っているデータセットとして FFHQ と LFW を採用した。2つのデータセットを採用した理由は、今回の実験で用いる ControlNet の学習データに含まれている顔画像ランドマークと含まれていない顔画像ランドマークによる生成画像を比較したかったためである。

まず、FFHQ[41] について紹介する。FFHQ は、70,000 枚の 1024×1024 pixel の高解像度実写顔画像から構成されているデータセットである。このデータセットの特徴は、年齢・性別・人種・装飾品などに関して多様な高品質顔画像が含まれている点である。図 4.30 に FFHQ に含まれる顔画像の例を示す。




図 4.30: FFHQ に含まれる顔画像の例

次に, LFW[3] について紹介する. LFW は, 13233 枚の 250×250 pixel の実写顔画像から構成されているデータセットである. 図 4.31 に LFW に含まれる顔画像の例を示す.



図 4.31: LFW に含まれる顔画像の例 [3]

これらのデータセットに対して、ランドマーク検出を行い FFHQ ランドマークデータセットと LFW ランドマークデータセットを作成した。ランドマーク検出モデルとしては dlib ライブラリの実装⁵を使用した。顔画像データセットからランドマークデータセットの作成の流れを図 4.32 に示す。実験では各ランドマークデータセットから 3000 枚をランダムにサンプリングし、条件データセットとする。




図 4.32: ランドマークデータセット作成の流れ

最後に、生成条件として用いるプロンプトデータセットの作成方法を示す。今回の実験ではランドマークを条件とした ControlNet の使用の有無による ID の多様性への影響評価を行うため、プロンプト条件による多様性は全ての生成顔画像集合で等しくする必要がある。よって 1 つの同じプロンプトデータセットを全てのランドマークデータセットによる生成の際に用いる。また、3000 枚のランドマーク条件画像に対して 1 種類のプロンプトで画像生成を行うと、使用するプロンプトと ControlNet の相性によって ControlNet の多様性への影響が変化し、実験結果も変化する可能性がある。よって 3000 種類の全て異なるプロンプトを使用することで、プロンプトと ControlNet の相性による影響を除去する。

顔画像生成の条件として用いる 3000 種類のプロンプトの作成方法を示す。顔画像を示すプロンプトフォーマットを作成し、穴埋め形式で 3000 種類のプロンプトを作成した。フォーマットは "a photo of { 人種 } { 性別・年齢 } face { 装飾品 } with { 髪型 } { 時間帯 }" である。ここに、人種 5 種類、性別・年齢 6 種類、装飾品 4 種類・髪型 5 種類、時間帯 5 種類を候補として穴埋めを行い、合計 3000 種類のプロンプトを作成した。男性を示すプロンプトが 1500 種類、女性を示すプロンプトが 1500 種類である。表 4.3 と表 4.4 に詳細なプロンプトフォーマットと穴埋め候補を示す。

これらのモデル・データセットを用いて実験を行う。

⁵<http://dlib.net/>

表 4.3: 男性を示すプロンプトの穴埋め候補. 全部で 1500 通りのプロンプトが作成できる.

プロンプトフォーマット				
”a photo of { 人種 } { 性別・年齢 } face { 装飾品 } with { 髪型 } { 時間帯 }”				
人種 (5 種類)	性別・年齢 (3 種類)	装飾品 (4 種類)	髪型 (5 種類)	時間帯 (5 種類)
an asian	man	with cap	short hair	in the morning
an american	boy	with glasses	long hair	in the evening
an european	old man	with earrings	bangs	in the afternoon
an african		空欄	buzz cut	at night
an indian			quiff	at midnight

表 4.4: 女性を示すプロンプトの穴埋め候補. 全部で 1500 通りのプロンプトが作成できる.

プロンプトフォーマット				
”a photo of { 人種 } { 性別・年齢 } face { 装飾品 } with { 髪型 } { 時間帯 }”				
人種 (5 種類)	性別・年齢 (3 種類)	装飾品 (4 種類)	髪型 (5 種類)	時間帯 (5 種類)
an asian	woman	with cap	short hair	in the morning
an american	girl	with glasses	long hair	in the evening
an european	old woman	with earrings	bangs	in the afternoon
an african		空欄	medium hair	at night
an indian			forehead	at midnight

実験方法

まず，ControlNet の有無による生成顔画像集合の本質属性の多様性への影響評価を行う．具体的には，ControlNet を用いずに生成した顔画像集合 (3000 枚) の多様性と，その生成顔画像集合からランドマーク画像を抽出し，条件とした ControlNet を用いて生成した顔画像集合 (3000 枚) の多様性を比較する．生成顔画像集合からランドマークを抽出し，ControlNet の条件とすることで，できるだけ公平な ID の多様性評価を行うことができる．

次に，ControlNet の条件ランドマーク画像の違いによる生成顔画像集合の本質属性の多様性への影響評価を行う．具体的には，条件となるランドマーク画像が異なる ControlNet 有りの生成による顔画像集合 6 種類の多様性を比較する．FFHQ，LFW，生成顔画像集合由来の 3 種類のランドマークデータセットから 2 種類の抽出方法で 6 種類のランドマーク条件集合 (各 3000 枚) を作成する．FFHQ，LFW，生成顔画像集合から，前処理として顔検出・アラインメントを行い，ランドマークを検出し 3 種類のランドマークデータセットを作成する．FFHQ は Face Landmark ControlNet の学習データに含まれており実写画像，LFW は学習データに含まれておらず実写画像，生成顔画像集合は学習データに含まれておらず生成画像であるため，これらのドメインの違いによる多様性への影響を比較する．図 4.33 に各ランドマークデータセットの違いを示す．




図 4.33: 3 種類のランドマークデータセットの違い．各列は元データセット名および実写顔か生成顔か，ControlNet(CN) に対して学習データ内か外かを表す．

このランドマークデータセットから，3000 種類全てを抽出する方法と，1000 種類を 3 枚分ずつ抽出し 3000 枚抽出する方法の 2 種類の方法で合計 6 種類のランドマーク条件集合を作成する．これらを条件として ControlNet を用いて 6 種類の顔画像集合 (各 3000 枚) を生成し，その本質属性の多様性を比較する．

最後に、FFHQ, LFW, 生成顔画像集合由来の 3 種類のランドマークデータセットを t-SNE[46] で可視化した。具体的には、それぞれのデータセットに関して、各ランドマーク情報を 2 次元から 1 次元に変換し t-SNE でプロットした。また、データセットごとにプロットされる点の色を変えることで、比較可能にした。

また今回の実験において、全ての生成顔画像集合はプロンプトデータセット 3000 種類から生成した。Realistic Vision V6.0 で推奨されているプロンプトは "RAW photo, subject, 8k uhd, dslr, soft lighting, high quality, film grain, Fujifilm XT3" の subject に生成対象のプロンプトを記入する形式である。よって、データセットで作成方法を紹介したプロンプトデータセットの各プロンプトはこの形式に沿って subject に代入され、生成条件となる。また、Realistic Vision V6.0 で推奨されているネガティブプロンプトは "(deformed iris, deformed pupils, semi-realistic, cgi, 3d, render, sketch, cartoon, drawing, anime), text, cropped, out of frame, worst quality, low quality, jpeg artifacts, ugly, duplicate, morbid, mutilated, extra fingers, mutated hands, poorly drawn hands, poorly drawn face, mutation, deformed, blurry, dehydrated, bad anatomy, bad proportions, extra limbs, cloned face, disfigured, gross proportions, malformed limbs, missing arms, missing legs, extra arms, extra legs, fused fingers, too many fingers, long neck, UnrealisticDream" である。全ての生成条件において、これをネガティブプロンプトとした。

評価方法

各顔画像集合の多様性評価は提案指標を用いて行った。各顔画像集合を入力として提案指標での評価を 10 回行い、その平均値を多様性評価値とした。この時、提案指標では迷惑属性 (顔の向き) ラベルから特徴量分離を行った。提案指標のハイパーパラメータは独立成分数が 400、迷惑成分数が 30 である。

また、ランドマークデータセットから 1000 枚を 3 枚分ずつ抽出し 3000 枚のランドマーク条件集合を作成する方法では、ランドマークの抽出の際に結果に影響が出ないようにするため、5 回抽出・評価を繰り返しその平均値を多様性評価値とした。

4.3.2 実験結果

まず表 4.5 に、ControlNet を用いずに生成した顔画像集合の多様性評価値と、その生成顔画像集合からランドマーク画像を抽出し、条件とした ControlNet を用いて生成した顔画像集合の多様性評価値を示す。

表 4.5: ControlNet(CN) の有無による多様性評価値の比較

CN 無し生成顔画像集合	0.7396
CN 有り生成顔画像集合	0.7562

次に表 4.6 に、6 種類のランドマーク条件集合をそれぞれ条件とした ControlNet 有りの生成による顔画像集合の多様性評価値を比較する。

表 4.6: ControlNet(CN) の条件ランドマーク画像の違いによる多様性評価値の比較

ランドマークデータセット	ランドマーク種類数 × 抽出回数	多様性評価値
FFHQ (実写顔・CN 学習データ内)	3000 種類 × 1 回	0.7383
	1000 種類 × 3 回	0.7361
LFW (実写顔・CN 学習データ外)	3000 種類 × 1 回	0.7402
	1000 種類 × 3 回	0.7358
生成顔画像集合 (生成顔・CN 学習データ外)	3000 種類 × 1 回	0.7190
	1000 種類 × 3 回	0.7213

最後に図 4.34～4.40 に、FFHQ, LFW, 生成顔画像集合由来の 3 種類のランドマークデータセットを t-SNE で可視化したグラフを示す。




図 4.34: t-SNE による各ランドマークデータセットの可視化. FFHQ の各ランドマークを赤色の点, LFW の各ランドマークを青色の点, 生成顔画像集合の各ランドマークを緑色の点でプロットした.




図 4.35: t-SNE による各ランドマークデータセットの可視化結果から FFHQ と LFW を抽出. FFHQ の各ランドマークを赤色の点, LFW の各ランドマークを青色の点でプロットした.




図 4.36: t-SNE による各ランドマークデータセットの可視化結果から LFW と生成顔画像集合を抽出. LFW の各ランドマークを青色の点, 生成顔画像集合の各ランドマークを緑色の点でプロットした.




図 4.37: t-SNE による各ランドマークデータセットの可視化結果から FFHQ と生成顔画像集合を抽出. FFHQ の各ランドマークを赤色の点, 生成顔画像集合の各ランドマークを緑色の点でプロットした.




図 4.38: t-SNE による各ランドマークデータセットの可視化結果から FFHQ を抽出. FFHQ の各ランドマークを赤色の点でプロットした.




図 4.39: t-SNE による各ランドマークデータセットの可視化結果から LFW を抽出. LFW の各ランドマークを赤色の点でプロットした.




図 4.40: t-SNE による各ランドマークデータセットの可視化結果から生成顔画像集合を抽出．生成顔画像集合の各ランドマークを赤色の点でプロットした．

4.3.3 考察

まず表 4.5 から、ControlNet を用いずに生成した顔画像集合よりも ControlNet を用いて生成した顔画像集合の方が本質属性の多様性が高いことがわかる．これより、ControlNet の使用は本質属性の多様性を向上させる場合があることがわかった．これは、ControlNet の使用により、画像生成モデルがより顔画像ドメインに特化するためであると考えられる．

次に表 4.6 から、ControlNet の条件が実写顔画像集合 (FFHQ と LFW) の場合に比べて生成顔画像集合の場合に多様性評価値が低くなることがわかる。また、FFHQ と LFW の結果は同程度であるため、ControlNet の学習データに含まれているかどうかは多様性に影響しないことがわかる。これは、生成顔画像集合のランドマーク分布が実写顔画像集合のランドマーク分布に比べて狭いことに起因すると考えられる。図 4.34～4.40 より、生成顔画像集合のランドマーク分布範囲は実写顔画像集合のランドマーク分布範囲に比べて狭いことが確認できる。条件集合の分布が狭いため、生成される顔画像集合の本質属性の多様性もそれを反映して低くなると考えられる。

さらに表 4.6 から、ControlNet の条件が実写顔画像集合 (FFHQ と LFW) の場合、ランドマーク種類数が 3000 種類の方が多様性評価値が高く、ControlNet の条件が生成顔画像集合の場合、反対にランドマーク種類数が 1000 種類の方が多様性評価値が高いことがわかった。これは、実写顔画像集合が Face Landmark ControlNet の学習分布内条件であり、生成顔画像集合が学習分布外条件であることに起因していると考えられる。図 4.34～4.40 より、実写顔画像集合のランドマーク分布 (FFHQ と LFW) と生成顔画像集合のランドマーク分布は少しずれていることが確認できる。Face Landmark ControlNet は実写顔画像で学習されているため、実写顔画像集合のランドマーク分布は学習分布内にあり、生成顔画像集合のランドマーク分布は学習分布から少し外れている。ControlNet を用いた生成顔画像集合の多様性を構成する要素として、条件間多様性と条件内多様性があると考えられる。条件間多様性とはランドマーク条件間の差異が生み出す生成画像の多様性である。条件内多様性とは同一条件から複数の生成画像を得た際の多様性である。ControlNet の条件が学習分布内の条件である場合、条件に対する生成結果は安定している。よって条件内多様性が小さく、条件間多様性を最大化することで生成顔画像集合の多様性を高くすることができる。ControlNet の条件が学習分布外の条件である場合、条件に対する生成結果が不安定である。よって条件内多様性が大きく、条件内多様性と条件間多様性のバランスをとることで生成顔画像集合の多様性を高くすることができる。これより、ControlNet の条件が実写顔画像集合の場合、ランドマーク種類数が 3000 種類の方が多様性評価値が高く、生成顔画像集合の場合、ランドマーク種類数が 1000 種類の方が多様性評価値が高くなったと考えられる。

これらの結果・考察から、ControlNet の使用により、生成顔画像集合の本質属性の多様性が高くなる場合があることがわかった。また、ControlNet の条件として生成顔画像集合よりも実写顔画像集合由来のランドマーク画像を用いる方が生成顔画像集合の多様性が高くなることがわかった。さらに、条件として実写顔画像集合を用いる場合、すべての条件で異なるランドマーク画像を用いた方が多様性が高くなり、生成顔画像集合を用いる場合、条件として同じランドマーク画像を複数回使いまわした方が多様性が高くなるこ

とがわかった。

第5章 結論

本研究では画像集合に対する迷惑属性に頑健な多様性評価指標を提案した。画像集合を表現する特徴量から本質特徴量と迷惑特徴量を解析的に分離し、本質特徴量に対して多様性評価を行うことで、迷惑属性に頑健な多様性評価指標となった。研究対象をランドマーク画像を条件とした ControlNet を用いた顔画像生成とし、顔画像集合における本質属性を ID、迷惑属性を顔の向きとした。実験を通じて、提案指標によって迷惑属性を除去することができ、提案指標が既存指標に比べて迷惑属性に頑健な多様性評価を実現できることを示した。さらに、提案指標を用いて ControlNet の有無による生成画像における本質属性の多様性への影響評価を行い、ControlNet の使用により多様性が向上する場合があることを示した。

本研究の貢献は大きく 3 つある。1 つ目は独立成分分析と特徴量寄与度評価指標を組み合わせた、解析的に特徴量を本質特徴量と迷惑特徴量に分離する方法 (迷惑属性フィルタリングモジュール) を提案したことである。迷惑属性フィルタリングモジュールにより、閉集合である画像集合から理論的な裏付けを持って迷惑属性と本質属性を分離することができるようになった。2 つ目は迷惑属性フィルタリングモジュールを用いた画像集合に対する多様性評価指標を提案したことである。これにより、画像集合から迷惑属性の影響を除去した本質属性の多様性を評価することができるようになった。これは条件付け画像生成において、条件 (迷惑属性) の多様性の影響を除去した多様性評価に応用することができる。3 つ目は提案指標を用いて ControlNet の有無による生成画像集合の本質属性の多様性への影響を評価したことである。これより、ControlNet を用いることで生成画像の多様性が向上する可能性があることがわかった。

将来研究として大きく 2 つの内容が考えられる。1 つ目は提案指標における 2 つの重要なハイパーパラメータを自動で決定する方法の開発である。提案指標の重要なハイパーパラメータとして独立成分数と迷惑成分数があった。独立成分数の自動決定は、赤池情報量基準 (AIC) やベイズ情報量基準 (BIC) といった統計手法により実現できる可能性がある。また迷惑成分数の自動決定は、データ増強により実現できる可能性がある。元特徴量に対して mix-up[47] などでデータ増強を行い、本質成分と迷惑成分の分離をより明確に行えるようにすることで、閾値を SAGE 値の 0 に設定でき、この課題に対処できると考える。2 つ目は他のタスクへの適用である。本研究で提案した迷惑属性に頑健な多様性評価指標は様々なタスクに応用可能であるが、本研究における実験では評価対象を顔画像集合のみに絞った。これを全身画像や風景画像な

どに応用することで、さらに提案指標の可能性を探ることができる.

謝辞

本研究を行うにあたり、主任指導教員である栗原聡教授には多大なご指導を承りました。橋本敦史特任講師、電気通信大学の稲葉通将准教授には、研究に対する考え方や取り組み方、技術的な御助言を多く頂きました。心より感謝申し上げます。

本研究は NEDO インタラクティブなストーリー型コンテンツ創作支援基盤の開発のもとで行ったものであり、NEDO プロジェクトの皆様のお力添えがあってこそこの本研究であったと思っております。厚く御礼申し上げます。

栗原研究室の皆様にも多くの御助言や御協力を頂きました。特に、畠山太郎氏、渡邊謙吾氏、岡田湧路氏には多くの知見や技術的な御助力を頂きました。また、論文執筆についての御助言を頂きました。心より感謝いたします。

最後にはなりましたが、家族には日頃から支えて頂いております。ありがとうございます。本研究は、以上の皆様だけでなく多くの方々からの御助言・御協力を頂けたからこそ完成したものです。改めて心より御礼申し上げます。

参考文献

- [1] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Aspell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning Transferable Visual Models From Natural Language Supervision. In *Proceedings of the 38th International Conference on Machine Learning*, July 2021.
- [2] S. Milborrow, J. Morkel, and F. Nicolls. The MUCT Landmarked Face Database. *Pattern Recognition Association of South Africa*, 2010. <http://www.milbo.org/muct>.
- [3] Gary B. Huang, Marwan Mattar, Tamara Berg, and Eric Learned-Miller. Labeled Faces in the Wild: A Database for Studying Face Recognition in Unconstrained Environments. In *Workshop on Faces in 'Real-Life' Images: Detection, Alignment, and Recognition*, 2008.
- [4] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-Resolution Image Synthesis with Latent Diffusion Models. In *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2022.
- [5] Aditya Ramesh, Mikhail Pavlov, Gabriel Goh, Scott Gray, Chelsea Voss, Alec Radford, Mark Chen, and Ilya Sutskever. Zero-Shot Text-to-Image Generation. In *Proceedings of the 38th International Conference on Machine Learning*, July 2021.
- [6] Dan Friedman and Adji Bousso Dieng. The Vendi Score: A Diversity Evaluation Metric for Machine Learning, July 2023.
- [7] Michael Yeung, Toya Teramoto, Songtao Wu, Tatsuo Fujiwara, Kenji Suzuki, and Tamaki Kojima. VariFace: Fair and Diverse Synthetic Dataset Generation for Face Recognition, December 2024.
- [8] Jiankang Deng, Jia Guo, Niannan Xue, and Stefanos Zafeiriou. ArcFace: Additive Angular Margin Loss for Deep Face Recognition. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2019.

-
- [9] Florian Schroff, Dmitry Kalenichenko, and James Philbin. FaceNet: A Unified Embedding for Face Recognition and Clustering. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2015.
- [10] Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. Beta-VAE: Learning Basic Visual Concepts with a Constrained Variational Framework. In *International Conference on Learning Representations*, February 2017.
- [11] Xi Chen, Yan Duan, Rein Houthoofd, John Schulman, Ilya Sutskever, and Pieter Abbeel. InfoGAN: Interpretable representation learning by information maximizing generative adversarial nets. In *Proceedings of the 30th International Conference on Neural Information Processing Systems*, NIPS’16, Red Hook, NY, USA, December 2016.
- [12] Tao Yang, Yuwang Wang, Yan Lu, and Nanning Zheng. DisDiff: Unsupervised disentanglement of diffusion probabilistic models. In *Proceedings of the 37th International Conference on Neural Information Processing Systems*, NIPS ’23, Red Hook, NY, USA, May 2024.
- [13] A. Hyvärinen and E. Oja. Independent component analysis: Algorithms and applications. *Neural Networks*, June 2000.
- [14] Ian C. Covert, Scott Lundberg, and Su-In Lee. Understanding global feature contributions with additive importance measures. In *Proceedings of the 34th International Conference on Neural Information Processing Systems*, NIPS ’20, Red Hook, NY, USA, December 2020.
- [15] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Proceedings of the 31st International Conference on Neural Information Processing Systems*, NIPS’17, Red Hook, NY, USA, December 2017.
- [16] Lvmin Zhang, Anyi Rao, and Maneesh Agrawala. Adding Conditional Control to Text-to-Image Diffusion Models. In *2023 IEEE/CVF International Conference on Computer Vision (ICCV)*, October 2023.

-
- [17] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Proceedings of the 34th International Conference on Neural Information Processing Systems*, NIPS '20, Red Hook, NY, USA, December 2020.
- [18] S. Kullback and R. A. Leibler. On information and sufficiency. *The Annals of Mathematical Statistics*, 1951.
- [19] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional Networks for Biomedical Image Segmentation. In Nassir Navab, Joachim Hornegger, William M. Wells, and Alejandro F. Frangi, editors, *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, Cham, 2015.
- [20] Yuxin Wu and Kaiming He. Group Normalization. In *Computer Vision – ECCV 2018: 15th European Conference, Munich, Germany, September 8-14, 2018, Proceedings, Part XIII*, Berlin, Heidelberg, September 2018.
- [21] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Proceedings of the 31st International Conference on Neural Information Processing Systems*, NIPS'17, Red Hook, NY, USA, December 2017.
- [22] Alexander Quinn Nichol and Prafulla Dhariwal. Improved Denoising Diffusion Probabilistic Models. In *Proceedings of the 38th International Conference on Machine Learning*, July 2021.
- [23] Prafulla Dhariwal and Alex Nichol. Diffusion models beat GANs on image synthesis. In *Proceedings of the 35th International Conference on Neural Information Processing Systems*, NIPS '21, Red Hook, NY, USA, June 2024.
- [24] Heliang Zheng, Jianlong Fu, Yanhong Zeng, Jiebo Luo, and Zheng-Jun Zha. Learning semantic-aware normalization for generative adversarial networks. In *Proceedings of the 34th International Conference on Neural Information Processing Systems*, NIPS '20, Red Hook, NY, USA, December 2020.

-
- [25] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. In *NeurIPS 2021 Workshop on Deep Generative Models and Downstream Applications*, 2021.
- [26] Patrick Esser, Robin Rombach, and Bjorn Ommer. Taming transformers for high-resolution image synthesis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 12873–12883, June 2021.
- [27] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, Dustin Podell, Tim Dockhorn, Zion English, Kyle Lacey, Alex Goodwin, Yannik Marek, and Robin Rombach. Scaling Rectified Flow Transformers for High-Resolution Image Synthesis, March 2024.
- [28] Florinel-Alin Croitoru, Vlad Hondru, Radu Tudor Ionescu, and Mubarak Shah. Diffusion Models in Vision: A Survey. *IEEE Trans. Pattern Anal. Mach. Intell.*, September 2023.
- [29] Ajay Bandi, Pydi Venkata Satya Ramesh Adapa, and Yudu Eswar Vinay Pratap Kumar Kuchi. The Power of Generative AI: A Review of Requirements, Models, Input–Output Formats, Evaluation Metrics, and Challenges. *Future Internet*, August 2023.
- [30] Tim Salimans, Ian Goodfellow, Wojciech Zaremba, Vicki Cheung, Alec Radford, and Xi Chen. Improved techniques for training GANs. In *Proceedings of the 30th International Conference on Neural Information Processing Systems, NIPS’16*, Red Hook, NY, USA, December 2016.
- [31] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. ImageNet: A large-scale hierarchical image database. In *2009 IEEE Conference on Computer Vision and Pattern Recognition*, June 2009.
- [32] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2818–2826, 2015.
- [33] Shane Barratt and Rishi Sharma. A Note on the Inception Score, June 2018.
- [34] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. GANs trained by a two time-scale update rule converge to a local nash equilibrium. In *Proceedings*

of the 31st International Conference on Neural Information Processing Systems, NIPS'17, Red Hook, NY, USA, December 2017.

- [35] Jack Hessel, Ari Holtzman, Maxwell Forbes, Ronan Le Bras, and Yejin Choi. CLIPScore: A Reference-free Evaluation Metric for Image Captioning, March 2022.
- [36] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. BLEU: A method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting on Association for Computational Linguistics*, ACL '02, USA, July 2002.
- [37] Xin Wang, Hong Chen, Si'ao Tang, Zihao Wu, and Wenwu Zhu. Disentangled Representation Learning. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, February 2024.
- [38] Marwa Farouk Ibrahim Ibrahim and Adel Ali Al-jumaily. ICA based feature learning and feature selection. In *2016 5th International Conference on Electronic Devices, Systems and Applications (ICEDSA)*, February 2016.
- [39] Nojun Kwak, Chong-Ho Choi, and Jin-Young Choi. Feature Extraction Using ICA. In *Proceedings of the International Conference on Artificial Neural Networks*, ICANN '01, Berlin, Heidelberg, August 2001.
- [40] Ionut Cosmin Duta, Li Liu, Fan Zhu, and Ling Shao. Improved Residual Networks for Image and Video Recognition. In *2020 25th International Conference on Pattern Recognition (ICPR)*, January 2021.
- [41] Tero Karras, Samuli Laine, and Timo Aila. A Style-Based Generator Architecture for Generative Adversarial Networks. *IEEE Trans. Pattern Anal. Mach. Intell.*, December 2021.
- [42] Tero Karras, Timo Aila, Samuli Laine, and Jaakko Lehtinen. Progressive growing of gans for improved quality, stability, and variation. In *Proceedings of International Conference on Learning Representations (ICLR) 2018*, 2018. International Conference on Learning Representations, ICLR ; Conference date: 30-04-2018 Through 03-05-2018.
- [43] K. Zhang, Z. Zhang, Z. Li, and Y. Qiao. Joint face detection and alignment using multitask cascaded convolutional networks. *IEEE Signal Processing Letters*, Vol. 23, No. 10, pp. 1499–1503, Oct 2016.

-
- [44] M.L. Menéndez, J.A. Pardo, L. Pardo, and M.C. Pardo. The Jensen-Shannon divergence. *Journal of the Franklin Institute*, 1997.
- [45] Mark W. Lipsey, Kelly Puzio, Cathy Yun, Michael A. Herbert, Kasia Steinka-Fry, Mikel W. Cole, Megan Roberts, Karen S. Anthony, and Matthew D. Busick. *Translating the Statistical Representation of the Effects of Education Interventions into More Readily Interpretable Forms*. Unknown Publisher, November 2012. reportnumber: NCSEER 2013-3000.
- [46] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of Machine Learning Research*, Vol. 9, No. 86, pp. 2579–2605, 2008.
- [47] Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, and David Lopez-Paz. Mixup: Beyond Empirical Risk Minimization. In *International Conference on Learning Representations*, February 2018.

研究業績

- (i) 北川峻, 畠山太郎, 蛭田興明, 橋本敦史, 栗原聡. 顔画像編集における NaviGAN に対する適切な GAN inversion 手法の選定. 第 37 回 人工知能学会全国大会. 2023 年 6 月.
- (ii) 北川峻, 畠山太郎, 蛭田興明, 橋本敦史, 栗原聡. 敵対的生成ネットワークを使用した多様な顔画像の特定パーツ誇張. 第 128 回知識ベースシステム研究会. 2023 年 3 月.
- (iii) 北川峻, 畠山太郎, 蛭田興明, 橋本敦史, 栗原聡. TEZUKA2023 におけるキャラクタービジュアル創作支援. 第 24 回 データ指向構成マイニングとシミュレーション研究会 (SIG-DOCMAS). 2023 年 11 月.
- (iv) 北川峻, 畠山太郎, 蛭田興明, 橋本敦史, 栗原聡. 漫画キャラクター創作支援に向けた画像生成ユーザーインターフェースの提案. 第 38 回 人工知能学会全国大会. 2024 年 5 月.
- (v) 畠山太郎, 北川峻, 蛭田興明, 橋本敦史, 栗原聡. グレースケールの疎な生成画像に対する透かし埋め込み手法の頑健性評価. 第 213 回 知能システム研究発表会. 2024 年 3 月.

付 録 A

A.1 実験における生成画像例

4.3 節で行った実験で生成した画像の例を示す。さらに、それぞれの生成画像に対応する条件 (プロンプトとランドマーク画像) も示す。まず、図 A.1 に生成画像のプロンプト条件を示す。例として表示する生成画像集合は全てこのプロンプト集合を条件として生成されている。次に、図 A.2 に ControlNet を使用せずに生成した顔画像の例を示す。次に、その生成顔画像から抽出したランドマーク画像を図 A.3 に示す。次に、そのランドマーク画像を画像条件として ControlNet を使用して生成した顔画像の例を図 A.4 に示す。次に、図 A.5 にランドマーク抽出対象となった FFHQ の顔画像を示す。次に、その顔画像から抽出したランドマーク画像を図 A.6 に示す。次に、そのランドマーク画像を画像条件として ControlNet を使用して生成した顔画像の例を図 A.7 に示す。次に、図 A.8 にランドマーク抽出対象となった LFW の顔画像を示す。次に、その顔画像から抽出したランドマーク画像を図 A.9 に示す。最後に、そのランドマーク画像を画像条件として ControlNet を使用して生成した顔画像の例を図 A.10 に示す。

人種 年齢・性別 装飾品 髪型 時間帯		
an asian boy face with cap with bangs in the evening	an african man face with cap with quiff in the afternoon	an african man face with quiff in the evening
a european old man face with long hair in the evening	an indian boy face with glasses with buzz cut at night	an asian old woman face with glasses with medium hair in the afternoon
an american girl face with earrings with bangs in the evening	an indian girl face with earrings with medium hair at midnight	an african girl face with earrings with bangs in the morning

図 A.1: 生成条件として使用したプロンプトの例. 以降で例示する生成画像の条件はこの図のプロンプトである.



図 A.2: ControlNet を使用せずに生成した顔画像の例. テキスト条件は図 A.1 に示したプロンプトである.



図 A.3: 生成顔画像から抽出したランドマーク画像の例. 図 A.2 に示した生成顔画像に対応している.



図 A.4: ControlNet を使用して生成した顔画像の例. 画像条件は図 A.3 に示した生成顔画像から抽出したランドマーク画像である. テキスト条件は図 A.1 に示したプロンプトである.



図 A.5: ランドマーク抽出対象となった FFHQ の顔画像の例




図 A.6: FFHQ から抽出したランドマーク画像の例. 図 A.5 に示した顔画像に対応している.



図 A.7: ControlNet を使用して生成した顔画像の例. 画像条件は図 A.6 に示した FFHQ の顔画像から抽出したランドマーク画像である. テキスト条件は図 A.1 に示したプロンプトである.



図 A.8: ランドマーク抽出対象となった LFW の顔画像の例



図 A.9: LFW から抽出したランドマーク画像の例. 図 A.8 に示した顔画像に対応している.



図 A.10: ControlNet を使用して生成した顔画像の例. 画像条件は図 A.9 に示した LFW の顔画像から抽出したランドマーク画像である. テキスト条件は図 A.1 に示したプロンプトである.

このように, 4.3 節の実験では, 高品質なランドマーク抽出および顔画像生成を実現できた.

A.2 追加実験

4.1 節で示した, 迷惑属性フィルタリングモジュールの性能を検証する追加実験を行う. 本研究で提案した迷惑属性フィルタリングモジュールでは, 特徴量寄与度評価指標を用いて各独立成分に対して本質属性ま

たは迷惑属性のラベル付けを行った。このラベル付けが正確に処理できていたのか確認する。

実験設定

ラベル付けを特徴量寄与度評価指標を用いずにランダムに行った場合の迷惑属性フィルタリングモジュールの性能を確認する。データセットや実験・評価方法は [4.1](#) 節に示した実験と基本的に同じであり、独立成分に対するラベル付けのみランダムに行う。また、独立成分数に対する本質成分数は [4.1](#) 節に示した本質属性ラベルから特徴量分離を行った実験結果と同様と設定する。

実験結果

まず、元特徴量と本質特徴量それぞれを学習データとして、ID クラス分類モデルを学習した際の精度を示す。図 [A.11](#) に独立成分数とモデル精度の関係を示す。元特徴量から ID クラス分類モデルを学習した場合、精度は 100%である。




図 A.11: ランダムに特徴量分離を行った場合の独立成分数と ID クラス分類モデル精度の関係. 元特徴量を学習データとした ID クラス分類モデル精度は独立成分数に関係ないため, 100%固定の黒色の点線としている. 赤色の折れ線グラフは独立成分数と本質特徴量を学習データとした ID クラス分類モデル精度の関係である.

次に, 元特徴量と本質特徴量それぞれを学習データとして, 顔の向きクラス分類モデルを学習した際の精度を示す. 図 A.12 に独立成分数と顔の向きクラス分類モデル精度の関係を示す. 元特徴量から顔の向きクラス分類モデルを学習した場合, 精度は約 69%である.




図 A.12: ランダムに特徴量分離を行った場合の独立成分数と顔の向きクラス分類モデル精度の関係。元特徴量を学習データとした顔の向きクラス分類モデル精度は独立成分数に関係ないため、約 69% 固定の黒色の点線としている。赤色の折れ線グラフは独立成分数と本質特徴量を学習データとした顔の向きクラス分類モデル精度の関係である。

最後に、元特徴量と本質特徴量における、同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均を示す。

図 A.13 と図 A.14 に独立成分数と $\cos$ 類似度平均の関係を示す。図 A.13 では y 軸の範囲が 0% から 100% に設定、図 A.14 では y 軸の範囲が 70% から 90% に設定されている。元特徴量における同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均は約 87% である。




図 A.13: ランダムに特徴量分離を行った場合の独立成分数と同じ ID で異なる顔の向き of 画像ペアの $\cos$ 類似度平均の関係. (y 軸の範囲は 0% から 100% に設定) 元特徴量における異なる顔の向き of 画像ペアの $\cos$ 類似度平均は独立成分数に関係ないため, 約 87% 固定の黒色の点線としている. 赤色の折れ線グラフは独立成分数と本質特徴量における異なる顔の向き of 画像ペアの $\cos$ 類似度平均の関係.




図 A.14: ランダムに特徴量分離を行った場合の独立成分数と同じ ID で異なる顔の向きの画像ペアの $\cos$ 類似度平均の関係。 (y 軸の範囲は 70% から 90% に設定) 元特徴量における異なる顔の向きの画像ペアの $\cos$ 類似度平均は独立成分数に関係ないため、約 87% 固定の黒色の点線としている。赤色の折れ線グラフは独立成分数と本質特徴量における異なる顔の向きの画像ペアの $\cos$ 類似度平均の関係。

考察

まず、図 4.9 と図 A.11 を比較する。本質特徴量を入力とした ID モデル精度に関して、図 4.9 では独立成分数に関わらずほぼ 100% であるのに対して、図 A.11 では迷惑成分が出現する独立成分数 270 以降、精度が単調減少していることがわかる。これよりランダムに特徴量分離を行った場合、本質特徴量が本質属性の情報を抽出できないといえる。よって、特徴量寄与度評価指標を用いた迷惑属性フィルタリングモジュールでは品質が高い特徴量分離を行えることがわかる。

次に、図 4.10 と図 A.12 を比較する。本質特徴量を入力とした顔の向きモデル精度に関して、図 4.10 では独立成分数 270 以降、独立成分数が増加するほど精度が減少しているのに対して、図 A.12 ではそこまで精度が減少していないことがわかる。これよりランダムに特徴量分離を行った場合、本質特徴量が迷惑

属性の情報を除去できないといえる。よって、特徴量寄与度評価指標を用いた迷惑属性フィルタリングモジュールでは品質が高い特徴量分離を行えることがわかる。

最後に、図 4.11 及び図 4.12 と図 A.13 及び図 A.14 を比較する。本質特徴量における同 ID で異なる顔の向きの画像ペアの類似度平均に関して、図 4.11 及び図 4.12 では独立成分数 270 以降、独立成分数が増加するほど類似度が増加し、元特徴量のそれを上回るのに対して、図 A.13 及び図 A.14 では類似度が単調減少し、元特徴量を下回ることがわかる。これよりランダムに特徴量分離を行った場合、本質特徴量における本質属性を表現する情報の純度が元特徴量よりも低くなるといえる。よって、特徴量寄与度評価指標を用いた迷惑属性フィルタリングモジュールでは品質が高い特徴量分離を行えることがわかる。